Gymnasium Oberwil

Maturarbeit

Entwicklung eines Convolutional Denoising Autoencoder mithilfe von Tensorflow und Keras

Eine Arbeit ueber Maschinelles Lernen, Kuenstliche Neuronale Netze, Convolutional Neural Networks, Autoencoders und Tensorflow/Keras

Luis Wirth, 4a

Betreut von
Dr. Jonas Gloor

Abgegeben im September 2019
LaTeX

Inhaltsverzeichnis

Inhaltsverzeichniss **I**

Vorwort **III**

Einleitung **IV**

Konvention und Notation **V**

1 Machinelles Lernen **1**
1.1 Allgemeine Begriffe . . . 2
1.1.1 Korrelation? . . . 2
1.1.2 Daten . . . 2
1.1.3 Modelle . . . 2
1.2 Training . . . 3
1.2.1 Verlust- und Kostenfunktionen . . . 3
1.2.2 Gradientenverfahren . . . 4
1.2.3 Stochastisches Gradientenverfahren fuer Machine Learning . . . 7
1.2.4 Adam Optimizer? . . . 7
1.3 Trainingsphaenomene . . . 7
1.3.1 Overfitting . . . 7

2 Deep Learning und Künstliche Neuronale Netze **8**
2.1 Perzeptron . . . 8
2.1.1 Was kann ein Perzeptron erlernen? . . . 9
2.2 Erweiterung der Kuenstlichen Neuronen . . . 9
2.2.1 Kuenstliche Neuronen im Allgemeinen . . . 10
2.2.2 Perzeptronen als Kuenstliche Neuronen . . . 10
2.2.3 Stueckweise lineare Neuronen . . . 10
2.2.4 Sigmoide Neuronen . . . 11
2.3 Topologie der Kuenstlichen Neuronalen Netzen . . . 11
2.4 Lernverhalten . . . 12
2.5 Vorwaertspropagierung . . . 13
2.5.1 Modellparameter initalisieren . . . 16
2.6 Rueckwaertspropagierung . . . 17
2.7 Universal Approximation Theorem? . . . 21
2.8 Vanishing Gradient Problem . . . 21
2.8.1 Kreuzentropie-Kostenfunktion . . . 21
2.8.2 ReLU . . . 21

3 Convolutional Neural Networks **22**
3.1 Bilder als Tensoren . . . 22
3.2 Topologie von CNNs . . . 24
3.3 Convolutional-Schichten und Filter . . . 24
3.3.1 Filter in der Bildverarbeitung . . . 24
3.3.2 Filter in CNNs . . . 25
3.3.3 Filteroperation intutitiv . . . 26
3.3.4 Filteroperationen als diskrete Faltungen . . . 27
3.3.5 Mehrere Filter . . . 28
3.3.6 Padding . . . 28
3.3.7 Stride . . . 29
3.3.8 Vorzuege von Filtern . . . 29
3.3.9 die Convolutional-Schicht . . . 30
3.4 Dimensionalitaetskontrolle . . . 31
3.4.1 die Pooling-Schicht . . . 31
3.4.2 die Upsampling-Schicht . . . 32

4 Autoencoder **33**
4.1 Topologie von Autoencodern . . . 33
4.2 Mathematische Betrachtung . . . 33
4.3 Bedeutung von Autoencodern . . . 34
4.3.1 Datenkompression . . . 34
4.3.2 Datengenerierung . . . 34
4.3.3 Eigenschaften erkennen . . . 34
4.4 Convolutional-Autoencoder . . . 34
4.5 Denoising-Autoencoder . . . 34

5 Entwicklung eines Denoising-Autoencoders **35**
5.1 TensorFlow . . . 35
5.1.1 Hardwarebeschleuniging . . . 35
5.1.2 Funktionsweise . . . 36
5.1.3 Tensorboard . . . 36
5.2 Keras . . . 36
5.3 Setup . . . 36
5.4 das Modell . . . 36
5.4.1 MNIST . . . 36
5.5 Entwicklung . . . 36

6 Diskussion **37**

A Programmcode **38**

B Python-Einfuehrung **39**

Literatur **40**

Abbildungsverzeichniss **41**

Tabellenverzeichniss **42**

Selbstständigkeitserklärung **43**

Vorwort

Einleitung

Die Leitfrage lautet: **Wie entwickelt man mithilfe von Tensorflow und Keras einen Convolutional Denoising Autoencoder?**

Konvention und Notation

Beschriftung

Zahlen und Tensoren

a	ein Skalar (Zahl)
$\boldsymbol{a}$	ein Vektor
$\boldsymbol{a} \in \mathbb{R}^n$	ein Vektor mit n Komponenten
$\boldsymbol{A}$	eine Matrix
$\boldsymbol{A} \in \mathbb{R}^{m \times n}$	eine Matrix mit m Zeilen und n Spalten
$\mathbf{A}$	ein Tensor
$\mathfrak{A}, \mathfrak{B}, \mathfrak{C}, \mathfrak{D}, \mathfrak{E}, \cdots$	a
$\mathfrak{a}, \mathfrak{b}, \mathfrak{c}, \mathfrak{d}, \mathfrak{e}, \mathfrak{f}, \mathfrak{g}, \cdots$	a

Mengen

(a, b)	ein geordnetes Paar (2-Tupel) der Elemente a und b
$\mathbb{A}$	eine Menge
$\mathbb{R}$	die Menge aller Reeller Zahlen
$\mathbb{Z}$	die Menge aller ganzer Zahlen
$\mathbb{N}$	die Menge aller natuerlicher Zahlen
$\{a, b\}$	die Menge, welche aus den Elementen a und b besteht
$\{1, \ldots, n\}$	die Menge aller ganzen Zahlen von 1 bis n
$\in$	... ist Element von ...

Indexierung

a_i	die i-te Vektorkomponente mit Startindex 1
$(\boldsymbol{A})_{i,j} =$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$A_{i,j}$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$\boldsymbol{A}_{i,:}$	die Zeile i der Matrix $\boldsymbol{A}$
$\boldsymbol{A}_{:,i}$	die Spalte i der Matrix $\boldsymbol{A}$
$\mathbf{A}_{i,:,:}$	der i-te Querschnitt entlang der Hoehe des Tensors $\mathbf{A}$
$\mathbf{A}_{:,i,:}$	der i-te Querschnitt entlang der Breite des Tensors $\mathbf{A}$
$\mathbf{A}_{:,:,i}$	der i-te Querschnitt entlang der Tiefe des Tensors $\mathbf{A}$

Lineare Algebra Operationen

$\boldsymbol{v} \cdot \boldsymbol{w}$	das Skalarprodukt von $\boldsymbol{v}$ mit $\boldsymbol{w}$
$\boldsymbol{A}^\top$	das Transponierte einer Matrix $\boldsymbol{A}$
$\boldsymbol{A} \odot \boldsymbol{B}$	das Elementeweises (Hadamard) Produkt
$\boldsymbol{A} * \boldsymbol{B}$	die diskrete Faltung von $\boldsymbol{A}$ ueber $\boldsymbol{B}$

Infinitesimalrechnung/Differentialrechnung

$f'(x)$	die Ableitung der Funktion f bezueglich seinem Argument x
$\frac{\mathrm{d}y}{\mathrm{d}x}$	die Ableitung von y bezueglich x
$\frac{\partial y}{\partial x}$	die partielle Ableitung von y bezueglich x
$\boldsymbol{\nabla} y$	der Gradient von y
$\boldsymbol{\nabla}_{\boldsymbol{x}} y$	der Gradient von y bezueglich $\boldsymbol{x}$ (Vektor)
$\int f(x)\,\mathrm{d}x$	das unbestimmte Integral der Funktion f bezueglich x
$\int_a^b f(x)\,\mathrm{d}x$	das bestimmte Integral der Funktion f bezueglich x von a bis b

Funktionen

$f : \mathbb{A} \to \mathbb{B}$	eine Funktion f mit Definitionsmenge $\mathbb{A}$ und Zielmenge $\mathbb{B}$
$f(x)$	eine Funktion f mit Argument x (Skalar)
$f(\boldsymbol{v})$	eine Funktion f mit Argument $\boldsymbol{v}$ (Vektor)
$\boldsymbol{f}[\boldsymbol{v}]$	die vektorisierte Funktion $\boldsymbol{f}$ mit Argument $\boldsymbol{v}$ (Vektor)
$\mathcal{A}$	ein Funktionenraum
$f * g$	die Faltung von f ueber g

Statistik

$\mathcal{N}$	die Gauss'sche Normalverteilung
ϕ	die Gauss'sche Dichtefunktion
μ	der Erwartungswert/Mittelwert
σ^2	die Varianz

Kapitel 1

Machinelles Lernen

Der Themenbereich des **Machinellen Lernens** beschäftigt sich mit Algorithmen und mathematischen Modellen, welche von selber lernen, Probleme zu loesen. Hierbei wird nicht explizit einprogrammiert, wie das Modell das Problem zu loesen hat, stattdessen wird das Modell trainiert, optimiert sich von selbst und findet selber einen Weg, das Problem zu loesen. Die Grundidee dabei ist, dass man Daten erfasst, generiert oder misst, welche analysiert werden sollen. Innerhalb dieser Daten existieren gewisse Gesetzmaessigkeiten und Mustern. Diese Muster sollen vom Modell erkannt werden und verallgemeinert werden. Nach dem erfolgreichen Lernen, kann das Modell Vorhersagen zu neuen Daten machen.

Man unterscheiden zwischen zwei Arten von Maschinellen Lernen.

- **Ueberwachtes Lernen** (engl.: supervised learning) ist ein Lernverfahren, bei welchem die Daten aus zwei Teilen bestehen, aus Inputs und Outputs. Man bezeichnet dabei die Outputs als Labels. Die Aufgabe des Modells ist es eine **Korrelation** zwischen den Inputs und den Labels zu erlernen und so ihre Beziehung zueinander zu verstehen. Anhand der Informationen, welche in den Inputs enthalten sind, sind dann die Labels vorherzusagen. Man gleicht dann die vorhergesagten Labels des Modells mit den wahren Labels ab (man "ueberwacht" sie) und bewertet so ihre Faehigkeiten.

  Voraussetztung dafuer ist, dass die Daten eben "gelabelt" sein muessen. Man muss schon im vorhinein Daten haben, bei welchen man die gewuenschten Labels hat. Natuerlich muss auch die erwaehnte Korrelation bestehen. Falls kein Zusammenhang zwischen den Inputs und den Outputs besteht, kann das Modell auch keine Vorhersagen machen und so auch nichts erlernen.

- **Unueberwachtes Lernen** (engl.: unsupervised learning) ist ein anderes Lernverfahren, bei welchem eben diese Labels nicht vorhanden sind. Dem Modell stehen nur die Inputdaten zur Verfuegung. Diese werden auch analysiert und das Modell soll Muster herausextrahieren, welche sich von sonstigem zuefaelligen Rauschen unterscheiden.

Der Grossteil der Modelle des Maschinellen Lernens benutzten ueberwachtes Lernen, da es auch deutlich mehr Anwendungsmoeglichkeiten besitzt. Es gibt nur wenige Arten von unueberwachtem Lernen, dazu gehoeren: Hauptkomponentenanalysen und Generative Adversial Networks. Aus diesem Grund, werden wir im folgenden uns grundsaetzlich mit ueberwachtem Lernen beschaeftigen.

(Mehrere, *Supervised learning — Wikipedia, The Free Encyclopedia*)
(Mehrere, *Unsupervised learning — Wikipedia, The Free Encyclopedia*)

1.1 Allgemeine Begriffe

1.1.1 Korrelation?

1.1.2 Daten

Um ein Modell zu trainieren braucht man Daten. Diese Daten bestehen immer aus **Inputs** und aus **Outputs**. Man unterscheidet hierbei zwei Arten von Outputs. Die **Labels** sind die erwarteten Outputs, welche die gewueschten Zielwerte sind. Die **Vorhersagen** sind die Outputs, welche das Modell produziert und hoffentlich moeglichst genau mit den Labels uebereinstimmen.

Diese Daten fuer Training kommen in der Form eines **Trainingsdatensatz** $\mathbb{X}$. Dabei handelt es sich um eine Menge von **Samples**, welche jeweils aus Inputs und Labels bestehen. Die Inputs werden in einem Vektor

$$\boldsymbol{x} = \begin{pmatrix} x_1 & x_2 & \cdots & x_m \end{pmatrix}^\mathsf{T}$$

und die Labels in einem Vektor

$$\hat{\boldsymbol{y}} = \begin{pmatrix} \hat{y}_1 & \hat{y}_2 & \cdots & \hat{y}_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst. Auch die Vorhersagen werden in einem Vektor

$$\boldsymbol{y} = \begin{pmatrix} y_1 & y_2 & \cdots & y_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst. Somit ist ein Trainingssample nichts anderes als ein Paar $(\boldsymbol{x}_i, \hat{\boldsymbol{y}}_i)$ eines Inputsvektor $\boldsymbol{x}$ und eines Labelvektor $\hat{\boldsymbol{y}}$.

Die Inputs bestehen aus gewissen **Attributen**, welche die Merkmals*typen* der Daten sind. Die sogennanten **Features** sind dann die spezifischen Werte der Attribute eines Samples. Der Algorithmus soll anhand dieser Features seine Vorhersagen machen. Diese Vorhersagen werden dann mit den Labels abgeglichen und so bewertet. Anhand der Bewertungen wird dann eine Optimierung des Modells vorgenommen. Unter korrekten Bedingungen (kein Overfitting) findet kein Auswendiglernen der Trainingsdaten statt, sondern ein Generalisieren des Zusammenhangs anhand von Mustern und Gesetzmassigkeiten.

Um eine endgueltige Bewertung des Modells durchzufuehren, wird ein Testdatensatz $\mathbb{T}$, welcher nicht Teil des Trainingsdatensatz ist, genutzt um Vorhersagen zu machen. Dies garantiert, dass kein Auswendiglernen moeglich ist.

BEISPIEL

1.1.3 Modelle

Ein **Modell** ist eine mathematische Funktion $h\colon \mathbb{R}^m \to \mathbb{R}^n$, Hypothesenfunktion gennant, welche die Inputs auf die Outputs abbildet $\boldsymbol{y} = h(\boldsymbol{x})$. Man kann diese Funktion gewissermassen als die Hypothese, welche das Modell bezueglich der Beziehung zwischen den Inputs und den Labels aufgestellt hat, betrachten. Diese Modelle koennen verwendet werden um vorallem entweder Klassifizierungsprobleme oder Regressionsprobleme zu loesen. Falls es sich um letzteres handelt, spricht man von einem Regressionsmodell. Ein solches Regressionsproblem werden wir in dieser Arbeit loesen.

Das Verhalten eines Modells wird bestimmt durch seine **Modellparameter** $\lambda_1, \lambda_2, \ldots, \lambda_k$. Sie bestimmen, wie die Hypothese des Modells lautet. Das Ziel ist es, die Modellparameter so einzustellen, dass die Vorhersagen $\boldsymbol{y}$ des Modells besser mit den Labels $\hat{\boldsymbol{y}}$ der Trainingsdaten

uebereinstimmen. Dies wird iterativ gemacht, indem immer wieder leichte Anpassungen an den Parametern vorgenommen werden, bis das Modell die gewuenschten Resultate liefert.

Neben den gelernten Parametern, gibt es auch noch sogenannte **Hyperparameter**. Diese koennen nicht erlernt werden, sondern muessen manuell vor dem Training gewaehlt werden und koennen den Lernvorgang erheblich beeinflussen. Dies bedeutet, dass man ausprobieren muss, welche Werte fuer die Hyperparameter die besten Resultate liefern.

Das wohl einfachste Regressionsmodell ist eine Regressionsgerade. Diese ist angemessen, falls ein einfacher linearen Zusammenhang der Form $y = \lambda_1 x + \lambda_0$ zwischen den Features und den Labels besteht. Nun muessten nur noch λ_0 und λ_1 bestimmt werden. BEISPIELMODELL AUTO

Fuer Machine Learning haben sich gewisse Modelle besonders guet etabliert, darunter waeren: Support Vector Machines, Evolutionäre Algorithmen, und Künstliche Neuronale Netze. Diese Arbeit wird sich vorwiegend mit Neuronalen Netzen auseinandersetzen.

Abbildung 1.1: Schema eines Modells

1.2 Training

1.2.1 Verlust- und Kostenfunktionen

Einsicht ist der erste Schritt zur Besserung. Das gilt auch beim Machine Learning, deshalb muss beim Training zuerst die Genauigkeit des Modells bewertet werden. Dies wird mithilfe von sogennaten Kostenfunktion bzw. Verlustfunktionen erreicht.

Eine **Verlustfunktion** $L(y, \hat{y})$ sollte ein Mass fuer die Abweichung der Vorhersagen y von den Labeln $\hat{y}$ sein. Aus ihr bildet man die **Kostenfunktion** $C(\boldsymbol{y}, \hat{\boldsymbol{y}})$, indem man die alle Verluste der einzelnen Ouputs aufsummiert. Somit erhaelt man die Kosten einer gesamten Vorhersage mit m Outputs (siehe Gl. (1.1)).
Der Fehler $\bar{C}(\mathbb{X})$ des gesamten Trainingsdatensatz $\mathbb{X}$, der Groesse p, ergibt sich aus dem arithemtischen Mittel der einzelnen Kosten der Vorhersagen (siehe Gl. (1.2)).

$$C\left(\boldsymbol{y}, \hat{\boldsymbol{y}}\right) = \sum_{i=1}^{m} L(y_i, \hat{y}_i) \tag{1.1}$$

$$\bar{C}(\mathbb{X}) = \frac{1}{p} \sum_{j=1}^{p} C\left(\boldsymbol{y}_j, \hat{\boldsymbol{y}}_j\right) \tag{1.2}$$

Eine Verlustfunktion L bzw. eine Kostenfunktion C sollte folgende Eigenschaften aufweisen:

- L ist minimal, wenn $y = \hat{y}$
- L waechst mit $|y - \hat{y}|$
- C ist nach jedem y_n partiell differenzierbar (erklaert in Sektion (1.2.2))

1.2.1.1 Mittlere quadratische Abweichung

Die bekannteste Verlustfunktion ist die "Mittlere quadratische Abweichung" (engl.: mean squared error). Sie ist definiert als das arithmetische Mittel aller quadrierten Differenzen zwischen den Vorhersagen und Labels. Zusaetzlich halbiert man noch das arithmetische Mittel, damit bei der Ableitung der Faktor 2 wegfaellt.

$$L_{MSE} = \frac{1}{2n}(\hat{y} - y)^2 \tag{1.3}$$

Die Kostenfunktion kann mithilfe des einer Summe berechnen werden, oder in diesem Fall mithilfe einer Vektorsubtraktion Vorhersagen $\boldsymbol{y}$ von den Labels $\hat{\boldsymbol{y}}$.

$$C_{MSE} = \frac{1}{2n}\sum_{i=1}^{n}(\hat{y}_i - y_i)^2 = \frac{1}{2n}(\hat{\boldsymbol{y}} - \boldsymbol{y})^2 \tag{1.4}$$

Sie erfuellt alle Anforderungen an eine Kostenfunktion:

- Ihr Funktionwert ist 0 und minimal fuer $\boldsymbol{y} = \hat{\boldsymbol{y}}$
- Sie ist proportional zu $(\hat{\boldsymbol{y}} - \boldsymbol{y})^2$
- Ihre partielle Ableitung nach einem y_i lautet: $C'_{MSE} = \frac{1}{n}(y_i - \hat{y}_i)$

1.2.1.2 Cross-entropy

1.2.2 Gradientenverfahren

Um ein Modell nun zu trainieren, muss man verstehen, dass es sich um ein Optimierungsproblem handelt. Das Modell ist am besten, also macht die besten Vorraussagen, wenn die Funktionswerte der Kostenfunktion am kleinsten sind. Deshalb muss diese Kostenfunktion C minimiert werden. Hierbei muss die Funktion C nicht mehr in Abhaengigkeit der Inputs betrachtet werden, sondern als Funktion der Modellparametern $C(\lambda_1, \lambda_2, \ldots, \lambda_k)$, denn diese sollen angepasst werden, um das Modell zu verbessern. $(\lambda_1, \ldots, \lambda_k) = \arg\min(C)$. Fuer diese Optimiertung wird das sogennante **Gradientenverfahren** (engl.: Gradient descent) verwendet. [1]

Allgemein koennen mithilfe des Gradientenverfahrens Funkionen $f(x_1, x_2, \ldots, x_n)$ vom Typ $\mathbb{R}^n \to \mathbb{R}$ (wie z.B. die Fehlerfunktion) minimiert werden. Dies geschieht, indem ein Startpunkt (Ortsvektor) $\boldsymbol{p}_0$, dessen Komponenten den Input von $f(\boldsymbol{p}_0)$ darstellt, gewaehlt wird. Nun werden iterativ neue Punkte $\boldsymbol{p}_t$ gesucht, welche immer naeher beim lokalen Minimun liegen, also Punkte, die den Funktionswert $f(\boldsymbol{p}_t)$ immer kleiner werden lassen. Dies wird durchgeführt, bis der Punkt genug nahe beim lokalen Minimun ist.

Dafuer muss ein Vektor $\boldsymbol{b}_t$ bestimmt werden, welcher auf den Punkt $\boldsymbol{p}_t$ draufaddiert einen neuen Punkt $\boldsymbol{p}_{t+1}$ bildet, bei dem der Funktionswert $f(\boldsymbol{p}_{t+1})$ kleiner ist als der von $f(\boldsymbol{p}_t)$. Dies geschieht am effizientesten, wenn $\boldsymbol{b}_t$ in die Richtung der staerksten Funktionswertabnahme zeigt.
Hierzu braucht man den sogennanten **Gradient $\boldsymbol{\nabla}$**, wofür man wiederum partielle Ableitungen braucht.

[1] Im Gymnasium wird beigebracht die lokalen Extrema (inkl. lokalen Minimas) zu bestimmen, indem die erste Ableitung f' gebildet wird und gleich null gesetzt wird. Dies ist hier nicht moeglich, da die Funktion $C'(\lambda_1, \lambda_2, \ldots, \lambda_n)$ deutlich zu komplex ist, um die Nullstellen analytisch zu bestimmen. Deshalb wird das Gradientenverfahren verwendet.

Partielle Ableitungen

Partielle Ableitungen sind eine Erweiterung der "normalen" Ableitungen auf multidimensionale Funktionen $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$. Man leitet dabei nur nach einem Argument x_i ab und betrachtet die restlichen Argumente als Konstanten. Es gelten die gleichen Ableitungsregeln wie bei der nicht-partiellen Ableitung. Die partielle Ableitung einer Funktion $f(x_1, \ldots, x_n)$ bezueglich einer Variable x_i in einem Punkt $\boldsymbol{a} = \begin{pmatrix} a_1 & \cdots & a_n \end{pmatrix}^\mathsf{T}$ ist analog zur normalen Ableitung folgendermassen definiert:

$$\frac{\partial f}{\partial x_i}(\boldsymbol{a}) := \lim_{h \to 0} \frac{f(a_1, \ldots, a_i + h, \ldots, a_n) - f(a_1, \ldots, a_i, \ldots, a_n)}{h}$$

Geometisch ist dies die Steigung der Tangente an die Funktion f im Punkt $\boldsymbol{a}$. Die Tangente liegt in der Richtung der Achse des Parametern x_i, nach dem man ableitet.

Gradient

Der Gradient $\boldsymbol{\nabla}$ ist ein Differentialoperator, den man auf eine Funktion $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$ anwendet kann, welcher ein Skalarfeld auf ein Vektorfeld (das sogennante Gradientenfeld) abbildet.
Um den Gradienten $\boldsymbol{\nabla} f$ der Funktion f zu bilden, fasst man alle partiellen Ableitungen der Funktion f, nach jedem Argument x_i, in einem Vektor zusammen. Meistens bestimmt man den Gradienten $\boldsymbol{\nabla} f(\boldsymbol{p})$ in einem spezifischen Punkt $\boldsymbol{p} = \begin{pmatrix} p_1 & \cdots & p_n \end{pmatrix}^\mathsf{T}$.

$$\boldsymbol{\nabla}_{\boldsymbol{x}} f(\boldsymbol{p}) = \frac{\partial f}{\partial \boldsymbol{x}}(\boldsymbol{p}) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(\boldsymbol{p}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\boldsymbol{p}) \end{pmatrix}$$

Geometisch ist der Gradient $\boldsymbol{\nabla} f(\boldsymbol{p})$ einer Funktion f in einem Punkt $\boldsymbol{p}$ dann der Vektor, welcher in die Richtung des steilsten Anstiegs von f zeigt. Sein Betrag gibt die Staerke des Anstiegs an.
MATRIX-GRADIENT EINBRINGEN

Abbildung 1.2: Skalarfeld mit zugehoerigem Gradientenfeld

Da der Gradient in die Richtung des steilsten Anstiegs zeigt, sollte der Vektor $\boldsymbol{b}_t$ gerade in die entgegengesetze Richtung zeigen. Also sollte er in die Richtung des negierten Gradient der Funktion f im Punkt $\boldsymbol{p}_t$ zeigen. Also kann jetzt das iterative Annahern an das lokalen Minimums folgendermassen beschrieben werden (wobei η eine spaeter erklaerte Schrittgroesse darstellt).

$$\boldsymbol{p}_{t+1} = \boldsymbol{p}_t - \eta \cdot \boldsymbol{\nabla} f(\boldsymbol{p}_t) \tag{1.5}$$

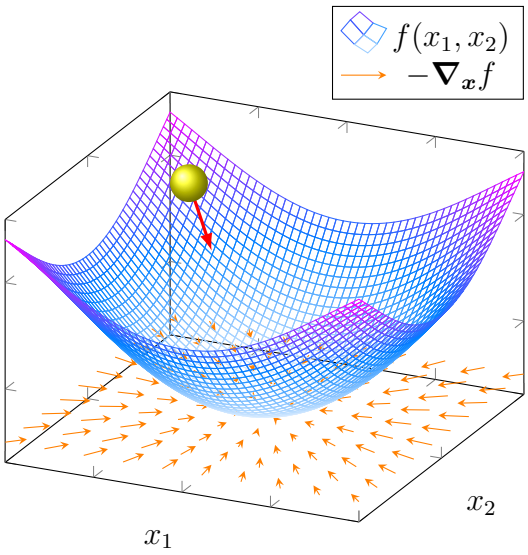

Abbildung 1.3: Visualisierung des Gradientenabstiegs: ein Ball rollt das Gradientenfeld hinab in das lokale Minimum.

Waehrend des Gradientenverfahren konvergiert der Punkt $\boldsymbol{p}_t$ zu einem beliebigen *lokalen* Minimum, abhängig davon wie der Startpunkt $\boldsymbol{p}_0$ gewaehlt wurde. Wie man diesen Startpunkt zu waehlen hat, wird in Sektion (2.5.1) erlauetert. Da dieser meist zufaellig bestimmt wird, ist es eine Glückssache ein sehr niedriges Minimum zu finden.

Die sogennante **Lernrate** η aus Gleichung (1.5) ist ein Hyperparameter. Sie ist ein positiver Proportionalitatsfaktor, welcher die Schrittgroesse des Gradientenabstieg bestimmt. Sie muss je nach zu minimierender Funktion anderst gewaehlt werden. Dabei hilft nur ausporbieren. Falls η nicht gut gewahelt wurde, gibt es Probleme beim Training:

- Falls η zu klein ist, verlaueft das Trainings unnoetig langsam und braucht sehr lange. Ausserdem kann es passieren, dass man bei einem hohen lokalen Minimum stecken bleibt.
- Falls η zu gross ist, kann es passiert, dass man ueber das lokale Minimum hinaus schiesst und somit nur darum herum springt.

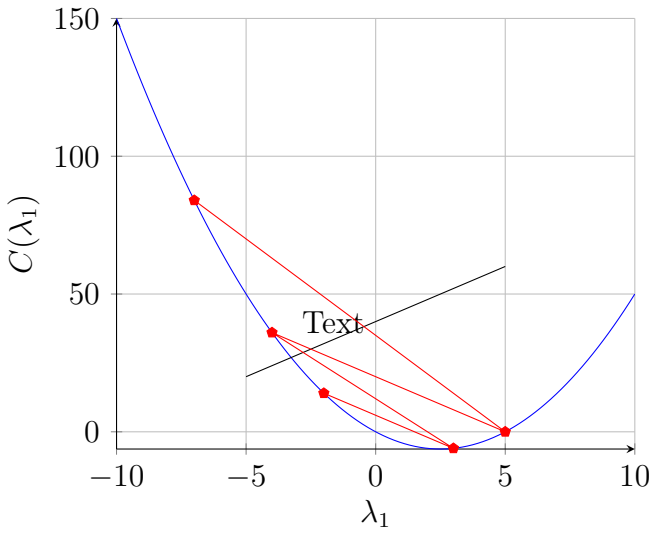

Abbildung 1.4: Visualisierung verschiedener Lernraten

1.2.3 Stochastisches Gradientenverfahren fuer Machine Learning

Wie vorhin erklaert, wird fuer das Trainieren eines Modells das Gradientenverfahren benutzt. Konkret wird die Kostenfunktion $C(\boldsymbol{y}, \hat{\boldsymbol{y}} \mid \lambda_0, \ldots, \lambda_n)$ (λ sind die Modellparameter, $\boldsymbol{y}$ die Vorhersagen und $\hat{\boldsymbol{y}}$ die Labels) minimieren, indem die Parameter angepasst werden. Dadurch macht das Modell immer bessere Vorhersagen. Fuer nur eine Iteration des Gradientenverfahren, muesste man den Gradienten fuer den *gesamten* Trainingsdatensatz berechnen. Dies waere zwar ein exakter Prozess, aber ein extrem langsamer zugleich. Bei grossen Datensaetzen wuerde es eine Ewigkeit dauern, bis das Modell nur annahernd guete Vorhersagen machen wuerde.

Aus diesem Grund verwendet man eine leicht abgeänderte Variante dieses Verfahren, naemlich das **Stochastische Gradientenverfahren** (engl.: Stochastic Gradient Descent) (SGD). Hierfuer wird der "echte" Gradient des gesamten Datensatzes mit dem Gradienten einiger Trainingssamples approximiert. Dazu wird der Trainingsdatensatz in sogennante **Mini-Batches** eingeteilt und der Gradient jeweils pro Mini-Batch berechnet. Als Konsequenz finden deutlich mehr Iterationen statt in *einer* Durchkaemmung der Trainingsdaten. Eine solche Durchkaemmung bezeichnet man als **Epoche**. Oft wird mehrere Epochen lang trainiert. Der Gradient eines genug grossen Mini-Batches ist zwar nicht ganz exakt, aber approximiert den Gradieten des gesamten Datensatzen genuegend gut. Sowohl die Mini-Batch Groesse, wie auch die Anzahl Epochen sind weitere Hyperparameter.

Die partiellen Ableitungen der gesamten Trainingsdaten wird mit dem arithmetischen Mittel der partiellen Ableitungen eines Mini-Batches der Groesse q approximiert.

$$\frac{\partial \bar{C}}{\partial \lambda_k} \approx \frac{1}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_k} \tag{1.6}$$

Eine Iteration des Stochastischen Graidentenverfahren wird analog zu Gleichung (1.5) folgendermassen durchgefuehrt.

$$\lambda_{k,t+1} = \lambda_{k,t} - \frac{\eta}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_{k,t}} \tag{1.7}$$

1.2.4 Adam Optimizer?

1.3 Trainingsphaenomene

1.3.1 Overfitting

Kapitel 2

Deep Learning und Künstliche Neuronale Netze

Nun betrachten wir ein spezifisches Modell, welches die wohl besten Resultate fuer die meisten Problemstellungen des Maschinelles Lernen (Bilderkennung, Spracherkennung, etc.) liefert. Es handelt sich um das **Kuenstliche Neuronale Netz** (eng.: Neural Network) kurz KNN. Der Bereich des Maschinelles Lernens, welcher sich mit Neuronalen Netzen beschaeftigt, bezeichnet man als **Deep Learning**.

Kuenstliche Neuronale Netze sind zum Teil biologisch von Nervensystemen vieler Lebewesen inspiriert. Sie sind aber lediglich eine Abstraktion ihrer Informationverarbeitung und versuchen nicht eine moeglichst genaue biologische Abbildung darzustellen. Es gibt nicht nur eine Art von Neuralem Netz, sondern es exisitieren die verschiedensten Architekturen, welche je nach Problemstellung ausgewaehlt werden muessen. Diese Arbeit wird vorallem von zwei solchen Architekturen gebrauch machen: Convolutional Neural Networks und sogennante Autoencodern.

2.1 Perzeptron

Um den Aufbau und die Funktion eines Kuenstlichen Neuronalen Netz besser zu verstehen, wird im folgenden ein Vorgaenger des KNN erklaert: das **Perzeptron**.

Das einlagige Perzeptron wurde erstmals 1958 von Frank Rosenblatt vorgestellt. Dieses besteht aus einem einzigen Kuenstlichen Neuron. Dieses Kuenstliche Neuron hat mehrere binaere Inputs und einen einzigen binaeren Output. Binaer bedeutet, dass der Wert nur entweder 0 (*aus*) oder 1 (*ein*) sein kann. Des weiteren besitzt es mehrere sogenannte **Gewichte** $w_1, \ldots, w_m \in \mathbb{R}$, fuer jeden Input x_i ein Gewicht w_i. Diese sind reelle Zahlen, welche das Verhalten des Perzeptron bestimmen. Die **gewichtete Summe**, also die Summe aller Produkte der Inputs mit ihrem Gewicht, wird mit $\tilde{z}$ bezeichnet. Sie ist das gleiche wie das Skalarprodukt des Gewichtevektor $\boldsymbol{w} = \begin{pmatrix} w_1 & \cdots & w_n \end{pmatrix}^\mathsf{T}$ mit dem Inputvektor $\boldsymbol{x}$.

$$\tilde{z} = \sum_{i=1}^{m} w_i x_i = \boldsymbol{w} \cdot \boldsymbol{x}$$

Zusaetzlich besitzt das Perzeptron einen **Schwellenwert** $\tilde{b}$. Zusammen mit den Gewichten, bilden sie die Modellparameter. Das Perzeptron verhaelt sich so, dass falls die gewichtete Summe $\tilde{z}$ groesser als der Schwellenwert $\tilde{b}$ ist, das Neuron feuert, d.h. der Output betraegt 1. Andernfalls ist er 0 (siehe erster Teil der Hypothesenfunktion h in Gleichung (2.1)). Es ist gaengig die Ungleichung der Bedingung in die Nullstellenform zu bringen und $\tilde{b}$ durch die **Neigung** (engl.: Bias) $b = -\tilde{b}$ zu ersetzten. Somit lautet die Ungleichung: $\tilde{z} + b > 0$. Der neue Term $\tilde{z} + b$ wird

mit z bezeichnet (siehe Rest der Gl. (2.1)). Die Neigung gibt an wie stark das Neuron dazu neigt zu feuern. Eine grosse Neigung laesst ein Neuron auch dann noch feuern, wenn nur wenige Inputs eingeschaltet sind.

$$h(\boldsymbol{x}) = \begin{cases} 1 & \text{falls } \tilde{z} > \tilde{b} \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \tilde{z} + b > 0 \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \boldsymbol{w} \cdot \boldsymbol{x} + b > 0 \\ 0 & \text{ansonsten} \end{cases} \tag{2.1}$$

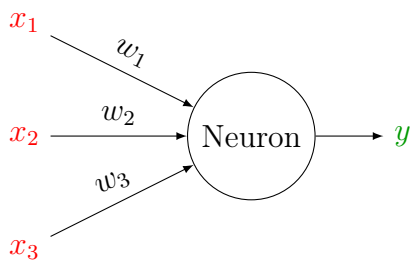

Abbildung 2.1: Perzeptron mit drei Inputs

Fuer das Trainieren des Perzeptron existieren spezielle Verfahren, welche hier aber nicht relevant sind. Das Gradientenverfahren kann naemlich nicht verwendet werden. Der Grund dafuer sollte spaeter in Sektion (2.2) einleuchtend werden.

2.1.1 Was kann ein Perzeptron erlernen?

Nun stellt sich die Frage, was ein Perzeptron erlernen kann und wofuer es genutzt werden kann. Das Perzeptron ist lediglich ein **Linearer Klassifikator** der Form $y = w_1x_1 + \cdots + w_mx_m$. Es ist also ein Klassifizierungsmodell, kein Regressionsmodell. Es kann die Features in zwei Klassen 0 oder 1 einordnen, wobei der Outputs der Hypothesenfunktion, diese Klassifiezierung angibt. Ueberschreitet y den Schwellenwert, werden die Features der Klasse 1 zugeordnet, sonst der Klasse 0. Jedoch muessen diese Klassen linear separierbar sein.

Lineare Separierbarkeit bedeutet, dass man alle Featurevektoren $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p \in \mathbb{R}^m$ innerhalb ihres Vektorraums $\mathbb{R}^m$ durch eine Hyperebene in ihre Klassen aufteilbar sein muessen. Falls das Perzeptron zwei Inputs hat, bedeutet dies, dass die Ortsvektoren einfach durch eine Gerade voneinander trennenbar sein muessen (siehe Abb. (2.2)).
Falls die Features nicht linear separierbar sind, bedeutet dies, dass das Perzeptron die Klassifizierung nicht erlernen kann. BEISPIEL

Abbildung 2.2: erfolgreiche lineare Separierung (links) und das Versagen bei XOR (rechts)

(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Linear separability — Wikipedia, The Free Encyclopedia*)

2.2 Erweiterung der Kuenstlichen Neuronen

Ein Perzeptron ist, wie vorhin erklaert, nur in der Lage, lineare Klassifikationen durchzufuehren. Um nun auch kompliziertere Probleme zu loesen, muss das Prinzip ausgebaut werden.

Ausserdem brauchen wir ein Kuenstliches Neuron, welches sich besonders gut als Baustein fuer KNNs eignet.

2.2.1 Kuenstliche Neuronen im Allgemeinen

Kuenstliche Neuronen sind immer so aufgebaut, dass sie einen oder mehrere Inputs haben und einen einzigen Output. Zu jedem Input x_i ist ein Gewicht w_i assoziert. Zuerst wird die gewichtete Summe der Inputs $\tilde{z}$ gebildet. Die Neigung b wird ebenfalls draufaddiert, um z zu erhalten. Nun muss die sogennante **Aktivierung** a gebildet werden. Sie ist der Output des Neurons. Die Aktivierung $a = \varphi(z)$ ist das Resultat der **Aktivierungsfunktion** φ angewendet auf z. Die verschiedenen Kuenstlichen Neuronen unterscheiden sich fast nur in ihrer Aktivierungsfunktion.

Abbildung 2.3: ein kuenstliches Neuron und seine Bestandteile

2.2.2 Perzeptronen als Kuenstliche Neuronen

Zuerst noch einmal ein Blick auf das Perzeptron im Angesicht der Aktivierungsfunktion. Ein wesentlicher Unterschied des Perzeptron gegenueber sonstigen Kuenstlichen Neuronen, besteht darin, dass seine Inputs und Outputs nur binaere Werte annehmen koennen. Um dieses Verhalten des Perzeptron zu erhalten, muss eine Stufenfunktion als Aktivierungfunktion verwendet werden: die Heaviside-Funktion Θ. Sie hat einen einzigen Stufensprung bei $x = 0$ vom Wert 0 auf 1 (siehe Abb. (2.4)).

$$\varphi^{\text{hlim}}(z) = \Theta(z) = \begin{cases} 1 & \text{falls } z \geq 0 \\ 0 & \text{falls } z < 0 \end{cases}$$

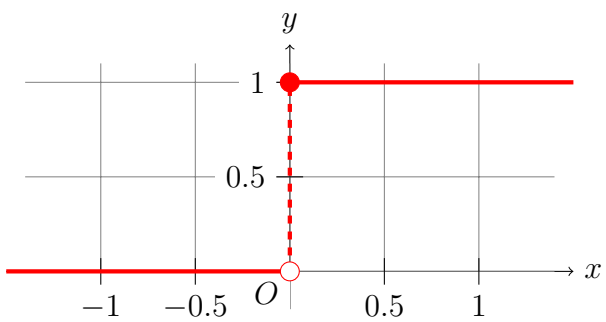

Abbildung 2.4: Definition und Graph der Heaviside-Funktion Θ

2.2.3 Stueckweise lineare Neuronen

Der naechste Schritt nach dem binaeren Perzeptron sind sogenannte stueckweise lineare Neuronen. Sie verwenden eine stueckweise lineare Aktivierungsfunktion. Diese bildet ein beschraenktes Intervall linear ab. Die Werte ausserhalb werden auf die konstanten Werte 0 oder 1 abbgebildet (siehe Abb. (2.5)).

Die Inputs koennen jetzt beliebige reelle Zahlen sein (vorzugsweise in der Naehe von 0 und 1). Ein KNN aus ausschliesslich linearen Neuronen ist ziemlich nutzlos, da jedliche Verkettung von linearen Funktion auch durch eine einzige lineare Funktion dargestellt werden koennte. Somit hat ein KNN gegenueber einem einzelnen Neuron keinen Mehrwert. Ausserdem koennen mit diesen Neuron auch nur lineare Probleme geloest werden.

$$\varphi^{\text{pwl}}(z) = \begin{cases} 1 & \text{falls } z > \frac{1}{2} \\ z + \frac{1}{2} & \text{falls } -\frac{1}{2} < z < \frac{1}{2} \\ 0 & \text{falls } z < \frac{1}{2} \end{cases}$$

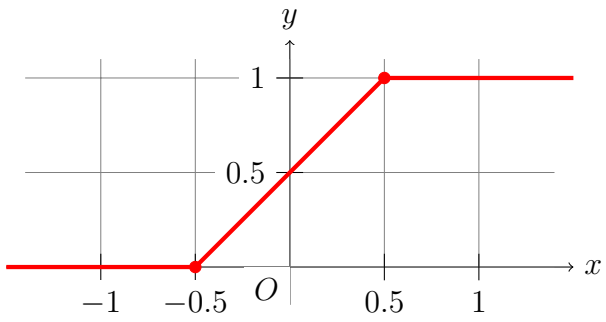

Abbildung 2.5: Formel und Graph einer stueckweisen linearen Funktion

2.2.4 Sigmoide Neuronen

Die logische naechste Erweiterung sind nicht-lineare Neuronen. Ein sehr beliebter Kandidat dafuer sind Sigmoide Neuronen. Den Namen haben sie von ihrer Aktivierungsfunktion: der Sigmoidfunktion σ. Eine sehr wichtige Eigenschaft von ihr ist, dass sie - im Gegensatz zu den vorhin genannten Aktivierungsfunktion - ueberall differenzierbar und strikt monoton steigend ist. Erst fuer diese Aktivierungsfunktion, kann das Gradientenverfahren angewendet werden und somit das KNN trainiert werden. Die anderen Funktionen haben Stellen bei welchen die Ableitungsfunktion null betraegt, somit kann das lokale Minimum nicht gefunden werden.

Nicht nur die Sigmoidfunktion erfuellt diese Bedingungen, sondern auch andere. Die Sigmoidfunktion wird bevorzugt, da ihre Ableitung sehr simpel ist (siehe Abb. (2.6)). Die Nichtlinearitaet dieser Neuronen ermoeglicht ein Erlernen von deutlich komplexeren Sachverhalten. Und wie spaeter in Sektion (2.7) erlautert, ist es moeglich mit der Kompostion von nicht-linearen Funktionen jede belibige Funktion zu approximieren!

Die Sigmoid-Funktion besitzt eine einzige Wendestelle $\sigma''(x = 0) = 0$ und hat zwei Asymptoten, eine $\lim\limits_{x \to -\infty} \sigma(x) = 0$ und eine zweite $\lim\limits_{x \to \infty} \sigma(x) = 1$ (siehe Abb. (2.6)).

$$\varphi^{\text{sig}}(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$
$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

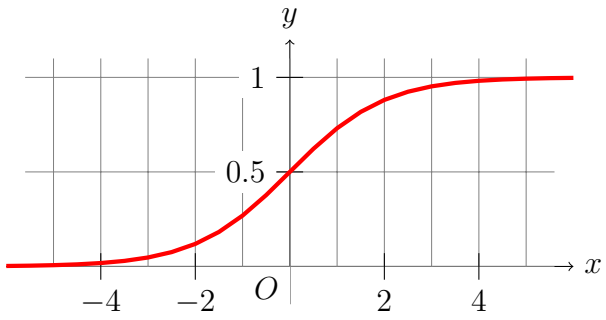

Abbildung 2.6: Definition, Ableitung und Graph der Sigmoid-Funktion σ

2.3 Topologie der Kuenstlichen Neuronalen Netzen

Nun sollten diese Sigmoiden Neuronen als Bausteine verwendet werden, um ein Kuenstliches Neuronales Netz zu bilden. Dazu werden sie miteinander verbunden und bilden so ein Netz, aehnlich wie ein Nervensystem.

Diese Neuronen sind in verschieden Schichten (engl.: Layers) arangiert. Die erste ist die **Inputschicht**. Sie behinhalten die Inputneuronen. Diese sind eigentlich keine richtigen Neuronen sondern eher Platzhalter fuer ihr jeweiliges Feature x_i. Als letztes kommt die **Outputschicht**

mit den Outputneuronen, welche jeweils einen Outputwert y_i besitzen. Dazwischen liegen die **Zwischenschichten** (engl.: Hiddenlayer). Von ihnen kann es beliebig viele geben und in ihnen beliebig viele Neuronen. Falls viele Zwischenschichten verwendet werden, bezeichnet man das Netzwerk als "deep". Daher ruert auch der Name des Deep Learnings. Der Aufbau eines KNN bezeichnet man als **Topologie** des Netzes. Die Topologie umfasst viele Hyperparameter. Darunter sind zum Beispiel die Anzahl Zwischenschichten, wie auch die Anzahl Neuronen pro Schicht.

Jedes Neuron aus einer Schicht ist mit jedem Neuron aus der naechsten Schicht ueber Verbindungen gekoppelt. Alle Verbindungen besitzten ein Gewicht analog zu den Inputs des Perzeptron. Die Aktivierung, also der Output, eines Neurons wandert entlang den jeweiligen Verbindung zu allen Neuronen der naechsten Schicht und dient als deren Input. Die soeben beschriebe Art von KNN nennt man **Feedforward-Netz**, da alle Werte ausschliesslich nach vorne propagiert werden.

In Abbildung (2.7) ist ein Beispiel eines Neuronalen Netzes abgebildet. In diesem Fall besitz es sowohl 4 Inputs, wie auch 4 Outputs. Es hat ausserdem 3 Zwischenschichten. Die erste und die dritte haben jeweils 3 Neuronen und die zweite besitzt 4 Neuronen.

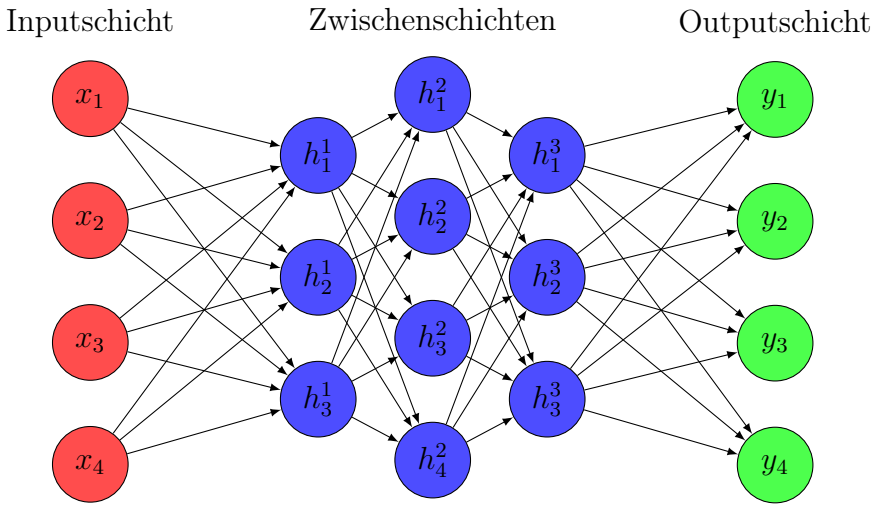

Abbildung 2.7: Schichten eines KNNs

2.4 Lernverhalten

Die Hoffnung beim Trainieren von KNNs besteht darin, dass das Modell fuer jede weiter Schicht eine hoeheres Abstraktionsniveau erreicht. Wuerde man zum Beispiel ein Netzwerk zur Gesichtserkennung trainieren, koennte man sich den Erkennungsprozess folgendermassen vorstellen. Die erste Zwischenschicht erkennt Kanten und Konturen. Die zweite vereint diese Merkmale zu Ecken und primitive geometrische Formen. Die dritte Schicht sollte dann schon komplexere geometrische Formen erkennen, welche gewissen Gesichtmerkmalen, wie der Nase, aehneln. Die letzten Schichten sollte dann all diese Merkmale zusammensetzen und so ein Gesicht erkennen. WEITERFUEHREN

2.5 Vorwaertspropagierung

Jetzt, da der Aufbau eines KNNs erklaert wurde, sollte nun die mathematische Funktionsweise des Modells erklaert werden. Hierfuer muessen einige Konventionen zur Bezeichnung der Teile eines KNNs getroffen werden. Es sollten vorallem noch Abbildungen (2.5) und (2.5) zum Verstaentniss der Nomenklatur studiert werden.

- l ist der Index einer Schicht. Die Indexierung beginnt bei 0.
- L ist der letzte Schichtindex und somit auch die gesamte Anzahl an Schichten.
- $|l|$ ist die Anzahl Neuronen in der l-ten Schicht. [1]
- n_j^l ist das j-te Neuron in der l-ten Schicht.
- z_j^l ist die gewichtete Summe der Inputs des j-ten Neuron in der l-ten Schicht.
- a_j^l ist die Aktivierung/Output des j-ten Neurons in der l-ten Schicht.
- b_j^l ist die Neigung fuer das j-te Neuron in der $(l+1)$-ten Schicht. [2]
- $w_{j,k}^l$ ist das Gewicht der Verbindung vom k-ten Neuron in der l-ten Schicht zum j-ten Neuron in der $(l+1)$-ten Schicht. [3]
- φ ist die gewaehlte Aktivierungsfunktion (grundsaetzlich ist diese immer die Sigmoidfunktion σ).

Die Vorwaertspropagierung beginnt bei den Inputneuronen, welche jeweils einen Inputwert in sich tragen. Diese werden, um fuer eine kohaerente Nomenklatur zu sorgen, analog zu den Aktivierungen der anderen Neuronen mit a_j^0 bezeichnet, wobei j der Index des Neurons ist.
Nun muessen die restlichen Aktivierungen der Neuronen bis und mit den Ouputneuronen berechnet werden. Dies geschieht rekursiv, anhand der Aktivierungen der voherigen Schicht. Und zwar folgendermassen (ersichtlich in Gleichung (FP1)).

Zuerst laueft eine Summe ueber alle Neuronen n_k^l der jetztigen Schicht l. Dabei wird die gewichtete Summe der Aktivierungen a_k^l mit den assozierten Gewichten $w_{j,k}^l$ gebildet. Hierbei ist das Gewicht jenes, welches das k-te Neuron der l-ten Schicht mit dem j-ten Neuron der $(l+1)$-ten Schicht verbindet. Zusaetzlich gehoert zu der gewichteten Summe auch die jeweilige Neigung b_j^l, welche dazuaddiert wird. Diese gewichtete Summe wird mit z_j^{l+1} bezeichnet.

$$z_j^{l+1} = \sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l \tag{FP1}$$

Auf diese Summe wird dann die Aktivierungsfunktion φ angewandt. Das ist dann die Aktivierung a_j^{l+1} des j-ten Neurons in der $(l+1)$-ten Schicht.

$$a_j^{l+1} = \varphi\left(\sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l\right) = \varphi\left(z_j^{l+1}\right) \tag{FP2}$$

[1] Diese Schreibweise hat nichts mit dem Betrag zu tun, sondern wird einfach gewaehlt, da sie sehr platzsparend ist.

[2] Diese Konvention wurde gewaehlt, damit die folgenden Gleichungen simpler sind.

[3] Man beachte die Reihenfolge!
Diese Konvention scheint zwar auf den ersten Blick unintuitiv, macht jedoch Sinn fuer die Matrixindezierung. (2.6).

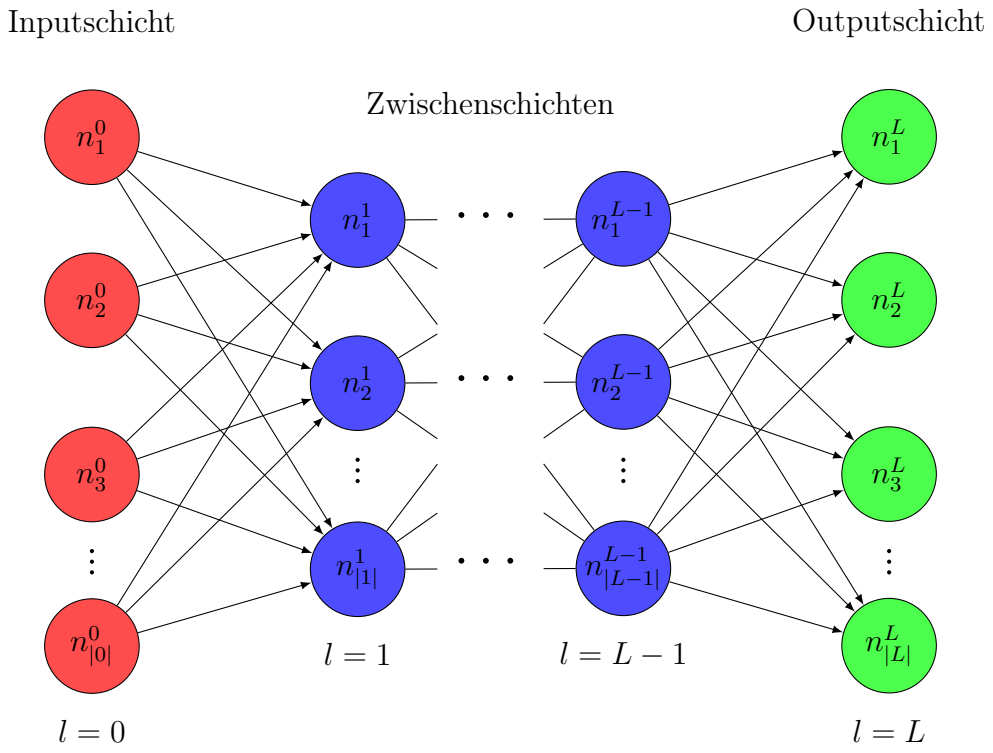

Abbildung 2.8: zum Verstaentniss der Nomenklatur

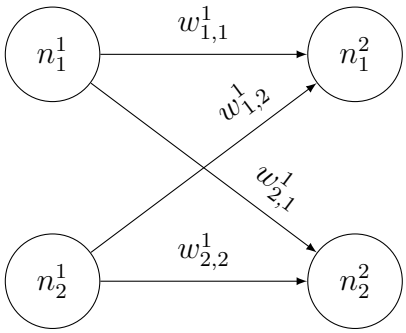

Abbildung 2.9: zum Verstaentniss der Gewichtebeschriftungen

Fuer Deep Learning braucht man vorallem sogennante Deep Neural Networks. Diese zeichnen sich dadurch aus, dass sie sehr viele Zwischenschichten besitzen. Deshalb bezeichnet man sie auch als "deep". Bei solchen Netzwerken ist es nicht unueblich, dass diese sehr viele Neuronen und Verbindungen (ueber 100'000) besitzen. Um hierbei nicht den Ueberblick zu verlieren und um nicht in den Indizes zu ertrinken, macht man Gebrauch von **Linearer Algebra**. Man verwendet Matrizen und Vektoren um die vielen Variabeln zusammenzufassen. Ausserdem besteht ein weiterer Vorteil darin, dass Computer mithilfe von Vektor- und Matrixoperationen die Berechnungen parallisieren koennen und in kuerzerer Zeit und mit weniger Ressourcen viele Berechnungen gleichzeitig ausfuehren koennen. Dies beschleunigt das Training der Modelle um ein Vielfaches. Dies wird spaeter in Sektion (**??**) noch weiter thematisiert.

Die Inputs $\boldsymbol{x}$, Vorhersagen $\boldsymbol{y}$ und Labels $\hat{\boldsymbol{y}}$ haben wir schon von Anfang an als Vektoren geschrieben. Nun sollen noch die Modellparameter und die restlichen Komponenten eines KNNs als Vektoren und Matrizen zusammengefasst werden. Sowohl alle gewichteten Summen z_j^l, wie auch alle Aktivierungen a_j^l einer Schicht l, werden in Vektoren $\boldsymbol{z}^l \in \mathbb{R}^{|l|}$ und $\boldsymbol{a}^l \in \mathbb{R}^{|l|}$ zusammengefasst. Auch alle Neigung b_j^l fuer eine Schicht $(l+1)$ bilden einen Vektor $\boldsymbol{b}^l \in \mathbb{R}^{|l+1|}$.

Zu guter letzt, wird noch eine **Gewichtsmatrix** $\boldsymbol{W}^l \in \mathbb{R}^{|l+1|\times|l|}$ definiert. Sie enthaltet alle Gewichte welche die l-te Schicht *zu* der $(l+1)$-ten Schicht verbindet. Das heisst der Eintrag in der j-ten Zeile und in der k-ten Spalte ist $w^l_{j,k}$ und verbindet so das Neuron n^l_k zu dem Neuron n^{l+1}_j.

$$\begin{aligned}
\boldsymbol{z}^l &= \begin{pmatrix} z^l_1 & z^l_2 & \cdots & z^l_{|l|} \end{pmatrix}^\mathsf{T} \\
\boldsymbol{a}^l &= \begin{pmatrix} a^l_1 & a^l_2 & \cdots & a^l_{|l|} \end{pmatrix}^\mathsf{T} \\
\boldsymbol{b}^l &= \begin{pmatrix} b^l_1 & b^l_2 & \cdots & b^l_{|l+1|} \end{pmatrix}^\mathsf{T}
\end{aligned}$$

$$\boldsymbol{W}^l = \begin{pmatrix} w^l_{1,1} & w^l_{1,2} & \cdots & w^l_{1,|l|} \\ w^l_{2,1} & w^l_{2,2} & \cdots & w^l_{2,|l|} \\ \vdots & \vdots & \ddots & \vdots \\ w^l_{|l+1|,1} & w^l_{|l+1|,2} & \cdots & w^l_{|l+1|,|l|} \end{pmatrix}$$

Mit diesen Definitionen kann nun Gleichung (FP1) in Matrixform geschrieben werden, denn die Matrixmultiplikation von $\boldsymbol{W}^l$ mit $\boldsymbol{a}^l$ ergibt einen Vektor $\tilde{\boldsymbol{z}}^{l+1}$, welcher alle gewichteten Summen $\tilde{z}^{l+1}_j$ ohne die jeweilige Neigung enthaelt.

$$\boldsymbol{W}^l\boldsymbol{a}^l = \begin{pmatrix} \sum_{j=1}^{|l|} w^l_{1,j}a^l_j & \sum_{j=1}^{|l|} w^l_{2,j}a^l_j & \cdots & \sum_{j=1}^{|l|} w_{|l+1|,j}a^l_j \end{pmatrix}^\mathsf{T} = \tilde{\boldsymbol{z}}^{l+1}$$

Nun muessen wir noch den Neigungsvektor $\boldsymbol{b}^l$ draufaddieren und wir erhalten Gleichung (FP1a), mithilfe dessen wir den Vektor der gewichteten Summen $\boldsymbol{z}^{l+1}$ bilden koennen.

$$\boldsymbol{z}^{l+1} = \mathbf{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l \tag{FP1a}$$

Der letzte Schritt besteht noch darin die Aktivierungsfunktion auf $\boldsymbol{z}^{l+1}$ anzuwenden um den Aktivierungsvektor $\boldsymbol{a}^{l+1}$ zu bilden. Hierfuer muss aber noch ein neues mathematisches Konzept eingefuehrt werden: die Vektorisierung einer Funktion.

Vektorisierung einer Funktion

Die Vektorisierung einer skalaren Funktion f, geschrieben als $\boldsymbol{f}[\boldsymbol{v}]$ hat als Argument einen Vektor $\boldsymbol{v}$, auf dessen Komponenten jeweils *einzeln* die Funktion f angewandt wird. Dieser neue Vektor ist der Rueckgabewert der Funktion. Er besitzt die gleichen Dimensionen wie der Argumentvektor.

$$\boldsymbol{f}[\boldsymbol{v}] = \begin{pmatrix} f(v_1) \\ \vdots \\ f(v_n) \end{pmatrix}$$

Nun kann ganz einfach die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf $\boldsymbol{z}^{l+1}$ angewandt werden.

$$\boldsymbol{a}^{l+1} = \boldsymbol{\varphi}\left[\boldsymbol{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l\right] = \boldsymbol{\varphi}\left[\boldsymbol{z}^{l+1}\right] \tag{FP2a}$$

(Nielsen, *Neural Networks and Deep Learning*)

2.5.1 Modellparameter initalisieren

Ein Schritt der getan werden muss, bevor das Training beginnt, ist das Initalisieren aller Modellparameter, in diesem Fall die Gewichte und Neigungen. Dies ist ein sehr essentieller Schritt, denn diese Startwerte entscheiden erheblich ueber die Leistungsfaehigkeit des Modells.

Wie in Sektion (1.2.2) gezeigt, muss am Anfang des Gradientenverfahrens ein Startpunkt $\boldsymbol{p}_0$ innerhalb des Gradientenfeldes $\boldsymbol{\nabla} C$ gewaehlt werden, von welchem aus der Gradientenabstieg beginnt. Da wir das Gradientenverfahren zur Optimierung der Modellparameter verwenden, ist unser Startpunkt, der Vektor aller Hyperparameter $\boldsymbol{\lambda} = \begin{pmatrix}\lambda_1 & \cdots & \lambda_k\end{pmatrix}^\mathsf{T}$. Dieser Startpunkt entscheidet darueber, in welches lokale Minimum konvergiert wird und bestimmt somit auch die bestmoegliche Exaktheit der Vorhersagen. Falls schlecht Initalwerte gewaehlt werden, konvergiert der Punkt in ein hohes lokales Minimum, was grosse Kostenfunktionswerte und schlecht Vorhersagen verursacht.

Es ist nicht moeglich im Vorhinein zu wissen, welche Initalwerte gute Resultate liefern. Man muss ausprobieren, deshalb initalisert man gaengierweise die Hyperparameter mit Zufallswerten. Dafuer nimmt man aber nicht irgendwelche Zufallsvariablen sondern man benutzt die Gauss'sche Normalverteilung $\mathcal{N}(\mu, \sigma^2)$ bzw. ihre Dichtefunktion

$$\phi(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

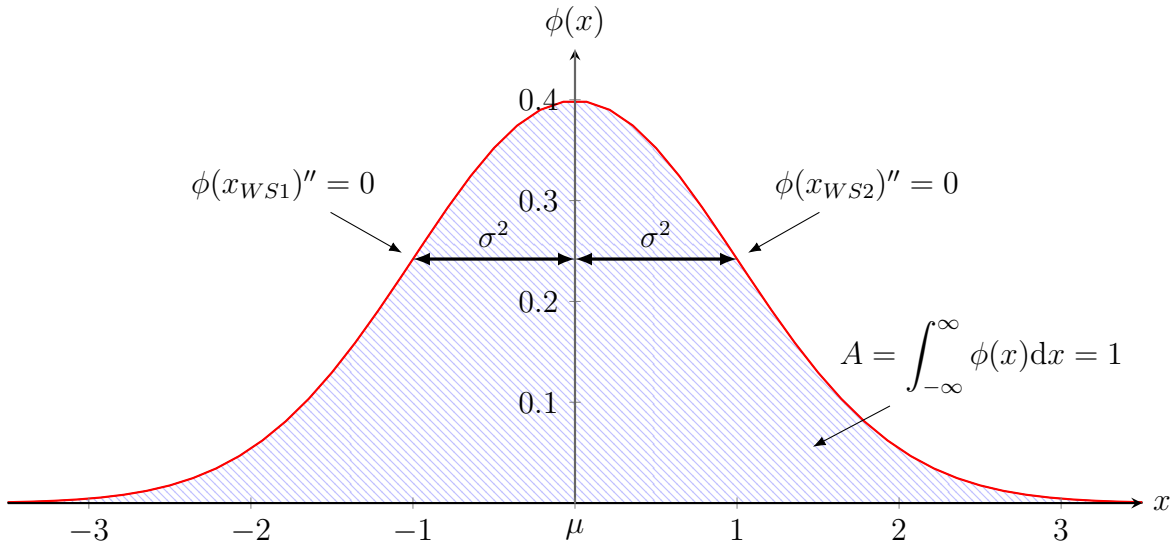

Abbildung 2.10: Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften

Um die Neigungen $b_{t=0}$ zu initalisieren benutzt man eine Normalverteilung $\mathcal{N}(0, 1)$ mit Erwartungswert $\mu = 0$ und Varianz $\sigma^2 = 1$. Um die Gewichte $w_{t=0}$ zu initalisieren benutzt man ebenfalls eine Normalverteilung mit Erwartungswert $\mu = 0$, jedoch wird die Varianz σ^2 so skaliert, dass die Summe aller Zufallesvariabeln der Gewichte einer Schicht eine Varianz von $\sigma^2_{tot} = 1$ hat.

$$w^l_{t=0} \sim \mathcal{N}(\mu = 0, \sigma^2 = \frac{1}{|l|}) \tag{2.2}$$

$$b^l_{t=0} \sim \mathcal{N}(\mu = 0, \sigma^2 = 1) \tag{2.3}$$

(Mehrere, *Normal distribution — Wikipedia, The Free Encyclopedia*)
(Nielsen, *Neural Networks and Deep Learning*)

2.6 Rueckwaertspropagierung

Die wahre Herausforderung besteht beim Gradientenverfahren darin, die partiellen Ableitungen der Modellparameter, also die Komponenten des Gradienten, zu bestimmen. Anderst gesamt muessen alle Terme $\frac{\partial C}{\partial w^l_{j,k}}$, wie auch alle Terme $\frac{\partial C}{\partial b^l_k}$ berechnet werden. Das Verfahren zum bestimmen dieser Ausdruecke ist so spezfisch und aufwendig, dass das Gradientenverfahren fuer KNNs einen eigenen Namen hat: die **Rueckwaertspropagierung** (engl.: Backpropagation) (auch Fehlerrueckfuehrung).

Da ein KNN, wie der Name es schon sagt, vernetzt ist, koennen die partiellen Ableitungen einer Schicht bezueglich seiner Nachbarsschichten berechnet werden. Dies ist auch der namensgebende Grundgedanke der Rueckwaertsprogagierung: Man beginnt in der letzten Schicht die partiellen Ableitungen zu bestimmen und berechnet dann im Rueckwaertsgang Schicht fuer Schicht die vorherigen partiellen Ableitungen, bis nach vorne.
Dies macht man mithilfe der Kettenregel der Ableitungen. Es ist sinnvoll fuer das Aufstellen dieser Gleichungen das Netzwerk als **Computation Graph** zu betrachten.

Ein Computation Graph ist eine Darstellung einer Verkettung von Funktionen als Netzwerk von Operationen. Die Knoten im Graph stellen Variabeln dar und die Pfade, welche die Knoten verbinden, sind die Funktionen, welche die Variabeln aufeinander abbilden. Die Funktion wird auf die Variable angewandet, von der der Pfad ausgeht. Der Knoten in welchem der Pfad endet, nimmt dann den Funktionswert an. Falls mehrere Pfade in einem Knoten enden, werden die einzelnen Werte der Pfade zusammenaddiert, um die Variable zu bilden.
In Abbildung (2.11) ist ein Beispiel eines Computation Graphs zusammen mit der Herleitung der partiellen Ableitungen dargestellt.

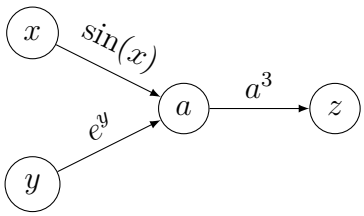

$$a(x,y) = \sin(x) + e^y$$
$$z(a(x,y)) = a^3(x,y) = (\sin(x) + e^y)^3$$

$$\frac{\partial z}{\partial x} = \frac{\partial a}{\partial x} \cdot \frac{\partial z}{\partial a} = \cos(x) \cdot 3a^2$$
$$\frac{\partial z}{\partial y} = \frac{\partial a}{\partial y} \cdot \frac{\partial z}{\partial a} = e^y \cdot 3a^2$$

Abbildung 2.11: Computation Graph einer exemplarischen Verkettung von Funktionen

Der erste Schritt der Rueckwaertsprogagierung besteht darin, dass man die partiellen Ableitungen $\frac{\partial C}{\partial z^l_j}$ der Kostenfunktion C bezueglich den gewichteten Summen z^l_j aller Schichten berechnet. Daraus laesst sich dann spaeter sehr einfach die partiellen Ableitungen bezueglich den Gewichten $\frac{\partial C}{\partial w^l_{j,k}}$ und bezueglich den Neigung $\frac{\partial C}{\partial b^l_j}$ berechnen.

Zur Uebersichtlichkeit definiert man einen **Fehler** δ^L_j fuer jedes j-te Neuron in jeder l-ten Schicht, welcher die partielle Ableitung bezueglich der gewichteten Summe ist (siehe Gl. (**??**).

Ebenfalls definiert man analog einen Fehlervektor $\boldsymbol{\delta}^l$, welcher alle Fehler δ_j^l einer Schicht l zusammenfasst (siehe Gl. (BP0a)). Nun heisst es diesen fuer jedes Neuron jeder Schicht zu berechnen.

$$\delta_j^l := \frac{\partial C}{\partial z_j^l} \tag{BP0}$$

$$\boldsymbol{\delta}^l := \begin{pmatrix} \frac{\partial C}{\partial z_1^l} & \frac{\partial C}{\partial z_2^l} & \cdots & \frac{\partial C}{\partial z_{|l|}^l} \end{pmatrix}^\mathsf{T} \tag{BP0a}$$

Da die Kostenfunktion unmittelbar auf die letzte Schicht L angewandt wird, beginnt man auch dort mit der Berechnung des Fehlers $\boldsymbol{\delta}^L$. Wir stellen nun einen Computation Graph auf, um die partiellen Ableitungen zu bilden.

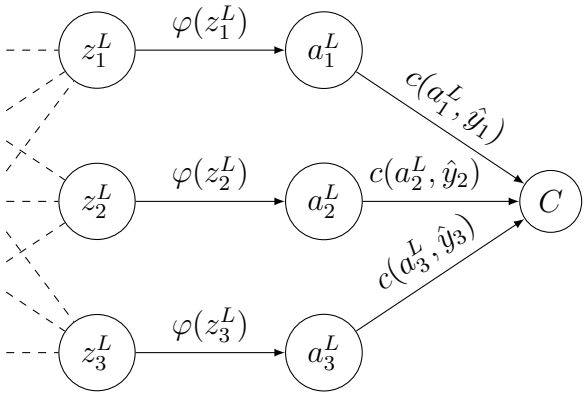

Abbildung 2.12: Computation Graph zur Berechnung von $\boldsymbol{\delta}^L$

Wir koennen dem Computation Graph aus Abbildung (2.12) entnehmen, dass die Kosten C eine Funktion in Abhaengigkeit von den letzten Aktivierungen a_j^L ist, welche wiederum in Abhaengigkeit von der jeweiligen gewichteten Summe z_j^L berechnet werden. Somit koennen wir mithilfe der Kettenregel die Beziehung (2.4) aufstellen.

$$\delta_j^L = \frac{\partial C}{\partial z_j^L} = \frac{\partial C}{\partial a_j^L} \cdot \frac{\partial a_j^L}{\partial z_j^L} \tag{2.4}$$

Da a_j^L durch die Anwendung der Aktivierungsfunktion φ auf z_j^L gebildet wird, ist $\frac{\partial a_j^L}{\partial z_j^L}$ einfach die Ableitung der Aktivierungsfunktion $\varphi'(z_j^L)$. Somit erhalten wir die erste (BP1) von vier wichtigen Gleichungen fuer die Rueckwaertsprogagierung.

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \cdot \varphi'(z_j^L) \tag{BP1}$$

Nun moechten wir diese Ausdruecke wieder in Matrixschreibweise realisieren, welche die ganze Schicht L zusammenfasst. Dazu muss eine neue Operation eingefuehrt werden: das Hadamard-Produkt.

Hadamard-Produkt

Das Hadamard-Produkt (auch elementweises Produkt) ist ein spezielles Produkt zweier gleichgrossen Matrizen $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ und $\boldsymbol{B} \in \mathbb{R}^{m\times n}$. Die resultierende Matrix ergibt sich aus der elementweisen Multiplikation der Ausgangsmatrizen.

$$\boldsymbol{A}\odot\boldsymbol{B} = \begin{pmatrix} A_{1,1}B_{1,1} & \cdots & A_{1,n}B_{1,n} \\ \vdots & \ddots & \vdots \\ A_{m,1}B_{m,1} & \cdots & A_{m,n}B_{m,n} \end{pmatrix} \in \mathbb{R}^{m\times n} \qquad \boldsymbol{v}\odot\boldsymbol{w} = \begin{pmatrix} v_1w_1 \\ \vdots \\ v_nw_n \end{pmatrix}$$

Mit $\boldsymbol{\varphi}'$ als die vektorisierte Ableitung der Aktivierungsfunktion, koenne wir den Fehlervektor der letzten Schicht nach Gleichung (2.5) berechnen.

$$\boldsymbol{\delta}^L = \begin{pmatrix} \frac{\partial C}{\partial a_1^L} & \frac{\partial C}{\partial a_2^L} & \cdots & \frac{\partial C}{\partial a_{|L|}^L} \end{pmatrix}^{\mathsf{T}} \odot \boldsymbol{\varphi}'(\boldsymbol{z}^L) \tag{2.5}$$

Dabei ist der erste Operand des Hadamard-Produkt, nichts anderes als der Gradient $\boldsymbol{\nabla}_{\boldsymbol{a}^L}C$ der Kostenfunktion C bezueglich dem Aktivierungsvektor $\boldsymbol{a}^L$ der letzten Schicht. Dieser Gradient kann einfach berechnet werden, indem man die vektorisierte Ableitungsfunktion fuer die gewaehlte Kostenfunktion bildet. Wuerde man die Mittlere quadratischen Abweichung $C = \frac{1}{2}(\hat{\boldsymbol{y}} - \boldsymbol{a}^L)^2$ als Kostenfunktion waehlen, haetten wir $\boldsymbol{\nabla}_{\boldsymbol{a}^L}C = (\boldsymbol{a}^L - \hat{\boldsymbol{y}})$.

Daraus folgt die kompakte matrix-version (BP1a) der Gleichung (BP1), welche den Fehlervektor fuer die letzte Schicht berechnet.

$$\boldsymbol{\delta}^L = \boldsymbol{\nabla}_{\boldsymbol{a}^L}C \odot \boldsymbol{\varphi}'(\boldsymbol{z}^L) \tag{BP1a}$$

Nun muessen wir eine rekursive Berechnungsmethode des Fehlers δ_j^{l-1} der vorherigen Schicht anhand des Fehlers δ_j^l der jetztigen Schicht erarbeiten. Dafuer stellen wir zuallererst wieder einen Computation Graph auf (siehe Abb. (2.13)).

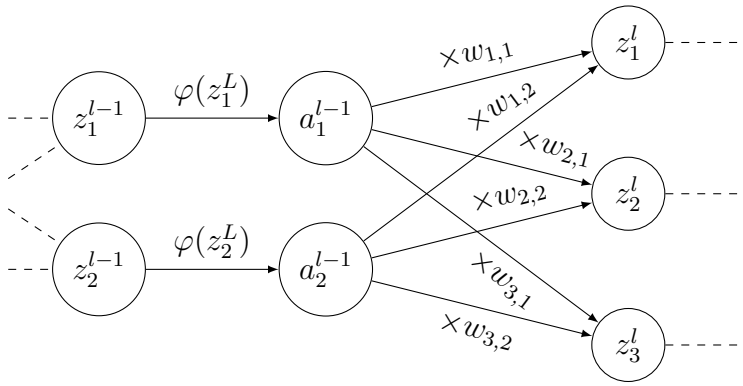

Abbildung 2.13: Computation Graph zur Berechnung von δ_j^{l-1}

Es gilt erneut die Gleichung (2.4) fuer die Berechnung des Fehlers δ_j^{l-1}.

$$\delta_j^{l-1} = \frac{\partial C}{\partial z_j^{l-1}} = \frac{\partial a_j^{l-1}}{\partial z_j^{l-1}} \cdot \frac{\partial C}{\partial a_j^{l-1}} \tag{2.4}$$

Zuerst einmal ist der erste Faktor wieder die Ableitung $\varphi'(z_j^{l-1})$ der Aktiverungsfunktion. Desweiteren beinflusst beim Uebergang der Schicht $(l-1)$ zur Schicht l eine Aktivierungen a_j^{l-1} alle gewichtete Summen z_k^l. Mit der Kettenregel folgt daher dass die partielle Ableitung $\dfrac{\partial C}{\partial a_j^{l-1}}$ die Summe aller $\dfrac{\partial C}{\partial z_k^l} \cdot \dfrac{\partial z_k^L}{\partial a_j^{l-1}}$ sein muss. Wir erhalten Gleichung (2.6).

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\frac{\partial C}{\partial z_k^l} \cdot \frac{\partial z_k^l}{\partial a_j^{l-1}} \right) \tag{2.6}$$

Um die gewichtete Summe z_k^l zu bilden, multipliziert man einfach die Aktivierung $a_j^{l=1}$ der vorherigen Schichten mit dem entsprechenden Gewichte $w_{k,j}^{l-1}$. Dadurch ist diese partielle Ableitung $\dfrac{\partial z_k^l}{\partial a_j^{l-1}}$ gerade das Gewicht selbst. Desweiteren ist $\dfrac{\partial C}{\partial z_k^l}$ per Definition der Fehler δ_k^l. Mit dieser Erkenntnis erhalten wir die zweite essentielle Gleichung (BP2) fuer die Rueckwaertsprogagierung.

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\delta_k^l \cdot w_{k,j}^{l-1} \right) \tag{BP2}$$

Auch diese Gleichung haetten wir gerne in der Matrixschreibweise. Wir beginnen mit der Erweiterung auf alle gewichteten Summen.

$$\boldsymbol{\delta}^{l-1} = \boldsymbol{\varphi}'(\boldsymbol{z}^{l-1}) \odot \begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|} \cdot \delta_k^l \end{pmatrix}^{\mathsf{T}}$$

Der zweite Operant des Hadamard-Produkts ist hierbei gerade das Produkt der Matrixmultiplikation zwischen der transponierten Gewichtsmatrix $(\boldsymbol{W}^{l-1})^{\mathsf{T}}$ der Schicht $(l-1)$ und dem Fehlervektor $\boldsymbol{\delta}^l$ der Schicht l (ersichtlich in folgender Gleichung).

$$\begin{aligned}
\begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|} \cdot \delta_k^l \end{pmatrix}^{\mathsf{T}} &= \begin{pmatrix} w_{1,1}^{l-1} & w_{2,1}^{l-1} & \cdots & w_{|l|,1}^{l-1} \\ w_{1,2}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{|l|,2}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1,|l-1|}^{l-1} & w_{2,|l-1|}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix} \begin{pmatrix} \delta_1^l & \cdots & \delta_{|l|}^l \end{pmatrix}^{\mathsf{T}} \\
&= \begin{pmatrix} w_{1,1}^{l-1} & w_{1,2}^{l-1} & \cdots & w_{1,|l-1|}^{l-1} \\ w_{2,1}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{2,|l-1|}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{|l|,1}^{l-1} & w_{|l|,2}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix}^{\mathsf{T}} \boldsymbol{\delta}^l = (\boldsymbol{W}^{l-1})^{\mathsf{T}} \boldsymbol{\delta}^l
\end{aligned}$$

Nun haben wir unsere rekursive Fehlerdefinition in Matrixschreibweise und somit die kompakte Version (BP2a) der zweiten wichtigen Formel (BP2).

$$\boldsymbol{\delta}^{l-1} = ((\boldsymbol{W}^{l-1})^{\mathsf{T}} \boldsymbol{\delta}^l) \odot \boldsymbol{\varphi}'(\boldsymbol{z}^{l-1}) \tag{BP2a}$$

In einem letzten Schritt muessen wir jetzt noch Formeln herleiten, mit welchen man anhand des Fehlers δ_j^l die partiellen Ableitungen der Gewichte und der Neigung berechnen kann.

Eine Neigung b_j^l ist Funktionsbestandteil der entsprechenden gewichteten Summe z_j^{l+1}. Somit gilt fuer die Neigung Formel (2.7).

$$\frac{\partial C}{\partial b_j^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial b_k^l} \tag{2.7}$$

Der erste Term ist hierbei per Definition unser Fehler δ_j^l und der zweite Term laesst sich zu 1 evaluieren, da die Summe z_k^{l+1} nur aus b_k^l besteht und aus Summanden, welche fuer die partielle Ableitung als konstant gelten. Somit ist die Ableitung der Neigung gerade unser Fehler und wir erhalten die dritte (BP3) von vier essentielen Gleichungen.

$$\frac{\partial C}{\partial b_j^l} = \delta_j^l \tag{BP3}$$

Somit ist der Kostengradient bezuglich der Neigung gerade der Fehlervektor (siehe Gl. (BP3a)).

$$\boldsymbol{\nabla}_{\boldsymbol{b}^l} C = \boldsymbol{\delta}^l \tag{BP3a}$$

Ein Gewicht $w_{j,k}^l$ ist ebenfalls ein Funktionsbestandteil der assozierten gewichteten Summe z_j^{l+1}. Dadurch gilt fuer die partiellen Ableitungen der kosten nach dem Gewicht Gleichung (2.8).

$$\frac{\partial C}{\partial w_{j,k}^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial w_{j,k}^l} \tag{2.8}$$

Dabei laesst sich der erste Teil wieder zum Fehler δ_j^{l+1} evaluieren. Die zweite partielle Ableitung ist gerade die Aktivierung a_k^l, da sich die gewichtete Summe aus der Multiplikation des Gewichtets mit der Aktivierung ergibt. Somit erhalten wir die letzte der vier essentielen Gleichungen (BP4).

$$\frac{\partial C}{\partial w_{j,k}^l} = \delta_j^{l+1} \cdot a_k^l \tag{BP4}$$

Die matrix-version davon ist Gleichung (BP4a).

$$\boldsymbol{\nabla}_{\boldsymbol{W}^l} C = \boldsymbol{\delta}^{l+1} (\boldsymbol{a}^l)^\mathsf{T} \tag{BP4a}$$

(Nielsen, *Neural Networks and Deep Learning*)

2.7 Universal Approximation Theorem?

Neural Network kann alles erlernen

2.8 Vanishing Gradient Problem

Gleichung BP1 sagt uns, dass der Lernprozess langsam ist, falls φ fast 0 oder 1 ist. Sigmoid. Das Neuron ist saturiert und lernt nicht mehr. In letzter Schicht

2.8.1 Kreuzentropie-Kostenfunktion

2.8.2 ReLU

Kapitel 3

Convolutional Neural Networks

Viele Anwendungen von Machine Learning sind verbunden mit Bild- oder Audioverarbeitung, wie z.B Bildklassifizierung, Gesichtserkennung oder Spracherkennung. Vorallem aber fuer hochaufloesende Bilder sind die KNNs, die wir soeben kennengelernt haben, nicht geeignet. Sie sind zum Teil gar nicht in der Lage eine Korrelation zwischen den Inputs und Outputs zu erlernen. Um diesen Umstand zu erklaeren, wird nun ein kleines Beispielmodell erlauetert:

Es soll ein KNN designed werden, welches eine Photographie klassifizieren soll, ob darauf ein Hund sichtbar ist oder nicht. Wir nehmen fuer dieses Gedankenexperiment bereits ein relativ niedrig aufgeloestes Bild mit 256×256 Pixel, dies entspricht weniger als 0.07 Megapixel (ein iPhone XS hat eine Kamera mit 12 Megapixel). Um die verschiedenen Farben zu codieren besitzt jeder Pixel drei Komponten R, G und B. Somit hat dieses Bild insgesamt $256 \times 256 \times 3 = 196'608$ Komponenten. Jede Komponente ist ein Feature welches das KNN zu verrechnen hat. Somit bestuende die erste Schicht des Netzwerkes aus fast $200'000$ Neuronen. Um diese Schicht nun mit seiner Nachbarsschicht, welche gleiche Dimensionen besitzt, zu verbinden, braucht es $196'608 \times 196'608 = 38'654'705'664$ Verbindungen und damit gleich so viele Gewichte! Fuer ein Netwerke ohne eine einzige Zwischenschichten gaebe es also ueber 38 Milliarden Modellparameter zu erlernen! Das dies nicht realistisch ist, sollte auf der Hand liegen.

Nicht nur die Anzahl Modellparameter sind ein Problem fuer KNNs in der Bildverarbeitung, sondern es bestehen noch weiter Probleme. Trotzdem sollte nun klar sein, dass eine andere Modellarchitektur noetig ist, um Machine Learning auf Bilder anzuwenden. Fuer genau solche Anwendungen wurde eine modifizierte Version eines KNNs entwickelt: das **Convolutional Neural Network** (CNN). Im Allgemeinen sind CNNs immer dann geeignet, wenn es Daten zu verarbeiten gibt, welche eine rasterartige Form haben, wie eben z.B Bilder. Diese Art von Netzwerk, macht Gebrauch von Konzepten aus der klassischen Bildverarbeitung, wie sie mit beispielsweise Photoshop gemacht werden kann. Wie beim Perzeptron und bei den klassischen KNNs auch, ist die Architektur biologisch inspiriert. Der folgende Abschnitt wird die Funktionsweise eines solchen CNNs erklaeren.

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.1 Bilder als Tensoren

CNNs operieren an Bildern. Sie stellen den Input fuer die Modelle dar. Um mit diesen Bildern rechnen zu koennen, ist es sinnvoll sie als sogennante **Tensoren** vom Rang 3 zu untersuchen,

anstatt sie als Anordnungen von Pixeln zu betrachten.
Um zu verstehen, was ein Tensor dritten Ranges ist, muessen wir zuerst verstehen, was ein Tensor im Allgemeinen ist.

Tensor

Ein Tensor $\mathbf{T}$ ist eine Verallgemeinerung von Skalaren, Vektoren und Matrizen auf n Dimensionen. Es handelt sich wie bei Matrizen um eine Zahlenanordnung. Dabei wird die Anzahl Dimensionen, innerhalb welchen die Zahlen liegen als Rang oder Stufe n des Tensors bezeichnet. Vorstellen kann man sich einen Tensor als ein Hyperrechteck mit n Dimensionen, innerhalb dessen die Zahlen in einem Raster angeordnet sind. Diese Zahlen sind die Elemente des Tensors. Ein Tensor nullten Ranges ist ein Skalar, einer erster Stufe ein Vektor und einer mit Rang 2 ist eine normale Matrix.

$$1 \in \mathbb{R} \text{ (Skalar)} \quad \begin{pmatrix} 1 & 2 & 3 \end{pmatrix} \in \mathbb{R}^3 \text{ (Vektor)} \quad \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \in \mathbb{R}^{2\times 3} \text{ (Matrix)}$$

Tensor 3. Ranges

Ein Tensor $\mathbf{T} \in \mathbb{R}^{h\times w\times d}$ mit Rang 3 ist eine 3-dimensionale Zahlenanordnung. Man kann sich diesen Tensor einfach als eine 3D-Matrix vorstellen; ein Volumen innerhalb dessen Zahlen in einem Raster angeordet sind. Analog zum Volumen, bezeichnet man die Form des Tensors mit Hoehe, Breite und Tiefe.
Ein Tensor von der Form $\mathbb{R}^{3\times 2\times 3}$ koennte folgendermassen aussehen:

$$\mathbf{T} = \begin{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} \end{pmatrix} \in \mathbb{R}^{3\times 2\times 3}$$

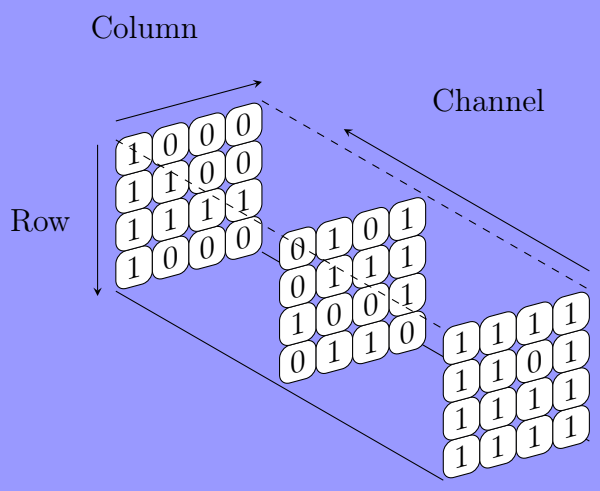

Ein Bild kann somit einfach als Tensor dritten Ranges $\mathbf{B} \in \mathbb{R}^{h\times w\times c}$, der Form (Bildhoehe $\times$ Bildbreite $\times$ Anzahl Farbkomponenten) betrachtet werden. Elemente der Matrix nehmen dann einfach die Werte der Pixelkomponenten an. Ein schwarzweiss Bild hat nur eine Komponente, welche die Helligkeit angibt. Somit waere es eine normale 2D-Matrix $\boldsymbol{B} \in \mathbb{R}^{h\times w}$ (siehe Abb. (3.1)).

Abbildung 3.1: Beispiel einer Bildmatrix

3.2 Topologie von CNNs

Ein CNN besteht, wie ein KNN auch, aus Schichten. Jede dieser Schichten erhaelt als Input ein Bild und hat auch wieder eines als Output.
Ein wichtiger Unterschied eines CNNs ist, dass es aus unterschiedlichen Typen von Schichten besteht. Man unterscheiden zwischen drei Arten von Schichten:

- **Fully-connected-Schichten**,
- **Convolutional-Schichten**,
- **Pooling-Schichten**, und
- **Upsampling-Schichten**.

Die fully-connected-Schicht ist altbekannt und ist einfach die klassische Schicht eines KNNs, bestehend aus Neuronen.
Die Convolutional-Schicht ist eine neuartige Schicht, welche es im KNN nicht gibt. Sie ist die Schicht, welche fuer das Training relevant ist, da sie die Modellparameter beinhalten. Sie extrahiert die relevanten Features aus den Inputbildern und lernt so die Bilder zu verstehen.
Die Pooling-Schicht, wie auch die Upsampling-Schicht beinhalten keine Modellparameter und sind fuer das Training deshalb nicht direkt relevant. Diese Schichten werden lediglich gebraucht um die verarbeiteten Bilder neu zu skalieren. Dies ist sinnvoll, da durch die Extraktion gewisser Featurse, die restlichen Features wegfallen. Somit muss weniger Information pro Bild gehalten werden und die Bilder sollten schrumpfen um Overfitting vorzubeugen. Die Pooling- Schichten reduzieren die Bilder und die Upsampling-Schichten erweitern die Bilder um mehr Pixel. Dies wird in Sektion (4) fuer die Autoencoder hilfreich werden.
Grundsaetzlich folgt auf eine Convolutional-Schicht immer entweder eine Pooling- oder eine Upsampling-Schicht. Somit bilden sie gewissermassen eine Einheit.

In Abbildung (3.2) ist ein Schema eines CNNs abbgebildet.

Abbildung 3.2: Schichtung eines CNNs

3.3 Convolutional-Schichten und Filter

Zuerst betrachten wir die Convolutional Schicht. Diese Schicht macht ausgiebig Gebrauch von sogennanten Filtern. Diese werden in diesem Abschnitt behandelt.

3.3.1 Filter in der Bildverarbeitung

Filter (auch Kerne) sind in der Bildverarbeitung sehr verbreitet. Jeder kennt sie entweder von Photoshop, von Instagram oder sonstigen Bildbearbeitungsprogrammen. Auch CNNs machen Gebrauch von solchen Filtern, in diesem Fall um die Features eines Bildes zu erlernen.

Ein Filter ist einfach eine Regionen, deutlich kleiner als das verarbeitete Bild $\mathbf{B}$, welche ueber alle Pixel wandert, diese manipuliert und so wieder ein neues Bild $\tilde{\mathbf{B}}$ liefert. Mathematisch

Abbildung 3.3: der Instagramfilter: Blablabla

gesehen handelt es sich bei einem Filter einfach um einen Tensor, den sogennanten **Filtertensor F** oder Faltungstensor (siehe Abb. (3.4)). Solche Filter sind immer quadratisch, wobei ihre Zeilen- und Spaltenlaenge mit f bezeichnet wird. Dabei ist f immer eine ungerade Zahl, damit ein Element, der sogennante **Zentralelement** (engl.: Center element), bezeichnet mit $(\mathbf{F})_C$, immer im Zentrum des Filters liegt.

Abbildung 3.4: eine 2D-Filtermatrix

Das Verhalten des Filters wird durch seine Matrixeintraege bestimmt. Die Elemente koennen also so gewaehlt werden, dass wenn der Filter auf ein Bild angewandt wird, er bestimmte Features aus dem Bild hervorhebt. Solche Features koennten zum Beispiel Raender oder Kanten sein, welche betont werden.

Ein gutes Beispiel ist der Sobel-Filter. Er ist ein typischer 2D-Kantendetektions-Filter mit einer Groesse von $f = 3$. Wir betrachten nun den Sobelfilter $\boldsymbol{G}_x$, welcher horizontale Kanten akzentuiert. Die Eintraege dieses Filters lauten wie folgt:

$$\boldsymbol{G}_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}$$

Angewandt auf ein schwarz-weisses Bild $\boldsymbol{B}$, erhaelt man ein neues Bild, bei welchem alle erkannten Katen weiss eingefaerbt sind und die restlichen Bereiche schwarz sind. Der Filter erkennt dabei jede Stelle als Kante, welche zwei Regionen mit genug grossem Kontrast voneinander trennt. In Abbildung (3.5) wurde der horizontale Sobelfilter auf ein Beispielbild angewandt. Links ist das Ursprungsbild und rechts ist das prozessierte Bild.

Abbildung 3.5: Sobel-Filter angewandt auf Beispielsbild

(Mehrere, *Sobel operator — Wikipedia, The Free Encyclopedia*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Kernel (image processing) — Wikipedia, The Free Encyclopedia*)

3.3.2 Filter in CNNs

Aus diktaktischen Gruenden betrachten wir nun zuerst nur 2D-Filter, welche sich fuer graustufige Bilder $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ eignen. Somit ist der hierfuer geeignete Filter einfach eine 2D-Matrix, bezeichnet mit $\boldsymbol{F} \in \mathbb{R}^{f \times f}$. Man bedenkte bei jeder Filtermatrix einfach immer, dass es sich eigentlich im Allgemeinen Fall um einen 3D-Tensor handelt.

Wie wir vorhin erfahren haben, koennen Filter genutzt werden um gewisse Features eines Bildes hervorzuheben und andere Features zu ignorieren. Dabei bestimmen die Filtereintraege, welche Features extrahiert werden. Somit bestimmt die Aufgabe darin, die richtigen Filtereintraege zu bestimmen, damit die gewuenschten Features erkannt werden und auf die gewuenschten Outputs abgebildet werden. Naheliegend sollte jetzt der Gedanke sein, die Filtereintreage als

die Modellparameter eines CNNs zu definieren. Mithilfe des Gradietenverfahrens sollten erneut diese Parameter erlernt werden.
Da die Filter die gleiche Funktion haben, wie die Gewichte in einem KNN, bezeichnet man die Filter in einem CNN mit $\mathbf{W}$. Die Groesse des Filters stellt dabei einene Hyperparameter dar.

$$\boldsymbol{W} = \begin{pmatrix} w_{1,1} & \cdots & w_{1,f} \\ \vdots & \ddots & \vdots \\ w_{f,1} & \cdots & w_{f,f} \end{pmatrix}$$

3.3.3 Filteroperation intutitiv

Wie wendet man nun einen solchen Filter auf ein Bild an? Um das Prozedere einer Filteroperation leichter verstaendlich zu machen, wird sie erneut fuer ein graustufiges Bild $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ erlauetert. Spaeter werden auch noch farbige Bilder erklaert.

Bei einer Filteroperation, wendet man einen Filter $\mathbf{W}$ auf eine Bildtensor $\mathbf{B}$ an und erhaelt so ein neues Bild $\tilde{\mathbf{B}}$. Man schreibt dafuer: $\tilde{\mathbf{B}} = \mathbf{W} * \mathbf{B}$.

Um nun diese Operation zu erklaeren, verwenden wir als Beispiel eine 2D-Filtermatrix $\boldsymbol{W} \in \mathbb{R}^{3\times3}$, bei welcher $f = 3$ gewaehlt wurde. Wie bereits vorhin erwaehnt wandert der Filter ueber das Bild. Dabei befindet sich der Filter immer ueber einer Region des Bilder, welche gleich gross ist, wie der Filter selber (in diesem Fall (3×3)), so dass den Filtermatrixeintraegen immer eindeutig Bildmatrixeintraege entsprechen. Diese Region des Bildes bezeichnet man als das **Rezeptive Feld** des Filters (siehe Abb. (3.6)). Das Zentralelement $(\mathbf{W})_c$ liegt dann gerade ueber dem sogennanten **Quellenpixel** (engl.: source pixel), bezeichnet mit $(\mathbf{B})_S$. Um das Rezeptive Feld zu kennzeichnen, bezeichnen wir es mit $\hat{\boldsymbol{B}}^{(y,x)}$, wobei die hochgestellten Indizes (y, x) die Position des Quellenpixel $(\boldsymbol{B})_S$ im Bild $\boldsymbol{B}$ angiebt. Somit ist das rezeptiven Feld einfach eine Untermatrix $\tilde{\boldsymbol{B}} \in \mathbb{R}^{3\times3}$ des Obermatrix $\boldsymbol{B}$.

Abbildung 3.6: ein Filter und sein rezeptives Feld

Der Filter beginnt nun oben links ueber das Bild zu wandern. Somit hat der Filter zu beginn das rezeptive Feld $\hat{\boldsymbol{B}}^{(2,2)}$, denn der Filter darf nicht ueber die Raender des Bildes hinausragen. Nun werden die Elemente der Filters mit den Elementen des rezeptiven Feldes verrechnet, welche die gleichen Dimensionen besitzen. Dabei wird einfach das Hadamard-Produkt (das elementweise Produkt) des beiden Matrizen miteinander gebildet. Nun erhalten wir eine neue Matrix $\boldsymbol{W} \odot \hat{\boldsymbol{B}}^{(2,2)} = \boldsymbol{P} \in \mathbb{R}^{3\times3}$. Nun werden noch alle Elemente der neuen Matrix $\boldsymbol{P}$ aufsummiert. Diese Zahl ist dann der Grauwert des ersten Pixels $(\tilde{\boldsymbol{B}})_{1,1}$ des bearbeiteten Bildes (siehe Gl. (3.1)). In diesem Sinne stellt der Filter eine Gewichtung der Nachbarspixel dar, welche bestimmt, wie die neuen Pixel aussehen.

$$(\tilde{\boldsymbol{B}})_{1,1} = \sum_{y=1}^{3} \sum_{x=1}^{3} (\boldsymbol{P})_{y,x} \tag{3.1}$$

Nun wird der Filter um ein Element nach rechts verschoben und die gleiche Prozedur angewendet, um den zweiten Pixel zu berechnen. Dies wird durchgezogen, bis eine ganze Zeile der Bildmatrix durchstreift wurde. Danach wird der Filter wieder nach ganz rechts verschoben und er bewegt sich ein Element nach unten. Das geschieht, bis das ganze Bild verrechnet wurde. Dabei werden die Elemente des urspruenglichen Bildes durchaus mehrmals verrechnet, da es zu einer Ueberlappung des vorherigen Filter und des verschobenen Filters kommt.

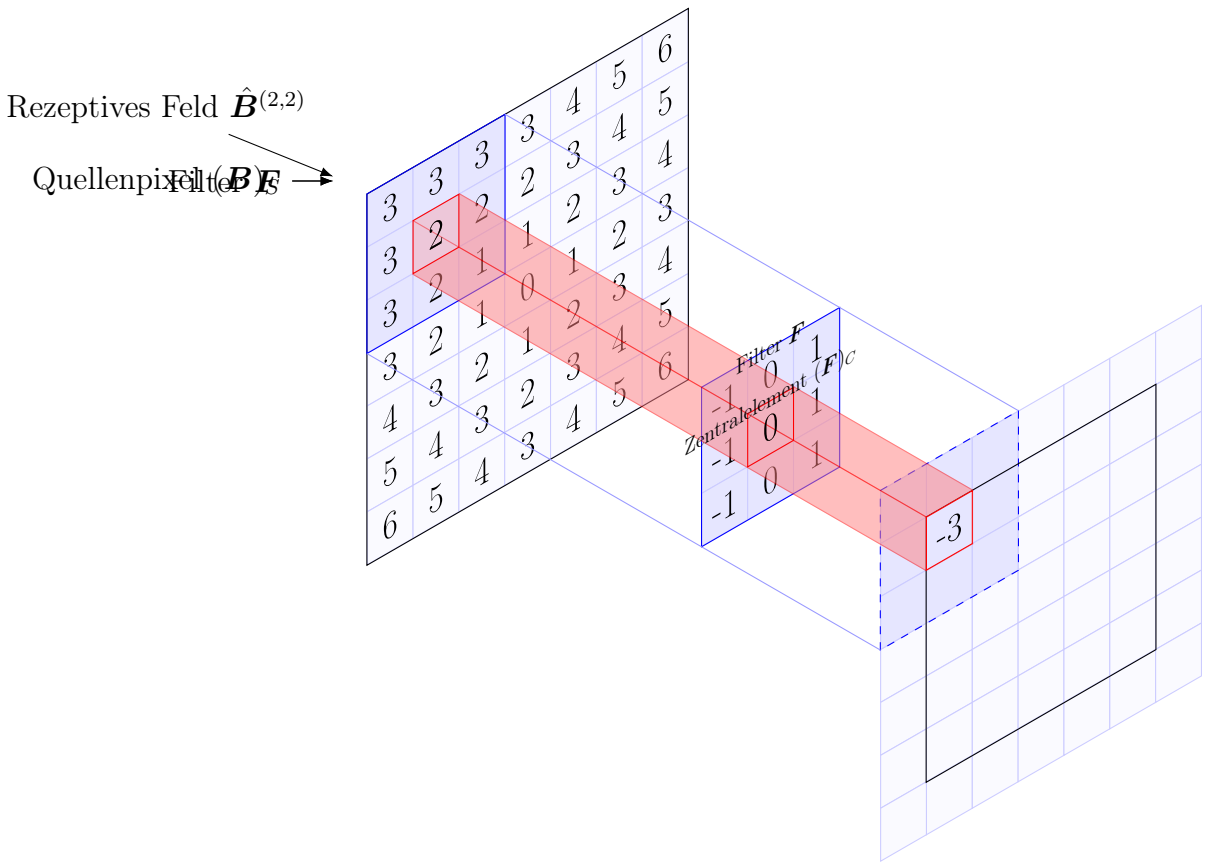

Abbildung 3.7: Schema, wie ein Filter ueber ein Bild laueft

Es ist zu bemerken, dass das neue Bild $\tilde{\boldsymbol{B}} \in \mathbb{R}^{(h-2)\times(w-2)}$ nicht mehr die gleichen Masse hat, wie das Ursprungsbild $\boldsymbol{B} \in \mathbb{R}^{h\times w}$. Das liegt daran, dass pro Lage des Filters jeweils nur ein Pixel des neuen Bildes berechnet wird. Man kann sich vorstellen, dass an der Position des Quellenpixel jeweils ein neuer Pixel entsteht. Dabei muss der Filter immer eine vollstaendige Region als rezeptives Feld haben. Dadurch kommt das Zentralelement nie auf den Raendern des Bilds zu liegen. Somit fallen diese weg.

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolution— Wikipedia, The Free Encyclopedia*)

3.3.4 Filteroperationen als diskrete Faltungen

Eigentlich handelt es sich bei einer Anwendung eines Filters auf ein Bild um eine spezifische mathematische Operation: eine **diskrete Faltung** (engl.: **Convolution**). Daher ruehrt auch der Name des Convolutional Neural Networks. Wir werden die Faltung als mathematische Operation nicht im vollen Umfang betrachten, da sie relativ kompliziert ist. Wir werden uns lediglich auf die Bedeutung der Faltung fuer Filter beschraenken. Damit ihr die Defintion trotzdem mal gesehen habt:

$$(f * g)(x) = \int_{-\infty}^{\infty} f(\tau)g(x-\tau)\mathrm{d}\tau \tag{3.2}$$

Streng genommen wird in CNNs nicht eine diskrete Faltung durchgefuehrt, sondern eine sogennante **Kreuzkorrelation**. Der Unterschied dabei ist, dass bei einer Kreuzkorrelation die

Faltungsmatrix nicht zuerst horizontal, wie auch vertikal gespiegelt wird, im Gegensatz zu der eigentlichen Faltung. Jedoch verwendet man begrifflich das Wort Faltung fuer beide Operationen. Im Verlauf dieser Arbeit wird mit dem Wort Faltung immer die Kreuzkorrelation gemeint sein.

Mithilfe der Faltungsoperation koennen wir die Schritte welche in Sektion (3.3.3) erklaert wurden zusammenfassen. Bei der Filteroperation handlet es sich lediglich um eine diskrete Faltung des Filtertensors $\mathbf{W}$ ueber den Bildtensor $\mathbf{B}$. Somit koennen wir folgende Formel verwenden um einen Pixel $\tilde{\boldsymbol{B}}(x, y)$ des neuen Bildes zu berechnen.

$$\tilde{\boldsymbol{B}}_{y,x} = (\boldsymbol{W} * \boldsymbol{B})_{y,x} = \sum_{v=0}^{f-1} \sum_{u=0}^{f-1} \boldsymbol{W}_{v,u} \boldsymbol{B}_{y+v,x+u} \tag{3.3}$$

Fuer farbige Bilder ist das Vorgehen praktisch das selbe. Es werden nun lediglich 3D-Tensoren anstatt 2D-Tensoren verwendet. Wir betrachten den allgemeinen Bildtensor $\mathbf{B}_{h \times w \times c}$, wobei c die Anzahl Farbkomponenten (engl.: channels) ist. Nun benutzt man einen Filter $\mathbf{W}_{f \times f \times c}$ mit beliebiger Groesse f aber mit der gleicher Tiefe c wie das Ursprungsbild $\boldsymbol{B}$. Dadruch muss der Filter nicht entlang der Tiefe des Bildes wandern, da er gerade gleich tief ist, wie das Bild. Das hat zur Folge, dass das verarbeitete Bild $\tilde{\boldsymbol{B}}$ immer eine 2D-Matrix ist. Die allgemeine Filtergleichung lautet:

$$\tilde{\boldsymbol{B}}_{y,x} = (\mathbf{W} * \mathbf{B})_{y,x} = \sum_{v=0}^{f-1} \sum_{u=0}^{f-1} \sum_{w=0}^{c} \mathbf{W}_{v,u,w} \mathbf{B}_{x+u,y+v,w} \tag{FO}$$

3.3.5 Mehrere Filter

Eine Filteroperation ist nicht auf einen einzigen Filter beschraenkt. Es koennen mehrere Filter auf das gleiche Ausgangsbild angewandt werden und zusammen ein Endbild erzeugen.

Die Anzahl Filter bezeichnen wir mit c. Nun macht man pro Filter $\mathbf{F}_i$ eine Faltung ueber das Ursprungsbild $\mathbf{B}$, wobei jede Faltung einen neue Matrix $\tilde{\boldsymbol{B}}_i = \mathbf{F}_i * \mathbf{B}$ liefert, wobei i der Index des Filters ist. All diese gefalteten Bilder $\boldsymbol{B}*_i$ sind zweidimensionale Matrizen, unabhaengig davon, wieviel Komponten das Ursprungsbild hatte. Aus diesem Grund koennen die einzelnen Matrizen $\tilde{\boldsymbol{B}}_i$ aufeinander gelegt werden und somit einen grossen 3D-Endtensor $\tilde{\mathbf{B}}$ bilden. Hierfuer muessen alle Filter $\mathbf{F}_i$ gleich gross sein. Die Tiefe des neuen Bildes $\tilde{\mathbf{B}}$ ist jetzt gerade die Anzahl Filter

Abbildung 3.8: aufeinander gelegte gefaltene Bilder

c. Wir haben bereits frueher immer die Tiefe des Bildes (bzw. die Anzahl Farbkomponenten) mit c bezeichnet. Somit ist c sowohl die Anzahl Filter einer Schicht, wie auch die Tiefe des verarbeiteten Bildes.

3.3.6 Padding

Wie bereits erwaehnt schrumpfen die Bilder (an den Raendern), wenn man einen Filter auf sie anwendet. Zur Erinnerung: Dies liegt daran, dass pro Lage des Zentralelement nur ein Pixel des neuen Bildes entsteht und das Zentralelement nunmal nicht auf allen Ursprungspixeln zu liegen kommt. Die Raender fallen so weg. Diese Groesse des Wegfalls haengt von der Filtergroesse f ab. Hierbei giltet folgende Formel fuer die neue Groesse n_1 des Bildes, anhand der alten Groesse n_0.

$$n_1 = n_0 - f + 1 \tag{3.4}$$

Das Problem hierbei ist, dass nach einigen Faltungen das Bild extrem geschrumpft ist und im Grenzfall kleiner als der Filter wird. Das darf natuerlich nicht passieren. Ausserdem kommt es dabei zu einem relativen Informationverlust an den Raender, da es im Innern des Bildes zu viel Ueberlappungen der Filterlagen kommt und es bei den Raendern nur seltener zur Ueberlappung kommt.

Diese Probleme werden mit sogennantem **Padding** behoben. Padding ist ein Schritt, welcher vor der eigentlichen Faltung stattfindet. Dabei werden einfach zusatzliche Raender (Zeilen und Spalten) an das Ursprungsbild angebracht. Der Tensor wird der Laenge und der Breite nach (nicht der Tiefe entlang!) an den Enden erweitert. Die neuen Elemente werden dabei auf den Wert 0 gesetzt.

Abbildung 3.9: Padding

Das Padding p ist eine Zahl, welche angibt wieviele Elemente an allen Raendern hinzugefuegt werden. Padding $p = 1$ bedeutet, dass an allen Kanten jeweils eine Reihe bzw. Spalte hinzugefuegt wird. Begrifflich unterscheidet man zwei Arten von Padding:

- **Valid-Padding**: Es werden keine zuesaezlichen Elemente angebracht. f ist also 0.
- **Same-Padding**: Es werden so viele Reihen und Spalten angebracht, dass die Groesse des Bildes nach der Faltung unveraendert bleibt.

Um Same-Padding durchzufuehren, muss man p so waehlen, dass es den Wegfall durch den Filter gerade kompensiert. Da durch das Padding das Bild der Laenge und Breite nach jeweils um zwei p laenger wird, erhaelt man den Ausdruck $n_1 = n_0 - f + 1 + 2p$. Wenn man diese Formel jetzt nach p aufloest, erhaelt man folgende Formel fuer das Waehlen des Valid-Paddings p.

$$p = \frac{f-1}{2} \tag{3.5}$$

3.3.7 Stride

Bis jetzt haben wir bei den Filterfaltungen, den Filter pro Anwendung immer nur um einen Pixel verschoben. Das muss aber nicht so sein. Man kann den Filter auch mit einer anderen Schrittgroesse verschieben. Diese Eigenschaft bezeichnet man als **Stride** s. Falls $s = 2$ gewaehlt wird, bedeutet das, dass der Filter sich pro Matrixmultiplikation um zwei Elemente bewegt. Somit wurde eine Position uebersprungen. Zur Folge hat dies, dass das neue Bild deutlich kleiner geworden ist, denn das Zentralelement uebspringt somit auch diese Felder und bildet so deutlich weniger Pixel.

Folgende Formel beschreibt die Dimensionen des neuen Bildes unter beruecksichtigung der Filtergroesse f, dem Padding p und dem Stride s.

$$n_1 = \frac{n_0 + 2p - f}{s} + 1 \tag{3.6}$$

3.3.8 Vorzuege von Filtern

Es stellt sich nun die Frage, weshalb sich Filter fuer Maschinelles Lernen mit Bildern eignen. Wie bereits erwaehnt besteht die Aufgabe von Filtern darin bestimmte Features eines Bildes

hervorzuheben und die restlichen auszublenden. Genau die gleiche Aufgabe erfuellen die Neuronen in einem KNN. Auch sie sollen Features der Inputsdaten erlernen, wobei gewisse Neuronen auf gewisse Features reagieren. Weshalb verwendet man also nicht einfach KNNs? (abgesehen von dem Problem mit der Ueberzahl an Modellparametern, siehe Sektion 3).

Man muss erkennen, dass Bilddaten sich deutlich von sonstigen Daten unterscheiden. Bildfeatures bzw. Pixel sind nur im Kontext von ihren Nachbarn relevant. Denn ein Pixel ist erst dann eine Kante oder eine Ecke, wenn er zwei verschiedene Farbregionen voneinander trennt. Oder ein Gegenstand wird erst durch eine ganzen Haufen von Pixeln und deren relative Position zueinander ausgezeichnet. Man bezeichnet diesen Umstand als **lokalisierte Features**.

Desweiteren sind Bildausschnitte nicht immer gleich orientiert. Wenn man ein Gesicht auf einem Bild erkennen moechte, sollte es aber keine Rolle spielen, wo auf dem Bild es sich befindet, welche Groesse es hat und was fuer eine Lage es hat. Um diese Eigenschaften irrelevant fuer das Modell zu machen, muss dieses gewisse **Invarianzen** erfuellen.

Die Eigenschaft, welche CNN geeignet macht fuer lokalisierte Features und solche Invarianzen, bezeichnet man als **Parameter-Sharing**. Sie bezeichnet den Umstand, dass auf mehrere oder alle Features die gleichen Modellparameter wirken. Bei CNNs wird dies durch die Bewegung der Filters bzw. seiner Eintraegen ueber (fast) alle Pixel bewerkstelligt. Somit ist es egal wo und wie sich die lokalisierten Features befinden. Dies fuehrt dann eben zu den gewuenschten Invarianzen: Translations-, Rotations- und Helligkeitsinvarianz.
Eine weiterer Vorteil durch dieses Parameter-Sharing ist, dass die Inputbilder beliebige Dimensionen besitzen koennen, da die Filter ihre Bewegung lediglich an die Groesse des Bildes anpassen muessen.

3.3.9 die Convolutional-Schicht

Nun moechten wir alles zusammentragen, was wir ueber Filter gelernt haben, um nun die Convolutional-Schicht zu definieren.

Beginnen tut eine Convolutional Schicht l mit seinem Input, also den Aktivierungen $\mathbf{A}^l \in \mathbb{R}^{h^l \times w^l \times c^l}$, welche die vorherigen Schicht $(l-1)$ produziert hat, oder falls es die erste Schicht ist erhaelt sie den Input $\mathbf{X}$ des Netzes, welchen man auch mit $\mathbf{A}^0$ bezeichnet.
Die Schicht besitzt c^l Varianten an Filtern $\mathbf{W}_i^l \in \mathbb{R}^{f^l \times f^l \times c^{l-1}}$. Diese Filter haben alle die gleichen Eigenschaften, bezueglich: der Groesse f^l, der Tiefe c^{l-1}, dem Padding p^l, dem Stride s^l. Sie unterscheiden sich nur in den Modellparametern $w^l_{i\,|\,\alpha,\beta,\gamma}$.

$$\mathbf{W^l}_i = \left[\begin{pmatrix} w^l_{i\,|\,1,1,1} & \cdots & w^l_{i\,|\,1,f,1} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,1} & \cdots & w^l_{i\,|\,f,f,1} \end{pmatrix} \overset{\text{Tiefe}}{\cdots} \begin{pmatrix} w^l_{i\,|\,1,1,c^l} & \cdots & w^l_{i\,|\,1,f,c^l} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,c^l} & \cdots & w^l_{i\,|\,f,f,c^l} \end{pmatrix} \right]$$

Nun wendet faltet man jeden Filter $\mathbf{W}_i^l$ einzeln ueber das Bilder $\mathbf{A}^l$ und erhaelt so mehrere neue 2D-Bilder $\tilde{\boldsymbol{A}}_i^l$.

$$\tilde{\boldsymbol{A}}_i^l = \mathbf{W}_i^l * \mathbf{A}^l \tag{3.7}$$

Die Faltung berechnet man nach folgender Gleichung:

$$\tilde{\boldsymbol{A}}^l_{i\,|\,y,x} = (\mathbf{W}_i^l * \mathbf{A}^l)_{y,x} = \sum_{v=0}^{f-1} \sum_{u=0}^{f-1} \sum_{w=0}^{c} \mathbf{W}^l_{i\,|\,v,u,w} \mathbf{A}^l_{x+u,y+v,w} \tag{FO}$$

Jede dieser Matrizen ist ein Querschnitt $\tilde{\boldsymbol{A}}^l_{:,:,i}$ entlang der Tiefe des neuen 3D-Tensors $\tilde{\boldsymbol{A}}^l \in \mathbb{R}^{h^{l+1} \times w^{l+1} \times c^l}$. Hierbei ist die Tiefe c^l gerade die Anzahl Filter c^l und die Hoehe h^{l+1} und die Breite w^{l+1} werden jeweils nach der folgenden Formel berchnet anhand der Hohe h^l und der Breite w^l des Ausgangsbild.

$$n_1 = \frac{n_0 + 2p - f}{s} + 1 \tag{3.8}$$

Da die Faltungsoperation eine lineare Operation, braucht man wieder eine Aktivierungsfunktion, um das Modell zu befaehigen nicht-lineare Probleme zu loesen. Deshalb wendet man in einem letzten Schritt die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf den Tensor $\tilde{\boldsymbol{A}}^l$ an und erhaelt so die neue Aktiverung der naechsten Schicht $\mathbf{A}^{l+1}$. Meistens waehlt man hier die ReLU-Aktiverungsfunktion $\boldsymbol{\varphi}^{ReLU}$.

$$\mathbf{A}^{l+1} = \boldsymbol{\varphi}(\tilde{\mathbf{A}}^l) \tag{3.9}$$

(Goodfellow, Bengio und Courville, *Deep Learning*)

3.4 Dimensionalitaetskontrolle

Beim Anwenden einer Convolutional Schicht gehen Informationen verloren, da nur die relevanten Features hervorgehoben werden und der Rest verworfen wird. Jedoch schrumpft das Bild entweder gar nicht (bei Same-Padding) oder es schrumpft nur sehr leicht (bei Valid-Padding). Dies ist ein Problem, da die Information in deutlich weniger Pixeln bzw. Tensorelementen codiert werden koennte. Deshalb haben wir einen unoetigen Ressourcenverbrauch und eine erhoehte Gefahr fuer Overfitting. Um diesem Problem entgegenzuwirken gibt es einerseits sogennante **Pooling-Schichten** und als Gegenstueck dazu **Upsampling-Schichten**. Ersteres wird verwendet um die Dimensionalitaet der Bilder zu vermindern und letzteres um die Dimensionalitaet der Bilder zu erweitern. Somit ermoeglich diese Schichten eine kontrollierte Art (im Gegensatz zum Padding) die Dimensionalitaet einzustellen.

3.4.1 die Pooling-Schicht

Die Pooling-Schicht verringert die Dimensionalitaet durch das Zusammenfassen eines Felds von Tensorelementen zu einem einzigen Tensorelement der naechsten Schicht erreicht. Dabei geht das Feld nur entlang der Laenge und Breite des Bildes und nicht entlang der Tiefe. Dies bedeutet, das Pooling wird auf jeden Channel einzeln angewandt, dadurch aendert sich die Tiefe des Bildes nicht.

Fuer die Beschreibung einer Pooling-Schicht wird viel Begrifflichkeit der Convolutional-Schicht und der Filter uebernommen. Die Groesse des Elementfelder, welches zusammengefasst wird, bezeichent man analog zur Filtergroesse mit f^l. Das Stride s^l bezeichnet auch beim Pooling wieder wie gross dieSchrittgreosse beim Verschieben des Felder ist. Meistens waehlt man den Stride s gerade gleich der Feldgroesse f, damit alle Pixel zusammengefasst werden. Kleiner als f kann s nicht gewaehlt werden.

Man unterscheidet zwischen zwei Arten von Pooling:

- **Average-Pooling**: Das Elementenfeld wird zusammengefasst, indem man das arithmetische Mittel der Element bildet.

- **Max-Pooling**: Das Elementenfeld wird zusammengefasst, indem das Element mit dem hoehsten Wert beibehalten wird und die anderen verworfen werden.

In Praxis verwendet man eigentlich nur Max-Pooling, da es deutlich bessere Resultate erziehlt.

Es ist festzustellen, dass eine Pooling-Schicht keinerlei Modellparameter besitzt. Somit gibt es nichts zu trainieren. Sie besitzt lediglich einige Hyperparameter, wie die Feldgroesse f und den Stride s.

Mit einer Pooling-Schicht, bei welcher $f = 2$ und $s = 2$ gewaehlt wurde, also ein (2×2)-Feld zusammengefasst wird, kommt es zu einer Dimensionalitaetsreduktion von 75%, da aus jeweils vier Element ein Element wird.

Um zu berechnen, was die neuen Dimensionen nach dem Pooling sind, gelten sie gleichen Formeln wie fuer die Filteroperationen:

$$n_1 = \frac{n_0 - f}{s} + 1 \tag{3.10}$$

3.4.2 die Upsampling-Schicht

Die Upsampling-Schicht bildet das Gegenstueck zur Pooling-Schicht, da sie die Dimensionaliaet der Bilder erhoeht. Auf den ersten Blick erscheint unklar, weshalb man die Dimensionalitaet erhoehen wollen koennte, da die eigentliche Motivation dieser Schichten in der Verhinderung von Overfitting besteht. Jedoch sollte in Kapitel (4) klar werden, weshalb solche Schicht noetig sind.

Man verwendet auch hier wieder den Begriff der Feldgroesse f^l. Diesemal beschreibt dieser Wert, wie stark das Bild hochskaliert wird. Beim Upsampling wird ein Element zu einem $(f \times f)$-Feld hochgerechnet und erweitert so die Dimensionalitaet.

Es stellt sich natuerlich die Frage, was fuer Werte das neue Feld erhaelt. Dafuer muss man eine Interpolationsart waehlen. Zwei Arten sind besonders verbreitet:

- **Bilineare Interpolation**
- **Naechste-Nachbar-Interpolation** (engl.: nearest-neighbor-interpolation)

Wir werden hier nur die Naechste-Nachbar-Interpolation betrachten. Sie ist ziemlich trivial, denn alle neuen Feldelemente nehmen einfach den Wert des alten Elements an. Der Wert wird also einfach vermehrt.

Kapitel 4

Autoencoder

Ein **Autoencoder** ist eine weitere KNN-Architektur eines KNNs. Diese Architekur beschreibt jedoch nicht die Schichtenarten, sondern beschreibt das Netzwerk auf der Ebene der Netzform. Autoencoder werden verwendet um **effiziente Daten-Codierungen** zu erlernen. Dies bedeutet das Modell versucht die wichtigsten Features, welche die meisten Informationen codieren zu extrahieren und diese in einer neuer Form zu repraesentieren. Er kann dann aus dieser neuen Form dann wieder eine der Ursprungsform sehr aehnliche Repraesentation reproduzieren.

benutzt um effiziente Codierungen von Daten zu erlernen. Strenggenommen gehoert er dem unueberwachtem Lernen bei, da die Daten keine Labels beinhalten. Jedoch ist diese Begrifflichkeit etwas irrefuehrend, da der Autoencoder trotzdem darauf trainiert wird, gewisse gewuenschte Outputs zu liefern. Die Labels sind naemlich in diesem Fall einfach gerade die Inputs. Semi-unueberwacht deshalb, weil die Labels in den Features enthalten sind.
Der Autoencoder soll eine komprimierte Repraesentation (Encoding) fuer einen Datensatz erlernen und somit die wesentlichen Features herausextrahieren. Er kann so zur **Dimensionalitaetsreduktion** verwendet werden. Dabei faellt das "Rauschen"(engl.:Noise) der Daten weg. Das Netzwerk rekonstruiert dann anhand der Codierung wieder die urspruenglichen Daten.

4.1 Topologie von Autoencodern

- Eingabeschicht
- Flaschenhals/Encoding
- Ausgabeschicht/Decoding

4.2 Mathematische Betrachtung

Falls lineare Neuronen verwendet werden, ist der Prozess der Dimensionalitaetsreduktion sehr aehnlich zur Hauptkomponentenanalyse.
Mathematik:

$$\phi : \mathcal{X} \to \mathcal{F} \tag{4.1}$$

$$\psi : \mathcal{F} \to \mathcal{X} \tag{4.2}$$

$$\phi, \psi = \arg\min_{\phi,\psi} \|X - (\phi \circ \psi)X\|^2 \tag{4.3}$$

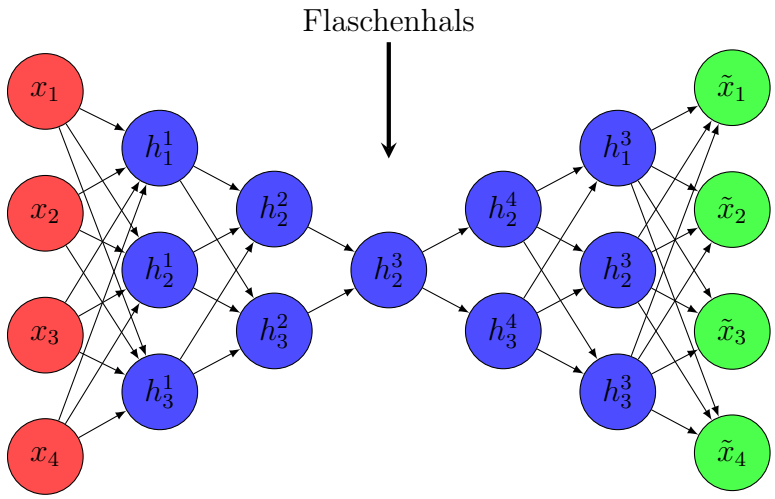

Abbildung 4.1: Schichten eines Autoencoders

4.3 Bedeutung von Autoencodern

4.3.1 Datenkompression

Falls ein Autoencoder nur aus linearen Neuronen besteht, ist die Dimensionsreduktion sehr aehnlich zu der Hauptkomponentenanalyse.
Problem: Netzwerk versucht Durchschnitt aller Trainingsdaten zu erlernen.

4.3.2 Datengenerierung

4.3.3 Eigenschaften erkennen

4.4 Convolutional-Autoencoder

4.5 Denoising-Autoencoder

Kapitel 5

Entwicklung eines Denoising-Autoencoders

In diesem Kapitel moechten wir uns nun der eigentlichen Entwicklung eines Machine-Learning-Modells widmen. Wir werden zuerst einige Frameworks und Tools, welche diese Entwicklung ermoeglichen betrachten und ihre grobe Funktionsweise verstehen. In einem naechsten Schritt programmieren wir dann ein konkretes Modell.

5.1 TensorFlow

TensorFlow, kurz TF, ist ein von Google entwickeltes Framework fuer datenstromorientriere Programmierung. Es ist im Grunde genommen ein Mathematik-Framework, dessen Hauptanwendungsbereich im Maschinellen Lernen liegt. TF ist in C++ und Python geschrieben. Das Python-Frontend ermoeglicht ein sehr einfaches erstellen von Computation Graphs um Modelle fuer Maschinelles Lernen zu designen. TF ist gratis und ein Open-Source-Projekt. Es kann auf Github gefunden werden unter: https://github.com/tensorflow/tensorflow.

5.1.1 Hardwarebeschleuniging

TF ist hauptsaechlich in C++ geschrieben, da diese Programmiersprache sehr nah am Maschinen Code ist (engl.: low-level), im Gegensatz zu vielen anderen Programmiersprachen. Somit ist der Code sehr hardwarenah und kann sehr schnell ausgefuehrt werden.

Hardwarebeschleuniging (engl. Hardware Acceleration)
Parallelisierung

5.1.1.1 CPU-Beschleunigung

5.1.1.2 GPU-Beschleunigung und CUDA

5.1.2 Funktionsweise

5.1.2.1 Tensoren

5.1.2.2 Computation Graphs

5.1.3 Tensorboard

5.2 Keras

Keras ist ein Open-Source Deep-Learning Framework geschrieben in Python. Keras wurde entwickelt um eine einheitliche Schnittstelle fuer verschieden Backends, wie TensorFlow, Microsoft Cognitive Toolkit und Theano zu bieten. Seit TF Version 1.4 ist Keras ein fester Bestandteil der TensorFlow-Core-API.
Keras ermoeglicht ein sehr simples und benutzerfreundliches defnieren von Deep-Learning-Modeln welche dann sehr einfach trainiert werden koennen.

5.3 Setup

Installationsschritte fuer Python, CUDA, CUDNN und Tensorflow auf arch-basierter Linuxdistribution mit Pacman.
Emacs und Spacemacs erwaehnen.

5.4 das Modell

Denoising Autoencoder fuer den MNIST-Datensatz.

5.4.1 MNIST

5.5 Entwicklung

Kapitel 6

Diskussion

Anhang A

Programmcode

Anhang B

Python-Einfuehrung

Literatur

[1] Andrew NG - deeplearning.ai. *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*. [Online; besucht am 17. Juni 2019]. 2017. URL: https://www.youtube.com/playlist?list=PLkDaE6sCZn6Gl29AoE31iwdVwSG-KnDzF.

[2] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. http://www.deeplearningbook.org. MIT Press, 2016.

[3] Mehrere. *Convolution— Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolution.

[4] Mehrere. *Convolutional neural network — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolutional_neural_network.

[5] Mehrere. *Kernel (image processing) — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Kernel_(image_processing).

[6] Mehrere. *Linear separability — Wikipedia, The Free Encyclopedia*. [Online; besucht am 9. Juli 2019]. 2019. URL: https://en.wikipedia.org/wiki/Linear_separability.

[7] Mehrere. *Normal distribution — Wikipedia, The Free Encyclopedia*. [Online; besucht am 26. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Normal_distribution.

[8] Mehrere. *Perzeptron — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 28. April 2019]. 2019. URL: https://de.wikipedia.org/wiki/Perzeptron.

[9] Mehrere. *Sobel operator — Wikipedia, The Free Encyclopedia*. [Online; besucht am 17. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Sobel_operator.

[10] Mehrere. *Supervised learning — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Supervised_learning.

[11] Mehrere. *Unsupervised learning — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Unsupervised_learning.

[12] Michael Nielsen. *Neural Networks and Deep Learning*. http://neuralnetworksanddeeplearning.com. 2018.

Abbildungsverzeichnis

1.1 Schema eines Modells . . . 3
1.2 Skalarfeld mit zugehoerigem Gradientenfeld . . . 5
1.3 Visualisierung des Gradientenabstiegs: ein Ball rollt das Gradientenfeld hinab in das lokale Minimum. . . . 6
1.4 Visualisierung verschiedener Lernraten . . . 6

2.1 Perzeptron mit drei Inputs . . . 9
2.2 erfolgreiche lineare Separierung (links) und das Versagen bei XOR (rechts) . . . 9
2.3 ein kuenstliches Neuron und seine Bestandteile . . . 10
2.4 Definition und Graph der Heaviside-Funktion Θ . . . 10
2.5 Formel und Graph einer stueckweisen linearen Funktion . . . 11
2.6 Definition, Ableitung und Graph der Sigmoid-Funktion σ . . . 11
2.7 Schichten eines KNNs . . . 12
2.8 zum Verstaentniss der Nomenklatur . . . 14
2.9 zum Verstaentniss der Gewichtebeschriftungen . . . 14
2.10 Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften 16
2.11 Computation Graph einer exemplarischen Verkettung von Funktionen . . . 17
2.12 Computation Graph zur Berechnung von $\boldsymbol{\delta}^L$ . . . 18
2.13 Computation Graph zur Berechnung von δ_j^{l-1} . . . 19

3.1 Beispiel einer Bildmatrix . . . 24
3.2 Schichtung eines CNNs . . . 24
3.3 der Instagramfilter: Blablabla . . . 25
3.4 eine 2D-Filtermatrix . . . 25
3.5 Sobel-Filter angewandt auf Beispielsbild . . . 25
3.6 ein Filter und sein rezeptives Feld . . . 26
3.7 Schema, wie ein Filter ueber ein Bild laueft . . . 27
3.8 aufeinander gelegte gefaltene Bilder . . . 28
3.9 Padding . . . 29

4.1 Schichten eines Autoencoders . . . 34

Tabellenverzeichnis

Selbstständigkeitserklärung

Ich erkläre hiermit, dass ich diese Arbeit selbständig durchgeführt und keine anderen als die angegebene Quellen, Hilfsmittel und Hilfspersonen beigezogen habe. Alle Textstellen in der Arbeit, die wörtlich oder sinngemäss aus Quellen entnommen wurden, habe ich als solche gekennzeichnet.

Luis Wirth