Gymnasium Oberwil

Maturarbeit

Bildsynthese von menschlichen Gesichtern mithilfe von Kuenstlicher Intelligenz

Eine Anwendung eines Autoencoders

Luis Wirth, 4a

Betreut von
Dr. Jonas Gloor

Abgegeben im September 2019

Inhaltsverzeichnis

1 Vorwort **2**

2 Einleitung **3**

3 Konventionen und Notation **4**

4 Machinelles Lernen - die Theorie **4**
4.1 Daten 4
4.2 Modelle (allgemein) 4
4.3 Training 5
4.3.1 Kostenfunktionen 5
4.3.2 Gradientenverfahren allgemein 5
4.3.3 Stochastisches Gradientenverfahren fuer Machine Learning 7
4.3.4 Adam Optimizer 8
4.4 Neural Networks 8
4.4.1 Backpropagation 8
4.4.2 Feedforward Neural Network 8
4.4.3 Convolutional Neural Networks 8
4.4.4 Autoencoder 8
4.4.5 Variational Autoencoder? 8
4.4.6 Detangled Autoencoder? 8

5 Entwicklung eines Autoencoders **9**

6 Diskussion? **10**

7 Schlusswort **11**

1 Vorwort

2 Einleitung

Die Leitfrage lautet: **Wie können mithilfe von Machine Learning Bilder von künstlichen meschlichen Gesichtern generiert werden?**

3 Konventionen und Notation

NOTATION ERKLAEREN (Vektor, Matrix, etc.)

Falls ein (Zeilen- oder Spalten-)Vektor $\vec{v}$ als Argument in eine Funktion f gegeben wird, ist zu verstehen, dass die einzelnen Komponenten des Vektors die Parameter der Funktion sind. $f(\vec{v}) = f(v_1, \cdots, v_n)$

4 Machinelles Lernen - die Theorie

Der Themenbereich des **Machinellen Lernens** beschäftigt sich mit Algorithmen und mathematischen Modellen, welche von selber lernen, Probleme zu loesen. Hierzu werden keine expliziten Instruktionen fest einprogrammiert (engl.: hard coding), sondern das Modell wird trainiert und optimiert sich von selbst. Dabei wird das Modell mit Trainingsdaten befuettern, mithilfe dessen eine Korrelation zwischen den Inputdaten und den Outputdaten erlernt werden soll. Der Zusammenhang der Daten wird von den Modellen verallgemeinert und das Modell kann dann Vorhersagen fuer neue Daten machen.

4.1 Daten

Der **Trainingsdatensatz** beinhaltet gewisse **Attribute**, die Merkmalstypen der Inputdaten. Die **Features** sind dann die spezifischen Werte der Attribute eines Trainingssample. Die sogenannten **Labels** sind die erwarteten Outputs, welche der Algorithmus vorherzusagen hat. Diese Vorhersagen werden mit den Labels abgeglichen und so bewertet. Anhand der Bewertungen wird dann eine Optimierung des Modells vorgenommen. Unter korrekten Bedingungen (keine Ueberanpassung) findet kein Auswendiglernen der Trainingsdaten statt, sondern ein Generalisieren des Zusammenhangs, anhand von Mustern und Gesetzmassigkeiten.

Um eine Endgueltige Bewertung des Modells durchzufuehren, wird ein Testdatensatz, welcher nicht Teil des Trainingsdatensatz ist, genutzt um Vorhersagen zu machen. Dies garantiert, dass kein Auswendiglernen moeglich ist.

Die Inputs/Features werden in einem Vektor $\vec{x} = (x_1, x_2, ..., x_n)^T$ und die Outputs/Vohersagen in einem Vektor $\vec{y} = (y_1, y_2, ..., y_m)^T$ zusammengefasst. Das gleiche macht man mit den Labels, wobei diese mit $\vec{\hat{y}} = (\hat{y}_1, \hat{y}_2, ..., \hat{y}_m)^T$ bezeichnet werden.

Am Beispiel eines Datensatz, welcher fuer Bilderkennung von Hunden und Katzen genutzt wird, werden diese Begriffe verdeutlicht. Die Inputdaten sind die Fotos von Hunden und Katzen. Deren Attribute sind die moeglichen RGB-Farbenwerte (drei Zahlen, welche von 0 bis 255 reichen) aller Pixel. Die Features sind die spezifischen RGB-Werte aller Pixel. Die Outputdaten sind die Labels, welche in diesem Fall angeben, ob ein Hund oder eine Katze auf dem Bild gezeigt wird. Dies wird meistens mit einer One-Hot-Kodierung bzw. einem One-Hot-Vektor gemacht. Jeder Labelart wird eine eigene Vektorkomponente zugewiesen. Falls das Label aktiv ist, ist die Komponent 1 ansonsten 0. Also Hund koennte als $\vec{l}_H = (1, 0)^T$ reprasentiert werden und Katze als $\vec{l}_K = (0, 1)^T$.

Abbildung 1: eine Veranschaulichung eines Machine Learning Modells

4.2 Modelle (allgemein)

Ein **Modell** ist eine differenzierbare mathematische Funktion $f\colon \mathbb{R}^n \to \mathbb{R}^m$ welche die Inputs auf die Outputs abbildet $\vec{y} = f(\vec{x})$. Im Zusammenhang mit Wertevorhersagen spricht man von

einem Regressionsmodell. Das Verhalten dieses Modells wird bestimmt durch seine **Modellparameter** $\phi_1, \phi_2, ...$ Das Ziel ist es die Modellparameter so einzustellen, dass die Vorherrsagen $\vec{y}$ besser mit den Labels $\vec{\hat{y}}$ uebereinstimmen. Dies wird iterativ gemacht, indem immer wieder leichte Anpassungen an den Parametern vorgenommen werden, bis sie das gewunschte Resultat liefern.

Das wohl einfachste Regressionsmodell ist eine Regressionsgerade. Diese ist angemessen, falls ein einfacher linearen Zusammenhang zwischen den Features und den Labels besteht. $y = \phi_1 x + \phi_0$. Nun muessten nur noch ϕ_0 und ϕ_1 bestimmt werden.

Neben den gelernten Parametern, gibt es auch noch sogenannte **Hyperparameter**. Diese koennen nicht erlernt werden, sondern muessen manuell vor dem Training gewaehlt werden und koennen den Lernvorgang erheblich beeinflussen.

Es gibt die verschiedensten Modelle. Einige der bekanntesten sind: Support Vector Machines, Evolutionäre Algorithmen, und Künstliche Neuronale Netze. Diese Arbeit wird sich vorwiegend auf Neuronale Netze beziehen.

BEISPIELMODELL (in der Art: Note anhand Lernstunden vorhersagen)

4.3 Training

4.3.1 Kostenfunktionen

Einsicht ist der erste Schritt zur Besserung. Das gilt auch beim Machine Learning, deshalb muss beim Training zuerst die Genauigkeit des Models bewertet werden. Dafuer gibt es sogennante **Kosten-, Verlust- oder Fehlerfunktionen**. Sie soll ein Mass fuer die Abweichung des Outputs $\vec{y}$ vom Label $\vec{\hat{y}}$ sein.

Die Fehler der einzlnen Outputs c_i werden aufsummiert um den Fehler C einer gesamten Vorhersage zu berechnen. Siehe Gleichung (1).
Der Fehler eines Datensatzen $\bar{C}$ ergibt sich aus dem arithmetischen Mittel der Vorhersagen-Fehler. Siehe Gleichung (2).

$$C(\vec{y}, \vec{\hat{y}}) = \sum_{i=1}^{m} c(y_i, \hat{y}_i) \qquad (1) \qquad\qquad \bar{C} = \frac{1}{p} \sum_{j=1}^{p} C\left(\vec{y}_j, \vec{\hat{y}}_j\right) \qquad (2)$$

Eine Kostenfunktion sollte folgende Eigenschaften aufweisen:

- c ist 0, wenn $y = \hat{y}$
- c waechst mit $|\vec{y} - \vec{\hat{y}}|$
- C ist nach jedem y_n partiell differenzierbar

Eine beliebte Kostenfunktion ist die "Mittlere quadratische Abweichung" (engl.: mean squared error).
$C_{MSE} = \frac{1}{2n} \sum_{i=1}^{n} (\hat{y}_i - y_i)^2 = \frac{1}{2n} (\vec{\hat{y}} - \vec{y})^2$ Sie erfuellt alle anforderungen, denn: Sie ist 0 falls $y = \hat{y}$.
Sie ist proportional zu $(\hat{y} - y)^2$ und ihre Ableitung nach y lautet: $C' = \frac{1}{n}(\hat{y} - y)$

4.3.2 Gradientenverfahren allgemein

Um ein Modell nun zu trainieren, gilt es zu verstehen, das es sich um ein Optimierungsproblem handelt. Das Modell ist am besten, also macht die besten Vorraussagen, wenn die Fehlerfunktion am kleinsten ist. Deshalb muss diese Fehlerfunktion C minimiert werden. Hierbei muss die

Funktion C nicht mehr in Abhangigkeit der Outputs und Labels betrachtet werden, sondern stattdessen in Abhangigkeit von den Modellparametern, $C(\phi_1, \phi_2, \cdots, \phi_n)$ denn diese sollen angepasst werden, um das Modell zu verbessern. Fuer diese Optimiertung wird das sogennante **Gradientenverfahren** (engl.: Gradient descent) verwendet. [1]

Allgemein koennen mithilfe des Gradientenverfahrens Funkionen $f(x_1, x_2, \cdots, x_n)$ vom Typ $\mathbb{R}^n \to \mathbb{R}$ (wie z.B. die Fehlerfunktion) minimiert werden. Dies beschieht, in dem ein Startpunkt (Ortsvektor) $\vec{p_0}$, dessen Komponenten den Input von f darstellt, gewaehlt wird. Nun werden iterativ neue Punkte $\vec{p_z}$ gesucht, welche immer naeher beim lokalen Minimun liegen, also Punkte die den Funktionswert $f(\vec{p_z})$ immer kleiner werden lassen. Dies wird durchgeführt, bis der Punkt genug nahe beim lokalen Minimun ist.

Dafuer muss ein Vektor $\vec{b_z}$ bestimmt werden, welcher auf den Punkt $\vec{p_z}$ draufaddiert einen neuen Punkt $\vec{p_{z+1}}$ bildet, bei dem der Funktionswert $f(\vec{p_{z+1}})$ kleiner ist als der von $f(\vec{p_z})$. Dies geschieht am effizientesten, wenn $\vec{b_z}$ in die Richtung der staerksten Funktionswertabnahme zeigt.

Hierzu braucht man den sogennanten **Gradient** $\vec{\nabla}$, wofür man wiederum partielle Ableitungen braucht.

Partielle Ableitungen

Partielle Ableitungen sind eine Erweiterung der "normalen" Ableitungen auf multidimensionale Funktionen $f(x_1, \cdots, x_n)$. Man leitet dabei nur nach einem Parameter x_i ab und betrachtet die restlichen Argumente als Konstanten. Es gelten die gleichen Ableitungsregeln wie bei der nicht-partiellen Ableitung. Die partielle Ableitung einer Funktion $f(x_1, \cdots, x_n)$ bezueglich der Variabel x_i in einem Punkt $\vec{a} = (a_1, \cdots, a_n)^T$ ist analog zur "normalen" Ableitung folgendermassen definiert:

$$\frac{\partial f}{\partial x_i}(\vec{a}) := \lim_{h \to 0} \frac{f(a_1, \cdots, a_i + h, \cdots, a_n) - f(a_1, \cdots, a_i, \cdots, a_n)}{h}$$

Geometisch ist dies die Steigung der Tangente im Punkt $\vec{a}$ in Richtung der Achse des Parametern x_i, nach dem man ableitet.

Gradient

Der Gradient $\vec{\nabla}$ ist ein Differentialoperator, welcher ein Skalarfeld auf ein Vektorfeld (das sogennante Gradientenfeld) abbildet.
Dabei fasst man alle partiellen Ableitungen einer Funktion f in einem Vektor zusammen.

$$grad(f) = \vec{\nabla} f = \begin{pmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{pmatrix}$$

Geometisch ist der Gradient $\vec{\nabla} f(\vec{p})$ einer Funktion f in einem Punkt $\vec{p}$ dann der Vektor, welcher in die Richtung des steilsten Anstiegs von f zeigt. Seine Magnitude gibt die Staerke des Anstiegs an.

Da der Gradient in die Richtung des steilsten Anstiegs zeigt, sollte der Vektor $\vec{b_z}$ in die Richtung des negierten Gradient der Funktion f im Punkt $\vec{p_z}$ zeigen. Also kann jetzt das iterative

[1] Im Gymnasium wird beigebracht die lokalen Extrema (inkl. lokalen Minimas) zu bestimmen, indem die erste Ableitung f' gebildet wird und gleich null gesetzt wird. Dies ist hier nicht moeglich, da die Funktion $C'(\phi_1, \phi_2, \cdots, \phi_n)$ deutlich zu komplex ist, um die Nullstellen zu bestimmen. Deshalb wird das Gradientenverfahren verwendet.

Annahern an das lokalen Minimums so beschrieben werden:

$$\vec{p}_{z+1} = \vec{p}_z - \eta \cdot \vec{\nabla} f(\vec{p}_z) \tag{3}$$

Waehrend des Gradientenverfahren konvergiert der Punkt $\vec{p}_z$ zu einem belibigen *lokalen* Minimum, abhängig davon wie der Startpunkt $\vec{p}_0$ gewaehlt wurde. Da dieser meist zufaellig bestimmt wird, ist es eine Glückssache ein sehr tiefes Minimum zu finden.

Die sogennante **Lernrate** η aus Gleichung (3) ist ein Hyperparameter. Sie ist ein positiver Proportionalitatsfaktor, welcher die Schrittgroesse des Gradientenabstieg bestimmt. Sie muss je nach zu minimierender Funktion anderst gewaehlt werden. Dabei hilft nur ausporbieren. Falls η nicht gut gewahelt wurde, gibt es Probleme beim Training:

- Falls η zu klein ist, verlaueft das Trainings unnotig langsam und braucht sehr lange. Ausserdem kann es passieren, dass man bei einem hohen lokalen Minimum stecken bleibt.
- Falls η zu gross ist, passiert es, dass man ueber das lokale Minimum hinaus schiesst und nur darum herum springt.

Abbildung 2: Visualiesierung verschiedener Lernraten

4.3.3 Stochastisches Gradientenverfahren fuer Machine Learning

Wie vorhin gesagt, wird fuer das Trainieren eines Modells das Gradientenverfahren benutzt. Konkret wird die Kostenfunktion $C(\phi_0, \cdots, \phi_n)$ minimieren, indem die Parameter angepasst werden, dadurch macht das Modell immer bessere Vorhersagen. Dafuer muesste man eigentlich den Gradieten fuer den gesamten Trainingsdatensatz bestimmen, um nur eine Iteration des Gradientenabstiegs durchzufuehren. Dies waere zwar ein exakter Prozess aber ein extrem langsamer zugleich. Bei grossen Datensaetzen wuerde es eine Ewigkeit dauern, bis das Modell nur annahernd guete Vorhersagen machen wuerde.

Aus diesem Grund verwendet man eine leicht abgeänderte Variante dieses Verfahren, naemlich das **Stochastische Gradientenverfahren** (engl.: Stochastic Gradient Descent). Dabei wird der "echte" Gradient des gesamten Datensatzes mit dem Gradienten einiger Trainingsbeispiel approximiert. Dabei wird der Trainingsdatensatz in sogennante **Mini-Batches** eingeteilt und der Gradient jeweils pro Mini-Batch berechnet. Dadurch finden deutlich mehr Iterationen statt in *einer* Durchkaemmung der Trainingsdaten, welche man **Epoche** nennt. Oft wird mehrere Epochen lang trainiert. Der Gradient eines genug grossen Mini-Batches ist zwar nicht ganz exakt, aber approximiert den Gradieten des gesamten Datensatzen genuegen gut. Sowohl die Mini-Batch Groesse, wie auch die Anzahl Epochen sind weitere Hyperparameter.

Die partiellen Ableitungen der gesamten Trainingsdaten wird mit dem arithmetischen Mittel der partiellen Ableitungen eines Mini-Batches der Groesse q approximiert. Siehe Gleichung (4).

$$\frac{\partial \bar{C}}{\partial \phi_n} \approx \frac{1}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \phi_n} \tag{4}$$

Eine Iteration des Stochastischen Graidentenverfahren wird analog zu Gleichung (3) folgendermassen durchgefuehrt:

$$\phi_{n,t+1} = \phi_{n,t} - \frac{\eta}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \phi_{n,t}} \tag{5}$$

4.3.4 Adam Optimizer

ZUSAMMENFASSUNG TRAININGSALGORITHMUS

4.4 Neural Networks

4.4.1 Backpropagation

4.4.2 Feedforward Neural Network

4.4.3 Convolutional Neural Networks

Conv2D, MaxPooling2D, UpSampling2D

4.4.4 Autoencoder

4.4.5 Variational Autoencoder?

4.4.6 Detangled Autoencoder?

5 Entwicklung eines Autoencoders

6 Diskussion?

7 Schlusswort

Abbildungsverzeichnis

1 eine Veranschaulichung eines Machine Learning Modells 4
2 Visualiesierung verschiedener Lernraten 7

Tabellenverzeichnis

Selbstständigkeitserklärung

Ich erkläre hiermit, dass ich diese Arbeit selbständig durchgeführt und keine anderen als die angegebene Quellen, Hilfsmittel und Hilfspersonen beigezogen habe. Alle Textstellen in der Arbeit, die wörtlich oder sinngemäss aus Quellen entnommen wurden, habe ich als solche gekennzeichnet.

Luis Wirth