Maturaarbeit

Maschinelles Lernen mit TensorFlow

Entwicklung eines Convolutional Denoising Autoencoders

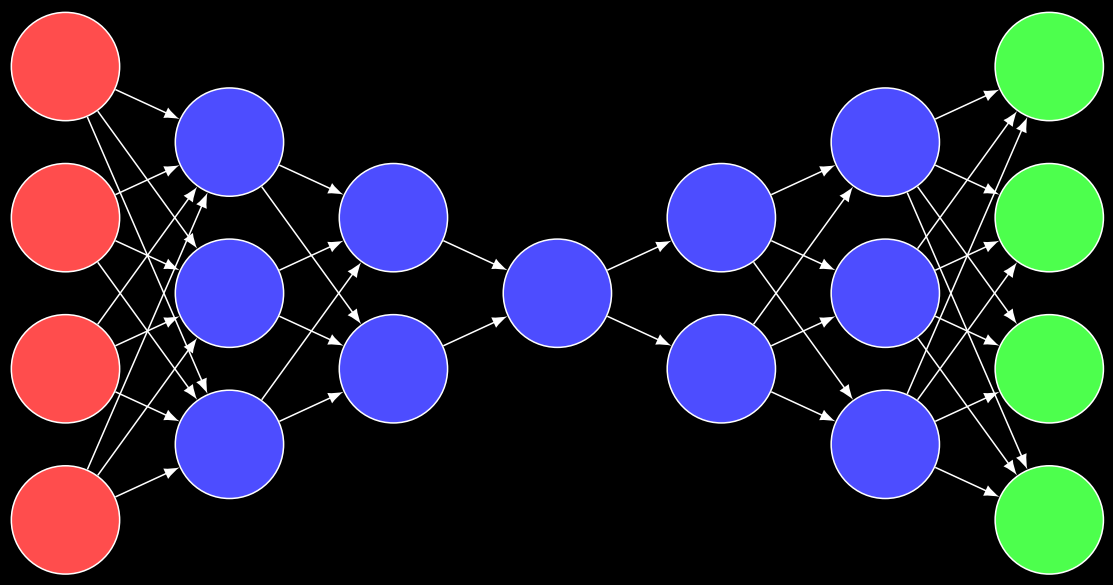

Luis Wirth

Gymnasium Oberwil
Klasse *4a*

Betreut von
Dr. Jonas Gloor

Abgegeben im September 2019

Inhaltsverzeichnis

Inhaltsverzeichnis **I**

Vorwort **III**

Einleitung **IV**

Konvention und Notation **V**

1 Maschinelles Lernen **1**
1.1 Allgemeine Begriffe . . . 1
1.1.1 Daten . . . 1
1.1.2 Modelle . . . 2
1.2 Training . . . 3
1.2.1 Verlust- und Kostenfunktionen . . . 3
1.2.2 Stochastisches Gradientenverfahren . . . 3
1.3 Trainingsphänomene . . . 5
1.3.1 Konvergenz und Divergenz . . . 5
1.3.2 Underfitting und Overfitting . . . 5

2 Deep Learning und Künstliche Neuronale Netze **7**
2.1 Perzeptron . . . 7
2.1.1 Lernpotenzial eines Perzeptrons . . . 8
2.2 Erweiterung der künstlichen Neuronen . . . 8
2.2.1 Künstliche Neuronen im Allgemeinen . . . 9
2.2.2 Perzeptronen als künstliche Neuronen . . . 9
2.2.3 ReLU Neuronen . . . 9
2.2.4 Sigmoid Neuronen . . . 10
2.3 Topologie der Künstlichen Neuronalen Netze . . . 11
2.4 Lernverhalten . . . 11
2.5 Vorwärtspropagierung . . . 12
2.5.1 Initialisierung der Modellparameter . . . 14
2.6 Rückwärtspropagierung . . . 15
2.7 Universal Approximation Theorem . . . 16

3 Convolutional Neural Networks **17**
3.1 Bilder als Tensoren . . . 17
3.2 Topologie der Convolutional Neural Networks . . . 18
3.3 Convolutional-Schichten und Filter . . . 19
3.3.1 Filter in der Bildverarbeitung . . . 19
3.3.2 Filter in CNNs . . . 20
3.3.3 Filteroperation intutitiv . . . 21
3.3.4 Filteroperationen als diskrete Faltungen . . . 22
3.3.5 Mehrere Filter . . . 23
3.3.6 Padding . . . 24
3.3.7 Stride . . . 24
3.3.8 Vorzüge von Filtern . . . 25
3.3.9 Convolutional-Schicht . . . 25
3.4 Dimensionalitätskontrolle . . . 26
3.4.1 Pooling-Schicht . . . 26
3.4.2 Upsampling-Schicht . . . 27

4 Autoencoder **28**
4.1 Topologie . . . 28
4.2 Funktionsweise . . . 29
4.3 Anwendungen . . . 30
4.3.1 Kompression . . . 30
4.3.2 Neue Datenrepräsentation . . . 31
4.3.3 Visualisierung von Daten . . . 31
4.4 Convolutional-Autoencoder . . . 31
4.5 Denoising-Autoencoder . . . 31
4.5.1 Generierung der verrauschten Bilder . . . 32

5 Frameworks für Maschinelles Lernen **33**
5.1 TensorFlow . . . 33
5.1.1 Frontend und Backend . . . 34
5.1.2 Graph . . . 34
5.1.3 Ausführungen . . . 35
5.1.4 Tensorboard . . . 36
5.2 Keras . . . 36
5.2.1 Sequential-Modell . . . 37
5.2.2 Schichten . . . 37
5.2.3 Training und Evaluierung . . . 38

6 Entwicklung eines Denoising-Autoencoders **40**
6.1 Das konkrete Modell . . . 40
6.1.1 Daten . . . 40
6.2 Setup . . . 40
6.3 Entwicklung . . . 42
6.3.1 Testprogramm . . . 42
6.3.2 Trainingsdaten . . . 42
6.3.3 Modell definieren . . . 44
6.3.4 Modell trainieren . . . 46
6.3.5 Modell ausführen . . . 47
6.3.6 Hyperparameter einstellen . . . 48
6.3.7 Diskussion des Modells . . . 49

Rückblick und Ausblick **51**

Schlusswort **52**

A Gradientenverfahren **53**

B Herleitung der Rückwärtsprogagierung für KNNs **56**

C Performance von TensorFlow **61**

D Programmcode **63**

Literatur **65**

Abbildungsverzeichniss **67**

Tabellenverzeichniss **68**

Selbstständigkeitserklärung **69**

Vorwort

Persönliche Themenwahl

Maschinelles Lernen (machine learning, kurz: ML) stösst seit einigen Jahren auf grosses Interesse sowohl in der Wissenschaft, als auch in der Wirtschaft. Dies motivierte mich, Näheres im Selbststudium darüber in Erfahrung bringen zu wollen. Bereits im Jahr 2017 begann ich, eine erste eigene Applikationen zu programmieren, welche einen Genetischen Algorithmus zur Anwendung brachte (Evolutionäre Entwicklung von lernfähigen Agenten).
Diese erste Erfahrung öffnete mir die Tür für ein Praktikum am Departement für Computational Sciences der Universität Basel. Dort durfte ich ein Künstliches Neuronales Netz in C++ programmieren, welches ich dann auf eine konkrete physikalische Problemstellung anwenden konnte (Vorhersage zu den Energiezuständen von Wassermolekülen in verschiedenen atomaren Konfigurationen).
Dieses erste Praktikum hatte mich dazu motiviert, mich tiefgehender mit der Thematik zu befassen und die grundlegende Funktionsweise von ML durchdringen zu wollen.

Daraufhin entstand die Idee, die vorliegende Arbeit zu verfassen. Auf diese Weise wollte ich mir ein ausgeprägteres mathematisches Verständnis für Maschinelles Lernen aneignen und auch fortgeschrittene Modelle betrachten. Zudem hatte ich auch schon von den verbeiteten Deep-Learning-Frameworks TensorFlow und Keras gehört, welche ich unbedingt erlernen wollte. Daher entschied ich mich, einen Convolutional-Autoencoder in TensorFlow zu programmieren und vorher die nötige Theorie zu erklären. Zuerst verfolgte ich das Ziel, diesen Autoencoder als ein generatives Modell zu entwickeln, um Bilder von künstlich generierten menschlichen Gesichter zu erzeugen.

Während meiner Sommerferien konnte ich ein 6-wöchiges Praktikum im Forschungszentrum von Adobe in San Francisco leisten, wo ich ebenfalls ein ML-Modell programmiert habe (Nutzung von Gesichtserkennung für Marketing-Zwecke). Durch meine praktikumsbezogenen Recherchen gelangte ich jedoch schnell zu der Erkenntnis, dass mein ursprüngliches ambitiöses Vorhaben bezüglich der generativen Nutzung eines Autoencoder den vorgegebenen Rahmen einer Maturaarbeit deutlich sprengen würde. Ich hätte nämlich nicht nur einen Autoencoder programmieren müssen, sondern sogar einen Variational Autoencoder, welcher mathematisch noch deutlich anspruchsvoller gewesen wäre.

Aus diesem Grund beschloss ich, meine Leitfrage in Abstimmung mit meiner Betreuungsperson anzupassen. Diese beschränkt sich nunmehr auf die Entwicklung eines Convolutional *Denoising* Autoencoder in TensorFlow und Keras sowie vorgängig die zugrundeliegende Theorie zu erklären.

Danksagung

Mein herzlicher Dank gilt dem Department für Computational Sciences der Universität Basel, namentlich Herrn Professor Stefan Goedecker, weil er und sein Team mir die ersten wissenschaftliche Einblicke in das Thema Machine Learning eröffnet haben.
Danken möchte ich ebenso der Firma Adobe, welche mir ermöglicht hat, im Rahmen eines 6-wöchigen Praktikums die kommerzielle Anwendung von Machine Learning vertieft kennenzulernen.
Ebenso danke ich meinen Eltern, Frau Dr. Doris Fellenstein und Herrn Dr. Victor Wirth für ihre Begleitung und Unterstützung während des Erstellungsprozesses meiner Maturaarbeit.
Last but not least gilt mein besonderer Dank meiner Betreuungsperson Herrn Dr. Jonas Gloor für seine wertvollen fachlichen Inputs.

Einleitung

Maschinelles Lernen erfreut sich aktuell grosser Beliebtheit und wird sehr erfolgreich in naturwissenschaftlichen, medizinischen oder auch wirtschaftlichen Themenbezügen angewendet. Es bietet ein enormes Innovationspotential und wird laufend weiterentwickelt. Obwohl das Schlagwort "Künstliche Intelligenz" in aller Munde ist, wissen die Wenigsten, wie sie tatsächlich funktioniert.

Das Ziel dieser Arbeit ist daher, dem Leser ein umfassendes Grundverständnis über Maschinelles Lernen zu vermitteln, sowie auf dieser Basis ein konkretes Anwendungsbeispiel zu entwickeln. Zu diesem Zweck werden zunächst die theoretischen Grundlagen zum modellbasierten Lernen dargelegt. Darauf aufbauend ist es möglich, ein konkretes Modell, namentlich Künstliche Neuronale Netze (KNN), in ihrer Funktionsweise zu erläutern. In logischer Konsequenz wird anschliessend die spezifische Architektur eines KNNs präsentiert. Namentlich handelt sich um ein Convolutional Neural Networks (CNN), welches sich besonders gut für Bildverarbeitungszwecke eignet und daher eine grosse Verbreitung in der Praxis aufweist. Mit der anschliessenden Erläuterung der mathematischen Beschreibung eines Autoencoders sind die theoretischen Grundlagen für ein konkretes Anwendungsbeispiel geschaffen.

Nachdem ein mathematisch fundiertes Verständnis für Maschinelles Lernen vermittelt wurde, sollen im Weiteren zwei Open-Source Implementationen vorgestellt werden. Dabei handelt es sich um TensorFlow, ein ursprünglich von Google entwickeltes Framework für Deep-Learning, und um Keras, eine übergeordnete Schnittstelle für eine vereinfachte TensorFlow-Verwendung. Neben ihrer grossen Verbreitung besitzen sie den Vorteil eines verkürzten Einstiegs in die ML-Programmierung.

Für das konkrete Modell werden wir einen sogenannten Convolutional-Denoising-Autoencoder entwickeln. Mit dessen Hilfe kann das Bildrauschen von Bildern entfernt werden. Eine beispielhafte Anwendungsmöglichkeit bildet das korrekte Einlesen von standardisierten (verrauschten) Formularen.

Die Leitfrage lässt sich demnach folgendermassen formulieren:

Wie funktioniert Maschinelles Lernen, aufgezeigt anhand eines konkreten Modells, unter Verwendung von TensorFlow und Keras?

Dabei lassen sich folgende Teilschritte unterscheiden:

1. Erarbeiten der allgemeine Theorie zum Maschinellen Lernen
2. Künstliche Neuronale Netze als Modelle für ML
3. Convolutional Neural Networks und Autoencoder als konkrete KNN-Architekturen
4. Grundsätzliche Funktionsweise der ML-Frameworks TensorFlow und Keras
5. Programmierung eines konkreten ML-Modells mit TensorFlow und Keras

Konvention und Notation

Beschriftung

Zahlen und Tensoren

a	ein Skalar (Zahl)
$\boldsymbol{a}$	ein Vektor
$\boldsymbol{A}$	eine Matrix
$\mathbf{A}$	ein Tensor

Mengen

(a, b)	ein geordnetes Paar (2-Tupel) der Elemente a und b
$\mathbb{A}$	eine Menge
$\mathbb{R}$	die Menge aller reellen Zahlen
$\mathbb{Z}$	die Menge aller ganzen Zahlen
$\mathbb{N}$	die Menge aller natürlichen Zahlen
$\{a, b\}$	die Menge, welche aus den Elementen a und b besteht
$\{1, \ldots, n\}$	die Menge aller ganzen Zahlen von 1 bis n
$a \in \mathbb{A}$	a ist ein Element der Menge $\mathbb{A}$
$\mathbb{R}^n$	ein n-dimensionale Vektorraum

Indexierung

a_i	die i-te Vektorkomponente mit Startindex 1
$(\boldsymbol{A})_{i,j}$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$A_{i,j}$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$\boldsymbol{A}_{i,:}$	die Zeile i der Matrix $\boldsymbol{A}$
$\boldsymbol{A}_{:,i}$	die Spalte i der Matrix $\boldsymbol{A}$
$\mathbf{A}_{i,:,:}$	der i-te Querschnitt entlang der Höhe des Tensors $\mathbf{A}$
$\mathbf{A}_{:,i,:}$	der i-te Querschnitt entlang der Breite des Tensors $\mathbf{A}$
$\mathbf{A}_{:,:,i}$	der i-te Querschnitt entlang der Tiefe des Tensors $\mathbf{A}$

Lineare Algebra Operationen

$\Sigma(\boldsymbol{A})$	die Summe aller Elemente von Matrix $\boldsymbol{A}$
$\boldsymbol{v} \cdot \boldsymbol{w}$	das Skalarprodukt von $\boldsymbol{v}$ mit $\boldsymbol{w}$
$\boldsymbol{A}^\mathsf{T}$	das Transponierte einer Matrix $\boldsymbol{A}$
$\boldsymbol{A} \odot \boldsymbol{B}$	das elementeweise (Hadamard) Produkt
$\boldsymbol{A} * \boldsymbol{B}$	die diskrete Faltung von $\boldsymbol{A}$ ueber $\boldsymbol{B}$

Infinitesimalrechnung

$f'(x)$	die Ableitung der Funktion f bezüglich seinem Argument x
$\dfrac{\mathrm{d}y}{\mathrm{d}x}$	die Ableitung von y bezüglich x
$\dfrac{\partial y}{\partial x}$	die partielle Ableitung von y bezüglich x
$\boldsymbol{\nabla} y$	der Gradient von y
$\boldsymbol{\nabla}_{\boldsymbol{x}} y$	der Gradient von y bezüglich $\boldsymbol{x}$ (Vektor)
$\int f(x)\,\mathrm{d}x$	das unbestimmte Integral der Funktion f bezüglich x
$\int_a^b f(x)\,\mathrm{d}x$	das bestimmte Integral der Funktion f bezüglich x von a bis b
$\lim\limits_{x \to a} f(x)$	der Limes/Grenzwert von f, wenn x gegen a strebt

Funktionen

$f : \mathbb{A} \to \mathbb{B}$	eine Funktion f mit Definitionsmenge $\mathbb{A}$ und Zielmenge $\mathbb{B}$
$f(x)$	eine Funktion f mit Argument x (Skalar)
$f(\boldsymbol{v})$	eine Funktion f mit Argument $\boldsymbol{v}$ (Vektor)
$\boldsymbol{f}[\boldsymbol{v}]$	die vektorisierte Funktion $\boldsymbol{f}$ mit Argument $\boldsymbol{v}$ (Vektor)
$\mathcal{A}$	ein Funktionenraum
$f * g$	die Faltung von f über g
$f \circ g$	die Komposition von den Funktionen f und g

Statistik

$\mathcal{N}$	die Gauss'sche Normalverteilung
ϕ	die Gauss'sche Dichtefunktion
μ	der Erwartungswert/Mittelwert
σ	die Standardabweichung
σ^2	die Varianz

Sonstiges

$\sum_{i=a}^{b} x$ die Summe mit von a bis b ueber x mit Laufvariable i

Erwähnung von Notation $\mathbb{R}$ für Skalare und $\mathbb{R}^n$ für Vektoren/Vektorräume...

Kapitel 1

Maschinelles Lernen

Im ersten Kapitel sollen die Grundlagen für ein fundiertes Verständnis von Maschinellem Lernen gelegt werden. Neben den verschieden Arten sollen essentielle Begriffe und das Modellkonzept dargelegt werden. Darüber hinaus werden die Funktionsweise des Trainings sowie daraus entstehende Phänomene erläutert. Auf dieser Basis erfolgt in Kapitel zwei die Darlegung eines konkreten Modells.

Maschinellen Lernens beschäftigt sich mit Algorithmen und mathematischen Modellen, welche die Fähigkeit entwickeln, Probleme selbständig zu lösen. Hierbei wird nicht explizit einprogrammiert, wie das Modell das Problem zu lösen hat, stattdessen wird das Modell trainiert, optimiert sich von selbst und findet selbst einen Weg, die Aufgabenstellung zu lösen. Die Grundidee dabei ist, dass Daten erfasst, generiert oder gemessen werden, welche anschliessend analysiert werden sollen. Innerhalb dieser Daten existieren gewisse Gesetzmässigkeiten und Muster. Diese Muster sollen vom Modell erkannt und verallgemeinert werden. Nach dem erfolgreichen Lernprozess, kann das Modell Vorhersagen für neue Daten machen.

Üblicherweise werden zwei Arten von Maschinellem Lernen unterschieden:

- **Überwachtes Lernen** (engl.: supervised learning) ist ein Lernverfahren, bei welchem die Daten aus zwei Teilen bestehen, aus Inputs und Outputs. Man bezeichnet dabei die Outputs als Labels. Die Aufgabe des Modells ist es, eine **Korrelation** zwischen den Inputs und den Labels zu erlernen und so ihre Beziehung zueinander zu verstehen. Anhand der Informationen, welche die Inputs enthalten, können die Labels vorhergesagt werden. Die vorhergesagten Labels des Modells werden mit den wahren Labels abgeglichen. Mit dieser Überwachung werden die Fähigkeiten des Modells bewertet.

  Voraussetzung dafür ist, dass die Daten "gelabelt" sein müssen. Daher müssen bereits vorgägig Daten vorhanden sein, bei welchen die gewünschten Labels aufweisen. Zudem muss auch die erwähnte Korrelation bestehen. Falls kein Zusammenhang zwischen den Inputs und den Outputs existiert, kann das Modell auch keine Vorhersagen machen und damit auch nichts erlernen.

- **Unüberwachtes Lernen** (engl.: unsupervised learning) ist ein anderes Lernverfahren, bei welchem diese Labels nicht vorhanden sind. Dem Modell stehen nur die Inputdaten zur Verfügung. Diese werden ebenfalls analysiert und das Modell soll Muster heraus extrahieren, welche sich von einem zufälligen Datenrauschen unterscheiden.

Der Grossteil der Modelle des Maschinellen Lernens zählt zum Überwachten Lernen, da es deutlich mehr Anwendungsmöglichkeiten bietet. Grundsätzlich steht daher das Überwachte Lernen im Vordergrund der Arbeit. Allerdings gehört der später erläuterte Autoencoder strenggenommen (aufgrund einer irreführender Zuordnung) zum Unüberwachten Lernen, auch wenn es der gleichen Systematik des Überwachten Lernens folgt (siehe Sektion 4).

GUTE QUELLE (Pionier) (Mehrere, *Supervised learning — Wikipedia, The Free Encyclopedia*)
(Mehrere, *Unsupervised learning — Wikipedia, The Free Encyclopedia*)

1.1 Allgemeine Begriffe

1.1.1 Daten

Um ein Modell zu trainieren, werden Daten benötigt. Diese Daten bestehen immer aus **Inputs** und **Outputs**. Man unterscheidet hierbei zwischen zwei Arten von Outputs. Die **Labels** sind die erwarteten Outputs, welche

die gewünschten Zielwerte sind. Die **Vorhersagen** sind die Outputs, die vom Modell produziert werden und welche hoffentlich möglichst genau mit den Labels übereinstimmen.

Diese Daten für das Training kommen in der Form eines **Trainingsdatensatzes** $\mathbb{X}$ dar. Es handelt sich um eine Menge von **Samples**, welche jeweils aus Inputs und Labels bestehen. Die Inputs werden in einem Vektor

$$\boldsymbol{x} = \begin{pmatrix} x_1 & x_2 & \cdots & x_m \end{pmatrix}^\mathsf{T}$$

und die Labels in einem Vektor

$$\hat{\boldsymbol{y}} = \begin{pmatrix} \hat{y}_1 & \hat{y}_2 & \cdots & \hat{y}_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst. Somit ist ein Trainingssample ein Paar $(\boldsymbol{x}_i, \hat{\boldsymbol{y}}_i)$ bestehend aus einem Inputvektor $\boldsymbol{x}$ und eines Labelvektor $\hat{\boldsymbol{y}}$. Die Vorhersagen werden ebenfalls in einem Vektor

$$\boldsymbol{y} = \begin{pmatrix} y_1 & y_2 & \cdots & y_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst.

Die Inputs beinhalten sogenannte **Features** (deutsch: Merkmale). Sie zeichnen die Inputs aus und umfassen ihren gesamten Informationsgehalt. Der Algorithmus soll anhand dieser Features seine Vorhersagen machen. Diese Vorhersagen werden dann mit den Labels abgeglichen und bewertet. Anhand der Bewertungen wird eine Optimierung des Modells vorgenommen. Unter korrekten Bedingungen (kein Overfitting (siehe 1.3.2)) findet kein Auswendig lernen der Trainingsdaten statt, sondern ein Generalisieren des Zusammenhangs anhand von Mustern und Gesetzmässigkeiten.

Um eine endgültige Bewertung des Modells durchzuführen, wird ein Testdatensatz $\mathbb{T}$ genutzt, um Vorhersagen zu generieren. Dieser ist nicht Teil des Trainingsdatensatz. Dies garantiert, dass kein Auswendiglernen möglich ist.

BEISPIEL

1.1.2 Modelle

Ein **Modell** ist eine mathematische Funktion $h\colon \mathbb{R}^m \to \mathbb{R}^n$, Hypothesenfunktion genannt, welche die Inputs auf die Outputs abbildet $\boldsymbol{y} = h(\boldsymbol{x})$. Man kann diese Funktion als die Hypothese auffassen, welche das Modell bezüglich der Beziehung zwischen den Inputs und den Labels aufgestellt hat. Diese Modelle können verwendet werden, um entweder Klassifizierungsprobleme oder Regressionsprobleme zu lösen. Falls es sich um Letzteres handelt, spricht man von einem Regressionsmodell. Ein solches Regressionsproblem soll im Rahmen dieser Arbeit gelöst werden.

Das Verhalten eines Modells bestimmt sich durch seine **Modellparameter** $\lambda_1, \lambda_2, \ldots, \lambda_k$. Sie determinieren, wie die Hypothese des Modells lautet. Das Ziel ist es, die Modellparameter so einzustellen, dass die Vorhersagen $\boldsymbol{y}$ des Modells besser mit den Labels $\hat{\boldsymbol{y}}$ der Trainingsdaten übereinstimmen. Dies wird iterativ gemacht, indem immer wieder leichte Anpassungen an den Parametern vorgenommen werden, bis das Modell die gewünschten Resultate liefert.

Neben den gelernten Parametern, gibt es auch noch sogenannte **Hyperparameter**. Diese können nicht erlernt werden, sondern müssen manuell vor dem Training gewählt werden und können den Lernvorgang erheblich beeinflussen. Dies bedeutet, dass man ausprobieren muss, welche Werte der Hyperparameter die besten Resultate liefern.

Das wohl einfachste Beispiel eines Regressionsmodell ist eine Regressionsgerade. Diese ist angemessen, falls ein einfacher linearen Zusammenhang der Form $y = \lambda_1 x + \lambda_0$ zwischen den Features und den Labels besteht. Danach müssten nur noch λ_0 und λ_1 bestimmt werden. BEISPIELMODELL AUTO

Für Maschinelles Lernen haben sich gewisse Modelle besonders gut etabliert, dazu zählen: Support Vector Machines, Evolutionäre Algorithmen, und Künstliche Neuronale Netze. Diese Arbeit wird sich vorwiegend mit Neuronalen Netzen auseinandersetzen.

Abbildung 1.1: Schema eines Modells

1.2 Training

1.2.1 Verlust- und Kostenfunktionen

Einsicht ist der erste Schritt zur Besserung. Diese Maxime gilt auch für das Machine Learning. Deshalb muss beim Training zuerst die Genauigkeit des Modells bewertet werden. Dies wird mithilfe von sogenannten Kostenfunktionen bzw. Verlustfunktionen erreicht.

Eine **Verlustfunktion** $L(y, \hat{y})$ soll ein Mass für die Abweichung der Vorhersage y von dem Label $\hat{y}$ sein. Aus ihr bildet man die **Kostenfunktion** $C(\boldsymbol{y}, \hat{\boldsymbol{y}})$, indem die Verluste der einzelnen Outputs aufsummiert werden. Somit erhält man die Kosten einer gesamten Vorhersage mit m Outputs (siehe Gl. (1.1)). Bei gewissen Kostenfunktionen gibt es keine Verlustfunktion, da diese nicht auf die einzelnen Outputpaare aufgeteilt werden kann. Der Fehler $\bar{C}(\mathbb{X})$ des gesamten Trainingsdatensatzes $\mathbb{X}$, der Grösse p, ergibt sich aus dem arithmetischen Mittel der einzelnen Kosten der Vorhersagen (siehe Gl. (1.2)).

$$C\left(\boldsymbol{y}, \hat{\boldsymbol{y}}\right) = \sum_{i=1}^{m} L(y_i, \hat{y}_i) \tag{1.1}$$

$$\bar{C}(\mathbb{X}) = \frac{1}{p} \sum_{j=1}^{p} C\left(\boldsymbol{y}_j, \hat{\boldsymbol{y}}_j\right) \tag{1.2}$$

Eine Kostenfunktion C sollte folgende Eigenschaften aufweisen:

- C ist minimal, wenn $\boldsymbol{y} = \hat{\boldsymbol{y}}$
- C wächst mit $|\boldsymbol{y} - \hat{\boldsymbol{y}}|$
- C ist nach jedem y_n partiell differenzierbar (erklärt in Anhang (A))

(Nielsen, *Neural Networks and Deep Learning*)

1.2.1.1 Mittlere quadratische Abweichung

Die bekannteste Kostenfunktion ist die "Mittlere quadratische Abweichung". (engl.: mean squared error). Sie ist definiert als das arithmetische Mittel aller quadrierten Differenzen zwischen den Vorhersagen und Labels. Zusätzlich halbiert man noch das arithmetische Mittel, damit bei der Ableitung der Faktor 2 wegfällt. Sie hat keine entsprechene Verlustfunktion, da man so das arithemtische Mittel nicht ausgedrückt werden kann.
Die Kostenfunktion kann mithilfe einer Summe berechnen werden, oder in diesem Fall mithilfe einer Vektorsubtraktion Vorhersagen $\boldsymbol{y}$ von den Labels $\hat{\boldsymbol{y}}$.

$$C_{MSE} = \frac{1}{2n} \sum_{i=1}^{n} (\hat{y}_i - y_i)^2 = \frac{1}{2n} (\hat{\boldsymbol{y}} - \boldsymbol{y})^2 \tag{1.3}$$

Sie erfüllt alle Anforderungen an eine Kostenfunktion:

- Ihr Funktionwert ist 0 und minimal für $\boldsymbol{y} = \hat{\boldsymbol{y}}$
- Sie ist proportional zu $(\hat{\boldsymbol{y}} - \boldsymbol{y})^2$
- Ihre partielle Ableitung nach einem y_i lautet: $C'_{MSE} = \frac{1}{n}(y_i - \hat{y}_i)$

1.2.2 Stochastisches Gradientenverfahren

Beim Training eines Modells handelt es sich um ein Optimierungsproblem. Das Modell macht die besten Vorraussagen, wenn die Funktionswerte der Kostenfunktion am kleinsten sind. Deshalb muss die gewählte Kostenfunktion C minimiert werden. Hierbei muss die Funktion C nicht mehr in Abhängigkeit der Inputs und Outputs betrachtet werden, sondern als Funktion der Modellparameter $C(\lambda_1, \lambda_2, \ldots, \lambda_k)$. Denn diese Werte sollten angepasst werden, um das Modell zu verbessern.

Für diese Optimierung wird das sogenannte **Gradientenverfahren** (engl.: Gradient descent) verwendet. Das Gradientenverfahren ist eine gängige Methode, um Funktionen $f : \mathbb{R}^n \to \mathbb{R}$ zu minimieren [1]. Falls dem Leser das Prinzip nicht vertraut ist, wird auf Anhang (A) verwiesen, in welchem die Funktionsweise des Gradientenverfahrens erklärt wird.

[1] Üblicherweise wird auf Gymnasialstufe vermittelt, dass die lokalen Extrema einer Funktion f bestimmt werden können, indem die erste Ableitung f' gebildet und gleich null gesetzt wird. Dies ist hier jedoch nicht möglich, da die Funktion $C'(\lambda_1, \lambda_2, \ldots, \lambda_n)$ zu kompliziert ist, um die Nullstellen analytisch zu bestimmen. Deshalb wird hier das numerische Gradientenverfahren verwendet.

Das Gradientenverfahren zur Minimierung verläuft iterativ nach folgender Gleichung:

$$\boldsymbol{\lambda}_{t+1} = \boldsymbol{\lambda}_t - \eta \cdot \boldsymbol{\nabla} C(\boldsymbol{\lambda}_t) \tag{1.4}$$

Wie die initialen Modellparameter $\boldsymbol{\lambda}_{t=0}$ zu wählen sind, wird in Sektion (2.5.1) erläutert.

Die sogenannte **Lernrate** η aus Gleichung (1.4) stellt einen Hyperparameter dar. Sie ist der positive Proportionalitätsfaktor, welcher die Schrittgrösse des Gradientenabstiegs bestimmt. Je nach zu minimierender Funktion muss sie anders gewählt werden. Dies geschieht durch Ausprobieren. Falls η nicht gut gewählt wurde, ergeben sich Probleme beim Training:

- Falls η zu klein ist, verläuft das Trainings unnötig langsam. Ausserdem kann es passieren, dass die Optimierung bei einem hohen lokalen Minimum stecken bleibt.
- Falls η zu gross ist, kann es passieren, dass man über das lokale Minimum hinaus schiesst und somit nur darum herum springt.

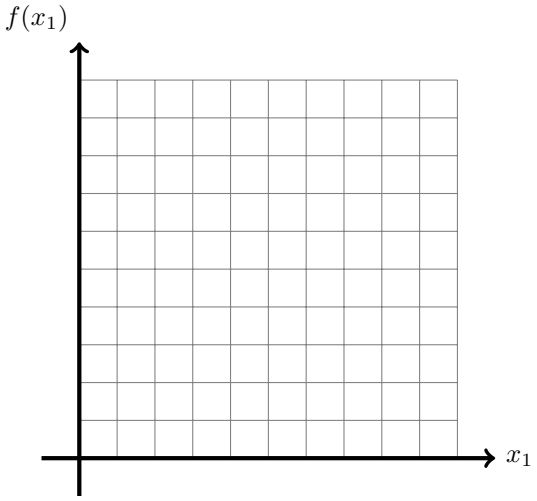

Abbildung 1.2: Visualisierung verschiedener Lernraten

Aus nachfolgend erläuterten Gründen wird für ML ein etwas angepasstes Verfahren des Gradientenabstiegs verwendet: das **Stochastische Gradientenverfahren** (SGD). Das Problem des herkömmlichen Gradientenverfahrens besteht darin, dass der Gradient für den *gesamten* Trainingsdatensatz berechnet werden muss. Dies ist zwar ein exakter Prozess, aber ein extrem langsamer zugleich. Bei grossen Datensätzen würde es sehr lange dauern, bis das Modell nur annähernd gute Vorhersagen machen könnte. Somit steht die Genauigkeit in keinem Verhältniss zur Effizienz dieser Methode.

Bei SGD wird der "echte" Gradient des gesamten Datensatzes mit dem Gradienten einiger Trainingssamples approximiert. Dazu wird der Trainingsdatensatz in sogenannte **Mini-Batches** eingeteilt und der Gradient jeweils pro Mini-Batch berechnet. Als Konsequenz finden deutlich mehr Iterationen in einer einzigen Durchkämmung der Trainingsdaten statt. Eine solche vollständige Durchkämmung der Trainingsdaten bezeichnet man als eine **Epoche**. Oft wird mehrere Epochen lang trainiert bis das Modell genügend gute Resultate liefert. Jedoch sollte auch nicht zu oft mit den gleichen Daten trainiert werden, da es sonst zu Overfitting (siehe Sektion 1.3.2) kommen kann. Der Gradienten eines genug grossen Mini-Batches ist zwar nicht ganz exakt, aber approximiert den Gradieten des gesamten Datensatzen genügend gut. Sowohl die Mini-Batch Grösse, wie auch die Anzahl Epochen sind weitere Hyperparameter.

Die partiellen Ableitungen der gesamten Trainingsdaten werden mit dem arithmetischen Mittel der partiellen Ableitungen eines Mini-Batches der Grösse q approximiert.

$$\frac{\partial \bar{C}}{\partial \lambda_k} \approx \frac{1}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_k} \tag{1.5}$$

Eine Iteration des Stochastischen Gradientenverfahrens wird analog zu Gleichung (1.4) folgendermassen durchgeführt.

$$\lambda_{k,t+1} = \lambda_{k,t} - \frac{\eta}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_{k,t}} \tag{1.6}$$

(Nielsen, *Neural Networks and Deep Learning*)

1.3 Trainingsphänomene

1.3.1 Konvergenz und Divergenz

Beim Training eines Modells kann es entweder zu **Konvergenz** oder **Divergenz** kommen. Falls die Vorhersagen im Verlaufe des Trainings immer besser mit den Labels übereinstimmen, bzw. die Kostenfunktion immer kleiner wird, gilt das Modell als konvergierend. Also findet das Gradientenverfahren erfolgreich ein lokales Minimum.

Jedoch kommt auch vor, dass ein Modell nicht konvergiert oder vielleicht sogar divergiert. Bei Divergenz werden die Kosten im Verlaufe des Training immer grösser. Dies kann verschiedene Gründe haben. Einige davon können sein:

- zu wenig Trainingsdaten
- zu schwache Korrelation zwischen Inputs und Labels
- falsche Hyperparameter
- falsches Modell

1.3.2 Underfitting und Overfitting

Falls ein Modell konvergiert, heisst das noch nicht, dass es die Gesetzmässigkeiten innerhalb der Trainingsdaten richtig erlernt hat. Im Wesentlichen kann es zu zwei Problemen: Overfitting oder Underfitting.

Overfitting bezeichnet das Phänomen, dass ein Modell zwar Vorhersagen erzeugt, welche jedoch zu stark an die gegeben Trainingssamples angepasst sind. Dies liegt zumeist daran, dass das Modell zu viele Parameter besitzt oder aber der Trainingsdatensatz zu wenige Samples dafür beinhaltet. Somit übersteigt die Komplexität des Modells gewissermassen jede der Aufgabenstellung.

Um das Phänomen zu verdeutlichen, wird ein lineares Regressionmodell betrachtet. Dieses besitzt eine Hypothesenfunktion $h = a_0 + a_1 x + a_2 x^2 + \cdots + a_n x^n$, welche ein Polynom n-ter Ordnung ist. Falls der Trainingsdatensatz nun aus n oder weniger Samples besteht, kann das Modell die Regressionkurve der Hypothesenfunktion exakt durch jeden Datenpunkt legen. Dies entspricht dem Verhalten eines Modells mit n Modellparametern, welches mit n Samples trainiert wird, und dabei exakt jedes Samples auswendig lernt anstatt dessen Gesetzmässigkeiten zu erkennen.
Beim Auswendiglernen misst das Modell dem Datenrauschen zu viel Bedeutung zu, welches durch die natürliche Varianz innerhalb der Trainingsdaten entsteht. Somit nutzt es irrelevante Modellparameter, um das Rauschen zu kopieren.
Dadurch kann das Modell zwar sehr gute Vorhersagen zum Trainingsdatensatz $\mathbb{X}$ machen, jedoch würde es schlechte Vorhersagen für einen anderen Testdatensatz $\mathbb{T}$ liefern, welchen es nicht auswendig lernen konnte.

Somit kann Overfitting folgendermassen definiert werden: Eine Hypothesenfunktion h overfittet dann, wenn eine alternative Hypothesenfunktion h' exisitert, für welche die Kosten bezüglich dem Trainingsdatensatz grösser sind $\bar{C}_{h'}(\mathbb{X}) > \bar{C}_h(\mathbb{X})$, jedoch die Kosten für Testdatensatz kleiner sind $\bar{C}_{h'}(\mathbb{T}) < \bar{C}_h(\mathbb{T})$.

Das Gegenteil von Overfitting ist **Underfitting**. Dabei handelt es sich um das Phänomen, dass eine Hypothesenfunktion h zu wenige Modellparameter λ_k besitzt, um die Komplexität der Aufgabenstellung zu bewältigen. Die Parameter reichen nicht aus, damit das Modell die Korrelation zwischen Inputs und Labels begreifen kann.

Bezogen auf das lineare Regressionmodell, bedeutet dies, dass der Grad n der polynomen Hypothesenfunktion h zu gering ist, um sich an die Datenpunkte der Sampels anzuschmiegen.
(Mehrere, *Überanpassung — Wikipedia, Die freie Enyklopädie*)

	Underfitting	Just right	Overfitting
Symptoms	- High training error - Training error close to test error - High bias	- Training error slightly lower than test error	- Low training error - Training error much lower than test error - High variance
Regression	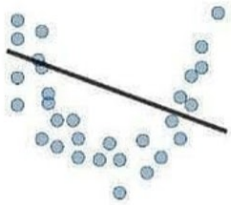		
Classification	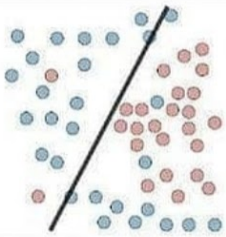	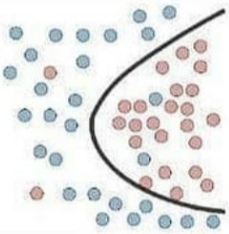	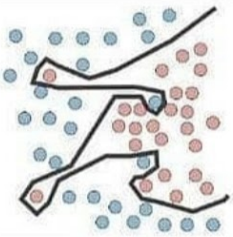
Deep learning	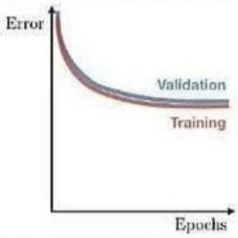	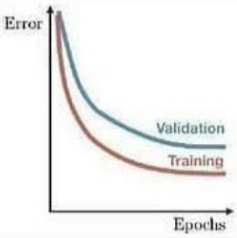	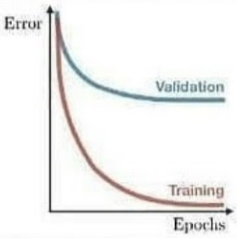
Remedies	- Complexify model - Add more features - Train longer		- Regularize - Get more data

Abbildung 1.3: Visalierung von Under- und Overfitting

Kapitel 2

Deep Learning und Künstliche Neuronale Netze

Nach dem im ersten Kapitel die Basis für ein fundiertes Verständnis von Maschinellem Lernen gelegt worden ist, soll es nun im zweiten Kapitel darum gehen, ein spezifisches Modell, namentlich Künstliche Neuronale Netze, zu erläutern. Darauf aufbauend wird in Kapitel drei die spezifische Architektur eines Künstlichen Neuronalen Netzes, namentlich das Convolutional Neural Network, dargelegt.

Die wohl besten Resultate für die meisten Problemstellungen des Maschinellen Lernens (Bilderkennung, Spracherkennung, etc.) werden durch **Künstliche Neuronale Netze** (KNN) (engl.: Neural Network) geliefert. Man bezeichnet diesen Bereich des Maschinellen Lernens auch als **Deep Learning**[1].

Künstliche Neuronale Netze sind vor allem biologisch durch Nervensystemen von Lebewesen inspiriert. Sie sind aber lediglich eine Abstraktion dieser Informationverarbeitung und versuchen nicht eine möglichst genaue biologische Abbildung zu kopieren. Es gibt nicht nur eine Art von Neuronalem Netz, sondern es existieren die verschiedensten Architekturen, welche je nach Problemstellung ausgewählt werden müssen. Diese Arbeit wird vor allem von zwei solcher Architekturen Gebrauch machen: Convolutional Neural Networks und sogenannte Autoencodern.

(Mehrere, *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*)

2.1 Perzeptron

Um den Aufbau und die Funktion eines Künstlichen Neuronalen Netzes besser zu verstehen, wird im folgenden ein Vorgänger des KNN erklärt: das **Perzeptron**.

Das einlagige Perzeptron wurde erstmals 1958 von Frank Rosenblatt vorgestellt (QUELLE). Dieses besteht aus einem einzigen Künstlichen Neuron. Dieses künstliche Neuron hat mehrere binäre Inputs und einen einzigen binären Output. Binär bedeutet, dass der Wert nur entweder 0 (*aus*) oder 1 (*ein*) sein kann. Des weiteren besitzt es mehrere sogenannte **Gewichte** $w_1, \ldots, w_m \in \mathbb{R}$, für jeden Input x_i ein Gewicht w_i. Diese sind reelle Zahlen, welche das Verhalten des Perzeptron bestimmen. Die **gewichtete Summe**, also die Summe aller Produkte der Inputs mit ihrem Gewicht, wird mit $\tilde{z}$ bezeichnet. Sie ist das gleiche wie das Skalarprodukt des Gewichtevektors $\boldsymbol{w} = \begin{pmatrix} w_1 & \cdots & w_n \end{pmatrix}^\mathsf{T}$ mit dem Inputvektor $\boldsymbol{x}$.

$$\tilde{z} = \sum_{i=1}^{m} w_i x_i = \boldsymbol{w} \cdot \boldsymbol{x}$$

Zusätzlich besitzt das Perzeptron einen **Schwellenwert** $\tilde{b}$. Zusammen mit den Gewichten, bilden sie die Modellparameter. Das Perzeptron verhält sich so, dass, falls die gewichtete Summe $\tilde{z}$ grösser als der Schwellenwert $\tilde{b}$ ist, das Neuron feuert, d.h. der Output 1 beträgt. Andernfalls ist er 0 (siehe erster Teil der Hypothesenfunktion h in Gleichung (2.1)). Es ist gängig, die Ungleichung der Bedingung in die Nullstellenform zu bringen und $\tilde{b}$ durch die **Neigung** (engl.: bias) $b = -\tilde{b}$ zu ersetzten. Somit lautet die Ungleichung: $\tilde{z} + b > 0$. Der neue Term $\tilde{z} + b$ wird mit z bezeichnet (siehe Rest der Gl. (2.1)). Die Neigung gibt an, wie stark das Neuron dazu neigt zu feuern.

[1] WEITERFÜHRENDE QUELLEN BÜCHER

$$h(\boldsymbol{x}) = \begin{cases} 1 & \text{falls } \tilde{z} > \tilde{b} \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \tilde{z} + b > 0 \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \boldsymbol{w} \cdot \boldsymbol{x} + b > 0 \\ 0 & \text{ansonsten} \end{cases} \tag{2.1}$$

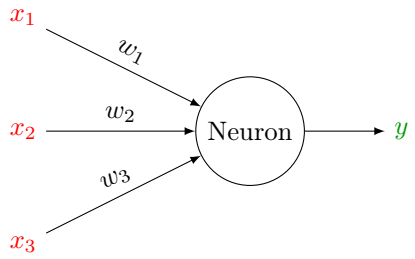

Abbildung 2.1: Perzeptron mit drei Inputs

Für das Trainieren des Perzeptrons existieren spezielle Verfahren, welche hier aber nicht weiter beleuchtet werden sollen. Dies aus dem Grund, weil das Gradientenverfahren hier nicht verwendet werden kann. Der Grund dafür soll später in Sektion (2.2) erläutert werden.

(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.1.1 Lernpotenzial eines Perzeptrons

Nun stellt sich die Frage, was ein Perzeptron eigentlich erlernen kann und wofür es nutzbar ist. Das Perzeptron ist lediglich ein **linearer Klassifikator** der Form $y = w_1 x_1 + \cdots + w_m x_m$. Es ist also ein Klassifizierungsmodell und kein Regressionsmodell. Es kann die Features in zwei Klassen 0 oder 1 einordnen, wobei der Output der Hypothesenfunktion diese Klassifizierung angibt. Überschreitet y den Schwellenwert $\tilde{b}$, werden die Features der Klasse 1 zugeordnet, sonst der Klasse 0. Jedoch müssen diese Klassen linear separierbar sein.

Lineare Separierbarkeit bedeutet, dass alle Featurevektoren $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p \in \mathbb{R}^m$ innerhalb ihres Vektorraums $\mathbb{R}^m$ durch eine Hyperebene in ihre Klassen aufteilbar sein müssen. Falls das Perzeptron zwei Inputs besitzt, bedeutet dies, dass die Ortsvektoren durch eine Gerade voneinander trennenbar sein müssen (siehe Abb. (2.2)).
Falls die Features nicht linear separierbar sind, kann das Perzeptron die Klassifizierung nicht erlernen.

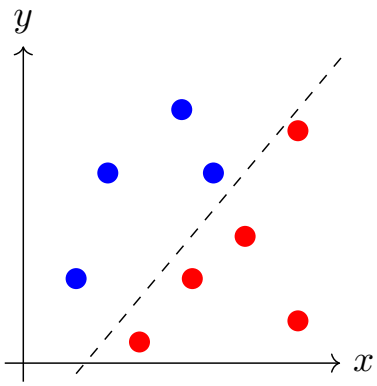

Abbildung 2.2: zwei-dimensionale lineare Separierung

(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Linear separability — Wikipedia, The Free Encyclopedia*)

2.2 Erweiterung der künstlichen Neuronen

Ein Perzeptron ist, wie vorhin erklärt, nur in der Lage, lineare Klassifikationen durchzuführen. Um nun auch Regressionsprobleme zu lösen, muss das Konzept ausgebaut werden. Ausserdem brauchen wir ein Künstliches Neuron benötigt, welches sich besonders gut als Baustein für KNNs eignet.

2.2.1 Künstliche Neuronen im Allgemeinen

Künstliche Neuronen sind immer so aufgebaut, dass sie einen oder mehrere Inputs und nur einen einzigen Output besitzen. Zu jedem Input x_i ist ein Gewicht w_i assoziert. Zuerst wird die gewichtete Summe der Inputs $\tilde{z}$ gebildet. Die Neigung b wird ebenfalls dazu addiert, um z zu erhalten. Nun muss die sogenannte **Aktivierung** a gebildet werden. Sie ist der Output des Neurons. Die Aktivierung $a = \varphi(z)$ ist das Resultat der **Aktivierungsfunktion** $\varphi : \mathbb{R} \to \mathbb{R}$ angewendet auf z. Die verschiedenen künstlichen Neuronen unterscheiden sich fast nur in ihrer Aktivierungsfunktion.

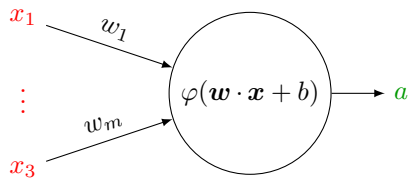

Abbildung 2.3: ein künstliches Neuron

(Nielsen, *Neural Networks and Deep Learning*)
(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)

2.2.2 Perzeptronen als künstliche Neuronen

Nun nochmal ein Blick auf das Perzeptron im Angesicht der Aktivierungsfunktion. Ein wesentlicher Unterschied des Perzeptrons gegenüber sonstigen künstlichen Neuronen, besteht darin, dass seine Inputs und Outputs nur binäre Werte annehmen können. Um dieses Verhalten des Perzeptrons zu erhalten, muss eine Stufenfunktion als Aktivierungfunktion verwendet werden: die Heaviside-Funktion Θ. Sie hat einen einzigen Stufensprung bei $x = 0$ vom Wert 0 auf 1 (siehe Abb. (2.4)).

$$\varphi^{\text{hlim}}(z) = \Theta(z) = \begin{cases} 1 & \text{falls } z \geq 0 \\ 0 & \text{falls } z < 0 \end{cases}$$

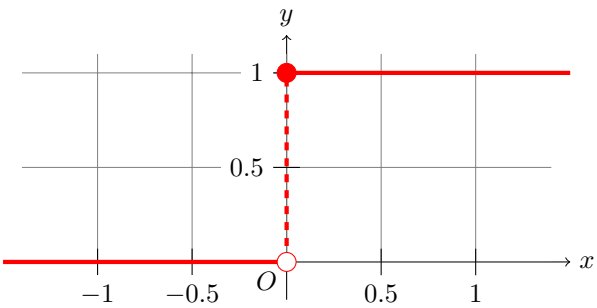

Abbildung 2.4: Definition und Graph der Heaviside-Funktion Θ

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)

2.2.3 ReLU Neuronen

Der nächste Schritt nach einer Stufenfunktion als Aktivierungsfunktion, sind lineare Aktivierungsfunktionen. Für diese können die Inputs nun beliebige reelle Zahlen sein. Jedoch sind solche lineare Neuronen in einem KNN von keinerlei Nutzen. Dies ist dadurch begründet, dass eine Verkettung von linearen Neuronen immer auf eine einzige lineare Funktion reduziert werden kann. Somit hat die Verkettung keinen Mehrwert.

Stattdessen verwendet man sogenannte ReLU Neuronen. Sie benutzen die **Rectified Linear Unit** (**ReLU**) als Aktivierungsfunktion. Diese ist eine nur teilweise lineare Aktiverungsfunktion. Die Werte grösser als 0 werden auf sich selbst linear abbgebildet und die Werte kleiner als 0 werden auf 0 abbgebildet (siehe Abb. (2.5)). Eine sehr wichtige Eigenschaft der ReLU-Funktion ist, dass sie - im Gegensatz zu den vorhin Heaviside-Funktion

Θ - fast überall differenzierbar[2]und strikt monoton steigend ist. Erst für diese Aktivierungsfunktion kann das Gradientenverfahren angewendet und somit das KNN trainiert werden.

Da die ReLU-Funktion nur teilweise linear ist, gehört sie genaugenommen den nicht-linearen Aktiverungsfunktionen an. Diese Nicht-Linearität erlaubt es dem Neuron, deutlich komplexere Systeme zu modellieren bzw. deutlich komplexere Probleme zu lösen. In Sektion (2.7) wird dargelegt, dass eine Kompostion von nicht-linearen Neuronen jede beliebige Funktion approximieren kann.

Das ReLU-Neuron werden wir an dieser Stelle zur Seite legen und erst wieder in Kapitel (3) im Zusammenhang mit KNNs zur Bilderkennung wieder betrachten.

$$\varphi^{\mathrm{ReLU}}(z) = \begin{cases} z & \text{falls } z > 0 \\ 0 & \text{falls } z \leq 0 \end{cases} = \max(z, 0) \qquad (2.2)$$

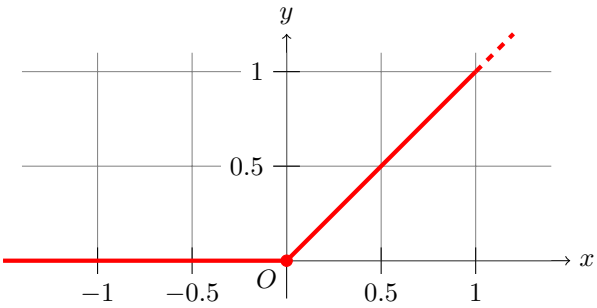

Abbildung 2.5: Formel und Graph der ReLU-Funktion

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.2.4 Sigmoid Neuronen

Ein weiteres nicht-lineares Neuron sind sogenannte Sigmoid-Neuronen. Den Namen haben sie von ihrer Aktivierungsfunktion: der Sigmoidfunktion σ.

Auch sie können in einem KNN aufgrund ihrer Nicht-Linearität zur Approximation jeder Funktion verwendet werden. Die Sigmoidfunktion gilt als meist verwendete Aktivierungsfunktion in KNNs. Dies ist damit begründet, dass sie sehr stark von der Linearität abweicht und auf diese Weise am schnellsten komplexe Sachverhalte modellieren kann. (QUELLE)

Die Sigmoid-Funktion besitzt eine einzige Wendestelle $\sigma''(x = 0) = 0$ und hat zwei Asymptoten, eine $\lim\limits_{x \to -\infty} \sigma(x) = 0$ und eine zweite $\lim\limits_{x \to \infty} \sigma(x) = 1$ (siehe Abb. (2.6)). Desweiteren zeichnet sie sich durch eine vergleichsweise einfache Ableitung aus.

$$\varphi^{\mathrm{sig}}(z) = \sigma(z) = \frac{1}{1 + e^{-z}}$$
$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

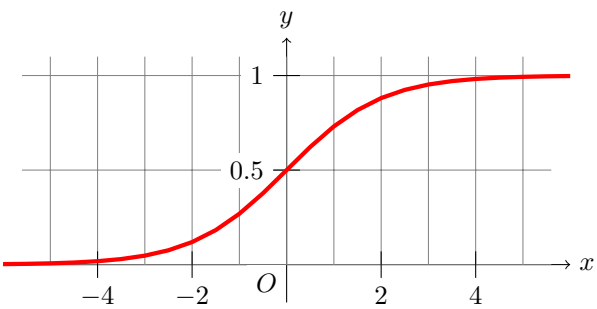

Abbildung 2.6: Definition, Ableitung und Graph der Sigmoid-Funktion σ

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Sigmoidfunktion — Wikipedia, Die freie Enyklopädie*)

[2]Eigentlich ist die ReLU-Funktion in $x = 0$ wegen des Knicks nicht differenzierbar. Für die Gradientenberechnung definiert man jedoch einfach die Ableitung $\varphi'^{\mathrm{ReLU}}(0) := 0$. Dies ist mathematisch zwar nicht korrekt, löst aber das Problem.

2.3 Topologie der Künstlichen Neuronalen Netze

Nun sollen die Sigmoiden-Neuronen als Bausteine für Künstliche Neuronale Netze Verwendung finden. Dazu werden sie miteinander verbunden und bilden so ein Netz, ähnlich wie ein Nervensystem.

Diese Neuronen sind in verschiedenen Schichten (engl.: Layers) arrangiert. Die erste ist die **Inputschicht**. Sie beinhaltet die Inputneuronen. Diese sind eigentlich keine richtigen Neuronen, sondern eher Platzhalter für ihr jeweiliges Feature x_i. Als letztes kommt die **Outputschicht** mit den Outputneuronen, welche jeweils einen Outputwert y_i besitzen. Dazwischen liegen die **Zwischenschichten** (engl.: hiddenlayers). Von ihnen kann es beliebig viele geben, und in ihnen können beliebig viele Neuronen liegen. Falls viele Zwischenschichten verwendet werden, bezeichnet man das Netzwerk als "deep". Daher rührt auch der Begriff des Deep Learnings. Den Aufbau eines KNN bezeichnet man als **Topologie** des Netzes. Die Topologie umfasst viele Hyperparameter. Darunter sind zum Beispiel die Anzahl der Zwischenschichten, wie auch die Anzahl der Neuronen pro Schicht.

Jedes Neuron aus einer Schicht ist mit jedem Neuron aus der nächsten Schicht über Verbindungen gekoppelt. Alle Verbindungen besitzten ein Gewicht analog zu den Inputs des Perzeptrons. Die Aktivierung, also der Output, eines Neurons wandert entlang den jeweiligen Verbindungen zu allen Neuronen der nächsten Schicht und dienen als deren Input.

In Abbildung (2.7) ist ein Beispiel eines Neuronalen Netzes abgebildet. In diesem Fall besitzt es sowohl 4 Inputs, als auch 4 Outputs. Es hat ausserdem 3 Zwischenschichten. Die erste und die dritte haben jeweils 3 Neuronen und die zweite besitzt 4 Neuronen.

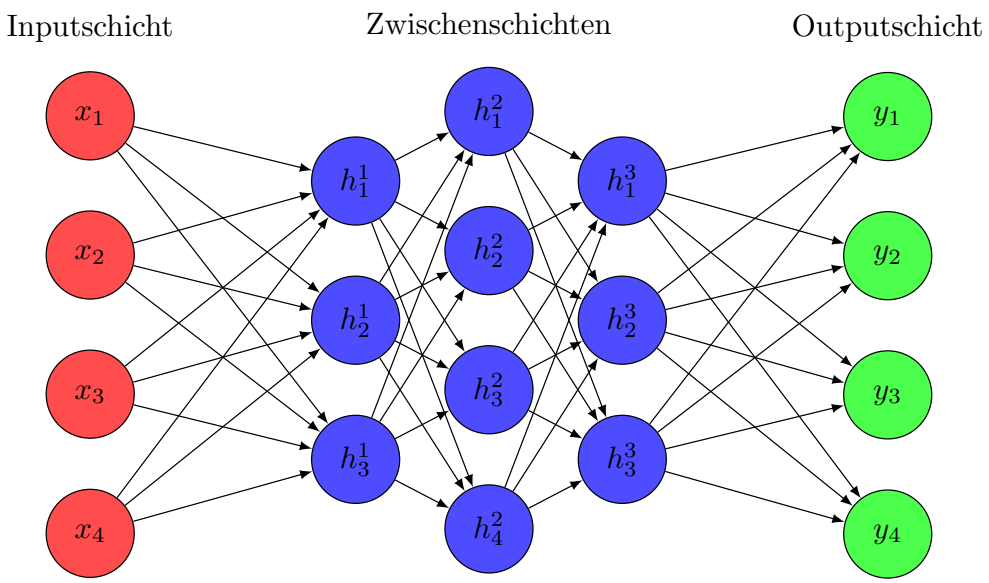

Abbildung 2.7: Schichten eines KNNs

(Mehrere, *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.4 Lernverhalten

Die Hoffnung beim Trainieren von KNNs besteht darin, dass das Modell für jede weitere Schicht eine höheres Abstraktionsniveau erreicht. Würde man zum Beispiel ein Netzwerk zur Gesichtserkennung trainieren, könnte man sich den Erkennungsprozess folgendermassen vorstellen: Die erste Zwischenschicht erkennt Kanten und Konturen. Die zweite vereint diese Merkmale zu Ecken und primitiven geometrischen Formen. Die dritte Schichte sollte dann schon komplexere geometrische Formen erkennen, welche gewissen Gesichtmerkmalen, wie der Nase, ähneln. Die letzten Schichten soll dann alle diese Merkmale zusammensetzen und so ein Gesicht als Ganzes erkennen.

2.5 Vorwärtspropagierung

Jetzt, da der Aufbau eines KNNs erläutert wurde, soll nun die mathematische Funktionsweise des Modells erklärt werden. Der Prozess der Berechnung der Outputwerte wird **Vorwärtspropagierung** genannt. Dieses Verfahren gibt dieser Art von KNN auch den Namen: Feedforward Neural Network. Für das Verständnis müssen einige Konventionen zur Bezeichnung der Teile eines KNNs getroffen werden. Es sollten vor allem noch Abbildungen (2.8) und (2.9) zum Verständnis der Nomenklatur studiert werden.

- l ist der Index einer Schicht. Die Indexierung beginnt bei 0.
- L ist der letzte Schichtindex und somit auch die gesamte Anzahl an Schichten (ohne die Inputschicht).
- $|l|$ ist die Anzahl Neuronen in der l-ten Schicht. [3]
- n_j^l bezeichnet das j-te Neuron in der l-ten Schicht.
- z_j^l ist die gewichtete Summe der Inputs des j-ten Neuron in der l-ten Schicht.
- a_j^l ist die Aktivierung/Output des j-ten Neurons in der l-ten Schicht.
- b_j^l ist die Neigung für das j-te Neuron in der $(l+1)$-ten Schicht. [4]
- $w_{j,k}^l$ ist das Gewicht der Verbindung vom k-ten Neuron in der l-ten Schicht zum j-ten Neuron in der $(l+1)$-ten Schicht. [5]
- φ ist die gewählte Aktivierungsfunktion (diese ist immer eine nicht-lineare Aktivierungsfunktion)

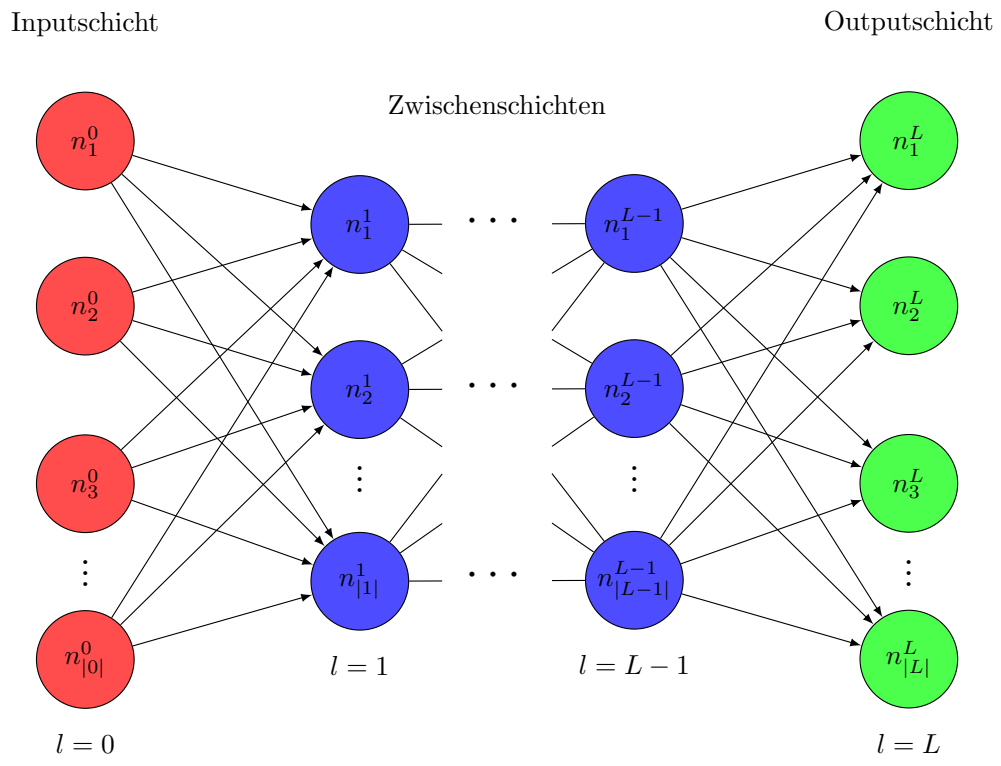

Abbildung 2.8: zum Verständnis der Nomenklatur

Die Vorwärtspropagierung beginnt bei den Inputneuronen, welche jeweils einen Inputwert in sich tragen. Diese Werte werden, um für eine kohärente Nomenklatur zu sorgen, analog zu den Aktivierungen der anderen Neuronen mit a_j^0 bezeichnet, wobei j der Index des Neurons ist.
Nun müssen die restlichen Aktivierungen der Neuronen bis und mit den Ouputneuronen berechnet werden. Dies

[3] Diese Schreibweise hat nichts mit dem Betrag zu tun, sondern wird gewählt, da sie sehr platzsparend ist.
[4] Diese Konvention wurde gewählt, damit die folgenden Gleichungen simpler sind.
[5] Man beachte die Reihenfolge!
Diese Konvention scheint zwar auf den ersten Blick unintuitiv, macht jedoch Sinn für die Matrixindezierung. (2.6).

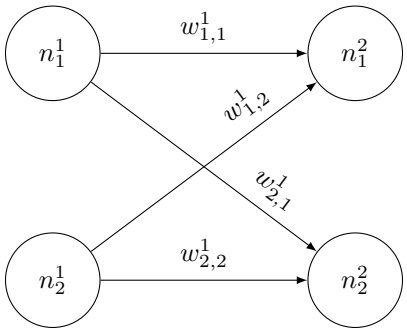

Abbildung 2.9: zum Verständnis der Gewichtebeschriftungen

geschieht rekursiv anhand der Aktivierungen der voherigen Schicht und zwar folgendermassen (ersichtlich in Gleichung (FP1)).

Zuerst läuft eine Summe über alle Neuronen n_k^l der jetztigen Schicht l. Dabei wird die gewichtete Summe der Aktivierungen a_k^l mit den assozierten Gewichten $w_{j,k}^l$ gebildet. Hierbei ist das Gewicht jenes, welches das k-te Neuron der l-ten Schicht mit dem j-ten Neuron der $(l+1)$-ten Schicht verbindet (siehe Abb. (2.9)). Zusätzlich gehört zu der gewichteten Summe auch die jeweilige Neigung b_j^l, welche dazu addiert wird. Diese gewichtete Summe wird mit z_j^{l+1} bezeichnet.

$$z_j^{l+1} = \sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l \tag{FP1}$$

Auf diese Summe wird dann die Aktivierungsfunktion φ angewandt. Das ist dann die Aktivierung a_j^{l+1} des j-ten Neurons in der $(l+1)$-ten Schicht.

$$a_j^{l+1} = \varphi\left(\sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l\right) = \varphi\left(z_j^{l+1}\right) \tag{FP2}$$

Für Deep Learning braucht man vor allem sogenannte Deep Neural Networks. Diese zeichnen sich dadurch aus, dass sie sehr viele Zwischenschichten besitzen. Deshalb bezeichnet man sie als “deep”. Bei solchen Netzwerken ist es nicht unüblich, dass sie sehr viele Neuronen und Verbindungen (über 100’000) besitzen. Um hier nicht den Überblick zu verlieren bzw. damit nicht zu viele Indizes notwendig sind, macht man Gebrauch von **Linearer Algebra**. Man verwendet Matrizen und Vektoren, um die vielen Variablen zusammenzufassen. Ausserdem besteht ein weiterer Vorteil darin, dass Computer mithilfe von Vektor- und Matrixoperationen die Berechnungen parallelisieren können und in kürzerer Zeit und mit weniger Ressourcen viele Berechnungen gleichzeitig ausführen können. Dies beschleunigt das Training der Modelle um ein Vielfaches. Später in Sektion (5.1) wird dies nochmals thematisiert.

Die Inputs $\boldsymbol{x}$, Vorhersagen $\boldsymbol{y}$ und Labels $\hat{\boldsymbol{y}}$ wurden bereits zu Beginn als Vektoren geschrieben. Nun sollen noch die Modellparameter und die restlichen Komponenten eines KNNs als Vektoren und Matrizen zusammengefasst werden. Sowohl alle gewichteten Summen z_j^l, wie auch alle Aktivierungen a_j^l einer Schicht l, werden in Vektoren $\boldsymbol{z}^l \in \mathbb{R}^{|l|}$ und $\boldsymbol{a}^l \in \mathbb{R}^{|l|}$ zusammengefasst. Auch alle Neigungen b_j^l für eine Schicht $(l+1)$ bilden einen Vektor $\boldsymbol{b}^l \in \mathbb{R}^{|l+1|}$.

Zu guter letzt, wird noch eine **Gewichtsmatrix** $\boldsymbol{W}^l \in \mathbb{R}^{|l+1|\times|l|}$ definiert. Sie enthält alle Gewichte, welche die l-te Schicht *zu* der $(l+1)$-ten Schicht verbindet. Das heisst, der Eintrag in der j-ten Zeile und in der k-ten Spalte ist $w_{j,k}^l$ und verbindet so das Neuron n_k^l zu dem Neuron n_j^{l+1}.

$$\boldsymbol{z}^l = \begin{pmatrix} z_1^l & z_2^l & \cdots & z_{|l|}^l \end{pmatrix}^\mathsf{T}$$
$$\boldsymbol{a}^l = \begin{pmatrix} a_1^l & a_2^l & \cdots & a_{|l|}^l \end{pmatrix}^\mathsf{T}$$
$$\boldsymbol{b}^l = \begin{pmatrix} b_1^l & b_2^l & \cdots & b_{|l+1|}^l \end{pmatrix}^\mathsf{T}$$

$$\boldsymbol{W}^l = \begin{pmatrix} w^l_{1,1} & w^l_{1,2} & \cdots & w^l_{1,|l|} \\ w^l_{2,1} & w^l_{2,2} & \cdots & w^l_{2,|l|} \\ \vdots & \vdots & \ddots & \vdots \\ w^l_{|l+1|,1} & w^l_{|l+1|,2} & \cdots & w^l_{|l+1|,|l|} \end{pmatrix}$$

Mit diesen Definitionen kann Gleichung (FP1) in Matrixform geschrieben werden. Dies, weil die Matrixmultiplikation von $\boldsymbol{W}^l$ mit $\boldsymbol{a}^l$ einen Vektor $\tilde{\boldsymbol{z}}^{l+1}$ ergibt, welcher alle gewichteten Summen $\tilde{z}^{l+1}_j$ ohne die jeweilige Neigung enthält.

$$\boldsymbol{W}^l\boldsymbol{a}^l = \begin{pmatrix} \sum_{j=1}^{|l|} w^l_{1,j}a^l_j & \sum_{j=1}^{|l|} w^l_{2,j}a^l_j & \cdots & \sum_{j=1}^{|l|} w_{|l+1|,j}a^l_j \end{pmatrix}^{\mathsf{T}} = \tilde{\boldsymbol{z}}^{l+1}$$

Nun muss noch der Neigungsvektor $\boldsymbol{b}^l$ dazu addiert werden, damit die Gleichung (FP1a) ensteht, mit welcher der Vektor der gewichteten Summen $\boldsymbol{z}^{l+1}$ gebildet werden kann.

$$\boldsymbol{z}^{l+1} = \mathbf{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l \tag{FP1a}$$

Im letzten Schritt wird die Aktivierungsfunktion auf $\boldsymbol{z}^{l+1}$ angewendet, um den Aktivierungsvektor $\boldsymbol{a}^{l+1}$ zu bilden. Hierfür muss aber noch ein neues mathematisches Konzept eingeführt werden: die Vektorisierung einer Funktion.

Vektorisierung einer Funktion

Die Vektorisierung einer skalaren Funktion f, geschrieben als $\boldsymbol{f}[\boldsymbol{v}]$ hat als Argument einen Vektor $\boldsymbol{v}$, auf dessen Komponenten jeweils *einzeln* die Funktion f angewendet wird. Dieser neue Vektor ist der Rückgabewert der Funktion. Er besitzt die gleichen Dimensionen wie der Argumentvektor.

$$\boldsymbol{f}[\boldsymbol{v}] = \begin{pmatrix} f(v_1) \\ \vdots \\ f(v_n) \end{pmatrix}$$

Nun kann die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf $\boldsymbol{z}^{l+1}$ angewendet werden.

$$\boldsymbol{a}^{l+1} = \boldsymbol{\varphi}\left[\boldsymbol{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l\right] = \boldsymbol{\varphi}\left[\boldsymbol{z}^{l+1}\right] \tag{FP2a}$$

(Nielsen, *Neural Networks and Deep Learning*)

2.5.1 Initialisierung der Modellparameter

Ein weiterer Schritt, der vollzogen werden muss, bevor das Training beginnen kann, ist das Initialisieren aller Modellparameter, in diesem Fall die Gewichte und Neigungen. Dies ist ein sehr essentieller Schritt, da diese Initialwerte die Leistungsfähigkeit des Modells erheblich beinflussen.

Wie in Sektion (1.2.2) gezeigt, muss am Anfang des Gradientenverfahrens ein Startpunkt $\boldsymbol{\lambda}_{t=0} = \begin{pmatrix}\lambda_1 & \cdots & \lambda_k\end{pmatrix}^{\mathsf{T}}$ innerhalb des Gradientenfeldes $\boldsymbol{\nabla}C$ gewählt werden, von welchem aus der Gradientenabstieg beginnt. Dieser Startpunkt entscheidet darüber, in welches lokale Minimum konvergiert wird und bestimmt somit auch die bestmögliche Exaktheit der Vorhersagen. Falls schlechte Initialwerte gewählt wurden, konvergiert der Punkt in ein hohes lokales Minimum, was grosse Kostenfunktionswerte und schlechte Vorhersagen verursacht.

Es ist nicht möglich im Vorhinein zu wissen, welche Initialwerte gute Resultate liefern. Es müssen verschiedene Werte ausprobiert werden. Dafür initialisert man gängierweise die Hyperparameter mit Zufallswerten. Zu diesem Zweck werden nicht irgendwelche Zufallsvariablen verwendet, sondern es gelangt die Gauss'sche Normalverteilung $\mathcal{N}(\mu, \sigma^2)$ bzw. ihre Dichtefunktion zur Anwendung.

$$\phi(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

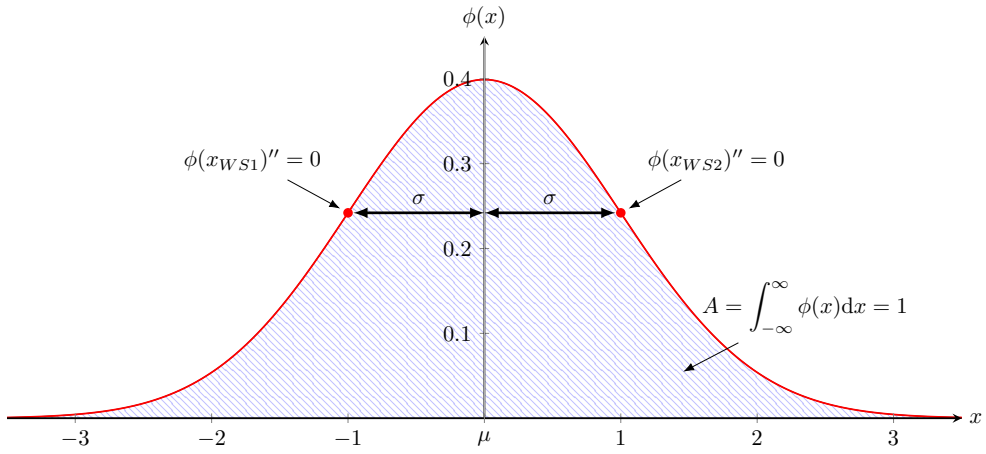

Abbildung 2.10: Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften

In den Anfängen des Maschinellen Lernens wurde häufig die normierte Normalverteilung verwendet. Jedoch hatte dies zur Konsequenz, dass mit jeder Schicht die Outputs eine stetig grösser werdende Standardabweichung σ aufwiesen. In der Konsequenz verlansamte sich der Lernprozess ohne nahe genug am lokalen Minimum zu sein. Dies wird auch als Saturierung der Neuronen bezeichnet (FUSSNOTE?).

In der Konsequenz wurde eine neue Technik entwickelt: die Glorot-Initalisierung (auch Xavier-Initalisierung genannt). Dabei gelangt erneut eine Normalverteilung mit Erwartungswert $\mu = 0$ zur Anwendung. Die Standardabweichung σ wird anhand der Grösse einer Schicht skaliert. Für eine Schicht l wird der Durchschnitt zwischen der Anzahl Inputs und der Anzahl Neuronen einer Schicht berechnet $r = \frac{|l-1|+|l|}{2}$. Der Kehrwert davon ist die Varianz der Normalverteilung. Die Gewichte werden folgendermassen initialisert:

$$w^l_{t=0} \sim \mathcal{N}\left(\mu = 0, \sigma^2 = \frac{2}{|l-1| + |l|}\right) \tag{2.3}$$

Durch dieses Verfahren bleibt die Varianz innerhalb einer Schicht erhalten. Teilweise wird diese Verfahren auch für die Neigungen b angewendet. Eine andere Möglichkeit besteht in der Initalisierung der Neigungen mit 0, wie Keras das etwa auch macht.

$$b^l_{t=0} = 0 \tag{2.4}$$

(Mehrere, *Normal distribution — Wikipedia, The Free Encyclopedia*)
(Nielsen, *Neural Networks and Deep Learning*)
(Géron, *Hands-On Machine Learning with Scikit-Learn and TensorFlow*)

2.6 Rückwärtspropagierung

Ein KNN wird üblicherweise, wie die meisten Modelle, mithilfe des Stochastischen Gradientenverfahrens trainiert. Die wahre Herausforderung besteht darin, die partiellen Ableitungen der Kostenfunktion bezüglich der Modellparameter zu berechnen. Anders gesagt müssen alle Terme $\frac{\partial C}{\partial w^l_{j,k}}$, wie auch alle Terme $\frac{\partial C}{\partial b^l_k}$, bestimmt werden. Das Verfahren zur Ermittlung dieser Ausdrücke ist so spezifisch und aufwendig, dass das SGD für KNNs einen eigenen Namen besitzt: die sogennante **Rückwärtspropagierung** (engl.: backpropagation, auch Fehlerrückführung).
Für das Verständnis von ML ist es nicht essentiell, die Rückwärtspropagierung zu verstehen. Jedoch kann so nachvollzogen werden, wie SGD in der Praxis funktioniert.

Grob umrissen besteht der Grundgedanke darin, die Werte der Kostenfunktion rückwärts durch das Modell zu schicken und dabei die partiellen Ableitungen mithilfe der Kettenregel zu bestimmen. Daher hat das Verfahren auch seinen Namen.

Für eine ausführliche Herleitung ist auf Anhang (B) zu verweisen, in welchem auf das Konzept eines Computational Graphs eingegangen wird.

2.7 Universal Approximation Theorem

Es stellt sich nun die Frage, was ein Neuronales Netz alles erlernen kann. Diese Frage kann mithilfe des **Universal Approximation Theorem** (UAT) beantwortet werden. Es handelt sich um einen mathematischer Beweis dafür, dass ein KNN grundsätzlich in der Lage, ist jede kontinuierliche Funktion beliebig exakt zu approximieren.

Etwas genauer ausgedrückt, besagt der UAT, dass ein KNN mit einer einzigen Zwischenschicht, welche eine endliche Anzahl Neuron besitzt, sich jeder kontinuierlichen Funktion annähern kann. Voraussetzung dafür ist, dass es sich bei den Neuronen um nicht-lineare Neuronen handelt. Da sich die meisten Klassen von Problemen als eine Funktion formulieren lassen, bedeutet dies, dass ein KNN theoretisch jedes Problem lösen kann! Beim UAT handelt es sich aber nur um eine theoretische Aussage über das Lernpotenzial eines KNNs. Jedoch trifft das Theorem keinerlei Aussage darüber, ob ein KNN wirklich erfolgreich darin ist, die jeweilige Funktion zu erlernen. Ein mögliches Hindernis könnte in Overfitting bestehen.

Da der eigentliche Beweis mathematisch ziemlich anspruchsvoll ist, wird er im Rahmen dieser Arbeit nicht weiter behandelt.

(Nielsen, *Neural Networks and Deep Learning*)
(Mehrere, *Universal approximation theorem — Wikipedia, The Free Encyclopedia*)

Kapitel 3

Convolutional Neural Networks

Nachdem in Kapitel zwei das Wesen von Künstlichen Neuronalen Netzen charakterisiert wurde, soll es nun in Kapitel drei darum gehen, eine spezfische Architektur einen KNNs, welche sich besonders gut für Bilderverarbeitung eignet, zu erklären. Es handelt sich um das Convolutional Neural Network.

Viele Anwendungen von Machine Learning sind mit einer Bild- oder Audioverarbeitung verbunden, wie z.B Bildklassifizierung, Gesichts- oder Spracherkennung. Vor allem für hochauflösende Bilder sind die KNNs, wie wir sie soeben kennengelernt haben, jedoch nicht geeignet. Sie sind zum Teil gar nicht in der Lage, eine Korrelation zwischen den Inputs und Outputs zu erlernen. Um diesen Umstand zu erklären, wird ein kleines Beispielmodell erläutert:

Es soll ein KNN entworfen werden, welches eine Photographie danach klassifizieren soll, ob ein Hund darauf sichtbar ist oder nicht. Für dieses Gedankenexperiment wird ein relativ niedrig aufgelöstes Bild mit 256×256 Pixel gewählt (dies entspricht weniger als 0.07 Megapixel, im Verlgeich dazu, hat ein iPhone XS hat eine Kamera mit 12 Megapixel). Um die verschiedenen Farben zu codieren, besitzt jeder Pixel drei Farbkomponenten: R (rot), G (grün) und B (blau). Somit hat dieses Bild insgesamt $256 \times 256 \times 3 = 196'608$ Komponenten. Jede Komponente ist ein Feature, welches das KNN zu verarbeiten hat. So bestünde die erste Schicht des Netzwerkes aus fast $200'000$ Neuronen. Um diese Schicht nun mit seiner Nachbarsschicht zu verbinden, welche die gleichen Grösse besitzt, werden $196'608 \times 196'608 = 38'654'705'664$ Verbindungen und damit gleich viele Gewichte benötigt! Für ein Netwerk ohne eine einzige Zwischenschichten gäbe es also über 38 Milliarden Modellparameter zu erlernen! Dass dies nicht realistisch ist, liegt wohl auf der Hand.

Nicht nur die Anzahl der Modellparameter sind ein Problem für KNNs in der Bildverarbeitung, sondern es existieren noch weiter Probleme. Ohne auf diese Einzugehen sollte nun klar sein, dass eine andere Modellarchitektur notwendig ist, um Machine Learning auf Bilder anwenden zu können. Für derartige Anwendungen wurde eine modifizierte Version eines KNNs entwickelt: das **Convolutional Neural Network** (CNN). Im Allgemeinen sind CNNs immer dann geeignet, wenn es Daten zu verarbeiten gilt, welche eine rasterartige Form aufweisen, wie z.B Bilder. Diese Art von Netzwerk macht Gebrauch von Konzepten aus der klassischen Bildverarbeitung, wie sie beispielsweise mit Photoshop gemacht wird. Wie beim Perzeptron und bei den klassischen KNNs wurde auch hier die Architektur von der Biologie inspiriert. Der folgende Abschnitt wird die Funktionsweise eines solchen CNNs erklären.

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.1 Bilder als Tensoren

CNNs verarbeiten Bildern. Diese Bilder stellen den Input für die Modelle dar. Um mit diesen Bildern erfassen zu können, ist es sinnvoll, sie als sogenannte **Tensoren** vom Rang 3 zu untersuchen, anstatt sie als Anordnungen von Pixeln zu betrachten. Um zu verstehen, was ein Tensor dritten Ranges ist, müssen soll zunächst erläutert werden, was mit einem Tensor im Allgemeinen gemeint ist.

Tensor

Ein Tensor $\mathbf{T}$ ist eine Verallgemeinerung von Skalaren, Vektoren und Matrizen auf n Dimensionen. Es handelt sich wie bei Matrizen um eine Zahlenanordnung. Dabei wird die Anzahl Dimensionen, innerhalb welcher die Zahlen liegen, als Rang oder Stufe n des Tensors bezeichnet. Vorstellen kann man sich einen Tensor als ein Hyperrechteck mit n Dimensionen, innerhalb dessen die Zahlen in einem Raster angeordnet sind. Diese Zahlen sind die Elemente des Tensors. Ein Tensor nullten Ranges ist ein Skalar, eine Tensor ersten Stufe ist ein Vektor und ein Tensor mit Rang 2 ist eine normale 2D-Matrix.

$$1 \in \mathbb{R} \text{ (Skalar)} \qquad \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \in \mathbb{R}^3 \text{ (Vektor)} \qquad \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \in \mathbb{R}^{2\times 3} \text{ (Matrix)}$$

Tensor 3. Ranges

Ein Tensor $\mathbf{T} \in \mathbb{R}^{h\times w\times d}$ mit Rang 3 ist eine 3-dimensionale Zahlenanordnung. Man kann sich diesen Tensor als eine 3D-Matrix vorstellen; ein Volumen, innerhalb dessen die Elemente in einem Raster angeordet sind. Analog zum Volumen bezeichnet man die Form des Tensors mit Höhe, Breite und Tiefe.

Die Schreibweisen-Konvention für Tensoren 3. Ordnung soll an folgendem Beispieltensor der Form $\mathbb{R}^{3\times 3\times 3}$ illustriert werden.

$$\mathbf{T} = \left[\begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & -1 & 0 \end{pmatrix} \begin{pmatrix} 0 & 0 & -1 \\ 0 & 0 & 0 \\ 1 & 0 & 0 \end{pmatrix} \begin{pmatrix} 0 & 1 & 0 \\ -1 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \right] =$$

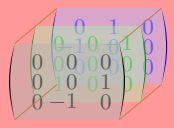

$\in \mathbb{R}^{3\times 3\times 3}$

Ein Bild kann somit als Tensor dritten Ranges $\mathbf{B} \in \mathbb{R}^{h\times w\times c}$ betrachtet werden, in der Form (Bildhöhe $\times$ Bildbreite $\times$ Anzahl Farbkomponenten). Die Elemente der Matrix nehmen dann die Werte der Pixelkomponenten an. Ein schwarz-weisses Bild hat nur eine Komponente, welche die Helligkeit angibt. Somit wäre es eine normale 2D-Matrix $\boldsymbol{B} \in \mathbb{R}^{h\times w}$ (siehe Abb. (**??**)).

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Tensor — Wikipedia, Die freie Enyklopädie*)

3.2 Topologie der Convolutional Neural Networks

Ein CNN besteht, wie ein KNN auch, aus mehreren Schichten. Jede dieser Schichten erhält als Input ein Bild und hat auch wieder eines als Output. Ein wichtiger Unterschied des CNNs ist, dass es aus unterschiedlichen Typen von Schichten besteht. Grundsätzlich lassen sich vier Arten von Schichten unterscheiden:

- **Fully-connected-Schichten**
- **Convolutional-Schichten**
- **Pooling-Schichten**
- **Upsampling-Schichten**

Die Fully-Connected-Schicht ist bereits bekannt und verköpert die klassische Schicht eines KNNs, bestehend aus Neuronen. Auf diese werden wir daher nicht weiter eingehen, da sie bereits im vorherigen Kapitel erläutert wurde.

Die Convolutional-Schicht ist eine neuartige Schicht, welche es im KNN nicht gibt. Sie ist die Schicht, welche für das Training relevant ist, da sie die Modellparameter beinhaltet. Sie extrahiert die relevanten Features aus den Inputbildern und lernt so die Bilder zu verstehen.

Die Pooling-Schichten, wie auch die Upsampling-Schichten, beinhalten keine Modellparameter und sind deshalb für das Training nicht direkt relevant. Diese Schichten werden lediglich benötigt, um die verarbeiteten Bilder

neu zu skalieren. Dies ist sinnvoll, da durch die Extraktion gewisser Features die restlichen Features wegfallen. Somit muss weniger Information pro Bild gespeichert werden und die Bilder sollten schrumpfen, um Overfitting vorzubeugen. Die Pooling- Schichten reduzieren die Bilder und die Upsampling-Schichten erweitern sie. Dies wird in Sektion (4) für die Entwicklung von Autoencoder hilfreich werden.
Grundsätzlich folgt auf eine Convolutional-Schicht entweder eine Pooling- oder eine Upsampling-Schicht. Somit bilden sie gewissermassen eine Einheit.

In Abbildung (3.1) ist ein Schema eines CNNs abbgebildet.

Abbildung 3.1: Schichtung eines CNNs

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.3 Convolutional-Schichten und Filter

Zuerst wir nun die Convolutional Schicht betrachtet. Diese Schicht macht ausgiebig Gebrauch von sogenannten Filtern. Diese werden in diesem Abschnitt ausführlich behandelt.

3.3.1 Filter in der Bildverarbeitung

Filter (auch Kerne) sind in der Bildverarbeitung sehr verbreitet. Jeder kennt sie entweder von Photoshop, von Instagram oder sonstigen Bildbearbeitungsprogrammen. Auch CNNs machen Gebrauch von solchen Filtern, in diesem Fall, um die Features eines Bildes zu erlernen.

Abbildung 3.2: der Instagramfilter “Amaro” auf ein Beispielbild angewandt (Richter, *Weisskopfadler*)

Ein Filter ist eine Region, die deutlich kleiner ist als das verarbeitete Bild $\mathbf{B}$, welche über alle Pixel wandert, diese manipuliert und so wieder ein neues Bild $\tilde{\mathbf{B}}$ erzeugt. Mathematisch gesehen handelt es sich bei einem solchen Filter um einen Tensor, den sogenannten **Filtertensor F** oder auch Faltungstensor (siehe Abb. (3.3) und Abb. (3.4)). Solche Filter sind immer quadratisch, wobei ihre Zeilen- und Spaltenlänge mit f bezeichnet wird. Dabei ist f immer eine ungerade Zahl, damit ein Element, das sogenannte **Zentralelement** (engl.: center element), bezeichnet mit $(\mathbf{F})_C$, immer im Zentrum des Filters liegt.

Das Verhalten des Filters wird durch seine Tensoreinträge bestimmt. Die Elemente können so gewählt werden, dass bei Anwendung des Filters auf ein Bild, dieser bestimmte Features hervorhebt. Solche Features könnten zum Beispiel Ränder oder Kanten sein, welche akzentuiert werden.

Nun wird ein beispielshafter Kantendetektionfilter betrachtet. Er besitzt die Filtergrösse $f = 3$ und seine Einträge lauten folgenermassen:

$$\boldsymbol{F}_K = \begin{pmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{pmatrix}$$

Angewendet auf ein schwarz-weisses Bild, wird ein neues Bild erzeugt, bei welchem alle erkannten Kanten weiss eingefärbt werden und die restlichen Bereiche schwarz sind. Der Filter erkennt dabei jede Stelle als Kante,

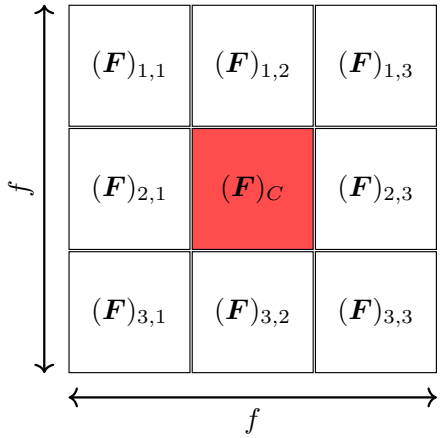

Abbildung 3.3: eine 2D-Filtermatrix mit rotem Zentralelement

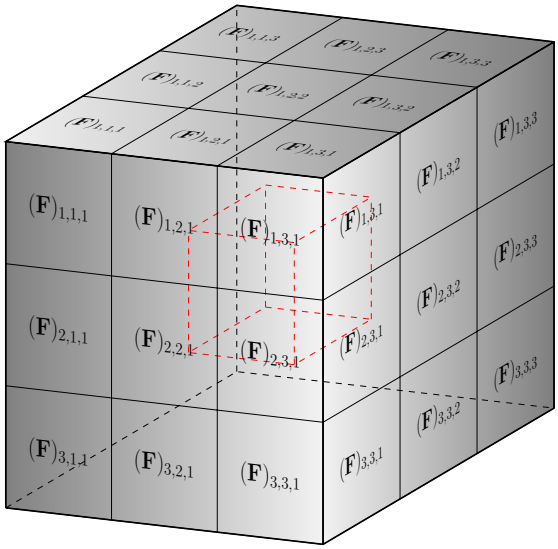

Abbildung 3.4: ein 3D-Filtertensor mit rotem Zentralelement

welche zwei Regionen mit genug grossem Kontrast voneinander trennt. In Abbildung (3.5) wurde der erwähnte Kantendetektionfilter auf ein Beispielbild angewendet. Links ist das Ursprungsbild und rechts ist das generierte Bild zu sehen [1].

Abbildung 3.5: Sobel-Filter angewandt auf Beispielsbild (Richter, *Weisskopfadler*)

(Mehrere, *Sobel operator — Wikipedia, The Free Encyclopedia*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Kernel (image processing) — Wikipedia, The Free Encyclopedia*)

3.3.2 Filter in CNNs

Aus didaktischen Gründen betrachten wird nun zunächst nur ein 2D-Filter betrachtet, welcher sich für graustufige Bilder $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ eignet. Somit ist der hierfür ausgewählte Filter eine 2D-Matrix, bezeichnet mit $\boldsymbol{F} \in \mathbb{R}^{f \times f}$. Man bedenke, dass es sich eigentlich bei jeder Filtermatrix um einen 3D-Tensor handelt.

Wie bereits dargelegt, können Filter genutzt werden, um gewisse Features eines Bildes hervorzuheben und andere Features zu ignorieren. Dabei bestimmen die Filtereinträge, welche Features extrahiert werden. Somit besteht die Aufgabe darin, die richtigen Filtereinträge zu bestimmen, damit die gewünschten Features erkannt werden und auf den gewünschten Output abgebildet werden. Naheliegend sollte jetzt der Gedanke sein, die Filtereinträge als die Modellparameter eines CNNs zu definieren. Mithilfe von SGD soll erneut diese Parameter erlernt werden.

Da die Filter die gleiche Funktion haben, wie die Gewichte in einem KNN, bezeichnet man die Filter in einem CNN mit $\boldsymbol{W}$. Die Grösse des Filters stellt dabei einen Hyperparameter dar.

[1] Dieses Bild wurde mithilfe von GIMP (GNU Image Manipulation Program) erzeugt. Dieses Programm bietet die Möglichkeit eine Filtermatrix auf ein Bild anzuwenden.

$$\boldsymbol{W} = \begin{pmatrix} w_{1,1} & \cdots & w_{1,f} \\ \vdots & \ddots & \vdots \\ w_{f,1} & \cdots & w_{f,f} \end{pmatrix}$$

3.3.3 Filteroperation intutitiv

Wie wendet man nun einen solchen Filter auf ein Bild an? Um das Prozedere einer Filteroperation leichter verständlich zu machen, soll es erneut für ein graustufiges Bild $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ erläutert werden. Zu einem später Zeitpunkt wird auch die Anwendung auf farbige Bilder erklärt (siehe Sektion (3.3.4)).

Bei einer Filteroperation wendet man einen Filter $\mathbf{W}$ auf einen Bildtensor $\mathbf{B}$ an und erhält so ein neues Bild $\tilde{\mathbf{B}}$. Man schreibt dafür: $\tilde{\mathbf{B}} = \mathbf{W} * \mathbf{B}$.

Um nun diese Operation zu erklären, wird als Beispiel eine 2D-Filtermatrix $\boldsymbol{W} \in \mathbb{R}^{3 \times 3}$ verwendet, bei welcher $f = 3$ gewählt wurde. Wie bereits oben erwähnt wandert der Filter über das Bild. Dabei befindet sich der Filter immer über einer Region des Bildes, welche gleich gross ist wie der Filter selbst (in diesem Fall (3×3)). Auf diese entsprechen den Filtermatrixeinträgen immer eindeutig Bildmatrixeinträge. Diese Region des Bildes bezeichnet man als das **Rezeptives Feld** des Filters (siehe Abb. (3.6)). Das Rezeptive Feld, bezeichnet mit $\hat{\boldsymbol{B}} \in \mathbb{R}^{3 \times 3}$, ist also eine Untermatrix der Obermatrix $\boldsymbol{B}$.

Jedem Element des Filters entspricht ein Element des Rezeptiven Feldes. Dem Zentralelement $(\boldsymbol{W})_c$ ist dabei gerade dem sogenannten Quellenpixel (engl.: source pixel) $(\mathbf{B})_s$ des Bildes zugeordnet. Ihn verwenden wir für eine Namenskonvention für das Rezeptive Feld. Das Rezeptive Feld wird mit $\hat{\boldsymbol{B}}^{(y,x)}$ bezeichnet, wobei die hochgestellten Indizes (y, x) die Position des Quellenpixel $(\boldsymbol{B})_S$ im Bild $\boldsymbol{B}$ angibt.

Abbildung 3.6: ein Filter und sein rezeptives Feld

Der Filter beginnt nun oben links über das Bild zu wandern. Somit hat der Filter zu anfangs das Rezeptive Feld $\hat{\boldsymbol{B}}^{(2,2)}$, denn der Filter darf nicht über die Ränder des Bildes hinausragen. Nun werden die Elemente des Filters mit den Elementen des Rezeptiven Feldes verrechnet, welche die gleichen Dimensionen besitzen. Dabei wird das Hadamard-Produkt (das elementweise Produkt) der beiden Matrizen miteinander gebildet. Daraus resultiert eine neue Matrix $\boldsymbol{W} \odot \hat{\boldsymbol{B}}^{(2,2)} = \boldsymbol{P} \in \mathbb{R}^{3 \times 3}$. Anschliessend werden alle Elemente der neuen Matrix $\boldsymbol{P}$ aufsummiert. Dieser Wert ist dann der Grauwert des ersten Pixels $(\tilde{\boldsymbol{B}})_{1,1}$ des neu enstandenen Bildes (siehe Gl. (3.1)). In diesem Sinne stellt der Filter eine Gewichtung der Nachbarspixel des Ursprungsbild dar, welche bestimmt, wie die neuen Pixel aussehen.

$$(\tilde{\boldsymbol{B}})_{1,1} = \Sigma(\boldsymbol{P}) = \sum_{y=1}^{3} \sum_{x=1}^{3} (\boldsymbol{P})_{y,x} \tag{3.1}$$

Nun wird der Filter um ein Element nach rechts verschoben und die gleiche Prozedur angewendet, um den zweiten Pixel zu berechnen. Dies wird so lange vollzogen, bis eine ganze Zeile der Bildmatrix durchstreift wurde. Danach wird der Filter wieder ganz nach links verschoben und er bewegt sich ein Element nach unten. Das geschieht bis das ganze Bild verrechnet wurde. Dabei werden die Elemente des ursprünglichen Bildes durchaus mehrfach verrechnet, da es zu einer Überlappung der vorherigen Position des Filters und der verschobenen Position kommt.

Es ist zu bemerken, dass das neue Bild $\tilde{\boldsymbol{B}} \in \mathbb{R}^{(h-2) \times (w-2)}$ nicht mehr die gleichen Masse aufweist wie das Ursprungsbild $\boldsymbol{B} \in \mathbb{R}^{h \times w}$. Das liegt daran, dass pro Lage des Filters jeweils nur ein Pixel des neuen Bildes entsteht. Man kann sich vorstellen, dass an der Position des Quellenpixels jeweils ein neuer Pixel generiert wird. Jedoch muss der Filter immer eine vollständige Region als Rezeptives Feld besitzen. Dadurch kommt das Zentralelement nie auf die Ränder des Bildes zu liegen, wodurch sie entfallen.

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolution— Wikipedia, The Free Encyclopedia*)

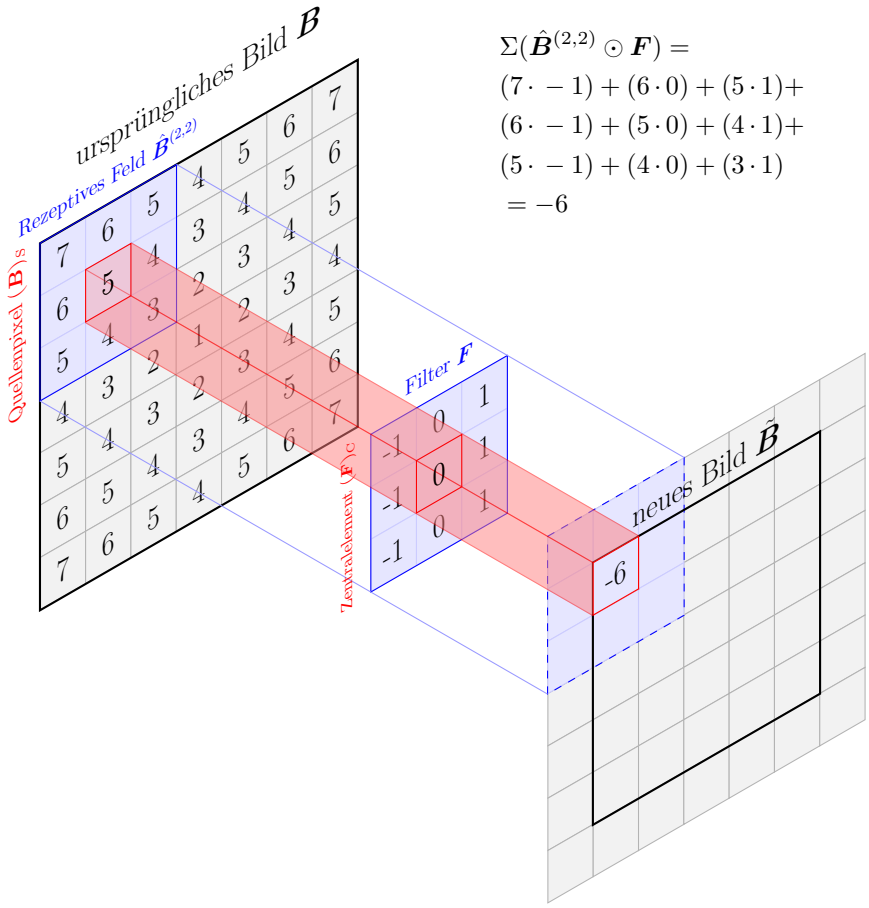

Abbildung 3.7: Schema, wie ein Filter über ein Bild läuft

3.3.4 Filteroperationen als diskrete Faltungen

Eigentlich handelt es sich bei der Anwendung eines Filters auf ein Bild um eine spezifische mathematische Operation: eine **diskrete Faltung** (engl.: **convolution**). [2] Daher rührt auch der Name des Convolutional Neural Networks. Da die Faltung als mathematische Operation relativ kompliziert ist, wird sie im Rahmen dieser Arbeit nicht in vollem Umfang betrachtet. Ihre Bedeutung soll auf die Faltung von Filtern beschränkt werden.

Diskrete Faltung

Definintion Faltung

$$(f * g)(x) = \int_{-\infty}^{\infty} f(\tau) g(x - \tau) \mathrm{d}\tau \tag{3.2}$$

Mithilfe der Faltungsoperation können die Schritte aus Sektion (3.3.3) zusammengefasst werden. Bei der Filteroperation handelt es sich nämlich um eine diskrete Faltung des Filtertensors $\mathbf{W}$ über den Bildtensor $\mathbf{B}$. Somit kann folgende Formel verwenden werden, um einen Pixel $\tilde{\boldsymbol{B}}_{y,x}$ des neuen Bildes zu berechnen.

$$(\tilde{\boldsymbol{B}})_{y,x} = (\boldsymbol{W} * \boldsymbol{B})_{y,x} = \sum_{v=1}^{f} \sum_{u=1}^{f} (\boldsymbol{W})_{v,u} (\boldsymbol{B})_{y+v-1,x+u-1} \tag{3.3}$$

[2] Streng genommen wird in CNNs nicht eine diskrete Faltung durchgeführt, sondern eine sogenannte **Kreuzkorrelation**. Der Unterschied besteht darin, dass bei einer Kreuzkorrelation die Faltungsmatrix nicht horizontal und vertikal gespiegelt wird. Dies im Gegensatz zu der eigentlichen Faltung, bei welcher diese Spiegelung statt findet. Jedoch wird begrifflich das Wort Faltung für beide Operationen verwendet. Im Verlauf dieser Arbeit wird mit dem Wort Faltung immer die Kreuzkorrelation gemeint sein.

Faltung Beispielrechnung

$$\boldsymbol{B} = \begin{pmatrix} 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \end{pmatrix} \text{ und } \boldsymbol{W} = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}$$

Für die Berechnung des ersten Pixels $(\tilde{\boldsymbol{B}})_{1,1}$ führen wir folgende Rechnung aus.

$$\begin{aligned}(\tilde{\boldsymbol{B}})_{1,1} = (\boldsymbol{W} * \boldsymbol{B})_{1,1} &= \sum_{v=1}^{f}\sum_{u=1}^{f}(\boldsymbol{W})_{u,v}(\boldsymbol{B})_{u,v} \\ &= 10\cdot 1 + 10\cdot 0 + 10\cdot -1 + 10\cdot 1 + 10\cdot 0 + 10\cdot -1 + 10\cdot 1 + 10\cdot 0 + 10\cdot -1 \\ &= 0\end{aligned}$$

Das Gesamtergebniss lautet dann:

$$\tilde{\boldsymbol{B}} = \boldsymbol{W} * \boldsymbol{B} = \begin{pmatrix} 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \end{pmatrix}$$

Für farbige Bilder ist das Vorgehen ähnlich. Es werden nun Tensoren dritten Ranges anstatt von Tensoren zweiten Ranges verwendet. Betrachten wird der allgemeinen Bildtensor $\mathbf{B}_{h\times w\times c}$, wobei c die Anzahl Farbkomponenten (engl.: channels) ist. Nun benutzt man einen Filter $\mathbf{W}_{f\times f\times c}$ mit beliebiger Grösse f aber mit der gleicher Tiefe c wie das Ursprungsbild $\mathbf{B}$. Dadurch muss der Filter nicht entlang der Tiefe des Bildes wandern, weil er die gleiche Tiefe aufweist. Das hat zur Folge, dass das verarbeitete Bild $\tilde{\boldsymbol{B}}$ immer eine Matrix ist. Die allgemeine Filtergleichung lautet:

$$(\tilde{\boldsymbol{B}})_{y,x} = (\mathbf{W} * \mathbf{B})_{y,x} = \sum_{v=1}^{f}\sum_{u=1}^{f}\sum_{w=1}^{c}(\mathbf{W})_{v,u,w}(\mathbf{B})_{x+u-1,y+v-1,w} \tag{FO}$$

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.3.5 Mehrere Filter

Eine Filteroperation ist nicht auf einen einzigen Filter beschränkt. Es können mehrere Filter auf das gleiche Ausgangsbild angewendet werden und zusammen ein Endbild erzeugen.

Die Anzahl Filter werden mit c bezeichnet. Nun wird pro Filter $\mathbf{W}_i$ eine Faltung über das Ursprungsbild $\mathbf{W}$ gemacht, wobei jede Faltung eine neue Matrix $\tilde{\boldsymbol{B}}_i = \mathbf{W}_i * \mathbf{B}$ liefert. Dabei ist i der Index des Filters. All diese gefalteten Bilder $\tilde{\boldsymbol{B}}_i$ sind zwei-dimensionale Matrizen, unabhängig davon, wieviele Komponenten das Ursprungsbild hatte. Aus diesem Grund können die einzelnen Matrizen $\tilde{\boldsymbol{B}}_i$ aufeinander gelegt werden und somit einen grossen 3D-Endtensor $\tilde{\mathbf{B}}$ bilden. Hierfür müssen alle Filter $\mathbf{W}_i$ gleich gross sein. Die Tiefe des

Abbildung 3.8: aufeinander gelegte gefaltene Bilder

neuen Bildes $\tilde{\mathbf{B}}$ ist jetzt gerade die Anzahl Filter c. Schon vorher wurde die Tiefe des Bildes (bzw. die Anzahl Farbkomponenten) mit c bezeichnet. Somit steht c sowohl die Anzahl Filter einer Schicht, wie auch für die Tiefe des verarbeiteten Bildes.

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.6 Padding

Wie bereits erwähnt schrumpfen die Bilder (an den Rändern), wenn man einen Filter auf sie anwendet. Zur Erinnerung: Dies liegt daran, dass pro Lage des Zentralelements jeweils nur ein Pixel des neuen Bildes entsteht. Das Zentralelement kommt jedoch nicht nicht auf allen Ursprungspixeln zu liegen. Auf diese Weise fallen die Ränder weg. Der Umfang des Wegfalls hängt von der Filtergrösse f ab. Folgende Formel gilt für die neue Grösse n_1 des Bildes, berechnet anhand der alten Grösse n_0. n bezeichnet eine der zwei Seitenlängen.

$$n_1 = n_0 - f + 1 \tag{3.4}$$

Das Problem hierbei ist, dass nach einigen Faltungen das Bild extrem geschrumpft ist und im Grenzfall kleiner als der Filter wird. Das darf natürlich nicht passieren. Zusätzlich kommt es zu einem relativen Informationverlust an den Rändern, im Vergleich zum Rest des Bildes. Dies rührt daher, das es im Innern des Bildes zu mehr Überlappungen der Filterlagen kommt und dies bei den Rändern seltener auftritt.

Diese unerwünschte Phänomen lässt sich mit sogenanntem **Padding** beheben. Padding ist ein Vorgang, welcher vor der eigentlichen Faltung stattfindet. Dabei werden zusätzliche Ränder (Zeilen und Spalten) an das Ursprungsbild angebracht. Der Tensor wird der Länge und der Breite und nicht der Tiefe entlang an den Enden erweitert. Die neuen Elemente werden dabei auf den Wert 0 gesetzt.

0	0	0	0	0	0	0
0	5	4	3	4	5	0
0	4	3	2	3	4	0
0	3	2	1	2	3	0
0	4	3	2	3	4	0
0	5	4	3	4	5	0
0	0	0	0	0	0	0

Abbildung 3.9: Padding $p = 1$ in blau

Das Padding p ist eine Zahl, welche angibt, wieviele Elemente an allen Rändern hinzugefügt werden. Padding $p = 1$ bedeutet, dass an allen Kanten jeweils eine Reihe bzw. Spalte hinzugefügt wird. Begrifflich unterscheidet man zwischen zwei Arten von Padding:

- **Valid-Padding**: Es werden keine züsäzlichen Elemente angebracht. p ist also 0.
- **Same-Padding**: Es werden so viele Reihen und Spalten angebracht, dass die Grösse des Bildes nach der Faltung unverändert bleibt.

Um Same-Padding durchzuführen, muss p so gewählen werden, dass es den Wegfall durch die Filteroperation gerade kompensiert. Da das Bilder durch das Padding der Länge und Breite nach jeweils um zwei p verlängert wird, erhält man den Ausdruck $n_1 = n_0 - f + 1 + 2p$. Wenn diese Formel nach p auflöst, erhält man folgende Formel für das Wählen des Same-Paddings p.

$$p = \frac{f-1}{2} \tag{3.5}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.7 Stride

Bis jetzt wurde bei den Filterfaltungen der Filter pro Verschiebung immer nur um einen Pixel bewegt. Dies ist nicht zwingend. Grundsätzlich können Filter auch mit anderen Schrittgrössen verschoben werden. Diese Schrittgröss bezeichnet man als **Stride** s. Falls $s = 2$ gewählt wird, bedeutet das, dass der Filter sich pro Hadamard-Produkt um zwei Elemente verschiebt. Somit wurde eine Position übersprungen. Dies hat zur Folge, dass das neue Bild deutlich kleiner wird, denn das Zentralelement überspringt somit auch diese Felder und bildet so deutlich weniger Pixel.

Folgende Formel beschreibt die Dimensionen des neuen Bildes unter Berücksichtigung der Filtergrösse f, dem Padding p und dem Stride s.

$$n_1 = \frac{n_0 + 2p - f}{s} + 1 \tag{3.6}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

7	6	5	4	5	6	7
6	5	4	3	4	5	6
5	4	3	2	3	4	5
4	3	2	1	2	3	4
5	4	3	2	3	4	5
6	5	4	3	4	5	6
7	6	5	4	5	6	7

Abbildung 3.10: Abbildung zum Stride: jetztige Position in blau, nächste Position mit $s = 1$ in rot, nächste Position mit $s = 2$ in grün

3.3.8 Vorzüge von Filtern

Es stellt sich nun die Frage, weshalb sich Filter für Maschinelles Lernen mit Bildern besonders eignen. Wie bereits erwähnt besteht die Aufgabe von Filtern darin, bestimmte Features eines Bildes hervorzuheben und die restlichen auszublenden. Die gleiche Aufgabe erfüllen die Neuronen in einem KNN. Auch sie sollen Features der Inputdaten erlernen, wobei gewisse Neuronen auf gewisse Features reagieren. Weshalb verwendet man also nicht einfach KNNs? (abgesehen von dem Problem mit der grossen Menge an Modellparametern, siehe Sektion 3)

Man muss erkennen, dass Bilddaten sich deutlich von sonstigen Daten unterscheiden. Bildfeatures bzw. Pixel sind nur im Kontext ihrer Nachbarn relevant. Denn ein Pixel ist erst dann eine Kante oder eine Ecke, wenn er zwei verschiedene Farbregionen voneinander trennt. Oder ein Gegenstand wird erst durch eine ganze Anzahl von Pixeln und deren relative Position zueinander charakterisiert. Man bezeichnet diesen Umstand als **lokalisierte Features**.

Desweiteren sind Bildausschnitte nicht immer gleich ausgerichtet. Wenn man ein Gesicht auf einem Bild erkennen möchte, sollte es aber keine Rolle spielen, wo es sich auf dem Bild befindet, welche Grösse es hat und welche Ausrichtung es aufweist. Um diese Eigenschaften irrelevant für das Modell zu machen, muss es gewisse **Invarianzen** erfüllen.

Die Eigenschaft, welche CNNs für lokalisierte Features und Invarianzen geeignet macht, bezeichnet man als **Parameter-Sharing**. Es bezeichnet den Umstand, dass auf mehrere oder alle Features die gleichen Modellparameter wirken. Bei CNNs wird dies durch die Bewegung des Filters bzw. seiner Einträge über (fast) alle Pixel bewerkstelligt. Somit ist es egal, wo und wie sich die lokalisierten Features befinden. Dies führt dann eben zu den gewünschten Invarianzen: Translations-, Rotations- und Helligkeitsinvarianz.

Eine weiterer Vorteil durch dieses Parameter-Sharing ist, dass die Inputbilder beliebige Dimensionen besitzen können, da die Filter ihre Bewegung lediglich an die Grösse des Bildes anpassen müssen.

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.9 Convolutional-Schicht

Nun soll all das zusammengefasst werden, was soeben über Filter geschrieben wurde, um die Convolutional-Schicht zu definieren.

Die Convolutional-Schicht l beginnt mit ihrem Input, also den Aktivierungen $\mathbf{A}^{l-1} \in \mathbb{R}^{h^l \times w^l \times c^l}$, welche die vorherige Schicht $(l-1)$ produziert hat. Falls es sich um die erste Schicht handelt, erhält sie den Input $\mathbf{X}$ des Netzes.

Die Schicht besitzt c^l Varianten an Filtern $\mathbf{W}_i^l \in \mathbb{R}^{f^l \times f^l \times c^{l-1}}$. Diese Filter haben alle die gleichen Eigenschaften bezüglich: der Grösse f^l, der Tiefe c^{l-1}, dem Padding p^l und dem Stride s^l. Sie unterscheiden sich nur in den Modellparametern $w^l_{i\,|\,\alpha,\beta,\gamma}$.

$$\mathbf{W}_i^l = \left[\begin{pmatrix} w^l_{i\,|\,1,1,1} & \cdots & w^l_{i\,|\,1,f,1} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,1} & \cdots & w^l_{i\,|\,f,f,1} \end{pmatrix} \quad \cdots \quad \begin{pmatrix} w^l_{i\,|\,1,1,c^l} & \cdots & w^l_{i\,|\,1,f,c^l} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,c^l} & \cdots & w^l_{i\,|\,f,f,c^l} \end{pmatrix} \right]$$

Nun wird jeder Filter $\mathbf{W}_i^l$ einzeln über das Bild $\mathbf{A}^l$ gefaltet, wodurch mehrere neue 2D-Bilder $\tilde{\boldsymbol{A}}_i^l$ entstehen.

$$\tilde{\boldsymbol{A}}_i^l = \mathbf{W}_i^l * \mathbf{A}^l \tag{3.7}$$

Die Faltung berechnet sich aus folgender Gleichung:

$$(\tilde{\boldsymbol{A}}_i)^l_{y,x} = (\mathbf{W}^l_i * \mathbf{A}^l)_{y,x} = \sum_{v=1}^{f}\sum_{u=1}^{f}\sum_{w=1}^{c}(\mathbf{W}^l_i)_{v,u,w}(\mathbf{A}^l)_{x+v-1,y+u-1,w} \tag{FO}$$

Jede dieser Matrizen ist ein Querschnitt $\tilde{\boldsymbol{A}}^l_{:,:,i}$ entlang der Tiefe des neuen 3D-Tensors $\tilde{\mathbf{A}}^l \in \mathbb{R}^{h^{l+1}\times w^{l+1}\times c^l}$. Hierbei ist die Tiefe c^l gerade die Anzahl der Filter c^l. Die Höhe h^{l+1} und die Breite w^{l+1} werden jeweils gemäss nachstender Formel berechnet, anhand der Höhe h^l und der Breite w^l des Ausgangsbildes:

$$n^{l+1} = \frac{n^l + 2p^l - f^l}{s^l} + 1 \tag{3.8}$$

Da die Faltungsoperation linear ist, wird wiederum eine nicht-lineare Aktivierungsfunktion benötigt, um das Modell zu befähigen, nicht-lineare Probleme zu lösen zu können. Deshalb wird in einem letzten Schritt die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf den Tensor $\tilde{\boldsymbol{A}}^l$ angewendet. So ergibt sich die neue Aktiverung $\mathbf{A}^{l+1}$ der nächsten Schicht. Empirisch lässt sich nachweisen, dass sich für CNNs die ReLU-Aktivierungsfunktion aus Sektion (2.2.3) besser eignet als die Sigmoidfunktion (QUELLE). Deshalb wird in der Regel die ReLU-Funktion für CNNs verwendet.

$$\mathbf{A}^{l+1} = \boldsymbol{\varphi}[\tilde{\mathbf{A}}^l] \tag{3.9}$$

(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)
(Nielsen, *Neural Networks and Deep Learning*)

3.4 Dimensionalitätskontrolle

Beim Anwenden einer Convolutional Schicht gehen Informationen verloren, da nur die relevanten Features hervorgehoben werden und der Rest verworfen wird. Jedoch schrumpft das Bild entweder gar nicht (bei Same-Padding) oder es schrumpft nur vergleichsweise leicht (bei Valid-Padding). Dies ist ein Problem, da die Information in deutlich weniger Pixeln bzw. Tensorelementen codiert werden könnte. In der Konsequenz zeigt sich ein unötig hoher Ressourcenverbrauch und eine erhöhte Gefahr für Overfitting (siehe Sektion (1.3.2)). Um diesem Effekt entgegenzuwirken, gibt es einerseits sogenannte **Pooling-Schichten** und als Gegenstück dazu **Upsampling-Schichten**. Ersteres wird verwendet, um die Dimensionalität der Bilder zu vermindern, und letzteres, um die Dimensionalität der Bilder zu erweitern. Somit ermöglichen diese Schichten eine kontrollierte Art, (im Gegensatz zum Padding) die Dimensionalität willentlich zu bestimmen.

3.4.1 Pooling-Schicht

Die Pooling-Schicht verringert die Dimensionalität durch das Zusammenfassen eines Feldes von Tensorelementen zu einem einzigen Tensorelement. Dabei wandert das Feld nur entlang der Länge und Breite des Bildes und nicht etwa entlang der Tiefe. Dies bedeutet, dass das Pooling auf jede Farbkomponente einzeln angewendet wird, wodurch sich die Tiefe des Bildes nicht ändert.

Für die Beschreibung einer Pooling-Schicht finden die gleichen Begriffe Anwendung, wie bei der Convolutional-Schicht und den Filtern. Die Grösse des Elementfeldes, welches zusammengefasst wird, bezeichnet man analog zur Filtergrösse mit f^l. Das Stride s^l bezeichnet auch beim Pooling, wie gross die Schrittgrösse beim Verschieben des Feldes ist. Meistens wählt man den Stride s^l gerade gleich der Feldgrösse f^l, damit alle Pixel zusammengefasst werden. Kleiner als f^l kann s^l nicht gewählt werden.

Man unterscheidet zwischen zwei Arten von Pooling:

- **Average-Pooling**: Das Elementenfeld wird zusammengefasst, indem das arithmetische Mittel der Elemente gebildet wird.
- **Max-Pooling**: Das Elementenfeld wird zusammengefasst, indem das Element mit dem höchsten Wert beibehalten wird und die anderen verworfen werden.

In der Praxis verwendet man eigentlich nur Max-Pooling, da es deutlich bessere Resultate erzielt.

MaxPooling Beispiel

Es sei eine MaxPooling-Schicht gewählt mit $f^l = 2$ und $s^l = 2$. Diese fasst also jedes (2×2)-Feld zu einem Element zusammen. Da aus vier Elementen jeweils eines wird, entspricht dies einer Informationsreduktion von 75%.

$$\begin{pmatrix} 5 & 2 & 4 & 3 \\ 8 & 9 & 5 & 1 \\ 3 & 8 & 6 & 7 \\ 8 & 1 & 4 & 2 \end{pmatrix} \rightarrow_{\text{MaxPool}} \begin{pmatrix} 9 & 5 \\ 8 & 7 \end{pmatrix}$$

Es ist festzuhalten, dass eine Pooling-Schicht keinerlei Modellparameter besitzt. Somit gibt es nichts zu trainieren. Sie besitzt lediglich einige Hyperparameter, wie die Feldgrösse f^l und den Stride s^l.

Um zu berechnen, was die neuen Dimensionen der Bildes nach dem Pooling sind, gelten die gleichen Formeln wie für die Filteroperationen:

$$n_1 = \frac{n_0 - f}{s} + 1 \tag{3.10}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)

3.4.2 Upsampling-Schicht

Die Upsampling-Schicht bildet das Gegenstück zur Pooling-Schicht, da sie die Dimensionalität des Bildes erhöht. Auf den ersten Blick erscheint unklar, weshalb man die Dimensionalität erhöhen will, da die eigentliche Motivation dieser Schichten in der Verhinderung von Overfitting besteht. Jedoch sollte mit dem Kapitel (4) klar werden, weshalb solche Schichten einen Nutzen haben können.

Man verwendet auch hier wieder den Begriff der Feldgrösse f^l. Dieses Mal beschreibt der Wert, wie stark das Bild hochskaliert wird. Beim Upsampling wird ein Element zu einem $(f^l \times f^l)$-Feld hochgerechnet und erweitert so die Dimensionalität.

Es stellt sich natürlich die Frage, was für Werte das neue Feld erhält. Dafür ist eine Interpolationsart zu wählen. Zwei Arten sind besonders verbreitet:

- **Bilineare Interpolation**
- **Nächste-Nachbar-Interpolation** (engl.: nearest-neighbor-interpolation)

Hier soll nur die Nächste-Nachbar-Interpolation betrachten werden. Sie ist vergleichsweise trivial, denn alle neuen Feldelemente nehmen einfach den Wert des alten Elements an. Der Wert auf diese Weise also vermehrt.

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)

Kapitel 4

Autoencoder

In Kapitel drei wurde die Architektur eines Convolutional Neural Networks dargelegt. Nun soll eine weitere Architekur erörtert werden, welche das letzte Bindeglied zur praktischen Programmierung eines Convolutional-Denoising-Autoencoder verköpert. Dieses ist notwendig, um die theoretische Funktionsweise eines Autoencoders zu verstehen. Zielsetzung ist, den Autoencoder mit dem Convolutional Neural Network zu fusionieren, um auf diese Weise einen einen Convolutional-Autoencoder zu erhalten. Zu guter letzt soll dann noch eine Anwendung eines solchen Convolutional-Autoencoder betrachtet werden, in der Form eines Denoiser.

Ein **Autoencoder** ist eine Architektur, welche ein KNN nicht nicht bezüglich der Schichtenarten, sondern auf der Ebene der Netzform beschreibt. Die Aufgabe eines Autoencoders besteht darin, eine neue Repräsentation einer Datenmenge zu erlernen. Diese neuartige Darstellung soll mit weniger Daten möglichst die gleiche Information codieren. Somit entwickelt das Modell eine **effiziente Daten-Codierung** für einen Datensatz. Dadurch kann er zur **Dimensionalitätsreduktion** verwendet werden. Neben dieser neuen Repräsentation erlernt das Netzwerk darüberhinaus, wie es aus dieser Codierung wieder die Ursprungsdaten reproduzieren kann.

Autoencoder gehören nicht dem klassischen überwachtem Lernen an. Strenggenommen zählen sie zum unüberwachtem Lernen, da in den Trainingsdaten keine Labels enthalten sein müssen. Jedoch ist diese Begrifflichkeit etwas irreführend, weil nur deshalb keine Labels benötigt werden, da sie den Features entsprechen! Somit wird das Netzwerk trotzdem darauf trainiert, gewisse gewünschte Outputs zu liefern.

(Saalmann, *Einführung in Autoencoder und Convolutional Neural Networks*)

4.1 Topologie

Ein Autoencoder besteht wie das klassische KNN aus Neuronen. Wie bereits erwähnt sind die "Labels" eines Autoencoders gleich den Features. Somit versucht ein Autoencoder, die Werte der Inputneuronen möglichst exakt in die Outputneuronen zu kopieren. Diese Operation wäre an sich ziemlich bedeutungslos, da mit den Daten nichts passiert. Das Netzwerk würde lediglich erlernen, eine Identitätsfunktion zu imitieren. Aus diesem Grund muss man gewisse Einschränkungen einführen. Diese bringen das Netzwerk dazu, interessante Methoden zu entwickeln, um die Features *approximativ* zu rekonstruieren.

Die angesprochene Einschränkung besteht darin, dass dem Autoencoder nicht beliebig viel Kapatzität für die Codierung der Features gewährt wird. Es stehen dem Netzwerk nur wenige Zahlenwerte zur Verfügung, um die Features in der neuen Repräsentation zwischenzuspeichern, bevor sie wieder in die ursprüngliche Form zurück transformiert werden. Die Kapazitätseinschräkung wird durch die Topologie des Autoencoders bezweckt.

Der einfachste Autoencoder besteht aus drei Schichten, welche sich wie folgt gliedern lassen:

- eine Inputschicht mit d Neuronen
- eine Zwischenschicht mit p Neuonen, bezeichnet als **Flaschenhals**
- eine Outputschicht mit d Neuronen

In Abbildung (4.1) ist ein beispielhafter Autoencoder abbgebildet, mit $d = 5$ Features und einem Flaschenhals der Grösse $p = 2$.

Die Inputschicht enthält die Features $\boldsymbol{x} \in \mathbb{R}^d$. Dagegen enthält die Outputschicht die **Rekonstruktionen** der Features, welche wir mit $\hat{\boldsymbol{x}} \in \mathbb{R}^d$ bezeichnen. Als logische Konsequenz müssen die beiden Schichten die gleiche

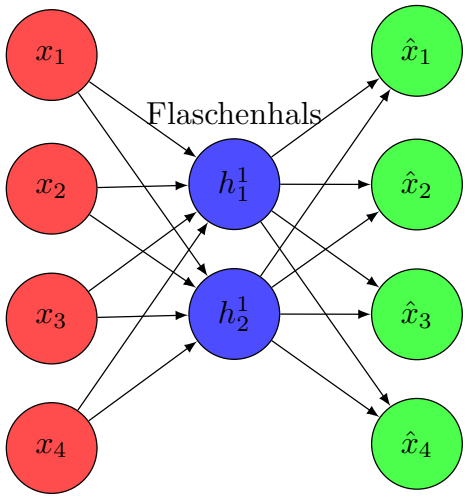

Abbildung 4.1: Schichten eines kurzen Autoencoders

Anzahl d an Neuronen besitzen. Die Flaschenhalsschicht hingegen besitzt nur p Neuronen, wobei $p \ll d$ ist. Somit ist sie deutlich kleiner als die anderen beiden Schichten und bildet damit die **Kapazitätsbeschränkung**.

Damit wurde ein Autoencoder mit nur einer Zwischenschicht betrachtet. Gängiger ist jedoch das Netz aus mehreren Zwischenschichten zu konstruieren. Dabei werden die Schichten zum Flaschenhals hin immer schmaler und die Schichten nach dem Flaschenhals wieder dicker. In Abbildung (4.2) ist dies gut ersichtlich. Aus Vereinfachungsgründen soll dennoch die Funktionsweise eines Autoencoder mit nur einer Zwischenschichten hergeleitet werden.

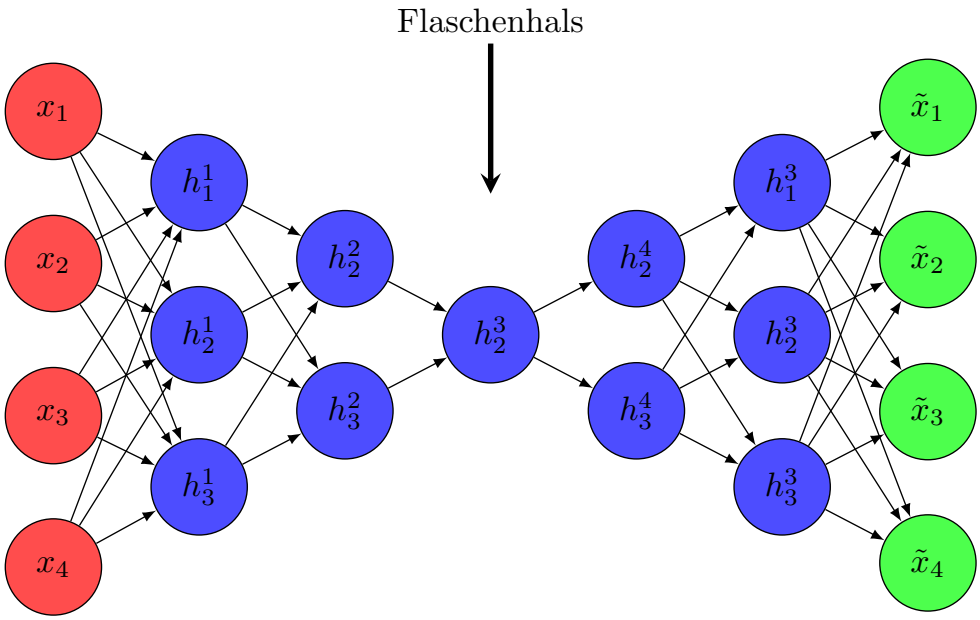

Abbildung 4.2: Schichten eines tieferen Autoencoders

4.2 Funktionsweise

Ein Autoencoder möchte die Features $\boldsymbol{x}$ von der Inputschicht in die Outputschicht kopieren. Jedoch zwingt der Flaschenhals den Autoencoder dazu, eine neue Repräsenation der Features zu erlernen. Dies aus dem Grund, weil die Features in ihrer jetzigen Form keinen Platz im Flaschenhals finden, da $p \ll d$. Daher muss das Modell die Informationen der Features, auf nur einige wenige relevante Eigenschaften komprimieren. Das Modell muss gewissermassen einen Code entwickeln. Diese neue Repräsentation nennt man das **Encoding**.

In einem zweiten Schritt muss der Autoencoder aus diesem Encoding wiederum versuchen, die ursprünlichen Features zu rekonstruieren. Diese Rekonstuktion bezeichnet man als das **Decoding**.

Encoder und Decoder

Daher kann man einen Autoencoder in zwei Teilmodelle untergliedern. Das eine Modell erzeugt das Encoding und das andere das Decoding. Dafür wird die Hypothesenfunktion h in ein Funktionenpaar (ϕ, ψ) aufgespaltet.

- $\phi : \mathcal{X} \to \mathcal{E}$ Encoder-Funktion
- $\psi : \mathcal{E} \to \mathcal{X}$ Decoder-Funktion

Die erste Teilfunktion ϕ ist für das Encoding zuständig. Sie bildet den Inputraum $\mathcal{X} \subseteq \mathbb{R}^d$ auf den Encodingraum $\mathcal{E} \subseteq \mathbb{R}^p$ ab, welcher die neue Repräsentation $\boldsymbol{x}^*$ enthält. Der Inputraum $\mathcal{X}$ enthält sämtliche Features $\boldsymbol{x}$.

Das Gegenstück ist die Teilfunktion ψ. Sie bildet den Encodingraum $\mathcal{E}$ zurück auf den Inputraum $\mathcal{X}$ ab.

Der Output des Autoencoders $\hat{\boldsymbol{x}}$ wird somit durch die aufeinander folgende Anwendung der Teilfunktionen auf die Features $\boldsymbol{x}$ gebildet:

$$\hat{\boldsymbol{x}} = \psi(\phi(\boldsymbol{x})) = (\psi \circ \phi)(\boldsymbol{x}) \tag{4.1}$$

Durch das trainieren dieses Modells, wird die Kostenfunktion minimiert. Als Beispiel kann der Mittlere-quadratischen-Fehler C_{MSE} dienen. Wird er als Kostenfunktion verwendet, so wird folgender Ausdruck minimiert:

$$\min_{\phi,\psi} \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|^2 = \min_{\phi,\psi} \|\boldsymbol{x} - (\psi \circ \phi)(\boldsymbol{x})\|^2 \tag{4.2}$$

Anderst ausgedrückt wird versucht Funktionen ϕ und ψ zu finden, welche die Differenz zwisceh den ursprünglichen Features $\boldsymbol{x}$ und den Rekonstruktionen $\hat{\boldsymbol{x}}$ minimieren. Dabei muss der Autoencoder eine Dimensionalitätsreduktion betreiben. Er entwickelt einen Code, um die Features in der Flaschenhalsschicht komprimiert zu repräsentieren. Durch die Kapazitätseinschräkung $p \ll d$ muss $\mathcal{E}$ eine niedrig-dimensionale Codierung der Features darstellen. Dem Modell ist es nicht möglich, die Inputs identisch wiederherzustellen, da bei der Abbildung ϕ Informationen verloren gegangen sind. Dadurch sollte der Code im optimalen Fall nur noch die Merkmale der Features umfassen, welche für die umfangreichste Information codieren. Dieser Code kann extrahiert werden, um eine Repräsentation der Features zu erhalten, welche nicht mehr mehrere hundert Merkmale umfasst, sondern nur noch einige wenige. Jegliche natürliche Schwankung in den Werten der Features geht verloren, da sie nicht im Code enthalten ist, weil sie nicht verallgmeinert werden kann.

Der Code

Bei der Suche dieser Funktionen muss der Autoencoder einen reduzierten Code entwickeln, um die Features neu zu repräsentieren. Durch diese Komprimierung ist es dem Modell unmöglich, die Rekonstruktion perfekt zu vollziehen. Sie ist immer approximativ, da bei der Komprimierung Informationen verloren gegangen sind. Am effektivsten wird die Kostenfunktion minimiert, wenn das Modell einen Code entwickelt, welcher die Features mit dem höchsten Informationsgehalt abstrahiert. Die Features, welche unwichtig sind oder nur durch zufälliges Rauschen der Daten enstanden sind, können daher verworfen werden.

Es ist wichtig zu erkennen das der Code, welcher der Autoencoder entwickelt, **datenspezifisch** ist. Das heisst, er kann nicht wie z.B ein Bildkompressionalgorithmus auf beliebige Daten angewendet werden. Stattdessen ist er nur sinnvoll für die Kompression von Daten zu verwenden, mit welchen er trainiert wurde. BEISPIEL EINER ABSTRAKTION (a la Menschliches Gesicht beschreiben).

4.3 Anwendungen

Die Eigenschaft, welche einen Autoencoder für die verschiedensten Anwendungen geeignet macht, ist die Dimensionalitätsreduktion. Wir werden nun einige Anwendungen grob betrachten.

4.3.1 Kompression

Es handlet sich um eine verlustbehaftete Kompression. Dimensionalitätsreduktion. Falls lineare Neuronen, ähnlich zur Hauptkomponentenanalyse $\frac{p}{d}$ des ursprünglichen Speicherbedarfs. Diese Komprimierung ist dabei Datenspezifisch.
Datenverkehr beschleunigen, weil weniger Daten.

4.3.2 Neue Datenrepräsentation

neues Datenformat

4.3.3 Visualisierung von Daten

Visualisierung von hochdimensionaler Daten in $\mathbb{R}^2$ und $\mathbb{R}^3$
Im übernachsten Kapitel werden wir eine Anwendung noch genauer Betrachten die des Denoisers.

4.4 Convolutional-Autoencoder

Ein Convolutional-Autoencoder ist, wie es der Name schon sagt, ein Autoencoder, welcher anstatt der normalen Fully-Connected-Schichten eines KNNs, die Schichten eines CNN verwendet. Dieser ist interessant, weil er zur Kompession von Bildern verwendet werden kann. Wie bereits erwähnt, ist auch hier die Kompression datenspezifisch. Beispielsweise könnte man einen Convolutional-Autoencoder mit einem Datensatz von menschlichen Gesichtern trainieren. Dieser würde dann einen datenspezifischen Code für diese Gesichter entwickeln. Man kann sich vorstellen, dass das Modell nicht mehr die Farbwerte der Features im Encoding speichert, sondern stattdessen diese Features abstrahiert. Somit könnten Eigenschaften, wie die Augenfarbe, Breite der Nase, Mundposition und vieles mehr im Flaschenhals gespeichert werden. Diese Informationen brauchen offenkundig weniger Kapazität als die gesamten Pixelwerte.

Des weiteren sind Convolutional-Autoencoder von Interesse, da sie zur weiteren Anwendung eines Autoencoder leiten: den Denoising-Autoencoder. Dieser soll im nächsten Abschnitt betrachtet werden.

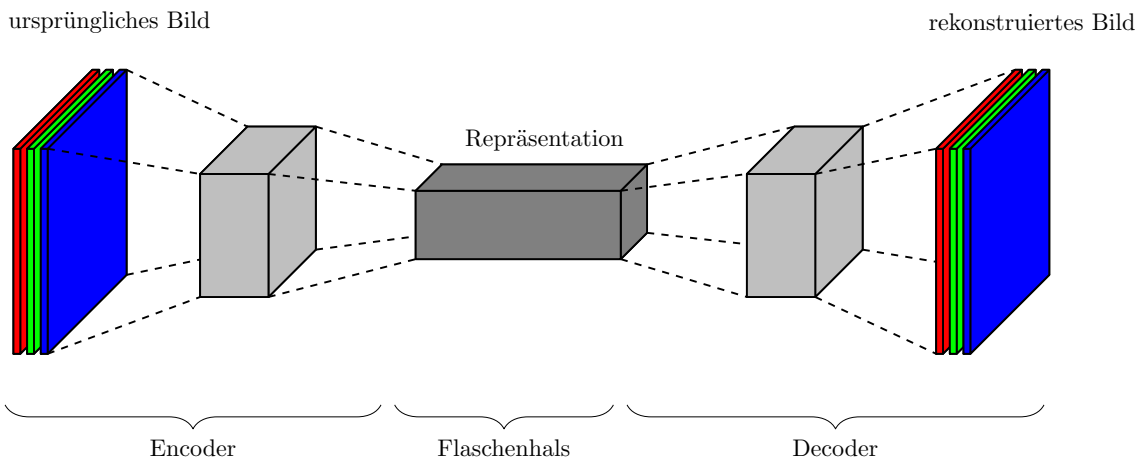

Abbildung 4.3: Darstellung eines Convolutional Autoencoders

(CodeParade, *Computer Generates Human Faces*)

4.5 Denoising-Autoencoder

Ein Denoising-Autoencoder oder einfach Denoiser verkörpert einen leicht abgeänderterten Autoencoder. Er wird vorallem verwendet, um ein Rauschen aus Bildern zu entfernen.

Im UNterschied zu klassischen Autoencodern benötigt er einen Datensatz mit wahren Labels, da er nicht die Features kopiert. Seinen Input besteht aus den verrauschten Bilder und die Labels beinhalten die unverrauschten Bilder. Somit wird er darauf trainiert, das Rauschen zu entfernen. Man mag sich nun die Frage stellen, weshalb hierfür ein Autoencoder und kein normales CNN verwendet wird. Empirisch hat sich gezeigt, dass sich Denoiser besser für das Entrauschen von Bilder geeignet sind (QUELLE). Das hat nachvollziehbare Gründe. Bei der Entwicklung des Codes für Encoding-Repräsentation, kann das Rauschen nicht codiert werden, da es völlig zufällig auftritt. Es existieren keine Muster oder Gesetzmässigkeiten, welche anderst codiert werden könnten. Somit muss der Autoencoder diese Rausch-Features verwerfen. Gegenüber sonstigen CNNS hat er ein leichteres Spiel.

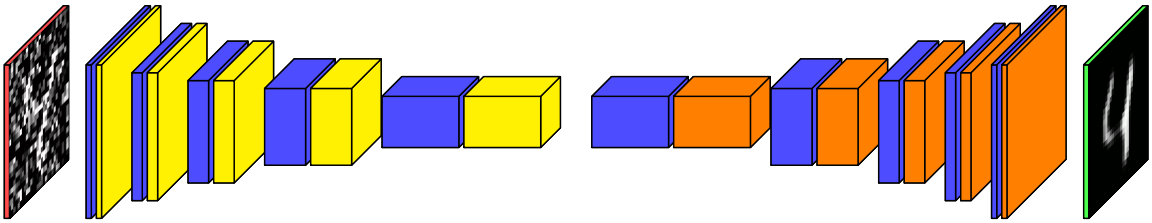

Abbildung 4.4: Visualisierung eines Convolutional-Denoising-Autoencoder

4.5.1 Generierung der verrauschten Bilder

Um den Autoencoder zu trainieren, müssen verrauschte Daten generieren werden. Dies geschieht, indem auf die Features ein additives Gauss'sches Rauschen anwendet wird. Dafür verwendet man üblicherweise eine Gauss'sche Normalverteilung $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ mit Erwartungswert $\mu = 0$ und Varianz $\sigma^2 = 1$. Dieser wird jeweils ein Zufallswert entnommen und addiert ihn zu jedem Feature hinzu. Auf diese Weise lässt sich ein verrauschter Datensatz entwickeln.

$$r \sim \mathcal{N}(\mu = 0, \sigma^2 = 1)$$
$$\tilde{x} = x + r$$

Kapitel 5

Frameworks für Maschinelles Lernen

In den Kapiteln eins bis vier wurde die theoretische Funktionsweise von Maschinellem Lernen dargelegt zusammen mit dem konkreten Modell eines KNN und deren konkreten Architekturen des CNN und des Autoencoder. Nun findet ein Übergang zur praktischen Programmierung eines Convolutional-Autoencoders statt. Es wird die grobe Funktionsweise von den Frameworks TensorFlow und Keras erörtert, welche dann für die eigentliche Entwicklung in Kapitel sechs Anwendung finden. Diese Frameworks habe eine Implementation für ML-Algorithmen realisiert.

5.1 TensorFlow

Abbildung 5.1: TF-Logo

TensorFlow (TF) ist ein von Google entwickeltes **Framework** für **datenstromorientierte Programmierung**. Es ist im Grunde genommen eine Mathematik-Programmbibliothek für numerische Berechnungen, dessen Hauptanwendungsbereich im Maschinellen Lernen liegt. TF zeichnet sich hauptsächlich durch seine einfache Bedienung aus, welche es dem Benutzer erlaubt ohne grossartige mathematische Vorkenntnisse ein ML-Modell zu definieren, zu trainieren und zu verwenden. Desweiteren sind die performanten Implementierungen bemerkenswert, welche es ermöglichen ein Modell sehr schnell zu trainieren und auszuführen. Somit ist TF gegenüber selbstgeschriebenen Implementationen zu bevorzugen. TF ist gratis und ein Open-Source-Projekt. Es kann auf Github gefunden werden (siehe QR-Code).

In der Industrie ist TensorFlow gut etabliert und weit verbreitet. Es wird von vielen Grossunternehmen des Internets für ihre Produkte verwenden. Einige dieser Firmen sind: Google, Twitter, AirBnB, Intel, CocaCola, Snapchat und noch viele mehr.

Grundsätzlich wurde TF für Maschinelles Lernen entwickelt. Speziell eignet es sich für Deep Learning. Es bietet die nötigen Werkzeuge, um ein Modell zu definieren und um es mit den eingebauten Algorithmen zu trainieren. Trotz dieser eigentlichen Grundidee von TF, sollten sich die Abstraktionen eigentlich für beliebige Anwendungen eignen, welche Gebrauch von numerischen Berechnungen machen.

Im Folgenden werden die grobe Funktionsweise von Tensorflow untersuchen. Um genau zu sein betrachten wir Tensorflow-Core Version r1.14[1]. Die Betrachtung von TF wird nicht sehr tiefgreifend sein, da bei der Programmierung in Kapitel sechs auf die High-Level-API Keras zurückgegriffen wird. Somit wird nur teilweise direkt mit TF gearbeitet. Trotzdem ist es hilfreich ein grobes Verständniss über TF zu besitzen, um die Funktionsweise zu verstehen.

Die wichtige Resource um TensorFlow zu lernen ist wohl die offizielle TensorFlow Website. Dort findet man auch die Dokumentation.

[1] Momentan befindet sich TF 2.0 in der Beta Version. Es handelt sich dabei um eine grosse Überarbeitung des Frameworks. Es ist zu empfehlen, sobald TF 2.0 offiziel veröffentlich wurde, es zu verwenden.

(Many, *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*)
(Mehrere, *TensorFlow Core r1.14 API-Docs*)

5.1.1 Frontend und Backend

Wie die meisten grossen Frameworks ist TensorFlow in Backend und Fontend aufgeteilt.

Fontend und Backend

Das **Frontend** ist der Teil eines Programms, mit welchem der Benutzer interagiert. Es stellt eine Schnittstelle zu dem sogenannten Backend eines Programms dar. Es offenbart so gewisse Funktionalitäten des Programmes dem Benuzter gegenüber, ohne dass er dabei etwas von der zugrundeliegenden Logik wahrnimmt.

Das **Backend** ist das Gegenstück zum Frontend. Es implementiert jegliche Programmlogik, welche das gewünschte Verhalten der Applikation hervorruft. Der Benutzer hat keinen direkten Zugriff auf diesen Teil des Programmes und bekommt somit nichts direkt von dessen Existenz mit.

Das Frontend von TF ist in **Python** geschrieben[2]. Python wird allgemein als eine sehr einsteigerfreundliche Programmiersprache wahrgenommen. Sie ermöglicht es dem Benutzer mit wenigen Zeilen Code und ziemlich intuitiv TensorFlow zu verwenden. Somit werden wir die Entwicklung eines Modells in Python vornehmen.

Das Backend von TF ist dagegen in **C++** (und CUDA) geschrieben. Dies hat den Grund, dass C++ im Gegensatz zu Python sehr performant ist. Dies bedeutet, dass die Ausführungszeit eines Programms sehr kurz ist. In der Konsequenz jedoch ist Programmcode deutlich anspruchsvoller und ausführlicher (engl.: verbose) geschrieben. Da der Benutzer jedoch keine direkte Interaktion mit dem Backend hat, muss er sich nicht mit C++ befassen.

TF ist gerade deshalb sehr attraktiv für ML, da es sehr performant (schnell ausführbar) ist und dadurch die Trainingszeit für die Modelle relativ kurz haltet. Dies wurde durch verschieden Designentscheidungen von TF erreicht.

Falls der Leser am Verständniss dieser Entscheide interessiert ist und an der eigentlichen Implemention von TF (dem Master) kann er im Anhang (C) dazu Informationen finden.

5.1.2 Graph

TensorFlow ist datenstromorientiert. Das bedeutet, dass eine Berechnung durch einen gerichteten Graphen beschrieben wird. Zuerst wird solch ein Graph aufgestellt und es werden ihm Knoten und Pfade hinzugefügt. Erst nach der Definition wird er dann ausgeführt. Es handelt sich dabei um einen **Computation Graph**, welcher schon in Anhang (B) erwähnt wurde. In TensorFlow wird dieser als einen `Graph` bezeichnet.

Dieser Graph führt eine Datenstrom-Berechnung aus. Er besteht aus einer Menge an Knoten, welche miteinander über Pfade verbunden sind. Die Knoten beinhalten Zahlenwerte, welche über die Pfade verrechnet und so auf den nächsten Knoten abbgebildet werden. Die Pfade sind also die Operationen, welche auf die Werte angewandt werden. Jeder Knoten hat null oder mehr Inputs und null oder mehr Outputs. Der Graph zeichnet sich bei der Erstellung nur durch seine Operationen aus.

Mithilfe des Graphs wird das eigentliche ML-Modell definiert. Die Ausführung von ihm stellt die Vorwärtspropagierung dar.

Abbildung 5.2: Visualisierung eines `Graph`

[2] TF besitzte mehrere Frontends, welche in den verschiedensten Programmiersprachen geschrieben sind. Wir werden jedoch nur das Python-Frontend betrachten, da es am besten von TF unterstützt ist.

5.1.2.1 Knoten und Tensoren

Die zentrale Dateneinheit in TensorFlow sind Tensoren, welche bereits in Sektion (3.1) präsentiert wurden. Auch die Knoten des Graphen repräsentieren Tensoren. Die meisten jedoch enthalten keine festen Zahlenwerte, sondern werden erst bei der der Ausführung des Graphen befüllt. Danach können die Werte ausgelesen werden.

Die Tensoren erlauben es den Daten innerhalb des Graphen belibige Dimensionaltäten und Formen anzunehmen. Es können sowohl Listen von Zahlen (Vektoren), wie auch Bilder (Tensoren dritter Stufe) verrechnet werden. Aus diesem Grund war es auch sinnvoll in Sektion (2.5) und im Anhang (B) die Gleichungen in Matrixform herzuleiten.

In Tensorflow bezeichnet man einen Tensor mit `Tensor`. Er ist definiert durch seine Form und den Datentyp seiner Elemente.

Fast alle Tensoren sind mit einer einzigen Graph-Ausführung assoziert. Sie besitzen ihren Wert nur für den jeweiligen Durchlauf, danach wird er verworfen. Man sagt die Tensoren sind "immutable", da die Werte nicht erhalten bleiben und so nicht modifiziert werden können.

Die soeben beschriebene Tensoren agieren einfach als Durchflussstellen innerhalb des Graphen. Sie müssen nicht explizit definiert werden, da sie automatisch eingefügt werden, wenn der Graph durch seine Operationen definiert wird.

Neben dieser Art von Knoten, gibt es auch noch Inputknoten. Diese können verwendet werden, um Werte in den Graphen einzuspeisen. Eine Art von Inputknoten beispielsweise wird benutzt um die Modellinputs einzufügen (`placeholder`). Eine andere Art wird verwendet um die Modellparameter einzuführen (`variable`). Die Modellparameter-Tensoren sind im Gegensatz zu den anderen Tensoren "mutable". Ihre Werte bleiben als also über mehrere Graphenausführungen erhalten und können beispielsweise beim Training modifiziert werden.

5.1.2.2 Pfade und Operationen

Die Knoten des Graphen werden über die Pfade aufeinander abbgebildet. Die Operationen, welche sie aufeinander abbildet, bezeichnet man als `Operation`. Eine Operation besitzt jeweils einen Namen und repräsentiert eine abstrakte Berechnung. Sie hat jeweils null oder mehr Tensor-Objekte als Input, wie auch als Output.

Man definiert meistens keine neuen Operationen, sondern verwendet einfach die vordefinierten. Ein Beispiel dafür wäre die `matmul(a,b)`-Operation, welche eine Matrixmultiplikation zwischen dem Knoten `a` und dem Knoten `b` ausführt. Das Resultat kann dann in einer neuen Knotenvariable `c` gespeichert werden.

Um den eigentlichen Graphen zu definieren, werden zu Beginn einige Inputknoten definiert. Diese werden dann durch die vordefinierten Operationen abbgebildet. Deren Resultate kann man dann erneut weiter verrechnen, bis der gewünschte Graph entsteht.

5.1.3 Ausführungen

5.1.3.1 Session

Für die Kommunikation zwischen Frontend und Backend ist die sogennante `Session` zuständig. Sie schickt den Graphen an das Backend, damit er dort performant ausgeführt werden kann. Diese Ausführung stellt die Vorwärtspropagierung dar.

Eine der essentiellen Aufgaben einer Session ist es den Graphen auszuführen. Dabei kann der Benutzer die Knoten angeben, dessen Werte die Funktions zurückgeben soll. Dabei erwartet diese Funktion die Werte mit denen die Inputknoten befüllt werden sollen.

5.1.3.2 Optimizer

Bevor das definierte Modell brachbare Resultate bei der Graphausführung liert, muss es trainiert werden. Dafür verwendet man einen sogennanten `Optimizer`. Dabei handelt es sich immer um Algorithmen, welche zur Minimieren oder Maximierung von Funktionen benutzt werden können. Es gibt verschiedene komplexe Optimizer, welche unterschiedliche Konvergenzgeschwindigkeiten und unterschiedliche Exaktheiten aufweisen. In der Theorie wurde nur das SGD-Verfahren behandelt.

Für ML verwendet man solche Optimizer zur Minimierung der Kostenfunktion, indem die Modellparameter angepasst werden. Dabei kann aus einer Menge von Konstenfunktion ausgewählt werden. Wir werden nur den Mittleren-Quadratischen-Fehler als Kostenfunktion verwenden.

Der Grund weshalb Computational Graphs für TensorFlow gewählt wurden, ist die einfache Bestimmung der Ableitungen der Variabeln innerhalb des Graphen, um die Optimierung vorzunehmen. Dieses Vorgehen wird in Sektion (B) ausführlich erklärt.

5.1.4 Tensorboard

TensorBoard ist ein externes Zusatzprogramm zu TensorFlow. Mit dessen Hilfe Daten zum Modell-Graph und zu dem Trainingsprozess erfasst und visualisiert werden können. Es ist möglich eine Visualisierung des Modell-Graphs zu betrachten. Desweiteren kann man Funktionsgraphen der Kostenfunktionentwicklung betrachten.

TensorBoard ist als Webserver geschrieben und kann über einen Webbrowser benutzt werden. Man muss TensorBoard als Callback in TensorFlow aktivieren, damit die nötigen Daten während der Graphausführung gesammelt werden.

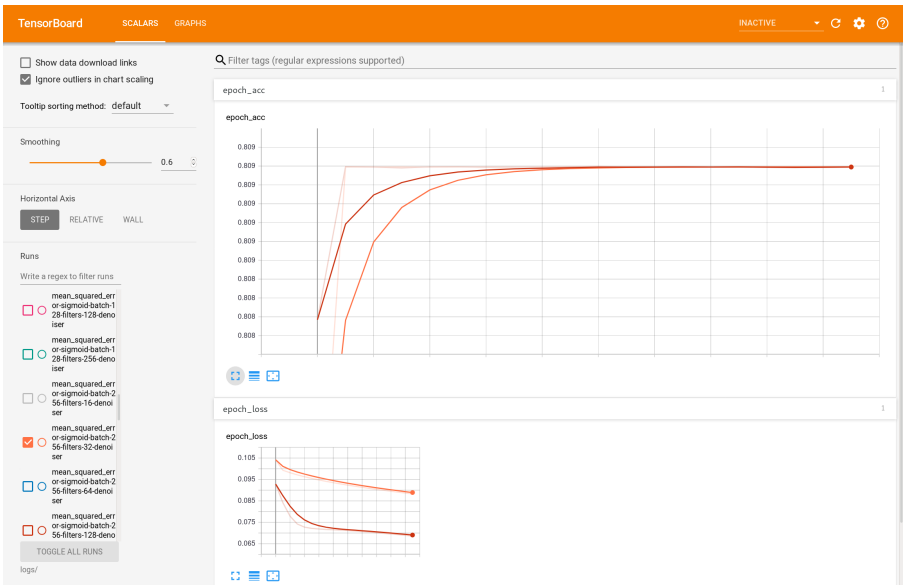

Abbildung 5.3: das TensorBoard-Webinterface

5.1.4.1 Hyperparameter einstellen

Der wichtigste Aspekt von TensorBoard für uns stellt die Tatsache dar, dass die Trainingsfortschritte visualisieren werden können. Man kann die Funktionsgraphen der Kostenfunktion betrachten. Es ist sogar möglich die Kostengraphen mehrerer Modelle gleichzeitig anzuzeigen und zu vergleichen. Somit kann man ein Modell, bei welchem mehrere Trainingsdurchläufe mit verschiedenen Hyperparameter durchgeführt wurden, gegenüberstellen. So können die besten Hyperparameter herausgesucht werden. Genau dieses Verfahren werden wir dann bei unserem eigenen Modell anwenden.

Der Graph ist interaktiv, was bedeutet, dass mit ihm interagiert werden kann und so detailiertere Angaben erhalten kann. Zum Beispiel kann so auch die beanspruchte Trainingszeit des Modells erfassen werden, welche meistens von Interesse ist.

In der untenstehenden Abbildung ist ein Graph von TensorBoard dargestellt, welcher die Entwicklung der Kostenfunktion für den Testdatensatz verschiedener Modell anzeigt. In diesem Beispiel hätte die orange Kurve ganz unten am besten abgeschnitten. Dieses Modell hat die kleinsten Kosten verursacht.

5.2 Keras

Abbildung 5.5: Keras-Logo

Um ein Modell in TF zu implementieren, müsste man das ganze Modell mit allen Operationen als Graphen definieren. Dies wäre ziemlich aufwendig und fehleranfällig. Man müsste die verschiedenen KNN-Schichten, wie z.B eine Convolutional-Schicht, selbst definieren. Damit dies nicht nötig ist, verschaffen wir uns Abhilfe mit der High-Level API **Keras**. Keras stellt Implementationen von verschiedenen KNN-Schichten zu verfügen, damit diese nicht mehr selbst erstellt werden müssen.

Keras ist ein Deep-Learning Framework geschrieben in Python. Keras wurde entwickelt, um eine einheitliche Schnittstelle für verschieden Backends, wie TensorFlow, Microsoft Cognitive Toolkit und Theano zu bieten. Seit TF Version 1.4 ist Keras ein fester Bestandteil der TensorFlow-Core-API. Keras ermöglicht ein sehr simples und benutzerfreundliches definieren von KNNs welche dann sehr einfach trainiert werden können.

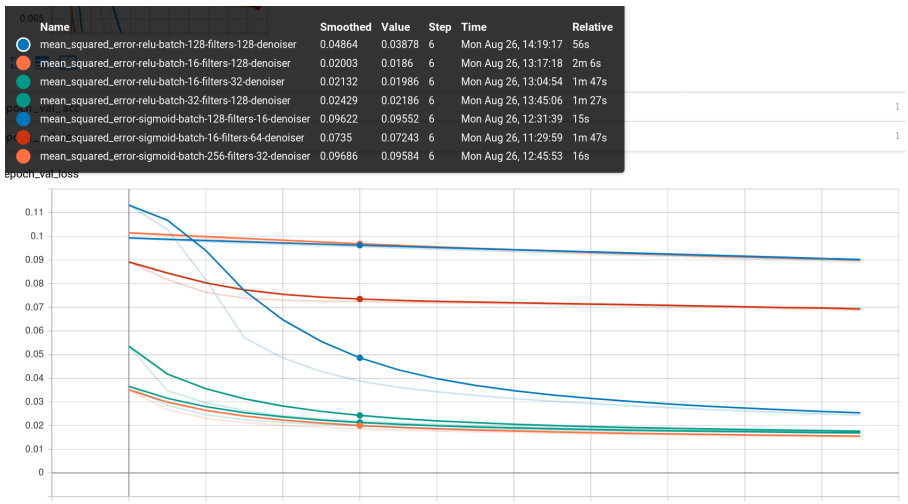

Abbildung 5.4: Trainingsvisualisierungen in TensorBoard

5.2.1 Sequential-Modell

Keras ist nicht eine eigenständige Programmbibliothek, sondern baut auf TensorFlow auf und dient dabei als High-level Schnittstelle. Keras verwendet die verschiedenen Konzepte von TF, wie Graphen und Operationen, um eigene KNN-Bestandteile zu implementieren. Dadurch ist es für den Benutzer deutlich einfach ein Modell aus diesem Baukasten zu konstruieren.

Die gängigste Vorgehensweise besteht darin, ein sogenanntes **Sequential-Modell** zu bauen. Dies ist ein Modell, welches einfach ein linearer Stapel von verschiedenen KNN-Schichten. Man kann dabei aus den vordefinierten Schichten von Keras auswählen. Im folgenden werden diese Schichten betrachtet.

5.2.2 Schichten

Man definiert den Graphen in Keras, indem die verschiedenen Schichten des gewünschten Modells in Variabeln gespeichert werden. Man referenziert bei der Deklaration jeder neuen Schicht jeweils die vorherige Schicht, damit sie verbunden werden. Am Ende der Erstellung der Schichten definiert man eine Modellvariable, welche die erste und die letzte Schicht als Argumenete erwartet.

Wir werden nun im folgenden die verschiedenen Schichttypen von Keras durchgehen, welche wir in der Theorie schon vorgestellt haben.

Noch eine Anmerkung zur Initalisierung der Modellparameter in Keras: Keras benutzt standardmässig ein anderes Vorgehen zur Initalisierung als in der Theorie in Sektion 2.5.1 erklärt. Es benutzt nämlich eine Glorot-Initalisierung mit einer Uniformen Verteilung. Wir werden deshalb explizit spezifizieren, dass wir die in der Theorie erklärte Variante der Glorot-Initalisierung mit einer Normalverteilung verwenden möchten.

(Mehrere, *Keras Documentation - Initalizers*)

Input-Schicht

Die Input-Schicht ist ziemlich selbsterklärend. Sie ist einfach die Platzhalter-Schicht, welche alle Features enthält. Man muss bei der Definierung die Form der Inputdaten angeben:

```
tf.keras.Input(shape=(<Form>)
```

Dense-Schicht

Die erste richtige KNN-Schicht ist die Fully-Connected-Schicht. Sie wird in Keras als `Dense` bezeichnet. Sie ist wie in der Theorie erklärt, die Schicht, welche aus Neuronen besteht und "dicht" zu jedem Neuron der nächsten Schicht verbunden ist. Als Argumente erwartet die Schicht die Anzahl Neuronen, aus welcher sie besteht, wie die Aktivierungsfunktion und die vorherige Schicht. Wie vorhin erwähnt überschreiben wir den Standard-Initalisierer mit dem `'glorot`$_n ormal' - Initalisierer$.

Conv2D-Schicht

Die Convolutional-Schicht eines CNNs wird in Keras mit `Conv2D` bezeichnet. Sie verhaltet sich wie in der Theorie erklärt. Um sie zu definieren, muss man die Anzahl Filter, die Filtergrösse f, den Stride s, das Padding p und die Aktivierungsfunktion angeben. Die Daten welche in eine Schicht eines CNNs gehen, müssen folgendes Format ausweisen: $(samples, channels, rows, cols)$. Der Output der Conv2D-Schicht hat wiederum folgende Form: $(samples, filters, new_rows, new_cols)$.

```
tf.keras.layers.Conv2D(filters=<#Filters>, kernel_size=<Filtergrösse>,
strides=<>, padding=<>, activation=<>, kernel_initalizer='glorot_normal')
```

MaxPool2D-Schicht

Die Pooling-Schicht in Keras, welche MaxPooling betreit, heisst `MaxPool2D`. Um sie zu definieren, muss die zusammenfassende Feldgrösse f, den Stride s und das Padding p angeben.

```
tf.keras.layers.MaxPool2D(pool_size=<Feldgrösse>, strides=<>, padding=<>)
```

UpSampling2D-Schicht

Die UpSampling-Schicht als Gegenstück zur Pooling-Schicht, heisst `UpSampling2D`. Dabei muss die Feldgrösse f und die Interpolationsmethode angegen werden.

```
tf.keras.layers.UpSampling2D(size=<>, interpolation=<>)
```

5.2.3 Training und Evaluierung

Nach dem das Modell definiert wurde, muss man es Kompilieren. Dies macht man mit der Methode `compile` diese erwartet als Arugmente, den Optimzier und eine Kostenfunktion. Man kann optional noch gewisse Metriken angeben, welche während des Trainings erfasst werden sollen.

```
model.compile(optimizer=tf.train.AdamOptimizer(0.001),
loss='categorical_crossentropy',
metrics=['accuracy'])
```

Die Optimizer sind die gleichen wie die in TensorFlow-Core. Sie befinden sich alle in tf.train. Die Kostenfunktionen sind auch die gleichen wie in TF-Core. Zum beispeil tf.loss.mean_squared_error.

Hier ein Beispiel:

```
model.compile(optimizer='sgd', loss='mean_squared_error')
```

Das Kompilieren bildet dann aus den gegeben Schichten den eigentlichen Computational Graph.

5.2.3.1 Fit

Nach der Kompilierung kann das Modell trainiert werden. Dies wird durch einen einzigen Methodenaufruf gemacht. Mann muss nur die `fit` Methode aufrufen. Diese erwartet als Parameter ein NumPy-Array aller Inputdaten, ein NumPy-Array aller Labels, die Anzahl Epochen und die Minibatch-Grösse. Optional kann man noch einen Testdatensatz angeben, welcher benutzt wird um die Kosten zu bestimmen.

```
model.fit(<inputs>, <labels>, epochs=<>, batch_size=<>)
```

5.2.3.2 Predict

Sobald das Modell trainiert wurde, kann man es dazu verwenden, Vorhersagen für neue Daten zu machen. Dazu benutzt man die `Predict`-Methode. Sie erwartet einfach ein Array mit Inputs. Als Rückgabewert hat sie die Vorhersagen zu den gegeben Inputs.

```
result = model.predict(data, batch size=32)
```

Kapitel 6

Entwicklung eines Denoising-Autoencoders

In diesem Kapitel soll nun das bisherige Wissen zusammengeführt werden, indem unter Anwendung von TensorFlow und Keras ein konkretes Anwendungsbeispiel programmiert wird.
Dabei wird darauf eingegangen, welche Schritte die Entwicklung eines solchen Modells umfasst und wie dabei am besten vorgegangen wird.

6.1 Das konkrete Modell

Wir werden nun einen Convolutional-Denoising-Autoencoder programmieren. Dieser kann verwendet werden um das Bildrauschen von Bildern zu eliminieren und sie so wieder erkenntlich zu machen. Zu Demonstrationszwecken werden handgeschriebene Ziffern vom MNIST-Datenset verwendet, weil die Funktionsfähigkeit auf dieser Basis sehr einfach erkennbar ist.

6.1.1 Daten

Als Trainingsdaten verwenden wir den **MNIST**-Datensatz. Er ist der wohl bekannteste Datensatz für beispielhaftes Maschinelles Lernen. Er besteht aus schwarz-weiss Bildern von handgeschrieben Ziffern. Zusätzlich würde es auch noch Labels zu den Ziffern geben, um das Modell beispielweise für Ziffernerkennung zu trainieren. Jedoch werden wir diese nicht brauchen, da wir einen Autoencoder entwickeln, dessen Labels den Inputs entsprechen.

Der Datensatz besteht aus einem Trainingsdatensatz von 60'000 Sampels und einem Testdatensatz von 10'000 Sampels. Alle Ziffern sind bereits korrekt formatiert, da ihre Grösse auf 28×28 Pixel normalisiert wurde und sie im Bild zentriert sind.

(Yann LeCun, *The MNIST Database of handwritten digits*)

6.2 Setup

Zunächst ist es wichtig, das Entwicklungsumfeld richtig zu konfigurieren. Das bedeutet konkret, dass Python zusammen mit den verschiedenen Programmbibliotheken installieren werden muss.

Die Installationsschritte werden in dieser Arbeit für eine arch-basierte Linuxdistribution erklärt, welche den **Pacman**-Package-Manager verwendet.

Falls der Leser ein anderes Betriebssystem verwendet möchte, ist auf die offizielle TensorFlow Website für die Installationsschritte zu verweisen:

Abbildung 6.1: grobes Schema des Modells

Abbildung 6.2: ein Auszug an MNIST-Bildern (invertierte Farben) (Steppan, *File:MnistExamples.png — Wikipedia, The Free Encyclopedia*)

Python3

Damit TensorFlow und Keras verwenden werden können, bedingt dies, dass Python3 installiert sein muss. Folgender Befehl muss in der Kommandozeile ausgeführt werden, um die Installation vorzunehmen.

```
sudo pacman -S python
```

TensorFlow

Für die Installation von TensorFlow muss unter Arch Linux das entsprechende Package installieren werden. Falls der Leser über eine Nvidia-Grafikkarte verfügt, welche eine "Compute Capability" von mehr als 3.5 besitzt, kann er von der GPU-Hardwarebeschleunigung Gebrauch machen. Somit ist die CUDA-Version von TF mihtilfe des folgenden Kommandos zu installieren:

```
sudo pacman -S python-tensorflow-cuda
```

Pacman installiert nun automatisch zuerst alle Programmabhängigkeiten, wie CUDA, cuDNN und das TensorFlow-Backend, bevor das eigentliche Python-TensorFlow installiert wird.

Falls keine geeignete Grafikkarte vorliegt, ist es ebenso möglich die normale TF-Version ohne Unterstützung für die GPU zu verwenden. Dies kann durch nachstehendes Kommando vorgenommen werden.

```
sudo pacman -S python-tensorflow
```

Dabei muss Keras nicht explizit installiert werden, da es in TensorFlow implementiert ist.

Python-Module

Für das Python-Programm werden zwei Packages benötigt, welche nicht in der Standardbibliothek von Python enthalten sind:

- NumPy: Ein Package, welches verschiedene mathematische Konzepte implementiert; vor allem Vektor- und Matrix-Arithmetik
- Matplotlib: Ein Package zum Erstellen von Plots und Grafiken

Man installiert beide mit folgenden Kommandos.

```
sudo pacman -S python-numpy
sudo pacman -S python-matplotlib
```

6.3 Entwicklung

Nun beginnt die eigentliche Programmierung.

6.3.1 Testprogramm

Zunächst wird ein kleines Testprogramm geschrieben, welches überprüft, ob alle Programmabhängigkeiten korrekt installiert wurden und verwendet werden können.
In den ersten Zeilen des Pythonprogamms werden die Importstatments geschreiben, um NumPy, Matplotlib und TensorFlow verfügbar zu machen. Keras muss wie gesagt nicht explizit geladen werden, da es in TensorFlow enthalten ist. Nun können die Versionnummern der verschiedenen Programmbibliotheken in die Konsole geschrieben werden, um zu überprüfen, ob alles richtig konfiguriert ist.

```
1 import numpy as np # NumPy wird impotiert
2 import matplotlib as mpl # Matplotlib wird impotiert
3 import tensorflow as tf # TensorFlow wird impotiert
4
5 print(np.__version__) # Schreibt die NumPy-Version nach stdout.
6 print(mpl.__version__) # Schreibt die Matplotlib-Version nach stdout.
7 print(tf.__version__) # Schreibt die TensorFlow-Version nach stdout.
```

Falls der Output folgenden Charakter hat (die Versionsnummern müssen nicht die gleichen sein) und keine Fehlermeldungen erfolgen, sollte alles funktionieren.

```
1 1.17.0
2 3.1.1
3 1.14.0
```

6.3.2 Trainingsdaten

Nun haben wir mit dem kleinen Testprogramm verifiziert, dass alle Programmabhängigkeiten funktionieren. Auf dieser Basis können wir mit dem eigentlichen Programm beginnnen.

In den folgenden Auschnitten wird der Code laufend weiter ausgebaut. Auf diese Weise zeigt sich, was er bewirkt. Das eigentliche Programm beginnt mit folgenden Importstatements.

```
1 import numpy as np
2 import matplotlib.pyplot as plt
3 import tensorflow as tf
```

6.3.2.1 Laden des MNIST-Datensatzes

Der erste Schritt besteht darin, die Datensätze zu laden. Wie bereits erwähnt, wird dabei vom MNIST-Datensatz Gebrauch gemacht. Da dieser stark verbreitet ist, existiert eine Funktion in Keras, welche automatisch diese Daten herunterlädt und sie als NumPy-Arrays zur Verfügung stellt. Die Funktion gibt die verschiedenen Komponenten der Daten in folgendem Format zurück `(x_train, y_train), (x_test, y_test)`. Da nur Interesse an den Features `x` besteht, werden die überflüssigen Labels `y` mithilfe der Wegwerf-Variable `_` verworfen.

```
1 (x_train, _), (x_test, _) = tf.keras.datasets.mnist.load_data()
```

Nun sind die Features fürs Training in der Variable `x_train` und die Features des Trainingsdatensatzes in der Variable `x_test` gespeichert.

6.3.2.2 Formatieren der Daten

In einem nächsten Schritt müssen die Daten transformiert werden, damit sie die richtige Form für das Modell haben. Wie bereits erwähnt, ist der MNIST-Datensatz einfach verwendbar, da alle Bilder die gleichen Masse aufweisen und die Ziffern zentriert sind.

Jedoch sind die Grauwerte zu normalisieren, denn im Moment liegen sie noch im Intervall $[0, 255]$ und sind vom Typ Integer. Das Modell kann am besten mit Kommazahlen, welche im Intervall $[0, 1]$ liegen, umgehen. Um diese Anpassung vorzunehmen, kann folgender Code angefügt werden.

```
x_train = x_train.astype('float32') / 255.0 # Normalisierung
x_test = x_test.astype('float32') / 255.0 # Normalisierung
```

Desweiteren werden im Modell ConvLayers verwendet. Diese in Keras implementierten ConvLayers erwarten Inputs in der Form (m, w, h, c), wobei m die Anzahl der Bilder ist, w die Bildbreite, h die Bildhöhe und c die Anzahl der Farbkomponenten. Die Bildbreite w und -höhe h von 28 Pixeln wird beibehalten, wie auch die Anzahl Farbkomponeten $c = 1$. Die Anzahl Bilder m lässt sich aus der Länge des Arrays entnehmen `len(x_train)`. Mithilfe vom NumPy lässt sich das Array wie folgt umformen.

```
x_test = np.reshape(x_test, (len(x_test), 28, 28, 1)) # neue Form: (60'000, 28, 28, 1)
x_train = np.reshape(x_train, (len(x_train), 28, 28, 1)) # neue Form: (10'000, 28, 28, 1)
```

Die Daten besitzen nun die richtige Form für das Modell.

6.3.2.3 Generieren der verrauschten Bilder

Den Input in das Modell stellen nicht die normalen MNIST-Bilder dar, sondern eine verrauschte Variante von diesen. Sie werden nun generiert, indem ein additives Gauss'sches Rauschen auf sie angewendet wird.

Zuerst wird eine Matrix $\boldsymbol{R} \in \mathbb{R}^{28\times28\times1}$ erstellt, welche die gleiche Form, wie die Bilder besitzt. Diese Matrix wird mit Zufallswerten gefüllt. Für die Zufallswerte wird eine normalisierte Gauss'sche Normalverteilung $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ mit Erwartungswert $\mu = 0$ und Varianz $\sigma^2 = 1$ verwendet. Da jedes Bild eine eigene Rauschmatrix verlangt, wird zu diesem Zweck eine Liste $(\boldsymbol{R}_1, \boldsymbol{R}_2, \ldots, \boldsymbol{R}_m)$ der Länge m an Rauschmatrizen erzeugt. Dafür kann die NumPy Funktion `np.random.normal(loc=<μ>, scale=<σ²>,size=<Form>)` verwendet werden. Die somit erhaltenen Rauschmatrizen werden dann mit einer Rauschkonstante `noise_factor` multiplziert und anschliessend wird das Produkt auf die MNIST-Bilder addiert. Nach dem Hinzufügen der Rauschwerte müssen die Grauwerte noch auf das Intervall $[0, 1]$ zurecht gestutzt werden. Auch hierfür kann eine NumPy-Funktion `np.clip(var, min, max)` angewendet werden. Diese Schritte werden sowohl mit dem Trainingsdatensatz, als auch mit dem Testdatensatz vollzogen.
Somit lautet der Code:

```
noise_factor = 0.5

# für x_train
noise_matrices = np.random.normal(loc=0.0, scale=1.0, size=x_train.shape)
noise_matrices *= noise_factor
x_train_noisy = x_train + noise_matrices
x_train_noisy = np.clip(x_train_noisy, 0.0, 1.0)

# für x_test in Kurzfassung
x_test_noisy = x_test + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_test.shape)
x_test_noisy = np.clip(x_test_noisy, 0.0, 1.0)
```

Mithilfe der Matplotlib ein Blick auf die verrauschten Bilder im Vergleich zu den Originalbildern geworfen werden. Dafür wird ein Plot erstellt, welcher jeweils 10 Bilder beider Arrays zeigt.

Für diesen Zweck wird eine `pyplot.figure` erstellt. Innerhalb dieser werden jeweils 10 `subplots` definiert, sowohl für die verrauschten Bilder, als auch für die Originale. Bevor die Bilder angezeigt werden können, müssen sie in die richtige Form für die Matplotlib gebracht werden. Sie sollen die Form (28×28) aufweisen. Ausserdem ist der Plot als schwarz-weiss Grafik zu spezifizieren.

```
n = 10 # jeweils 10 Bilder
plt.figure()
for i in range(n):
  # Originalbilder
  ax = plt.subplot(2, n, 1+i)
  img_clean = x_test[i].reshape(28, 28)
  plt.imshow(img_clean)
  plt.gray()

  # verrauschte Bilder
  ax = plt.subplot(2, n, 1+n+i)
  img_noisy = x_test_noisy[i].reshape(28, 28)
  plt.imshow(img_noisy)
  plt.gray()
plt.show()
```

Das Ergebniss ist in Abbildung (6.3) sichtbar.

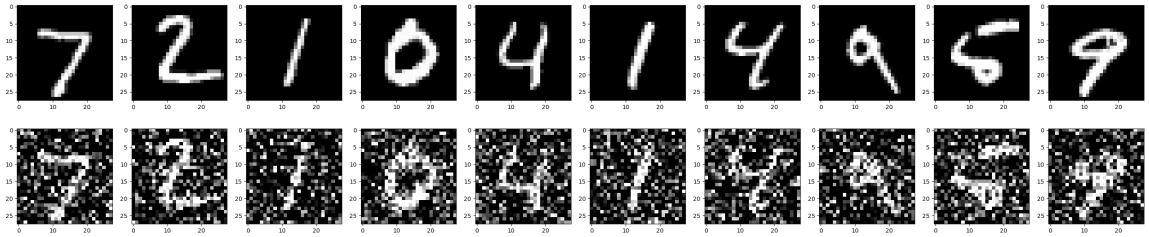

Abbildung 6.3: Verrauschte Bilder neben den Orignalbildern

Die Daten liegen nun vollständig und im richtigem Format vor. Somit kann zur Definition des Modells übergegangen werden.

6.3.3 Modell definieren

Mithilfe von Keras kann das Modell eines Convolutional-Denoising-Autoencoder definiert werden. Dies geschieht nach dem Vorbild der Theorie. Wie bereits erklärt umfasst die Topologie eines CNNs die verschiedensten Hyperparameter. Für diese werden der Einfachheit halber zunächst unbegründeten Werte verwendet. Zu einem späteren Zeitpunkt werden die passenden Hyperparameter durch iteratives Ausprobieren ermittelt.

Das Modell beginnt mit der Inputschicht $l = 0$, welche ein Tensor ist, der die Inputwerte enthält. Die Schicht hat logischerweise die gleiche Form, wie ein MNIST-Bild.

```
input_data = tf.keras.Input(shape=(28, 28, 1))
```

Nach dieser Inputschicht folgt der Encoder des Autoencoders. Dieser besteht sowohl aus Convolutional-Schichten, wie auch aus Pooling-Schichten, welche sich abwechseln. Für alle Schichten werden vorerst unbegründeten Hyperparameter gewählt. Für die Convolutional-Schichten wird eine Filtergrösse $f^l = 3$, eine Anzahl Filter von $c^l = 32$, ein Stride $s = 1$, Same-Padding und die ReLU-Aktivierungsfunktion $\varphi = \varphi^{\text{ReLU}}$ verwendet. Da Keras standardmässig die Initialisierung der Modellparameter mit einer Uniformen Verteilung vornimmt, muss der `kernel_initalizer` explizit auf `'glorot_normal'` gesetzt werden. Dadurch findet die Initalisation gleich wie in Sektion 2.5.1 statt.
Der Code für die Defition einer solchen Convolutional-Schicht lautet:

```
conv_layer = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3),
strides=(1, 1), padding='same', activation='relu',
kernel_initializer='glorot_normal')
```

Für die Pooling-Schichten wird analog eine Feldgrösse $f = 2$, ein Stride $s = 2$ und Same-Padding gewählt. Dies hat zur Wirkung, dass jedes (2×2)-Feld zu einem einzigen Element zusammengefasst wird.
Der Code für eine dieser Pooling-Schichten lautet:

```
pool_layer = tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=None, padding='same')
```

Für den Decoder werden die gleichen Convolutional-Schichten wie für den Encoder verwendet. Anstelle von Pooling-Schichten verwendet er UpSampling-Schichten, welche jeweils nach einer Convolutional-Schicht folgen. Für die UpSampling-Schichten wurde eine Feldgrösse $f = 2$ gewählt. Somit wird ein einziger Pixel auf ein 2×2-Felder hochskaliert. Als Interpolationsmethode wird der Nächste-Nachbar-Algorithmus verwendet. Die beschriebene UpSampling-Schicht wird folgendermassen definiert:

```
upsampling_layer = tf.keras.layers.UpSampling2D(size=(2, 2), interpolation='nearest')
```

Nun folgt die Deklarierung aller Schichten und deren Verknüpfung.
Das Modell weist einen Flaschenhals auf, welcher zwei Convolutional-Schichten tief ist. Das bedeutet, dass der Encoder aus zwei Convoutional-Layer-Pooling-Player-Paaren besteht. Danach folgt der einschichtige Flaschenhals. Im Anschluss liegt der Decoder, der zwei Convolutional-Layer-Upsampling-Layer-Paaren umfasst. Um die jeweils neue Schicht zur vorherigen Schicht zu verbinden, gibt man die Vorherige in Klammern am Ende des Statements an.
Der ganze Graph wird durch folgenden Code gebildet:

```
# Encoder
input_data = tf.keras.Input(shape=(28, 28, 1))
econv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same',
  activation='relu', kernel_initializer='glorot_normal')(input_data)
emaxpool0 = tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=None, padding='same')(econv0)
econv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same',
  activation='relu', kernel_initializer='glorot_normal')(emaxpool0)
emaxpool1 = tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=None, padding='same')(econv1)

# Flaschenhals der Form (7, 7, 32)
encoded =  emaxpool1

# Decoder
dconv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same',
  activation='relu', kernel_initializer='glorot_normal')(encoded)
dupsample0 = tf.keras.layers.UpSampling2D(size=(2, 2), interpolation='nearest')(dconv0)
dconv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same',
  activation='relu', kernel_initializer='glorot_normal')(dupsample0)
dupsample1 = tf.keras.layers.UpSampling2D(size=(2, 2), interpolation='nearest')(dconv1)
dconv2 = tf.keras.layers.Conv2D(filters=1, kernel_size=(3, 3), strides=(1, 1), padding='same',
  activation='sigmoid', kernel_initializer='glorot_normal')(dupsample1)
decoded = dconv2
```

Auffallend im Code ist, dass der Decoder nicht etwa zwei Convolutional-Layers besitzt, sondern sogar drei. Die letzte Schicht wird benötigt, damit die Daten wieder die richtige Formatierung aufweisen. Das heisst einerseits, dass die Outputs wieder in der Ursprungsform (28×28) vorliegen müssen. Andererseits sollen die Outputs wieder im Intervall $[0, 1]$ befinden. Mithilfe der Sigmoid-Funktion als Aktivierungsfunktion werden sie genau auf dieses Intervall abgebildet.
Für alle anderen Schichten wurde die ReLU-Aktivierungsfunktion gewählt.

Nun muss noch eine Modellvariable deklariert werden, indem man die Input- `input_data` und die Outputschicht `decoded` angibt. Danach ist das Modell zu kompilieren. Bei der Kompilierung kann das Optimierungsverfahren und die Kostenfunktion gewählt werden. Für die Optimierung wird das Stochastische-Gradientenverfahren SGD verwendet. Als Kostenfunktion wird der Mittlere-Quadratische-Fehler C_{MSE} gewählt.

```
autoencoder = tf.keras.Model(input_data, decoded)
autoencoder.compile(optimizer='sgd', loss='mean_squared_error') # SGD und MSE
```

Mithilfe von `tf.keras.Model.summary` kann man eine Zusammenfassung des Modells in Textform erhalten. So können Informationen bezüglich der Form der verschiedenen Schichten abgerufen werden, um zu überprüfen, ob alles stimmig ist. Nachfolgende Summary gilt für unser Modell:

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         [(None, 28, 28, 1)]       0
_________________________________________________________________
conv2d (Conv2D)              (None, 28, 28, 32)        320
_________________________________________________________________
max_pooling2d (MaxPooling2D) (None, 14, 14, 32)        0
_________________________________________________________________
conv2d_1 (Conv2D)            (None, 14, 14, 32)        9248
_________________________________________________________________
max_pooling2d_1 (MaxPooling2 (None, 7, 7, 32)          0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 7, 7, 32)          9248
_________________________________________________________________
up_sampling2d (UpSampling2D) (None, 14, 14, 32)        0
_________________________________________________________________
conv2d_3 (Conv2D)            (None, 14, 14, 32)        9248
_________________________________________________________________
up_sampling2d_1 (UpSampling2 (None, 28, 28, 32)        0
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 28, 28, 1)         289
=================================================================
Total params: 28,353
Trainable params: 28,353
Non-trainable params: 0
_________________________________________________________________
```

Es zeigt sich, dass das Modell gesamthaft circa 28'000 Parameter umfasst, welche zu trainieren sind.

6.3.4 Modell trainieren

Nun gilt es das definierte Modell zu trainieren. Mit Keras kann dies mit einem einzigen Funktionsaufruf durchgeführt werden. Diese Funktion erwartet einige Argumente. Zuerst sind die Features und Labels anzugeben. Die Features wurden in der Variable `x_train_noisy` gespeichert. Die Labels sind die unverrauschten MNIST-Bilder, welche in der Variable `x_train` enthalten sind. Desweiteren wird die Grösse eines Mini-Batches als 128 Sampels spezifiziert. Das Training erfolgt über 100 Epochen. Wichtig ist auch, dass die Trainingssampels vor dem Training druchmischt werden, damit keine Mustern innerhalb der Anordnung der Samples erlernt werden. Als letzen Argument wird noch der Testdatensatz angegeben.

```
autoencoder.fit(x=x_train_noisy, y=x_train, batch_size=128, epochs=100, shuffle=True,
  validation_data=(x_test_noisy, x_test))
```

Sofern TensorFlow eine geeignete Nvidia-Grafikkarte vorfindet und auch die CUDA-Version von TF installiert ist, erfolgt das Training mithilfe von GPU-Hardwarebeschleunigung. Dadurch sollte das Trainings innherhalb einiger Minuten abgeschlossen sein. Während des Trainings schreibt TensorFlow Informationen zum aktuellen Fortschritt in die Kommandozeile. Diese Infos weisen nachstehenden Charakter auf und geben Auskunft über die aktuelle Epoche und die Werte der Kostenfunktion. Die Kosten für den Trainingsdatensatz werden mit `loss` bezeichnet und die für den Testdatensatz mit `val_loss`.

```
Epoch 3/100
60000/60000 [==============================] - 4s 60us/sample - loss: 0.0911 - val_loss: 0.0772
```

Das Kostenfunktion hat nach dem Training einene Wert `val_los` von 0.0180, bezüglich dem Testdatensatz.

Jetzt, da das Modell trainiert wurde, ist es sinnvoll es auf dem Computer als Modelldatei abzuspeichern. So muss das es nicht jedesmal wieder neu trainieren werden, sondern kann über die Modelldatei eingelesen werden. Für dieses Einlesen, wird folgender Code benötigt.

```
autoencoder.save('denoiser.model')
```

Um das Modell wieder einzulesen verwendet man folgenden Code:

```
autoencoder = tf.keras.models.load_model('denoiser.model')
```

Mit der Summary-Funktion kann man überprüfen, ob das richtige Modell geladen wurde.

6.3.5 Modell ausführen

Da das Modell nun trainiert ist, kann es nun für seinen eigentlichen Zweck genutzt werden. Dieser besteht darin, Bilder zu entrauschen. Dafür gelangen die Bilder aus dem Testdatensatz zur Anwendung. Damit ist garantiert, dass diese unbenutzten Daten vom Modell nicht auswenig gelernt werden konnten. Mit der Funktion `tf.keras.model.predict` erhält man alle Vorhersagen des Autoencoders zum gesamten Testdatensatz.

```
denoised_imgs = autoencoder.predict(x_test)
```

Mithilfe von der Matplotlib können die entrauschten Bilder mit den ursprünglichen MNIST-Bilder direkt verglichen werden. So kann mit blossem Auge beurteilt werden, wie gut die Ergebnisse tatsächlich sind.

```
n = 10 # jeweils 10 Bilder
plt.figure()
for i in range(n):
  # verrauschte Bilder
  ax = plt.subplot(3, n, 1+i)
  plt.imshow(x_test_noisy[i].reshape(28, 28))
  plt.gray()

  # entrauschte Bilder
  ax = plt.subplot(3, n, 1+n+i)
  plt.imshow(decoded_imgs[i].reshape(28, 28))
  plt.gray()

  # Original-Bilder
  ax = plt.subplot(3, n, 1+2*n+i)
  plt.imshow(x_test[i].reshape(28, 28))
  plt.gray()
plt.show()
```

In der ersten Zeile der Grafik sind die verrauschten Bilder dargestellt. Darunter folgen die Rekonstuktionen als Ergebniss des Modells und ganz unten sind die Original-Bilder zu sehen. Wirkliche Unterschiede zwischen der

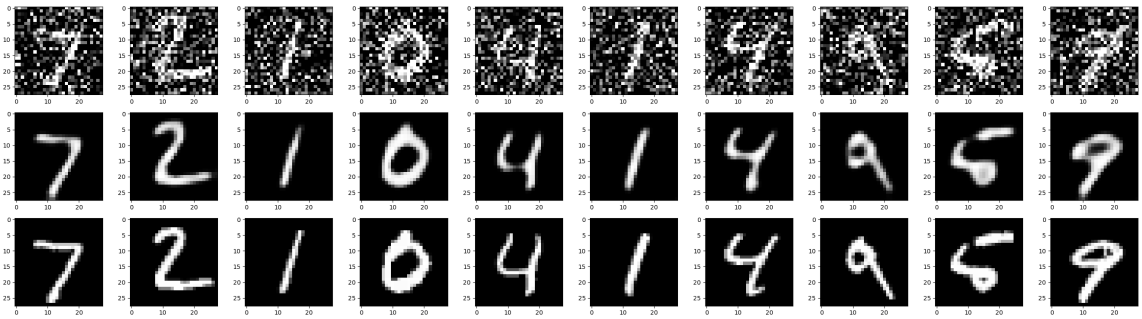

Abbildung 6.4: Verrauschte Bilder, Rekonstruktionen und Orignalbilder

zweiten und der dritten Zeile sind kaum zu erkennen.

6.3.6 Hyperparameter einstellen

Um die Hyperparameter einzustellen, müssen lediglich verschiedene Werte ausprobiert werden. Die Applikation wird insofern modifiziert, als dass verschiedene Modelle konstruiert werden, welche unterschiedliche Hyperparametern verwenden. Beim Training werden mithilfe von TensorBoard Daten zum Lernfortschritt und den Kosten der verschiedenen Modelle erfasst. Auf diese Weise kann eine Auswertung erstellt werden, um die besten Hyperparameter zu identifizieren.

Zuerst werden einige Arrays definiert, welche die zu testenden Hyperparameter beinhalten. Ein Hyperparameter ist die Anzahl Epochen. Diesen werden wir aber nicht testen, da es offensichtlich ist, dass mit einer längeren Trainingszeit sich auch die Resultate verbessern. Alle Modelle werden für 20 Epochen traniert.

Folgende Mini-Batch-Grössen sollen ausprobiert werden: 16, 32, 64, 128, 265. Die Vermutung liegt nahe, dass mit kleineren Mini-Batches die Gradientapproximationen besser mit dem reellen Gradienten übereinstimmt und damit die Resultate besser werden.
Als zu testende Anzahl von Filtern werden definiert: 16, 32, 64, 128, 256. Für die Aktivierungsfunktionen werden Sigmoid und ReLU ausprobiert und gelangen für das ganze Modell zur Anwendung. Jedoch wird für die letzte Schicht immer die Sigmoid-Aktivierungsfunktion verwendet, damit die Outputs im Intervall $[0, 1]$ liegen.

```
EPOCHS = 20

BATCH_SIZES = [ 16, 32, 64, 128, 256 ]
FILTER_NUMS = [ 16, 32, 64, 128, 256 ]
ACTIVATIONFUNCTIONS = [ 'sigmoid', 'relu' ]
```

Nun werden wir den gesamten Code zum Bauen des Graphens, zur Kompilierung und zum Training des Modells in verschachtele For-Loops stecken, welche alle Kombinationen an Hyperparameter ausprobiert.

```
for activation_function in ACTIVATIONFUNCTIONS:
  for batch_size in BATCH_SIZES:
    for num_filters in FILTER_NUMS:
      # ganzer Modell-Code
```

Nun muss der Code zur Definition des Modells insofern modiziert werden, dass die Variabeln `activation_function`, `batch_size` und `num_filters` an den entsprechenden Stellen anstatt der Konstanten benutzt werden.

6.3.6.1 TensorBoard konfigurieren

Um den Lernprozess und die Leistungen des Modells zu analysieren, wird nun nun TensorBoard konfiguriert. Dafür müssen die Methoden `compile` und `fit` angepasst werden. Zuerst müssen wir in der `compile` Methode die zu erfassenden Metriken angeben. Von Interesse ist die `'accuracy'`.

```
autoencoder.compile(optimizer='sgd', loss='mean_squared_error', metrics=['accuracy'])
```

Nun muss eine TensorFlow-Variable definiert werden. Hierbei ist anzugeben, wo die erfassten Daten gespeichert werden sollen. Dabei ist es sinnvoll den Dateien der einzelnen Modelle aussagekräftige Namen zu geben. Deshalb benennen wir die Dateien in folgendem Format: “denoiser-(Aktivierungsfunktion)-(Mini-Batch Grösse)-batches-(Anzahl Filter)-filters”.

```
NAME = 'denoiser-{}-{}-batches-{}-filters'.format(activation_function, batch_size, num_filters)
tensorboard = tf.keras.callbacks.TensorBoard(log_dir='logs/{}'.format(NAME))
```

Zu letzt muss noch die TensorBoard-Variable als `callback` in der `fit`-Methode spezifiziert werden.

```
autoencoder.fit(x=x_train_noisy, y=x_train, batch_size=batch_size, epochs=EPOCHS, shuffle=True,
  validation_data=(x_test_noisy,x_test), callbacks=[tensorboard])
```

6.3.6.2 TensorBoard-Analyse

Um nun die besten Hyperparameter mithilfe von TensorBoard herauszufinden, muss zuerst der TensorBoard-Webserver gestartet werden. Dafür navigiert man zuerst mit der Kommandozeile in das Verzeichniss, welches die Logdateien enthält. Dort kann dann der Webserver mithilfe folgendem Kommando gestartet werden.

```
tensorboard --logdir .
```

Nun kann mit einem WebBrowser zur angegebenen Webadresse navigieren. Meistens ist diese: `http://localhost:6006/`. Der Graph, welcher die Kosten bezüglich dem Testdatensatz aufzeichnet ist von Interesse. Dieser sieht folgendermassen aus:

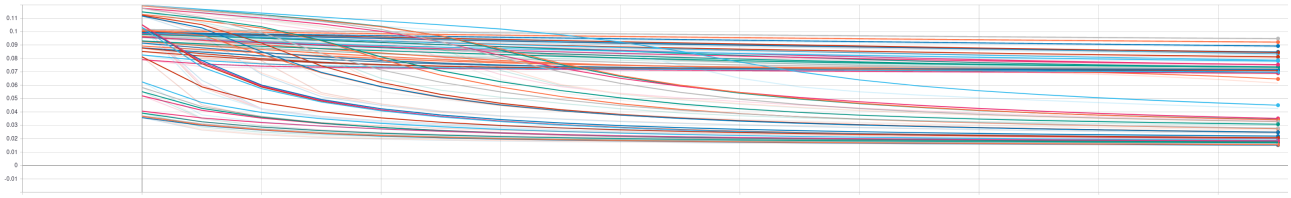

Abbildung 6.5: Kosten bezüglich dem Testdatensatz

Dank dem interaktivem Interface, kann dem Graphen entnommen werden, das folgende Modelle mit den angegebenen Hyperparametern, die besten Resultate liefern:

Rang	Aktivierungsfunktion	Minibatch-Grösse	Anzahl Filter	Kosten
1	ReLU	16	265	0.015
2	ReLU	16	128	0.01521
3	ReLU	16	64	0.01588
4	ReLU	16	32	0.0167
⋮	⋮	⋮	⋮	⋮
50	Sigmoid	256	16	0.09438

Tabelle 6.1: Rangliste der besten Modelle mit ihren Hyperparametern

6.3.7 Diskussion des Modells

2 bis drei Seiten.
Diese Ergebnisse stimmen ziemlich gut mit den Erwartungen überein. Wie bereits in der Theorie behauptet, liefern die ReLU-Aktivierungsfunktion bessere Ergebnisse in CNNs als die Sigmoid-Aktivierungsfunktion. Deshalb finden sich auf den ersten Plätzen nur Modelle mit der ReLU-Aktivierungsfunktion.
Auch, dass die kleinste Minibatch-Grösse die besten Resultate liefert ist naheliegend. Durch die kleine Grösse sind die Fehler bei der Approximation des wahren Gradienten kleiner als bei grossen Batches.
Die Anzahl Filter haben den geringsten Einfluss, jedoch gibt es trotzdem minimale Vorteile von einer grösseren Anzahl davon.
Auf Modell selber bezogen: Echt gutes Modell.

6.3.7.1 Maximale Leistung

Wie hoch kann man den Noise-Factor stellen?

6.3.7.2 Mögliche Verbesserungen

Es gibt konkrete Verbesserungsmöglichkeiten, welche nicht umgesetzt wurden bei der Entwicklung des Denoisers. Es wäre vermutlich möglich gewesen bessere Resulate zu erziehlen, wenn verschiedene Topologien durchprobiert werden wären. Denn die Anzahl Zwischenschichten stellt auch einen Hyperparameter dar. Jedoch hätte dies das Training noch länger gemacht.
Eine Modifikation, welche wahrscheinlich das Modell deutlich verbessert hätte, wäre eine alternative Kostenfunktion gewesen: die Kreuzentropy-Kostenfunktion. Diese lässt die Neuronen eines Netzes weniger schnell saturieren und erzeugt so bessere Resultate.

Es ist darauf hinzuweisen, dass das hier konstruierte Modell bei weitem nicht das eigentliche Potenzial von TensorFlow und Keras ausschöpft.

Rückblick und Ausblick

Ausblick

Eigentliches Potenzial von TensorFlow und Keras aufzeigen

Variational Autoencoder

Generative Adversial Networks

Recurrent Neural Networks

Weitere Technische Aspekte

Weitere Kostenfunktionen

Cross-entropy.

Weitere Optimisierungsverfahren

Adam-Optimizer Momentum-Optimizer

Frameworks

TensorFlow 2.0 PyTorch

Schlusswort

Persoenlicher Eindruck
endminted

Anhang A

Gradientenverfahren

Das Gradientenverfahren ist ein numerisches Verfahren, um Funkionen $f(x_1, x_2, \ldots, x_n)$ vom Typ $\mathbb{R}^n \to \mathbb{R}$ (wie z.B. die Fehlerfunktion) zu minimieren. Dies geschieht, indem ein Startpunkt (Ortsvektor) $\boldsymbol{p}_0$ gewählt wird, dessen Komponenten den Input von $f(\boldsymbol{p}_0)$ darstellen. Nun werden iterativ neue Punkte $\boldsymbol{p}_t$ gesucht, welche immer näher beim lokalen Minimun liegen, also Punkte, die den Funktionswert $f(\boldsymbol{p}_t)$ immer kleiner werden lassen. Dies wird durchgeführt, bis der Punkt genügend nahe beim lokalen Minimun ist.

Dafür muss ein Vektor $\boldsymbol{b}_t$ bestimmt werden, welcher auf den Punkt $\boldsymbol{p}_t$ addiert einen neuen Punkt $\boldsymbol{p}_{t+1}$ bildet, bei dem der Funktionswert $f(\boldsymbol{p}_{t+1})$ kleiner ist als der von $f(\boldsymbol{p}_t)$. Dies geschieht am effizientesten, wenn $\boldsymbol{b}_t$ in die Richtung der stärksten Funktionswertabnahme zeigt.
Hierzu wird man den sogennanten **Gradient $\boldsymbol{\nabla}$** verwendet, für den wiederum partielle Ableitungen benötigt werden.

Partielle Ableitungen

Partielle Ableitungen sind eine Erweiterung der "normalen" Ableitungen auf multidimensionale Funktionen $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$. Man leitet dabei nur nach einem Argument x_i ab und betrachtet die restlichen Argumente als Konstanten. Es gelten die gleichen Ableitungsregeln wie bei der nicht-partiellen Ableitung. Die partielle Ableitung einer Funktion $f(x_1, \ldots, x_n)$ bezüglich einer Variable x_i in einem Punkt $\boldsymbol{a} = \begin{pmatrix} a_1 & \cdots & a_n \end{pmatrix}^\mathsf{T}$ ist analog zur normalen Ableitung folgendermassen definiert:

$$\frac{\partial f}{\partial x_i}(\boldsymbol{a}) := \lim_{h \to 0} \frac{f(a_1, \ldots, a_i + h, \ldots, a_n) - f(a_1, \ldots, a_i, \ldots, a_n)}{h}$$

Geometrisch ist dies die Steigung der Tangente an die Kurve der Funktion f im Punkt $\boldsymbol{a}$. Die Tangente liegt in der Richtung der Achse des Parameters x_i, nach welchem abgeleitet wurde.

Gradient

Der Gradient $\boldsymbol{\nabla}$ ist ein Differentialoperator, den man auf eine Funktion $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$ anwendet kann, welcher ein Skalarfeld auf ein Vektorfeld (das sogenannte Gradientenfeld) abbildet. Um den Gradienten $\boldsymbol{\nabla} f$ der Funktion f zu bilden, fasst man alle partiellen Ableitungen der Funktion f, nach jedem Argument x_i, in einem Vektor zusammen. Meistens bestimmt man den Gradienten $\boldsymbol{\nabla} f(\boldsymbol{p})$ in einem spezifischen Punkt $\boldsymbol{p} = \begin{pmatrix} p_1 & \cdots & p_n \end{pmatrix}^\mathsf{T}$.

$$\boldsymbol{\nabla}_{\boldsymbol{x}} f(\boldsymbol{p}) = \frac{\partial f}{\partial \boldsymbol{x}}(\boldsymbol{p}) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(\boldsymbol{p}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\boldsymbol{p}) \end{pmatrix}$$

Geometrisch ist der Gradient $\boldsymbol{\nabla} f(\boldsymbol{p})$ einer Funktion f in einem Punkt $\boldsymbol{p}$ der Vektor, welcher in die Richtung des steilsten Anstiegs von f zeigt. Sein Betrag gibt die Stärke des Anstiegs an.

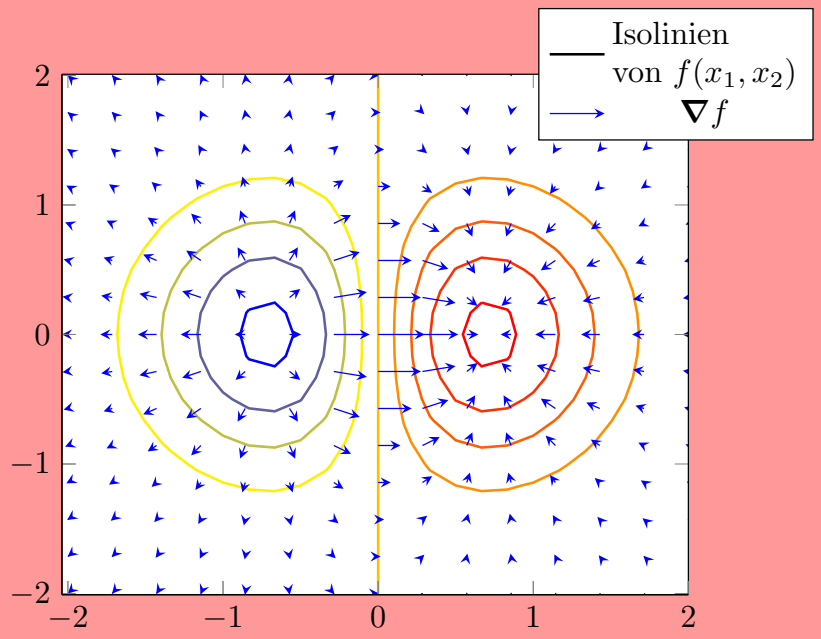

Da der Gradient in die Richtung des steilsten Anstiegs zeigt, sollte der Vektor $\boldsymbol{b}_t$ gerade in die entgegengesetze Richtung zeigen. Demnach sollte er in die Richtung des negierten Gradienten der Funktion f im Punkt $\boldsymbol{p}_t$ weisen. Jetzt kann das iterative Annähern an das lokale Minimum folgendermassen beschrieben werden:

$$\boldsymbol{p}_{t+1} = \boldsymbol{p}_t - \alpha \cdot \boldsymbol{\nabla} f(\boldsymbol{p}_t) \tag{A.1}$$

Dabei stellt α einen Proportionalitätsfaktor dar, welcher die Schrittgrösse beim Abstieg bestimmt.
Während des Gradientenverfahren konvergiert der Punkt $\boldsymbol{p}_t$ zu einem beliebigen *lokalen* Minimum, abhängig davon, wie der Startpunkt $\boldsymbol{p}_0$ gewählt wurde.

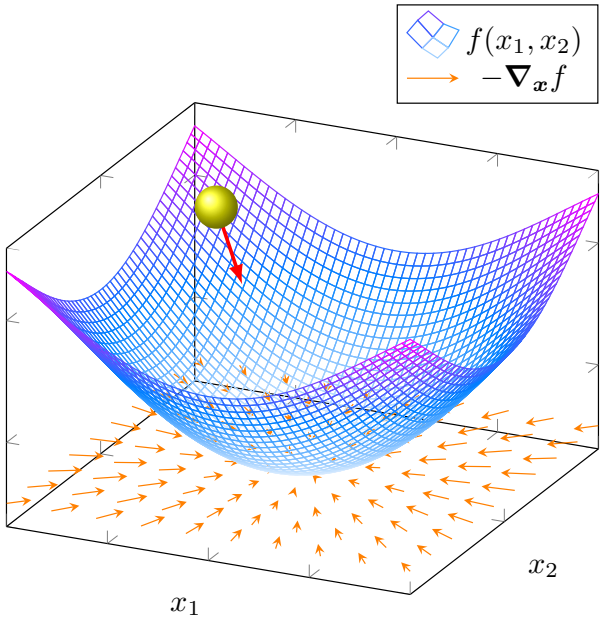

Abbildung A.1: Visualisierung des Gradientenabstiegs: Ein Ball rollt das Gradientenfeld hinab in das lokale Minimum.

Anhang B

Herleitung der Rückwärtsprogagierung für KNNs

Da ein KNN, wie der Name schon andeutet, vernetzt ist, können die partiellen Ableitungen einer Schicht anhand seiner Nachbarsschichten berechnet werden. Dies ist auch der namensgebende Grundgedanke der Rückwärtsprogagierung: Man beginnt damit die partiellen Ableitung der letzten Schicht zu bestimmen und berechnet dann retrograd Schicht für Schicht die vorherigen partiellen Ableitungen, bis zur Inputsschicht.
Dies geschieht unter Anwendung der Kettenregel der Ableitungen. Es ist sinnvoll, für das Aufstellen dieser Gleichungen das Netzwerk als **Computational Graph** zu betrachten.

Computational Graph

Ein Computational Graph ist die Darstellung einer Verkettung von Funktionen als Netzwerk von Operationen. Die Knoten im Graph stellen Variablen dar und die Pfade, welche die Knoten verbinden, sind die Funktionen, welche die Variablen aufeinander abbilden. Die Funktion wird auf die Variable angewendet, von der der Pfad ausgeht. Der Knoten, in welchem der Pfad endet, nimmt dann den Funktionswert an. Falls mehrere Pfade in einem einzigen Knoten enden, werden die einzelnen Werte der Pfade zusammenaddiert, um die Variable zu bilden. In diesem Graphen sind die Abhängigkeiten der Variablen voneinander gut ersichtlich. Auf dieser Basis können mithilfe der Kettenregel die Ableitungen unkompliziert bestimmt werden.

Beispiel: Computational Graph

Untenstehend ist ein Beispiel eines Computational Graph zusammen mit der Herleitung der partiellen Ableitungen dargestellt.

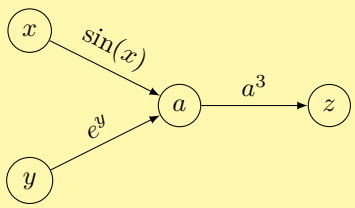

$$a(x,y) = \sin(x) + e^y$$
$$z(a(x,y)) = a^3(x,y) = (\sin(x) + e^y)^3$$

$$\frac{\partial z}{\partial x} = \frac{\partial a}{\partial x} \cdot \frac{\partial z}{\partial a} = \cos(x) \cdot 3a^2$$
$$\frac{\partial z}{\partial y} = \frac{\partial a}{\partial y} \cdot \frac{\partial z}{\partial a} = e^y \cdot 3a^2$$

Der erste Schritt der Rückwärtsprogagierung besteht darin, dass die partiellen Ableitungen $\frac{\partial C}{\partial z_j^l}$ der Kostenfunktion C bezüglich den gewichteten Summen z_j^l aller Schichten berechnet werden müssen. Daraus lassen sich dann später die partiellen Ableitungen bezüglich den Gewichten $\frac{\partial C}{\partial w_{j,k}^l}$ und bezüglich den Neigungen $\frac{\partial C}{\partial b_j^l}$ ermitteln.

Zur Übersichtlichkeit definiert man einen **Fehler** δ_j^l für jedes j-te Neuron in jeder l-ten Schicht, welcher die partielle Ableitung bezüglich der gewichteten Summe dieses Neurons darstellt (siehe Gl. (BP0). Ebenfalls definiert man analog einen Fehlervektor $\boldsymbol{\delta}^l$, welcher alle Fehler δ_j^l einer Schicht l zusammenfasst (siehe Gl. (BP0a)). Nun heisst es, diesen Wert für jedes Neuron jeder Schicht zu berechnen.

$$\delta_j^l \coloneqq \frac{\partial C}{\partial z_j^l} \tag{BP0}$$

$$\boldsymbol{\delta}^l \coloneqq \begin{pmatrix} \frac{\partial C}{\partial z_1^l} & \frac{\partial C}{\partial z_2^l} & \cdots & \frac{\partial C}{\partial z_{|l|}^l} \end{pmatrix}^\mathsf{T} \tag{BP0a}$$

Da die Kostenfunktion unmittelbar auf die letzte Schicht L angewendet wird, beginnt dort auch die Berechnung des Fehlers $\boldsymbol{\delta}^L$. Nun wird ein Computational Graph aufgestellt, um die partiellen Ableitungen zu bestimmen.

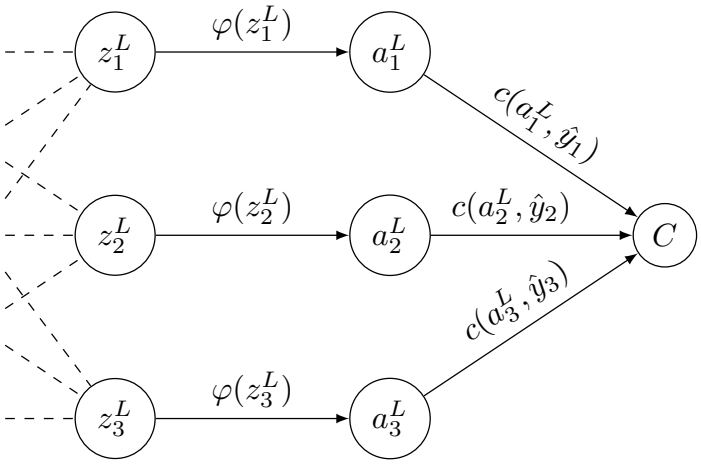

Abbildung B.1: Computational Graph zur Berechnung von $\boldsymbol{\delta}^L$

Aus dem Computational Graph der Abbildung (B.1) kann entnommen werden, dass die Kosten C eine Funktion in Abhängigkeit von den letzten Aktivierungen a_j^L ist. Diese ist wiederum eine Funktion in Abhängigkeit von der jeweiligen gewichteten Summe z_j^L. Somit kann mithilfe der Kettenregel die Beziehung (B.1) aufstellt werden.

$$\delta_j^L = \frac{\partial C}{\partial z_j^L} = \frac{\partial C}{\partial a_j^L} \cdot \frac{\partial a_j^L}{\partial z_j^L} \tag{B.1}$$

Da a_j^L durch die Anwendung der Aktivierungsfunktion φ auf z_j^L gebildet wird, ist $\frac{\partial a_j^L}{\partial z_j^L}$ die Ableitung der Aktivierungsfunktion $\varphi'(z_j^L)$. Auf diese Weise lässt sich die erste (BP1) von vier wichtigen Gleichungen für die Rückwärtsprogagierung herleiten.

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \cdot \varphi'(z_j^L) \tag{BP1}$$

Um diese Ausdrücke wieder in Matrixschreibweise zu realisieren, welche die ganze Schicht L zusammenfasst, muss eine neue Operation eingeführt werden: das Hadamard-Produkt.

Hadamard-Produkt

Das Hadamard-Produkt (auch elementweises Produkt) ist eine spezielle Multiplikation zweier gleichgrosser Matrizen $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ und $\boldsymbol{B} \in \mathbb{R}^{m\times n}$. Die resultierende Matrix ergibt sich aus der elementweisen Multiplikation der Ausgangsmatrizen.

$$\boldsymbol{A} \odot \boldsymbol{B} = \begin{pmatrix} A_{1,1}B_{1,1} & \cdots & A_{1,n}B_{1,n} \\ \vdots & \ddots & \vdots \\ A_{m,1}B_{m,1} & \cdots & A_{m,n}B_{m,n} \end{pmatrix} \in \mathbb{R}^{m\times n} \qquad \boldsymbol{v} \odot \boldsymbol{w} = \begin{pmatrix} v_1 w_1 \\ \vdots \\ v_n w_n \end{pmatrix}$$

Mit $\boldsymbol{\varphi}'$ als die vektorisierte Ableitung der Aktivierungsfunktion, kann der Fehlervektor der letzten Schicht nach Gleichung (B.2) berechnen werden.

$$\boldsymbol{\delta}^L = \begin{pmatrix} \frac{\partial C}{\partial a_1^L} & \frac{\partial C}{\partial a_2^L} & \cdots & \frac{\partial C}{\partial a_{|L|}^L} \end{pmatrix}^\mathsf{T} \odot \boldsymbol{\varphi}'[\boldsymbol{z}^L] \tag{B.2}$$

Dabei ist der erste Operand des Hadamard-Produkts nichts anderes als der Gradient $\boldsymbol{\nabla}_{\boldsymbol{a}^L} C$ der Kostenfunktion C bezüglich dem Aktivierungsvektor $\boldsymbol{a}^L$ der letzten Schicht. Dieser Gradient kann ermittelt werden, indem die vektorisierte Ableitungsfunktion für die gewählte Kostenfunktion gebildet wird. Würde die Mittlere quadratischen Abweichung $C = \frac{1}{2|L|}(\hat{\boldsymbol{y}} - \boldsymbol{a}^L)^2$ als Kostenfunktion gewählt werden, ergibt sich $\boldsymbol{\nabla}_{\boldsymbol{a}^L} C = (\boldsymbol{a}^L - \hat{\boldsymbol{y}}) \cdot \frac{1}{|L|}$.

Daraus folgt die kompakte Matrix-Version (BP1a) der Gleichung (BP1), welche den Fehlervektor für die letzte Schicht berechnet.

$$\boldsymbol{\delta}^L = \boldsymbol{\nabla}_{\boldsymbol{a}^L} C \odot \boldsymbol{\varphi}'(\boldsymbol{z}^L) \tag{BP1a}$$

Nun soll eine rekursive Berechnungsmethode des Fehlers δ_j^{l-1} der vorherigen Schicht anhand des Fehlers δ_j^l der jetzigen Schicht erarbeiten werden. Zu diesem Zweck ist wiederum ein Computational Graph aufzustellen (siehe Abb. (B.2)).

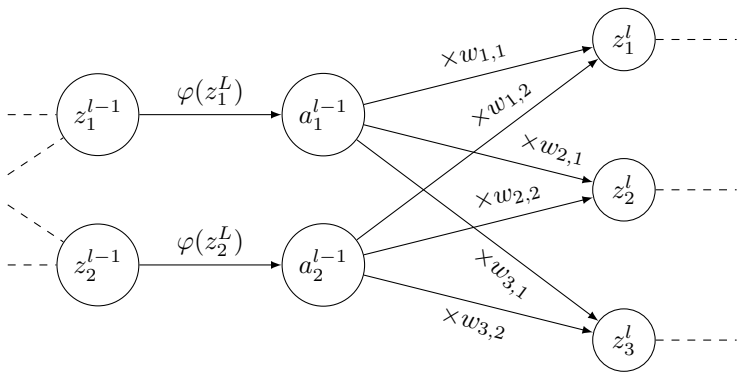

Abbildung B.2: Computational Graph zur Berechnung von δ_j^{l-1}

Es gilt erneut die Gleichung (B.1) für die Berechnung des Fehlers δ_j^{l-1}.

$$\delta_j^{l-1} = \frac{\partial C}{\partial z_j^{l-1}} = \frac{\partial a_j^{l-1}}{\partial z_j^{l-1}} \cdot \frac{\partial C}{\partial a_j^{l-1}} \tag{B.1}$$

Der erste Faktor entspricht der Ableitung $\varphi'(z_j^{l-1})$ der Aktiverungsfunktion. Beim Übergang einer Schicht $(l-1)$ zur Schicht l beinflusst eine Aktivierung a_j^{l-1} alle gewichteten Summen z_k^l. Mit der Kettenregel folgt daher, dass die partielle Ableitung $\frac{\partial C}{\partial a_j^{l-1}}$ die Summe aller $\frac{\partial C}{\partial z_k^l} \cdot \frac{\partial z_k^l}{\partial a_j^{l-1}}$ sein muss. Daraus ergibt sich Gleichung (B.3).

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\frac{\partial C}{\partial z_k^l} \cdot \frac{\partial z_k^l}{\partial a_j^{l-1}} \right) \tag{B.3}$$

Um die gewichtete Summe z_k^l zu bilden, wird Aktivierung a_j^{l-1} der vorherigen Schicht mit den entsprechenden Gewichten $w_{k,j}^{l-1}$ multipliziert. Dadurch entspricht diese partielle Ableitung $\frac{\partial z_k^l}{\partial a_j^{l-1}}$ gerade dem Gewicht selbst. Desweiteren ist $\frac{\partial C}{\partial z_k^l}$ per Definition der Fehler δ_k^l. Mit dieser Erkenntnis lässt sich die zweite essentielle Gleichung (BP2) für die Rückwärtsprogagierung aufstellen.

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\delta_k^l \cdot w_{k,j}^{l-1} \right) \tag{BP2}$$

Auch diese Gleichung soll in der Matrixschreibweise dargestellt werden. Zu diesem Zweck wird der Erweiterungen auf alle gewichteten Summen begonnen:

$$\boldsymbol{\delta}^{l-1} = \boldsymbol{\varphi}'[\boldsymbol{z}^{l-1}] \odot \begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|}^{l-1} \cdot \delta_k^l \end{pmatrix}^\mathsf{T}$$

Der zweite Operant des Hadamard-Produkts ist hierbei gerade das Produkt der Matrixmultiplikation zwischen der transponierten Gewichtsmatrix $(\boldsymbol{W}^{l-1})^\mathsf{T}$ der Schicht $(l-1)$ und dem Fehlervektor $\boldsymbol{\delta}^l$ der Schicht l.

$$\begin{aligned}
\begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|} \cdot \delta_k^l \end{pmatrix}^\mathsf{T} &= \begin{pmatrix} w_{1,1}^{l-1} & w_{2,1}^{l-1} & \cdots & w_{|l|,1}^{l-1} \\ w_{1,2}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{|l|,2}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1,|l-1|}^{l-1} & w_{2,|l-1|}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix} \begin{pmatrix} \delta_1^l & \cdots & \delta_{|l|}^l \end{pmatrix}^\mathsf{T} \\
&= \begin{pmatrix} w_{1,1}^{l-1} & w_{1,2}^{l-1} & \cdots & w_{1,|l-1|}^{l-1} \\ w_{2,1}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{2,|l-1|}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{|l|,1}^{l-1} & w_{|l|,2}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix}^\mathsf{T} \boldsymbol{\delta}^l = (\boldsymbol{W}^{l-1})^\mathsf{T} \boldsymbol{\delta}^l
\end{aligned}$$

Damit wurde die die rekursive Fehlerdefinition in Matrixschreibweise abbgebildet. Und wir erhalten die kompakte Version (BP2a) der zweiten wichtigen Formel (BP2).

$$\boldsymbol{\delta}^{l-1} = ((\boldsymbol{W}^{l-1})^\mathsf{T} \boldsymbol{\delta}^l) \odot \boldsymbol{\varphi}'[\boldsymbol{z}^{l-1}] \tag{BP2a}$$

In einem letzten Schritt sind nun noch die noch Formeln herzuleiten, mit welchen anhand des Fehlers δ_j^l die partiellen Ableitungen der Gewichte und der Neigungen berechnen werden können.

Eine Neigung b_j^l ist Funktionsbestandteil der entsprechenden gewichteten Summe z_j^{l+1}. Somit gilt für die Neigung Formel (B.4).

$$\frac{\partial C}{\partial b_j^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial b_k^l} \tag{B.4}$$

Der erste Term ist hierbei per Definition der Fehler δ_j^{l+1} und der zweite Term lässt sich auf 1 kürzen, da die Summe z_k^{l+1} nur aus b_k^l besteht und aus Summanden, welche für die partielle Ableitung als konstant gelten. Somit entspricht die Ableitung der Neigung gerade dem Fehler, womit die dritte (BP3) von vier essentiellen Gleichungen ermittelt wurde.

$$\frac{\partial C}{\partial b_j^l} = \delta_j^{l+1} \tag{BP3}$$

Somit entspricht der Kostengradient bezüglich der Neigung dem Fehlervektor.

$$\boldsymbol{\nabla}_{\boldsymbol{b}^l} C = \boldsymbol{\delta}^{l+1} \tag{BP3a}$$

Ein Gewicht $w_{j,k}^l$ ist ebenfalls ein Funktionsbestandteil der assozierten gewichteten Summe z_j^{l+1}. Dadurch gilt

für die partiellen Ableitungen der Kosten nach dem Gewicht die Gleichung (B.5).

$$\frac{\partial C}{\partial w_{j,k}^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial w_{j,k}^l} \tag{B.5}$$

Dabei lässt sich der erste Teil der Gleichung entspricht wieder dem Fehler δ_j^{l+1}. Die zweite partielle Ableitung ist gerade die Aktivierung a_k^l, da sich die gewichtete Summe aus der Multiplikation des Gewichtes mit der Aktivierung ergibt. Auf diese Weise ensteht die letzte der vier essentiellen Gleichungen (BP4).

$$\frac{\partial C}{\partial w_{j,k}^l} = \delta_j^{l+1} \cdot a_k^l \tag{BP4}$$

Die Matrix-Version lässt sich als Gleichung (BP4a) ausdrücken.

$$\boldsymbol{\nabla}_{\boldsymbol{W}^l} C = \boldsymbol{\delta}^{l+1} (\boldsymbol{a}^{\boldsymbol{l}})^\mathsf{T} \tag{BP4a}$$

Zusammenfassung Rückwärtsprogagierung

0. Vorwärtspropagierung durchführen und dabei alle Zwischenwerte beibehalten.
1. Berechnung des Fehlers $\boldsymbol{\delta}^L$ der letzten Schicht, anhand der Formel:
$$\boldsymbol{\delta}^L = \boldsymbol{\nabla}_{\boldsymbol{a}^L} C \odot \boldsymbol{\varphi}'(\boldsymbol{z}^L) \tag{BP1a}$$
2. Rekursive Berechnung des Fehlers $\boldsymbol{\delta}^{l-1}$ der jeweils vorherigen Schicht, anhand der Formel:
$$\boldsymbol{\delta}^{l-1} = ((\boldsymbol{W}^{l-1})^\mathsf{T} \boldsymbol{\delta}^l) \odot \boldsymbol{\varphi}'[\boldsymbol{z}^{l-1}] \tag{BP2a}$$
3. Berechnung des Kostengradienten bezüglich der Neigungen, anhand der Formel:
$$\boldsymbol{\nabla}_{\boldsymbol{b}^l} C = \boldsymbol{\delta}^{l+1} \tag{BP3a}$$
4. Berechnung des Kostengradienten bezüglich den Gewichten anhand der Formel:
$$\boldsymbol{\nabla}_{\boldsymbol{W}^l} C = \boldsymbol{\delta}^{l+1} (\boldsymbol{a}^{\boldsymbol{l}})^\mathsf{T} \tag{BP4a}$$
5. Gewichte und Neigung mit SGD aktualisieren

(Nielsen, *Neural Networks and Deep Learning*)
(Rojas, *Neural Networks — A Systematic Introduction*)

Anhang C

Performance von TensorFlow

Devices

Die Kernstücke des Masters sind die verschiedenen **Devices**, auf welchen die Berechnungen ausgeführt werden. Ein Device ist jedliche Art von Computerprozessor, auf welchem die Graphen ausführt werden können. Zu diesen Prozessoren gehören die CPU (Hauptprozessor) und die GPU (Grafikprozessor). [1]

Der Master analysiert die verfügbaren Devices und bewertete sie, bezüglich ihren Fähigkeiten. Anhand dieser Bewertung entscheidet der Master dann, auf welchem Device die Berechnugen ausgefürt werden. [2] Insofern GPUs zur Verfügung stehen, wählt TF grundsätzlich immer diese, da sie Tensoroperationen deutlich schneller als CPUs verarbeiten können.

Performance und Hardwarebeschleunigung

Nun möchten wir die Gründe für die beachtliche Performance von TF erschliessen. Der erste wichtiger Faktor dabei ist, dass der Master hauptsächlich in C++ geschrieben ist. C++ ist eine Programmiersprache die sehr nahe am Maschinen-Code (engl.: low-level) ist. Somit ist der Code sehr hardwarenah und kann so schneller ausgeführt werden. Der Nachteil besteht dafür darin, dass die Programmiersprache ziemlich verbos ist. Das bedeutet man braucht viel Code um eine relativ einfach Idee auszudrücken. Deshalb wurde der Client von TF in Python geschrieben, was Abhilfe verschafft und so ein relativ einfaches und unverboses Entwickeln ermöglicht.

Der andere wichtige Aspekt für die Performance ist wohl die sogennante **Hardwarebeschleuniging** (engl. Hardware Acceleration), von welcher TF gebrauch macht.
Hardwarebeschleunigung bezeichnet eine Sammlung an Methoden, bei welchen man spezialisierte Hardware verwendet um rechenintensive Aufgaben schneller auszuführen. Die Architektur einer CPU ist zwar so ausgelegt, dass sie beliebige Aufgaben ausführen kann, jedoch meistens nicht besonders effizient. Deshalb wurden einerseits neue externe Hardwarebausteine, wie die GPU, welche sich für Grafikberechnungen besonders eignet, entwickelt. Andererseits wurde auch die interne Architektur der CPU so angepasst, dass sie auch spezielisierte Aufgaben besser meistert.

Der Grossteil der Hardwarebeschleunigung wird durch die **Parallelisierung** von Operationen erreicht. Dabei spaltet man eine rechenintensive Aufgabe in viele Teilaufgaben auf, welche gleichzeitig in gleicher Weise ausgeführt werden. Voraussetzung dafür ist, dass die Teilaufgaben unabhängig voneinander bearbeitet werden können.
Ein typisches Beispiel für die Paralleliserbarkeit von Operationen ist die Matrixmultiplikation. Möchte man eine Matrix $\boldsymbol{A} \in \mathbb{R}^{n \times m}$ mit einer zweiten Matrix $\boldsymbol{B} \in \mathbb{R}^{m \times p}$ multiplizieren, muss man praktisch m-mal die gleichen Schritte ausführen: Man berechnet jeweils das Skalarprodukt zwischen der i-ten Zeile von $\boldsymbol{A}$ und der i-ten Spalte von $\boldsymbol{B}$. Alle diese Skalarprodukte haben keinen Einfluss aufeindander und können so unabhänigig mit der gleichen Prozedur berchnet werden.

Allgemein eignen sich Tensoroperatiön für Parallelisierung und damit zur Hardwarebeschleunigung. Nun ist auch ersichtlich, weshalb TensorFlow als Hauptdatentyp Tensoren verwendet; damit es gebrauch von der Hardwarebeschleunigung machen kann. wir fast alle Gleichungen des Maschinellen

[1] Die normale TensorFlow Version ist nicht in der Lage die GPU zu verwenden. Um sie verfügbar zu machen, muss man die GPU Version installieren. Wir werden im folgenden von der GPU-Version ausgehen, da sie erhebliche Performance Vorteile gewährt.

[2] Es ist möglich die Graphen auf mehreren Devices gleichzeitig auszuführen und so noch schneller die Modelle zu trainieren. Dies ist jedoch erst für sehr aufwendige Projekte nötig und erfordert ein fortgeschritteneres Versteantniss.

CPU-Beschleunigung

Die Hardwarebeschleunigung der CPU ist für TensorFlow nur von geringfügiger Relevanz, da TF sich vorallem für GPU-Hardwarebeschleunigung eignet und dafür optimiert ist. Ausserdem ist es praktisch unmöglich die gleiche Performance von TF mit einer CPU zu erreichen, welche mit einer GPU möglich ist.

Hauptsächlich parallelisiert TensorFlow mithilfe von der **SIMD**. SIMD ist ein Prinzip zur Paralleliserung einer Insturktion für mehrere Dateneinheiten und steht deshalb für "Single Instruction, Multiple Data". SIMD umfasst einerseits die spezifische CPU-Architektur und den dazugehörigen Befehlssatz, um die Operatiön zu parallelisieren. Es gibt verschiedene
SSE4.1, SSE4.2, AVX, AVX2, FMA

GPU-Beschleunigung durch cuDNN und CUDA

cuDNN ist die NVIDIA CUDA Deep Neural Network library. Sie ist eine GPU-beschleunigte Bibliothek für deep neural networks. Sie stellt implementation für standard routines wie Vorwärts- und Rückwärtspropagierung bereit.

CUDA

cuDNN

Automatische Gradientenberechnung

Als wir die Rückwärtsprogagierung hergeleitet haben, haben wir mithilfe von Computational Graphs die Kettenregel angewandt um die partiellen Ableitungen zu bilden. Genau das gleiche macht TF, jedoch automatisiert. Aus diesem Grund ist TF auch datenstromorient.

Anhang D

Programmcode

```
import numpy as np
import matplotlib.pyplot as plt

import tensorflow as tf

# MNIST-Datensatz laden
(x_train, _), (x_test, _) = tf.keras.datasets.mnist.load_data()

# Daten formatieren
x_train = x_train.astype('float32') / 255.0
x_test = np.reshape(x_test, (len(x_test), 28, 28, 1))
x_test = x_test.astype('float32') / 255.0
x_train = np.reshape(x_train, (len(x_train), 28, 28, 1))

# verrauschte Bilder (Input) generieren
noise_factor = 0.5
x_train_noisy = x_train + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_train.shape)
x_test_noisy = x_test + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_test.shape)
x_train_noisy = np.clip(x_train_noisy, 0.0, 1.0)
x_test_noisy = np.clip(x_test_noisy, 0.0, 1.0)

# Modell definieren
input_data = tf.keras.Input(shape=(28, 28, 1))
econv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same', activation='relu', kernel_initi
emaxpool0 = tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=None, padding='same')(econv0)
econv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same', activation='relu', kernel_initi
emaxpool1 = tf.keras.layers.MaxPooling2D(pool_size=(2, 2), strides=None, padding='same')(econv1)
encoded =  emaxpool1
dconv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same', activation='relu', kernel_initi
dupsample0 = tf.keras.layers.UpSampling2D(size=(2, 2), interpolation='nearest')(dconv0)
dconv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3, 3), strides=(1, 1), padding='same', activation='relu', kernel_initi
dupsample1 = tf.keras.layers.UpSampling2D(size=(2, 2), interpolation='nearest')(dconv1)
dconv2 = tf.keras.layers.Conv2D(filters=1, kernel_size=(3, 3), strides=(1, 1), padding='same', activation='sigmoid', kernel_ini
decoded = dconv2

# Modell kompilieren
autoencoder = tf.keras.Model(input_data, decoded)
autoencoder.compile(optimizer='sgd', loss='mean_squared_error')

print(autoencoder.summary())

# Modell trainieren und als Modelldatei speichern
autoencoder.fit(x=x_train_noisy, y=x_train, batch_size=128, epochs=100, shuffle=True, validation_data=(x_test_noisy, x_test), c
autoencoder.save('denoiser.model')

# Vorhersagen zum Testdatensatz erstellen
decoded_imgs = autoencoder.predict(x_test)
```

```python

# Matplotlib Abbildung anzeigen
n = 10 # jeweils 10 Bilder
plt.figure()
for i in range(n):
    # verrauschte Bilder
    ax = plt.subplot(3, n, 1+i)
    plt.imshow(x_test_noisy[i].reshape(28, 28))
    plt.gray()

    # entrauschte Bilder
    ax = plt.subplot(3, n, 1+n+i)
    plt.imshow(decoded_imgs[i].reshape(28, 28))
    plt.gray()

    # Original-Bilder
    ax = plt.subplot(3, n, 1+2*n+i)
    plt.imshow(x_test[i].reshape(28, 28))
    plt.gray()
plt.show()
```

Literatur

[1] CodeParade. *Computer Generates Human Faces*. [Online; besucht am 21. August 2019]. Youtube. 2017. URL: https://www.youtube.com/watch?v=4VAkrUNLKSo.

[2] Andrew NG - deeplearning.ai. *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*. [Online; besucht am 17. Juni 2019]. 2017. URL: https://www.youtube.com/playlist?list=PLkDaE6sCZn6Gl29AoE31iwdVwSG-KnDzF.

[3] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, 2017.

[4] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. http://www.deeplearningbook.org. MIT Press, 2016.

[5] Many. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. Software available from tensorflow.org. 2015. URL: https://www.tensorflow.org/.

[6] Mehrere. *Convolution— Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolution.

[7] Mehrere. *Convolutional neural network — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolutional_neural_network.

[8] Mehrere. *Keras Documentation - Initalizers*. [Online; besucht am 03. September 2019]. URL: https://keras.io/initializers/.

[9] Mehrere. *Kernel (image processing) — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Kernel_(image_processing).

[10] Mehrere. *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 4. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/K%C3%BCnstliches_Neuron.

[11] Mehrere. *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 04. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/K%C3%BCnstliches_neuronales_Netz.

[12] Mehrere. *Linear separability — Wikipedia, The Free Encyclopedia*. [Online; besucht am 9. Juli 2019]. 2019. URL: https://en.wikipedia.org/wiki/Linear_separability.

[13] Mehrere. *Normal distribution — Wikipedia, The Free Encyclopedia*. [Online; besucht am 26. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Normal_distribution.

[14] Mehrere. *Perzeptron — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 28. April 2019]. 2019. URL: https://de.wikipedia.org/wiki/Perzeptron.

[15] Mehrere. *Sigmoidfunktion — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 4. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/Sigmoidfunktion.

[16] Mehrere. *Sobel operator — Wikipedia, The Free Encyclopedia*. [Online; besucht am 17. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Sobel_operator.

[17] Mehrere. *Supervised learning — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Supervised_learning.

[18] Mehrere. *Tensor — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 13. Juli 2019]. 2019. URL: https://de.wikipedia.org/wiki/Tensor.

[19] Mehrere. *TensorFlow Core r1.14 API-Docs*. [Online; besucht am 14. September 2019]. 2019. URL: https://www.tensorflow.org/api_docs/python/tf.

[20] Mehrere. *Überanpassung — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 31. August 2019]. 2019. URL: https://de.wikipedia.org/wiki/%C3%9Cberanpassung.

[21] Mehrere. *Universal approximation theorem — Wikipedia, The Free Encyclopedia*. [Online; besucht am 22. August 2019]. 2019. URL: https://en.wikipedia.org/wiki/Universal_approximation_theorem.

[22] Mehrere. *Unsupervised learning — Wikipedia, The Free Encyclopedia.* [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Unsupervised_learning.

[23] Michael Nielsen. *Neural Networks and Deep Learning.* http://neuralnetworksanddeeplearning.com. 2018.

[24] Manfred Richter. *Weisskopfadler.* [Online; besucht am 18. August 2019]. 2019. URL: https://pixabay.com/de/photos/wei%C3%9Fkopfseeadler-vogel-4370916/.

[25] Raúl Rojas. *Neural Networks — A Systematic Introduction.* Springer-Verlag, 1996.

[26] Elias Saalmann. *Einführung in Autoencoder und Convolutional Neural Networks.* Universität Leipzig, 2018.

[27] Josef Steppan. *File:MnistExamples.png — Wikipedia, The Free Encyclopedia.* [Online; besucht am 18. August 2019]. 2017. URL: https://en.wikipedia.org/wiki/File:MnistExamples.png.

[28] Christopher J.C. Burges Yann LeCun Corinna Cortes. *The MNIST Database of handwritten digits.* [Online; besucht am 15. August 2019]. URL: http://yann.lecun.com/exdb/mnist/.

Abbildungsverzeichnis

1.1 Schema eines Modells . . . 2
1.2 Visualisierung verschiedener Lernraten . . . 4
1.3 Visalierung von Under- und Overfitting . . . 6

2.1 Perzeptron mit drei Inputs . . . 8
2.2 zwei-dimensionale lineare Separierung . . . 8
2.3 ein künstliches Neuron . . . 9
2.4 Definition und Graph der Heaviside-Funktion Θ . . . 9
2.5 Formel und Graph der ReLU-Funktion . . . 10
2.6 Definition, Ableitung und Graph der Sigmoid-Funktion σ . . . 10
2.7 Schichten eines KNNs . . . 11
2.8 zum Verständnis der Nomenklatur . . . 12
2.9 zum Verständnis der Gewichtebeschriftungen . . . 13
2.10 Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften . . . 15

3.1 Schichtung eines CNNs . . . 19
3.2 der Instagramfilter "Amaro" auf ein Beispielbild angewandt (Richter, *Weisskopfadler*) . . . 19
3.3 eine 2D-Filtermatrix mit rotem Zentralelement . . . 20
3.4 ein 3D-Filtertensor mit rotem Zentralelement . . . 20
3.5 Sobel-Filter angewandt auf Beispielsbild (Richter, *Weisskopfadler*) . . . 20
3.6 ein Filter und sein rezeptives Feld . . . 21
3.7 Schema, wie ein Filter über ein Bild läuft . . . 22
3.8 aufeinander gelegte gefaltene Bilder . . . 23
3.9 Padding $p = 1$ in blau . . . 24
3.10 Abbildung zum Stride: jetztige Position in blau, nächste Position mit $s = 1$ in rot, nächste Position mit $s = 2$ in grün . . . 25

4.1 Schichten eines kurzen Autoencoders . . . 29
4.2 Schichten eines tieferen Autoencoders . . . 29
4.3 Darstellung eines Convolutional Autoencoders . . . 31
4.4 Visualisierung eines Convolutional-Denoising-Autoencoder . . . 32

5.1 TF-Logo . . . 33
5.2 Visualisierung eines `Graph` . . . 34
5.3 das TensorBoard-Webinterface . . . 36
5.5 Keras-Logo . . . 36
5.4 Trainingsvisualisierungen in TensorBoard . . . 37

6.1 grobes Schema des Modells . . . 40
6.2 ein Auszug an MNIST-Bildern (invertierte Farben) (Steppan, *File:MnistExamples.png — Wikipedia, The Free Encyclopedia*) . . . 41
6.3 Verrauschte Bilder neben den Orignalbildern . . . 44
6.4 Verrauschte Bilder, Rekonstruktionen und Orignalbilder . . . 47
6.5 Kosten bezüglich dem Testdatensatz . . . 49

A.1 Visualisierung des Gradientenabstiegs: Ein Ball rollt das Gradientenfeld hinab in das lokale Minimum. . . . 55

B.1 Computational Graph zur Berechnung von $\boldsymbol{\delta}^L$ . . . 57
B.2 Computational Graph zur Berechnung von δ_j^{l-1} . . . 58

Tabellenverzeichnis

6.1 Rangliste der besten Modelle mit ihren Hyperparametern 49

Selbstständigkeitserklärung

Ich erkläre hiermit, dass ich diese Arbeit selbständig durchgeführt und keine anderen als die angegebene Quellen, Hilfsmittel und Hilfspersonen beigezogen habe. Alle Textstellen in der Arbeit, die wörtlich oder sinngemäss aus Quellen entnommen wurden, habe ich als solche gekennzeichnet.

Luis Wirth