Maturaarbeit

Maschinelles Lernen mit TensorFlow

Entwicklung eines Convolutional Denoising Autoencoders

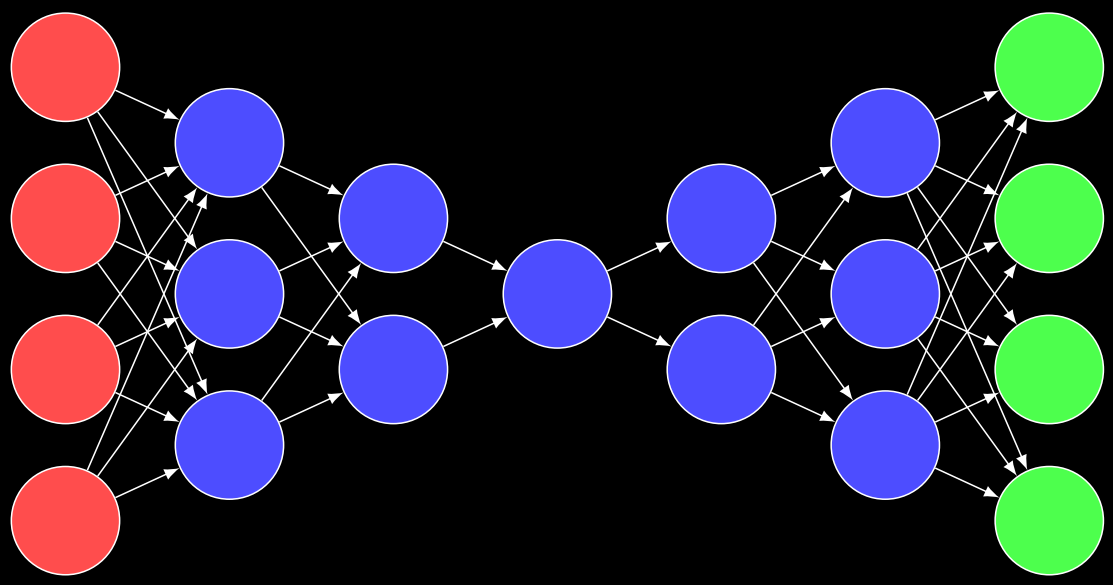

Luis Wirth

Gymnasium Oberwil
Klasse *4a*

Betreut von
Dr. Jonas Gloor

Abgegeben im September 2019

Inhaltsverzeichnis

Inhaltsverzeichnis **I**

Vorwort **IV**

Einleitung **V**

Konvention und Notation **VI**

1 Maschinelles Lernen **1**
1.1 Allgemeine Begriffe . . . 1
1.1.1 Daten . . . 1
1.1.2 Modelle . . . 2
1.2 Training . . . 3
1.2.1 Verlust- und Kostenfunktionen . . . 3
1.2.2 Gradientenverfahren . . . 4
1.2.3 Stochastisches Gradientenverfahren . . . 7
1.3 Trainingsphänomene . . . 7
1.3.1 Konvergenz und Divergenz . . . 7
1.3.2 Underfitting und Overfitting . . . 8

2 Deep Learning und Künstliche Neuronale Netze **10**
2.1 Perzeptron . . . 10
2.1.1 Lernpotenzial eines Perzeptrons . . . 11
2.2 Erweiterung der Künstlichen Neuronen . . . 11
2.2.1 Künstliche Neuronen im Allgemeinen . . . 12
2.2.2 Perzeptronen als Künstliche Neuronen . . . 12
2.2.3 ReLU Neuronen . . . 12
2.2.4 Sigmoid Neuronen . . . 13
2.3 Topologie der Künstlichen Neuronalen Netzen . . . 13
2.4 Lernverhalten . . . 15
2.5 Vorwärtspropagierung . . . 15
2.5.1 Initialisierung der Modellparameter . . . 18
2.6 Rückwärtspropagierung . . . 19
2.7 Universal Approximation Theorem . . . 24

3 Convolutional Neural Networks **25**
3.1 Bilder als Tensoren . . . 25
3.2 Topologie von CNNs . . . 26
3.3 Convolutional-Schichten und Filter . . . 27
3.3.1 Filter in der Bildverarbeitung . . . 27
3.3.2 Filter in CNNs . . . 28
3.3.3 Filteroperation intutitiv . . . 28
3.3.4 Filteroperationen als diskrete Faltungen . . . 30
3.3.5 Mehrere Filter . . . 31

3.3.6 Padding . . . 32
3.3.7 Stride . . . 32
3.3.8 Vorzüge von Filtern . . . 33
3.3.9 Convolutional-Schicht . . . 33
3.4 Dimensionalitätskontrolle . . . 34
3.4.1 Pooling-Schicht . . . 34
3.4.2 Upsampling-Schicht . . . 35

4 Autoencoder **36**
4.1 Topologie . . . 36
4.2 Funktionsweise . . . 37
4.3 Anwendungen . . . 39
4.3.1 Kompression . . . 39
4.3.2 Neue Datenrepräsentation . . . 39
4.3.3 Visualisierung von Daten . . . 39
4.4 Convolutional-Autoencoder . . . 39
4.5 Denoising-Autoencoder . . . 40
4.5.1 Generierung der verrauschten Bilder . . . 40

5 Frameworks für Maschinelles Lernen **42**
5.1 TensorFlow . . . 42
5.1.1 Client und Master . . . 43
5.1.2 Verwendung — der Client . . . 43
5.1.3 Implementation — der Master . . . 48
5.1.4 Tensorboard . . . 50
5.2 Keras . . . 52
5.2.1 Funktionsweise . . . 52
5.2.2 Schichten . . . 52
5.2.3 Training und Evaluierung . . . 53
5.2.4 Keras Beispielmodell . . . 54

6 Entwicklung eines Denoising-Autoencoders **55**
6.1 Das konkrete Modell . . . 55
6.1.1 Daten . . . 55
6.2 Setup . . . 55
6.3 Entwicklung . . . 57
6.3.1 Testprogramm . . . 57
6.3.2 Trainingsdaten . . . 57
6.3.3 Modell definieren . . . 59
6.3.4 Modell trainieren . . . 62
6.3.5 Modell ausführen . . . 63
6.3.6 Hyperparameter einstellen . . . 64
6.3.7 Diskussion des Modells . . . 65

Schlusswort **66**

A Programmcode **67**

B Ausfuehrungen zu TensorFlow **69**

C Intuitiver Beweis fuer UAT? **70**

Literatur **71**

Abbildungsverzeichniss **73**

Tabellenverzeichniss **75**

Selbstständigkeitserklärung **76**

Vorwort

Persönliche Themenwahl

Maschinelles Lernen (machine learning, kurz: ML) stösst seit einigen Jahren auf grosses Interesse sowohl in der Wissenschaft, als auch in der Wirtschaft. Dies motivierte mich, Näheres im Selbststudium darüber in Erfahrung bringen zu wollen. Bereits im Jahr 2017 begann ich, eine erste eigene Applikationen zu programmieren, welche einen Genetischen Algorithmus zur Anwendung brachte (Evolutionäre Entwicklung von lernfähigen Agenten).
Diese erste Erfahrung öffnete mir die Tür für ein Praktikum am Departement für Computational Sciences der Universität Basel. Dort durfte ich ein Künstliches Neuronales Netz in C++ programmieren, welches ich dann auf eine konkrete physikalische Problemstellung anwenden konnte (Vorhersage zu den Energiezuständen von Wassermolekülen in verschiedenen atomaren Konfigurationen).
Dieses erste Praktikum hatte mich dazu motiviert, mich tiefgehender mit der Thematik zu befassen und die grundlegende Funktionsweise von ML durchdringen zu wollen.

Daraufhin entstand die Idee, die vorliegende Arbeit zu verfassen. Auf diese Weise wollte ich mir ein ausgeprägteres mathematisches Verständnis für Maschinelles Lernen aneignen und auch fortgeschrittene Modelle betrachten. Zudem hatte ich auch schon von den verbeiteten Deep-Learning-Frameworks TensorFlow und Keras gehört, welche ich unbedingt erlernen wollte. Daher entschied ich mich, einen Convolutional-Autoencoder in TensorFlow zu programmieren und vorher die nötige Theorie zu erklären. Zuerst verfolgte ich das Ziel, diesen Autoencoder als ein generatives Modell zu entwickeln, um Bilder von künstlich generierten menschlichen Gesichter zu erzeugen.

Während meiner Sommerferien konnte ich ein 6-wöchiges Praktikum im Forschungszentrum von Adobe in San Francisco leisten, wo ich ebenfalls ein ML-Modell programmiert habe (Nutzung von Gesichtserkennung für Marketing-Zwecke). Durch meine praktikumsbezogenen Recherchen gelangte ich jedoch schnell zu der Erkenntnis, dass mein ursprüngliches ambitiöses Vorhaben bezüglich der generativen Nutzung eines Autoencoder den vorgegebenen Rahmen einer Maturaarbeit deutlich sprengen würde. Ich hätte nämlich nicht nur einen Autoencoder programmieren müssen, sondern sogar einen Variational Autoencoder, welcher mathematisch noch deutlich anspruchsvoller gewesen wäre.

Aus diesem Grund beschloss ich, meine Leitfrage in Abstimmung mit meiner Betreuungsperson anzupassen. Diese beschränkt sich nunmehr auf die Entwicklung eines Convolutional *Denoising* Autoencoder in TensorFlow und Keras sowie vorgängig die zugrundeliegende Theorie zu erklären.

Danksagung

Mein herzlicher Dank gilt dem Department für Computational Sciences der Universität Basel, namentlich Herrn Professor Stefan Goedecker, weil er und sein Team mir die ersten wissenschaftliche Einblicke in das Thema Machine Learning eröffnet haben.
Danken möchte ich ebenso der Firma Adobe, welche mir ermöglicht hat, im Rahmen eines 6-wöchigen Praktikums die kommerzielle Anwendung von Machine Learning vertieft kennenzulernen.
Ebenso danke ich meinen Eltern, Frau Dr. Doris Fellenstein und Herrn Dr. Victor Wirth für ihre Begleitung und Unterstützung während des Erstellungsprozesses meiner Maturaarbeit.
Last but not least gilt mein besonderer Dank meiner Betreuungsperson Herrn Dr. Jonas Gloor für seine wertvollen fachlichen Inputs.

Einleitung

Maschinelles Lernen erfreut sich aktuell grosser Beliebtheit und wird sehr erfolgreich in naturwissenschaftlichen, medizinischen oder auch wirtschaftlichen Themenbezügen angewendet. Es bietet ein enormes Innovationspotential und wird laufend weiterentwickelt. Obwohl das Schlagwort "Künstliche Intelligenz" in aller Munde ist, wissen die Wenigsten, wie sie tatsächlich funktioniert.

Das Ziel dieser Arbeit ist daher, dem Leser ein umfassendes Grundverständnis über Maschinelles Lernen zu vermitteln, sowie auf dieser Basis ein konkretes Anwendungsbeispiel zu entwickeln. Zu diesem Zweck werden zunächst die theoretischen Grundlagen zum modellbasierten Lernen dargelegt. Darauf aufbauend ist es möglich, ein konkretes Modell, namentlich Künstliche Neuronale Netze (KNN), in ihrer Funktionsweise zu erläutern. In logischer Konsequenz wird anschliessend die spezifische Architektur eines KNNs präsentiert. Namentlich handelt sich um ein Convolutional Neural Networks (CNN), welches sich besonders gut für Bildverarbeitungszwecke eignet und daher eine grosse Verbreitung in der Praxis aufweist. Mit der anschliessenden Erläuterung der mathematischen Beschreibung eines Autoencoders sind die theoretischen Grundlagen für ein konkretes Anwendungsbeispiel geschaffen.

Nachdem ein mathematisch fundiertes Verständnis für Maschinelles Lernen vermittelt wurde, sollen im Weiteren zwei Open-Source Implementationen vorgestellt werden. Dabei handelt es sich um TensorFlow, ein ursprünglich von Google entwickeltes Framework für Deep-Learning, und um Keras, eine übergeordnete Schnittstelle für eine vereinfachte TensorFlow-Verwendung. Neben ihrer grossen Verbreitung besitzen sie den Vorteil eines verkürzten Einstiegs in die ML-Programmierung.

Für das konkrete Modell werden wir einen sogenannten Convolutional-Denoising-Autoencoder entwickeln. Mit dessen Hilfe kann das Bildrauschen von Bildern entfernt werden. Eine beispielhafte Anwendungsmöglichkeit bildet das korrekte Einlesen von standardisierten (verrauschten) Formularen.

Die Leitfrage lässt sich demnach folgendermassen formulieren:

Wie funktioniert Maschinelles Lernen und wie entwickelt man mit diesem Wissen ein konkretes Modell in TensorFlow und Keras?

Dabei lassen sich folgende Teilschritte unterscheiden:

1. Erarbeiten der allgemeine Theorie zum Maschinellen Lernen
2. Künstliche Neuronale Netze als Modelle für ML
3. Convolutional Neural Networks und Autoencoder als konkrete KNN-Architekturen
4. Funktionsweise der ML-Frameworks TensorFlow und Keras
5. Programmierung eines konkreten ML-Modells mit TensorFlow und Keras

Konvention und Notation

Beschriftung

Zahlen und Tensoren

a	ein Skalar (Zahl)
$\boldsymbol{a}$	ein Vektor
$\boldsymbol{a} \in \mathbb{R}^n$	ein Vektor mit n Komponenten
$\boldsymbol{A}$	eine Matrix
$\boldsymbol{A} \in \mathbb{R}^{m \times n}$	eine Matrix mit m Zeilen und n Spalten
$\mathbf{A}$	ein Tensor

Mengen

(a, b)	ein geordnetes Paar (2-Tupel) der Elemente a und b
$\mathbb{A}$	eine Menge
$\mathbb{R}$	die Menge aller reellen Zahlen
$\mathbb{Z}$	die Menge aller ganzen Zahlen
$\mathbb{N}$	die Menge aller natürlichen Zahlen
$\{a, b\}$	die Menge, welche aus den Elementen a und b besteht
$\{1, \ldots, n\}$	die Menge aller ganzen Zahlen von 1 bis n
$a \in \mathbb{A}$	a ist ein Element der Menge $\mathbb{A}$

Indexierung

a_i	die i-te Vektorkomponente mit Startindex 1
$(\boldsymbol{A})_{i,j}$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$A_{i,j}$	das Matrixelement in der i-ten Zeile und der j-ten Spalte
$\boldsymbol{A}_{i,:}$	die Zeile i der Matrix $\boldsymbol{A}$
$\boldsymbol{A}_{:,i}$	die Spalte i der Matrix $\boldsymbol{A}$
$\mathbf{A}_{i,:,:}$	der i-te Querschnitt entlang der Höhe des Tensors $\mathbf{A}$
$\mathbf{A}_{:,i,:}$	der i-te Querschnitt entlang der Breite des Tensors $\mathbf{A}$
$\mathbf{A}_{:,:,i}$	der i-te Querschnitt entlang der Tiefe des Tensors $\mathbf{A}$
$\boldsymbol{A} = \begin{pmatrix}$	Definition einer Matrix $\boldsymbol{A}$
$\mathbf{A} = \begin{bmatrix} \boldsymbol{A}_{:,:,1} & \cdots & \boldsymbol{A}_{:,:,c} \end{bmatrix}$	Definition eines Tensors $\mathbf{A}$

Lineare Algebra Operationen

$\boldsymbol{v} \cdot \boldsymbol{w}$	das Skalarprodukt von $\boldsymbol{v}$ mit $\boldsymbol{w}$
$\boldsymbol{A}^\mathsf{T}$	das Transponierte einer Matrix $\boldsymbol{A}$
$\boldsymbol{A} \odot \boldsymbol{B}$	das elementeweise (Hadamard) Produkt
$\boldsymbol{A} * \boldsymbol{B}$	die diskrete Faltung von $\boldsymbol{A}$ ueber $\boldsymbol{B}$

Infinitesimalrechnung

$f'(x)$	die Ableitung der Funktion f bezüglich seinem Argument x
$\frac{\mathrm{d}y}{\mathrm{d}x}$	die Ableitung von y bezüglich x
$\frac{\partial y}{\partial x}$	die partielle Ableitung von y bezüglich x
$\boldsymbol{\nabla} y$	der Gradient von y
$\boldsymbol{\nabla}_{\boldsymbol{x}} y$	der Gradient von y bezüglich $\boldsymbol{x}$ (Vektor)
$\int f(x)\,\mathrm{d}x$	das unbestimmte Integral der Funktion f bezüglich x
$\int_a^b f(x)\,\mathrm{d}x$	das bestimmte Integral der Funktion f bezüglich x von a bis b
$\lim_{x \to a} f(x)$	der Limes/Grenzwert von f, wenn x gegen a strebt

Funktionen

$f : \mathbb{A} \to \mathbb{B}$	eine Funktion f mit Definitionsmenge $\mathbb{A}$ und Zielmenge $\mathbb{B}$
$f(x)$	eine Funktion f mit Argument x (Skalar)
$f(\boldsymbol{v})$	eine Funktion f mit Argument $\boldsymbol{v}$ (Vektor)
$\boldsymbol{f}[\boldsymbol{v}]$	die vektorisierte Funktion $\boldsymbol{f}$ mit Argument $\boldsymbol{v}$ (Vektor)
$\mathcal{A}$	ein Funktionenraum
$f * g$	die Faltung von f über g
$f \circ g$	die Komposition von den Funktionen f und g

Statistik

$\mathcal{N}$	die Gauss'sche Normalverteilung
ϕ	die Gauss'sche Dichtefunktion
μ	der Erwartungswert/Mittelwert
σ	die Standardabweichung
σ^2	die Varianz

Sonstiges

$\sum_{i=a}^{b} x$ die Summe mit von a bis b ueber x mit Laufvariable i

Erwähnung von Notation $\mathbb{R}$ für Skalare und $\mathbb{R}^n$ für Vektoren/Vektorräume...

Kapitel 1

Maschinelles Lernen

Der Themenbereich des **Maschinellen Lernens** beschäftigt sich mit Algorithmen und mathematischen Modellen, welche von selber lernen, Probleme zu lösen. Hierbei wird nicht explizit einprogrammiert, wie das Modell das Problem zu lösen hat, stattdessen wird das Modell trainiert, optimiert sich von selbst und findet selber einen Weg, das Problem zu lösen. Die Grundidee dabei ist, dass man Daten erfasst, generiert oder misst, welche analysiert werden sollen. Innerhalb dieser Daten existieren gewisse Gesetzmässigkeiten und Muster. Diese Muster sollen vom Modell erkannt werden und verallgemeinert werden. Nach dem erfolgreichen Lernen, kann das Modell Vorhersagen für neuen Daten machen.

Man unterscheidet zwischen zwei Arten von Maschinellem Lernen.

- **Überwachtes Lernen** (engl.: supervised learning) ist ein Lernverfahren, bei welchem die Daten aus zwei Teilen bestehen, aus Inputs und Outputs. Man bezeichnet dabei die Outputs als Labels. Die Aufgabe des Modells ist es eine **Korrelation** zwischen den Inputs und den Labels zu erlernen und so ihre Beziehung zueinander zu verstehen. Anhand der Informationen, welche in den Inputs enthalten sind, sind dann die Labels vorherzusagen. Man gleicht dann die vorhergesagten Labels des Modells mit den wahren Labels ab (man "überwacht" sie) und bewertet so die Fähigkeiten des Modells..

  Voraussetzung dafür ist, dass die Daten eben "gelabelt" sein müssen. Man muss schon im Vorhinein Daten haben, bei welchen man die gewünschten Labels hat. Natürlich muss auch die erwähnte Korrelation bestehen. Falls kein Zusammenhang zwischen den Inputs und den Outputs besteht, kann das Modell auch keine Vorhersagen machen und so auch nichts erlernen.

- **Unüberwachtes Lernen** (engl.: unsupervised learning) ist ein anderes Lernverfahren, bei welchem eben diese Labels nicht vorhanden sind. Dem Modell stehen nur die Inputdaten zur Verfügung. Diese werden ebenfalls analysiert und das Modell soll Muster heraus extrahieren, welche sich von sonstigem zufälligen Rauschen unterscheiden.

Der Grossteil der Modelle des Maschinellen Lernens benutzen überwachtes Lernen, da es auch deutlich mehr Anwendungsmöglichkeiten besitzt. Es gibt nur wenige Arten von unüberwachtem Lernen, dazu gehören: Hauptkomponentenanalysen und Generative Adversial Networks. Aus diesem Grund, werden wir im folgenden uns grundsätzlich mit überwachtem Lernen beschäftigen.

(Mehrere, *Supervised learning — Wikipedia, The Free Encyclopedia*)
(Mehrere, *Unsupervised learning — Wikipedia, The Free Encyclopedia*)

1.1 Allgemeine Begriffe

1.1.1 Daten

Um ein Modell zu trainieren, braucht man Daten. Diese Daten bestehen immer aus **Inputs** und **Outputs**. Man unterscheidet hierbei zwischen zwei Arten von Outputs. Die **Labels** sind die erwarteten

Outputs, welche die gewünschten Zielwerte sind. Die **Vorhersagen** sind die Outputs, welche das Modell produziert und hoffentlich möglichst genau mit den Labels übereinstimmen.

Diese Daten für das Training kommen in der Form eines **Trainingsdatensatzes** $\mathbb{X}$. Dabei handelt es sich um eine Menge von **Samples**, welche jeweils aus Inputs und Labels bestehen. Die Inputs werden in einem Vektor

$$\boldsymbol{x} = \begin{pmatrix} x_1 & x_2 & \cdots & x_m \end{pmatrix}^\mathsf{T}$$

und die Labels in einem Vektor

$$\hat{\boldsymbol{y}} = \begin{pmatrix} \hat{y}_1 & \hat{y}_2 & \cdots & \hat{y}_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst.Somit ist ein Trainingssample nichts anderes als ein Paar $(\boldsymbol{x}_i, \hat{\boldsymbol{y}}_i)$ eines Inputsvektor $\boldsymbol{x}$ und eines Labelvektor $\hat{\boldsymbol{y}}$. Die Vorhersagen werden ebenfalls in einem Vektor

$$\boldsymbol{y} = \begin{pmatrix} y_1 & y_2 & \cdots & y_n \end{pmatrix}^\mathsf{T}$$

zusammengefasst.

Die Inputs beinhalten sogenannte **Features** (deutsch: Merkmale). Sie zeichnen die Inputs aus und umfassen ihren ganzen Informationsgehalt. Der Algorithmus soll anhand dieser Features seine Vorhersagen machen. Diese Vorhersagen werden dann mit den Labels abgeglichen und so bewertet. Anhand der Bewertungen wird dann eine Optimierung des Modells vorgenommen. Unter korrekten Bedingungen (kein Overfitting) findet kein Auswendig lernen der Trainingsdaten statt, sondern ein Generalisieren des Zusammenhangs anhand von Mustern und Gesetzmässigkeiten.

Um eine endgültige Bewertung des Modells durchzuführen, wird ein Testdatensatz $\mathbb{T}$, welcher nicht Teil des Trainingsdatensatz ist, genutzt, um Vorhersagen zu machen. Dies garantiert, dass kein Auswendig lernen möglich ist.

BEISPIEL

1.1.2 Modelle

Ein **Modell** ist eine mathematische Funktion $h\colon \mathbb{R}^m \to \mathbb{R}^n$, Hypothesenfunktion genannt, welche die Inputs auf die Outputs abbildet $\boldsymbol{y} = h(\boldsymbol{x})$. Man kann diese Funktion gewissermassen als die Hypothese, welche das Modell bezüglich der Beziehung zwischen den Inputs und den Labels aufgestellt hat, betrachten. Diese Modelle können verwendet werden um vor allem entweder Klassifizierungsprobleme oder Regressionsprobleme zu lösen. Falls es sich um letzteres handelt, spricht man von einem Regressionsmodell. Ein solches Regressionsproblem werden wir in dieser Arbeit lösen.

Das Verhalten eines Modells wird bestimmt durch seine **Modellparameter** $\lambda_1, \lambda_2, \ldots, \lambda_k$. Sie bestimmen, wie die Hypothese des Modells lautet. Das Ziel ist es, die Modellparameter so einzustellen, dass die Vorhersagen $\boldsymbol{y}$ des Modells besser mit den Labels $\hat{\boldsymbol{y}}$ der Trainingsdaten übereinstimmen. Dies wird iterativ gemacht, indem immer wieder leichte Anpassungen an den Parametern vorgenommen werden, bis das Modell die gewünschten Resultate liefert.

Neben den gelernten Parametern, gibt es auch noch sogenannte **Hyperparameter**. Diese können nicht erlernt werden, sondern müssen manuell vor dem Training gewählt werden und können den Lernvorgang erheblich beeinflussen. Dies bedeutet, dass man ausprobieren muss, welche Werte für die Hyperparameter die besten Resultate liefern.

Das wohl einfachste Regressionsmodell ist eine Regressionsgerade. Diese ist angemessen, falls ein einfacher linearen Zusammenhang der Form $y = \lambda_1 x + \lambda_0$ zwischen den Features und den Labels besteht. Nun müssten nur noch λ_0 und λ_1 bestimmt werden. BEISPIELMODELL AUTO

Für Maschinelles Lernen haben sich gewisse Modelle besonders gut etabliert, darunter wären: Support Vector Machines, Evolutionäre Algorithmen, und Künstliche Neuronale Netze. Diese Arbeit wird sich vorwiegend mit Neuronalen Netzen auseinandersetzen.

Abbildung 1.1: Schema eines Modells

1.2 Training

1.2.1 Verlust- und Kostenfunktionen

Einsicht ist der erste Schritt zur Besserung. Das gilt auch beim Machine Learning, deshalb muss beim Training zuerst die Genauigkeit des Modells bewertet werden. Dies wird mithilfe von sogenannten Kostenfunktionen bzw. Verlustfunktionen erreicht.

Eine **Verlustfunktion** $L(y, \hat{y})$ soll ein Mass für die Abweichung der Vorhersage y von dem Label $\hat{y}$ sein. Aus ihr bildet man die **Kostenfunktion** $C(\boldsymbol{y}, \hat{\boldsymbol{y}})$, indem man die Verluste der einzelnen Outputs aufsummiert. Somit erhält man die Kosten einer gesamten Vorhersage mit m Outputs (siehe Gl. (1.1)). Bei gewissen Kostenfunktionen gibt es keine Verlustfunktion, da sie nicht auf die einzelnen Outputpaare aufgebrochen werden kann.
Der Fehler $\bar{C}(\mathbb{X})$ des gesamten Trainingsdatensatzes $\mathbb{X}$, der Grösse p, ergibt sich aus dem arithmetischen Mittel der einzelnen Kosten der Vorhersagen (siehe Gl. (1.2)).

$$C\left(\boldsymbol{y}, \hat{\boldsymbol{y}}\right) = \sum_{i=1}^{m} L(y_i, \hat{y}_i) \tag{1.1}$$

$$\bar{C}(\mathbb{X}) = \frac{1}{p} \sum_{j=1}^{p} C\left(\boldsymbol{y}_j, \hat{\boldsymbol{y}}_j\right) \tag{1.2}$$

Eine eine Kostenfunktion C sollte folgende Eigenschaften aufweisen:

- C ist minimal, wenn $\boldsymbol{y} = \hat{\boldsymbol{y}}$
- C wächst mit $|\boldsymbol{y} - \hat{\boldsymbol{y}}|$
- C ist nach jedem y_n partiell differenzierbar (erklärt in Sektion (1.2.2))

(Nielsen, *Neural Networks and Deep Learning*)

1.2.1.1 Mittlere quadratische Abweichung

Die bekannteste Kostenfunktion ist die "Mittlere quadratische Abweichung". (engl.: mean squared error). Sie ist definiert als das arithmetische Mittel aller quadrierten Differenzen zwischen den Vorhersagen und Labels. Zusätzlich halbiert man noch das arithmetische Mittel, damit bei der Ableitung der Faktor 2 wegfällt. Sie hat keine entsprechene Verlustfunktion, da man so das arithemtische Mittel nicht schreiben kann.
Die Kostenfunktion kann mithilfe einer Summe berechnen werden, oder in diesem Fall mithilfe einer Vektorsubtraktion Vorhersagen $\boldsymbol{y}$ von den Labels $\hat{\boldsymbol{y}}$.

$$C_{MSE} = \frac{1}{2n} \sum_{i=1}^{n} (\hat{y}_i - y_i)^2 = \frac{1}{2n} (\hat{\boldsymbol{y}} - \boldsymbol{y})^2 \tag{1.3}$$

Sie erfüllt alle Anforderungen an eine Kostenfunktion:

- Ihr Funktionwert ist 0 und minimal für $\boldsymbol{y} = \hat{\boldsymbol{y}}$
- Sie ist proportional zu $(\hat{\boldsymbol{y}} - \boldsymbol{y})^2$
- Ihre partielle Ableitung nach einem y_i lautet: $C'_{MSE} = \frac{1}{n}(y_i - \hat{y}_i)$

1.2.1.2 Cross-entropy

1.2.2 Gradientenverfahren

Dies geschieht am effizientesten, wenn $\boldsymbol{b}_t$ in die Richtung der stärksten Funktionswertabnahme zeigt. Hierzu braucht man den sogennanten **Gradient $\boldsymbol{\nabla}$**, wofür man wiederum partielle Ableitungen braucht.

Partielle Ableitungen

Partielle Ableitungen sind eine Erweiterung der "normalen" Ableitungen auf multidimensionale Funktionen $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$. Man leitet dabei nur nach einem Argument x_i ab und betrachtet die restlichen Argumente als Konstanten. Es gelten die gleichen Ableitungsregeln wie bei der nicht-partiellen Ableitung. Die partielle Ableitung einer Funktion $f(x_1, \ldots, x_n)$ bezüglich einer Variable x_i in einem Punkt $\boldsymbol{a} = \begin{pmatrix} a_1 & \cdots & a_n \end{pmatrix}^\mathsf{T}$ ist analog zur normalen Ableitung folgendermassen definiert:

$$\frac{\partial f}{\partial x_i}(\boldsymbol{a}) \coloneqq \lim_{h \to 0} \frac{f(a_1, \ldots, a_i + h, \ldots, a_n) - f(a_1, \ldots, a_i, \ldots, a_n)}{h}$$

Geometrisch ist dies die Steigung der Tangente an die Funktion f im Punkt $\boldsymbol{a}$. Die Tangente liegt in der Richtung der Achse des Parametern x_i, nach dem man ableitet.

Gradient

Der Gradient $\boldsymbol{\nabla}$ ist ein Differentialoperator, den man auf eine Funktion $f(\boldsymbol{x}) = f(x_1, \ldots, x_n) : \mathbb{R}^n \to \mathbb{R}$ anwendet kann, welcher ein Skalarfeld auf ein Vektorfeld (das sogennante Gradientenfeld) abbildet.
Um den Gradienten $\boldsymbol{\nabla} f$ der Funktion f zu bilden, fasst man alle partiellen Ableitungen der Funktion f, nach jedem Argument x_i, in einem Vektor zusammen. Meistens bestimmt man den Gradienten $\boldsymbol{\nabla} f(\boldsymbol{p})$ in einem spezifischen Punkt $\boldsymbol{p} = \begin{pmatrix} p_1 & \cdots & p_n \end{pmatrix}^\mathsf{T}$.

$$\boldsymbol{\nabla}_{\boldsymbol{x}} f(\boldsymbol{p}) = \frac{\partial f}{\partial \boldsymbol{x}}(\boldsymbol{p}) = \begin{pmatrix} \frac{\partial f}{\partial x_1}(\boldsymbol{p}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\boldsymbol{p}) \end{pmatrix}$$

Geometrisch ist der Gradient $\boldsymbol{\nabla} f(\boldsymbol{p})$ einer Funktion f in einem Punkt $\boldsymbol{p}$ dann der Vektor, welcher in die Richtung des steilsten Anstiegs von f zeigt. Sein Betrag gibt die Stärke des Anstiegs an.

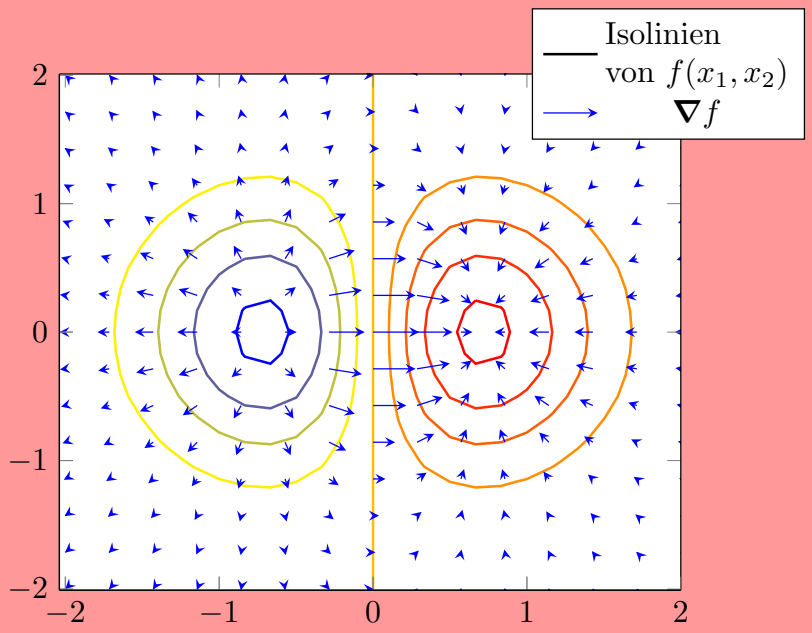

Da der Gradient in die Richtung des steilsten Anstiegs zeigt, sollte der Vektor $\boldsymbol{b}_t$ gerade in die entgegengesetze Richtung zeigen. Also sollte er in die Richtung des negierten Gradienten der Funktion f im Punkt $\boldsymbol{p}_t$ zeigen. Also kann jetzt das iterative Annähern an das lokale Minimum folgendermassen beschrieben werden (wobei η eine später erklärte Schrittgrösse darstellt).

$$\boldsymbol{p}_{t+1} = \boldsymbol{p}_t - \eta \cdot \boldsymbol{\nabla} f(\boldsymbol{p}_t) \tag{1.4}$$

Während des Gradientenverfahren konvergiert der Punkt $\boldsymbol{p}_t$ zu einem beliebigen *lokalen* Minimum, abhängig davon wie der Startpunkt $\boldsymbol{p}_0$ gewählt wurde. Wie man diesen Startpunkt zu wählen hat, wird in Sektion (2.5.1) erlaütert. Da dieser meist zufällig bestimmt wird, ist es eine Glückssache ein sehr niedriges Minimum zu finden.

Die sogennante **Lernrate** η aus Gleichung (1.4) ist ein Hyperparameter. Sie ist ein positiver Proportionalitatsfaktor, welcher die Schrittgrösse des Gradientenabstiegs bestimmt. Sie muss je nach zu

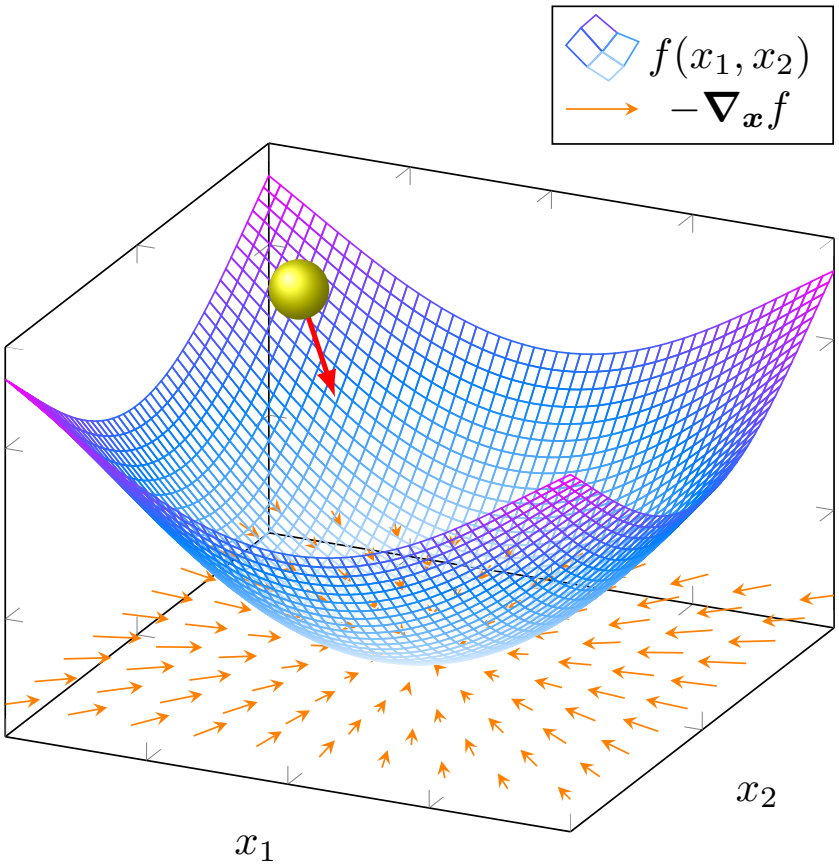

Abbildung 1.2: Visualisierung des Gradientenabstiegs: ein Ball rollt das Gradientenfeld hinab in das lokale Minimum.

minimierender Funktion anders gewählt werden. Dabei hilft nur Ausprobieren. Falls η nicht gut gewählt wurde, gibt es Probleme beim Training:

- Falls η zu klein ist, verläuft das Trainings unnötig langsam und braucht sehr lange. Ausserdem kann es passieren, dass man bei einem hohen lokalen Minimum stecken bleibt.
- Falls η zu gross ist, kann es passiert, dass man über das lokale Minimum hinaus schiesst und somit nur darum herum springt.

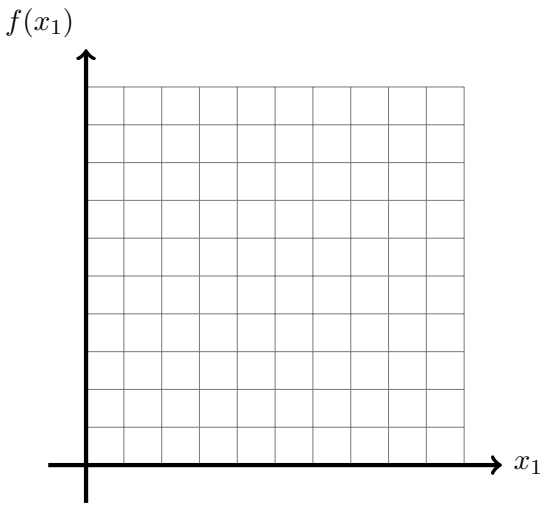

Abbildung 1.3: Visualisierung verschiedener Lernraten

(Nielsen, *Neural Networks and Deep Learning*)

1.2.3 Stochastisches Gradientenverfahren

Wie oben erklärt, wird für das Trainieren eines Modells das Gradientenverfahren benutzt. Konkret wird die Kostenfunktion $C(\boldsymbol{y}, \hat{\boldsymbol{y}} \mid \lambda_0, \ldots, \lambda_n)$ (λ_i sind die Modellparameter, $\boldsymbol{y}$ die Vorhersagen und $\hat{\boldsymbol{y}}$ die Labels) minimiert, indem die Parameter angepasst werden. Dadurch macht das Modell immer bessere Vorhersagen. Für nur eine Iteration des Gradientenverfahren, müsste man den Gradienten für den *gesamten* Trainingsdatensatz berechnen. Dies wäre zwar ein exakter Prozess, aber ein extrem langsamer zugleich. Bei grossen Datensätzen würde es eine Ewigkeit daürn, bis das Modell nur annahernd güte Vorhersagen machen würde.

Aus diesem Grund verwendet man eine leicht abgeänderte Variante dieses Verfahren, nämlich das **Stochastische Gradientenverfahren** (engl.: Stochastic Gradient Descent) (SGD). Hierfür wird der "echte" Gradient des gesamten Datensatzes mit dem Gradienten einiger Trainingssamples approximiert. Dazu wird der Trainingsdatensatz in sogennante **Mini-Batches** eingeteilt und der Gradient jeweils pro Mini-Batch berechnet. Als Konseqünz finden deutlich mehr Iterationen in *einer* Durchkämmung der Trainingsdaten statt. Eine solche Durchkämmung bezeichnet man als **Epoche**. Oft wird mehrere Epochen lang trainiert. Der Gradient eines genug grossen Mini-Batches ist zwar nicht ganz exakt, aber approximiert den Gradieten des gesamten Datensatzen genügend gut. Sowohl die Mini-Batch Grösse, wie auch die Anzahl Epochen sind weitere Hyperparameter.

Die partiellen Ableitungen der gesamten Trainingsdaten wird mit dem arithmetischen Mittel der partiellen Ableitungen eines Mini-Batches der Grösse q approximiert.

$$\frac{\partial \bar{C}}{\partial \lambda_k} \approx \frac{1}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_k} \tag{1.5}$$

Eine Iteration des Stochastischen Gradientenverfahren wird analog zu Gleichung (1.4) folgendermassen durchgeführt.

$$\lambda_{k,t+1} = \lambda_{k,t} - \frac{\eta}{q} \sum_{i=1}^{q} \frac{\partial C_i}{\partial \lambda_{k,t}} \tag{1.6}$$

(Nielsen, *Neural Networks and Deep Learning*)

1.3 Trainingsphänomene

1.3.1 Konvergenz und Divergenz

Beim Training eines Modells, kann es entweder zu **Konvergenz** oder **Divergenz** kommen. Falls die Vorhersagen im Verlaufe des Trainings immer besser mit den Labels übereinstimmen, bzw. die Kostenfunktion immer kleiner wird, sagt man, dass das Modell konvergiert. Also findet das Gradientenverfahren erfolgreich ein lokales Minimum.

Es passiert aber auch oft, dass ein Modell nicht konvergiert oder vielleicht sogar divergiert; die Kosten werden also grösser im Verlaufe des Training. Dies kann verschiedene Gründe haben. Einige davon können sein:

- zu wenig Trainingsdaten
- zu schwache Korrelation zwischen Inputs und Labels
- falsche Hyperparameter
- falsches Modell

1.3.2 Underfitting und Overfitting

Falls ein Modell konvergiert, heisst das noch nicht, dass es die Gesetzmässigkeiten innerhalb der Trainingsdaten richtig erlernt hat. Es kann dabei zu zwei Problemen kommen: Overfitting und Underfitting.

Overfitting bezeichnet das Problem, dass ein Modell Vorhersagen erzeugt, welche zu stark an die Trainingssamples angepasst sind. Meistens liegt das daran, dass das Modell zu viele Modellparameter besitzt oder der Trainingsdatensatz zu wenige Samples besitzt. Somit übersteigt die Komplexität des Modells gewissermassen die des Problems.

Um das Problem zu verdeutlichen betrachten wir ein lineares Regressionmodell. Dieses besitzt eine Hypothesenfunktion $h = a_0 + a_1x + a_2x^2 + \ldots + a_nx^n$, welcche einfach ein Polynom n-ter Ordnung ist. Falls der Trainingsdatensatz nun aus n oder weniger Samples besteht, kann das Modell die Regressionkurve der Hypothesenfunktion exakt durch jeden Datenpunkt legen. Dies entspricht dem Verhalten, dass ein Modell mit n Modellparametern, welches mit n Samples trainiert wird, exakt jedes Samples auswendig lernt, anstatt die Gesetzmässigkeiten zu erlernen. Beim Auswendiglernen wiegt das Modell dem Datenrauschen, welches durch die natürliche Varianz innerhalb der Trainingsdaten entsteht, zu viel Gewicht zu. Somit nutzt es eigentlich unrelevante Modellparameter dazu dieses Rauschen zu erlernen.
Dadurch kann das Modell zwar sehr gute Vorhersagen zum Trainingsdatensatz $\mathbb{X}$ machen, jedoch würde es sehr schlechte Vorhersagen für einen zusätzlichen Testdatensatz $\mathbb{T}$ liefern.

Somit können wir Overfitting folgendermassen definieren. Eine Hypothesenfunktion overfittet dann, wenn eine alternative Hypothesenfunktion h' exisitert, für welche die Kosten bezüglich dem Trainingsdatensatz grösser sind $\bar{C}_{h'}(\mathbb{X}) > \bar{C}_h(\mathbb{X})$, jedoch die Kosten für Testdatensatz kleiner sind $\bar{C}_{h'}(\mathbb{T}) < \bar{C}_h(\mathbb{T})$.

Das Gegenteil von Overfitting ist **Underfitting**. Dabei handelt es sich um das Problem, dass eine Hypothesenfunktion h zu wenige Modelparameter λ_k besitzt, um die Komplexität eines Problems zu bewältigen. Die Parameter reichen nicht aus, damit das Modell die Korrelation zwischen Inputs und Labels erlernen kann, beziehungsweise durch die Hyptothesenfunktion die gewünschte Abbildung durchzuführen.

Bezogen auf das lineare Regressionmodell, bedeutet dies, dass der Grad n des polynomen Hypothesenfunktion h zu gering ist, um sich an die Datenpunkte der Sampels anzuschmiegen.
(Mehrere, *Überanpassung — Wikipedia, Die freie Enyklopädie*)

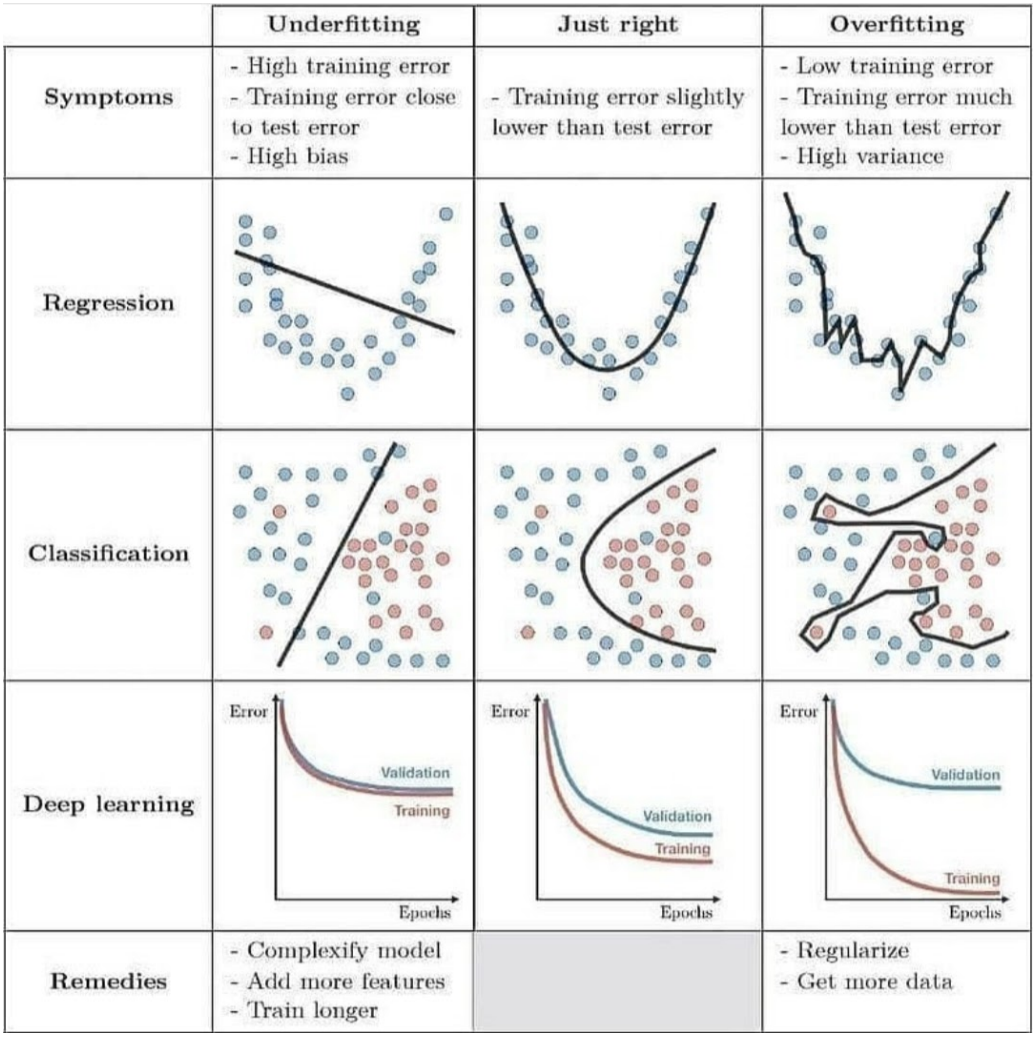

	Underfitting	Just right	Overfitting
Symptoms	- High training error - Training error close to test error - High bias	- Training error slightly lower than test error	- Low training error - Training error much lower than test error - High variance
Regression			
Classification			
Deep learning	Error Validation Training Epochs	Error Validation Training Epochs	Error Validation Training Epochs
Remedies	- Complexify model - Add more features - Train longer		- Regularize - Get more data

Abbildung 1.4: Visalierung von Under- und Overfitting

Kapitel 2

Deep Learning und Künstliche Neuronale Netze

Nun betrachten wir ein spezifisches Modell, welches die wohl besten Resultate für die meisten Problemstellungen des Maschinellen Lernens (Bilderkennung, Spracherkennung, etc.) liefert. Es handelt sich um das **Künstliche Neuronale Netz** (eng.: Neural Network) kurz KNN. Der Bereich des Maschinellen Lernens, welcher sich mit Neuronalen Netzen beschäftigt, bezeichnet man als **Deep Learning**.

Künstliche Neuronale Netze sind zum Teil biologisch von Nervensystemen vieler Lebewesen inspiriert. Sie sind aber lediglich eine Abstraktion ihrer Informationverarbeitung und versuchen nicht eine möglichst genaü biologische Abbildung darzustellen. Es gibt nicht nur eine Art von Neuronalem Netz, sondern es exisitieren die verschiedensten Architekturen, welche je nach Problemstellung ausgewählt werden müssen. Diese Arbeit wird vorallem von zwei solchen Architekturen gebrauch machen: Convolutional Neural Networks und sogenannte Autoencodern.

(Mehrere, *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*)

2.1 Perzeptron

Um den Aufbau und die Funktion eines Künstlichen Neuronalen Netzes besser zu verstehen, wird im folgenden ein Vorgänger des KNN erklärt: das **Perzeptron**.

Das einlagige Perzeptron wurde erstmals 1958 von Frank Rosenblatt vorgestellt. Dieses besteht aus einem einzigen Künstlichen Neuron. Dieses Künstliche Neuron hat mehrere binäre Inputs und einen einzigen binären Output. Binär bedeutet, dass der Wert nur entweder 0 (*aus*) oder 1 (*ein*) sein kann. Des weiteren besitzt es mehrere sogenannte **Gewichte** $w_1, \ldots, w_m \in \mathbb{R}$, für jeden Input x_i ein Gewicht w_i. Diese sind reelle Zahlen, welche das Verhalten des Perzeptron bestimmen. Die **gewichtete Summe**, also die Summe aller Produkte der Inputs mit ihrem Gewicht, wird mit $\tilde{z}$ bezeichnet. Sie ist das gleiche wie das Skalarprodukt des Gewichtevektors $\boldsymbol{w} = \begin{pmatrix} w_1 & \cdots & w_n \end{pmatrix}^\mathsf{T}$ mit dem Inputvektor $\boldsymbol{x}$.

$$\tilde{z} = \sum_{i=1}^{m} w_i x_i = \boldsymbol{w} \cdot \boldsymbol{x}$$

Zusätzlich besitzt das Perzeptron einen **Schwellenwert** $\tilde{b}$. Zusammen mit den Gewichten, bilden sie die Modellparameter. Das Perzeptron verhält sich so, dass falls die gewichtete Summe $\tilde{z}$ grösser als der Schwellenwert $\tilde{b}$ ist, das Neuron feürt, d.h. der Output 1 beträgt. Andernfalls ist er 0 (siehe erster Teil der Hypothesenfunktion h in Gleichung (2.1)). Es ist gängig die Ungleichung der Bedingung in die Nullstellenform zu bringen und $\tilde{b}$ durch die **Neigung** (engl.: bias) $b = -\tilde{b}$ zu ersetzten. Somit lautet die Ungleichung: $\tilde{z} + b > 0$. Der neue Term $\tilde{z} + b$ wird mit z bezeichnet (siehe Rest der Gl. (2.1)). Die Neigung gibt an wie stark das Neuron dazu neigt zu feürn. Eine grosse Neigung lässt ein Neuron auch dann noch feürn, wenn nur wenige Inputs eingeschaltet sind. SCHLECHT

$$h(\boldsymbol{x}) = \begin{cases} 1 & \text{falls } \tilde{z} > \tilde{b} \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \tilde{z} + b > 0 \\ 0 & \text{ansonsten} \end{cases} = \begin{cases} 1 & \text{falls } \boldsymbol{w} \cdot \boldsymbol{x} + b > 0 \\ 0 & \text{ansonsten} \end{cases} \tag{2.1}$$

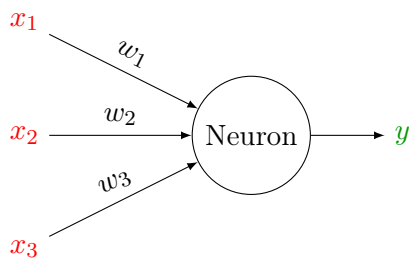

Abbildung 2.1: Perzeptron mit drei Inputs

Für das Trainieren des Perzeptrons existieren spezielle Verfahren, welche hier aber nicht relevant sind. Das Gradientenverfahren kann nämlich nicht verwendet werden. Der Grund dafür sollte später in Sektion (2.2) einleuchtend werden.
(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.1.1 Lernpotenzial eines Perzeptrons

Nun stellt sich die Frage, was ein Perzeptron erlernen kann und wofür es genutzt werden kann. Das Perzeptron ist lediglich ein **linearer Klassifikator** der Form $y = w_1x_1 + \cdots + w_mx_m$. Es ist also ein Klassifizierungsmodell, kein Regressionsmodell. Es kann die Features in zwei Klassen 0 oder 1 einordnen, wobei der Output der Hypothesenfunktion, diese Klassifizierung angibt. Überschreitet y den Schwellenwert, werden die Features der Klasse 1 zugeordnet, sonst der Klasse 0. Jedoch müssen diese Klassen linear separierbar sein.

Lineare Separierbarkeit bedeutet, dass alle Featurevektoren $\boldsymbol{x}_1, \ldots, \boldsymbol{x}_p \in \mathbb{R}^m$ innerhalb ihres Vektorraums $\mathbb{R}^m$ durch eine Hyperebene in ihre Klassen aufteilbar sein müssen. Falls das Perzeptron zwei Inputs hat, bedeutet dies, dass die Ortsvektoren einfach durch eine Gerade voneinander trennenbar sein müssen (siehe Abb. (2.2)).
Falls die Features nicht linear separierbar sind, bedeutet dies, dass das Perzeptron die Klassifizierung nicht erlernen kann. BEISPIEL

Abbildung 2.2: erfolgreiche lineare Separierung (links) und das Versagen bei XOR (rechts)

(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Linear separability — Wikipedia, The Free Encyclopedia*)

2.2 Erweiterung der Künstlichen Neuronen

Ein Perzeptron ist, wie vorhin erklärt, nur in der Lage, lineare Klassifikationen durchzuführen. Um nun auch kompliziertere Probleme zu lösen, muss das Prinzip ausgebaut werden. Ausserdem brauchen wir ein Künstliches Neuron, welches sich besonders gut als Baustein für KNNs eignet.

2.2.1 Künstliche Neuronen im Allgemeinen

Künstliche Neuronen sind immer so aufgebaut, dass sie einen oder mehrere Inputs haben und einen einzigen Output. Zu jedem Input x_i ist ein Gewicht w_i assoziert. Zürst wird die gewichtete Summe der Inputs $\tilde{z}$ gebildet. Die Neigung b wird ebenfalls draufaddiert, um z zu erhalten. Nun muss die sogenannte **Aktivierung** a gebildet werden. Sie ist der Output des Neurons. Die Aktivierung $a = \varphi(z)$ ist das Resultat der **Aktivierungsfunktion** $\varphi : \mathbb{R} \to \mathbb{R}$ angewendet auf z. Die verschiedenen Künstlichen Neuronen unterscheiden sich fast nur in ihrer Aktivierungsfunktion.

Abbildung 2.3: ein künstliches Neuron und seine Bestandteile

(Nielsen, *Neural Networks and Deep Learning*)
(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)

2.2.2 Perzeptronen als Künstliche Neuronen

Zürst noch einmal ein Blick auf das Perzeptron im Angesicht der Aktivierungsfunktion. Ein wesentlicher Unterschied des Perzeptron gegenüber sonstigen Künstlichen Neuronen, besteht darin, dass seine Inputs und Outputs nur binäre Werte annehmen können. Um dieses Verhalten des Perzeptrons zu erhalten, muss eine Stufenfunktion als Aktivierungfunktion verwendet werden: die Heaviside-Funktion Θ. Sie hat einen einzigen Stufensprung bei $x = 0$ vom Wert 0 auf 1 (siehe Abb. (2.4)).

$$\varphi^{\text{hlim}}(z) = \Theta(z) = \begin{cases} 1 & \text{falls } z \geq 0 \\ 0 & \text{falls } z < 0 \end{cases}$$

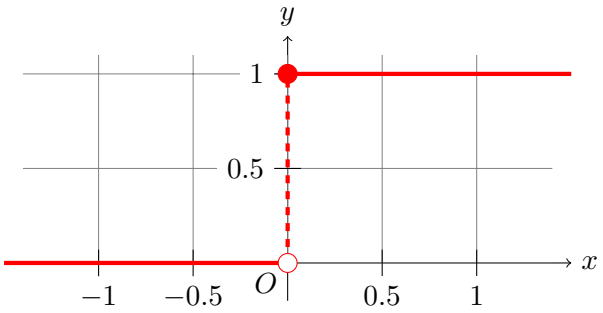

Abbildung 2.4: Definition und Graph der Heaviside-Funktion Θ

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Perzeptron — Wikipedia, Die freie Enyklopädie*)

2.2.3 ReLU Neuronen

Der nächste Schritt nach einer Stufenfunktion als Aktivierungsfunktion, waren lineare Aktivierungsfunktionen. Für diese können die Inputs nun belibige reelle Zahlen sein. Jedoch sind solche lineare Neuronen in einem KNN von keinem Nutzen. Das hat den Grund, dass eine Verkettung von linearen Neuronen, immer auf eine einzige lineare Funktion reduziert werden kann. Somit hat die Verkettung keinen Mehrwert.

Stattdessen verwendet man sogennante ReLU Neuornen. Sie benutzen die **Rectified Linear Unit** (**ReLU**) Aktivierungsfunktion. Diese ist eine nur teilweise lineare Aktiverungsfunktion. Die Werte grösser als 0 werden auf sich selber linear abbgebildet und die Werte kleiner als 0 werden auf 0 abbgebildet (siehe Abb. (2.5)). Eine sehr wichtige Eigenschaft von ihr ist, dass sie - im Gegensatz zu den

vorhin genannten Aktivierungsfunktionen - fast überall differenzierbar[1]und strikt monoton steigend ist. Erst für diese Aktivierungsfunktion, kann das Gradientenverfahren angewendet werden und somit das KNN trainiert werden.

Da sie nur teilweise linear ist, gehört sie genaugenommen den Nicht-linearen-Aktiverungsfunktionen an. Diese Nicht-Linearität erlaubt es dem Neuronen deutlich komplexere Systeme zu modellieren und so deutlich komplexere Probleme zu lösen. Wir werden in Sektion (2.7) sogar erfahren, dass eine Kompostion von nicht-linearen Neurön jede beliebige Funktion approximieren kann.

Wir werden diese Art von Neuron vorerst zur Seite legen und erst wieder in Kapitel (3) im Zusammenhang mit KNNs zur Bilderkennung betrachten.

$$\varphi^{\text{ReLU}}(z) = \begin{cases} z & \text{falls } z > 0 \\ 0 & \text{falls } z \leq 0 \end{cases} = \max(z, 0) \quad (2.2)$$

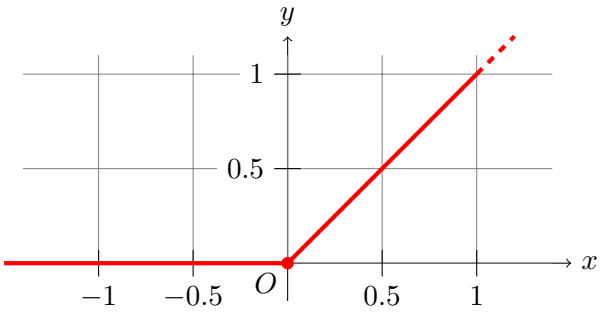

Abbildung 2.5: Formel und Graph der ReLU-Funktion

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.2.4 Sigmoid Neuronen

Ein weiteres nicht-lineares Neuron, sind sogennante Sigmoid-Neuronen. Den Namen haben sie von ihrer Aktivierungsfunktion: der Sigmoidfunktion σ.

Auch sie kann aufgrund ihrer Nicht-linearität zur Approximation jeder Funktion in einem KNN verwendet werden. Sie ist die Aktivierungsfunktion, welche am meisten in KNNs eigesetzt wird. Da sie wirklich sehr stark von Lineartiät abweicht und so am schnellsten komplexe Sachverhalte modellieren kann.

Die Sigmoid-Funktion besitzt eine einzige Wendestelle $\sigma''(x = 0) = 0$ und hat zwei Asymptoten, eine $\lim\limits_{x \to -\infty} \sigma(x) = 0$ und eine zweite $\lim\limits_{x \to \infty} \sigma(x) = 1$ (siehe Abb. (2.6)). Desweiteren zeichnet sie sich durch ihre simple Ableitung aus.

(Mehrere, *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*)
(Mehrere, *Sigmoidfunktion — Wikipedia, Die freie Enyklopädie*)

2.3 Topologie der Künstlichen Neuronalen Netzen

Nun sollten diese Sigmoiden Neuronen als Bausteine verwendet werden, um ein Künstliches Neuronales Netz zu bilden. Dazu werden sie miteinander verbunden und bilden so ein Netz, ähnlich wie ein Nervensystem.

[1]Eigentlich ist die ReLU-Funktion in $x = 0$ wegen des Knicks nicht differenzierbar. Für die Gradientenberechnung definiert man jedoch einfach die Ableitung $\varphi'^{\text{ReLU}}(0) := 0$. Dies ist mathematisch zwar nicht korrekt, löst aber das Problem.

$$\varphi^{\text{sig}}(z) = \sigma(z) = \frac{1}{1+e^{-z}}$$
$$\sigma'(z) = \sigma(z)(1-\sigma(z))$$

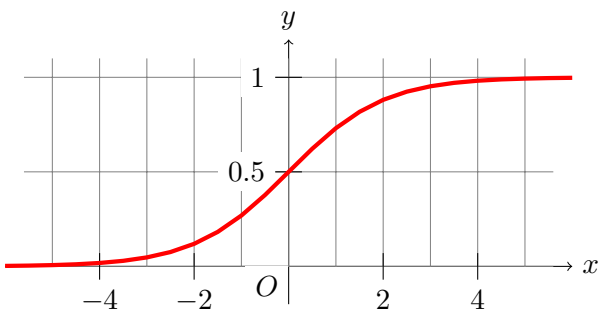

Abbildung 2.6: Definition, Ableitung und Graph der Sigmoid-Funktion σ

Diese Neuronen sind in verschieden Schichten (engl.: Layers) arangiert. Die erste ist die **Inputschicht**. Sie beinhaltet die Inputneuronen. Diese sind eigentlich keine richtigen Neuronen sondern eher Platzhalter für ihr jeweiliges Feature x_i. Als letztes kommt die **Outputschicht** mit den Outputneuronen, welche jeweils einen Outputwert y_i besitzen. Dazwischen liegen die **Zwischenschichten** (engl.: hiddenlayers). Von ihnen kann es beliebig viele geben und in ihnen beliebig viele Neuronen. Falls viele Zwischenschichten verwendet werden, bezeichnet man das Netzwerk als "deep". Daher rürt auch der Name des Deep Learnings. Der Aufbau eines KNN bezeichnet man als **Topologie** des Netzes. Die Topologie umfasst viele Hyperparameter. Darunter sind zum Beispiel die Anzahl Zwischenschichten, wie auch die Anzahl Neuronen pro Schicht.

Jedes Neuron aus einer Schicht ist mit jedem Neuron aus der nächsten Schicht über Verbindungen gekoppelt. Alle Verbindungen besitzten ein Gewicht analog zu den Inputs des Perzeptrons. Die Aktivierung, also der Output, eines Neurons wandert entlang den jeweiligen Verbindung zu allen Neuronen der nächsten Schicht und dient als deren Input. Die söben beschriebe Art von KNN nennt man **Feedforward-Netz**, da alle Werte ausschliesslich nach vorne propagiert werden.

In Abbildung (2.7) ist ein Beispiel eines Neuronalen Netzes abgebildet. In diesem Fall besitzt es sowohl 4 Inputs, als auch 4 Outputs. Es hat ausserdem 3 Zwischenschichten. Die erste und die dritte haben jeweils 3 Neuronen und die zweite besitzt 4 Neuronen.

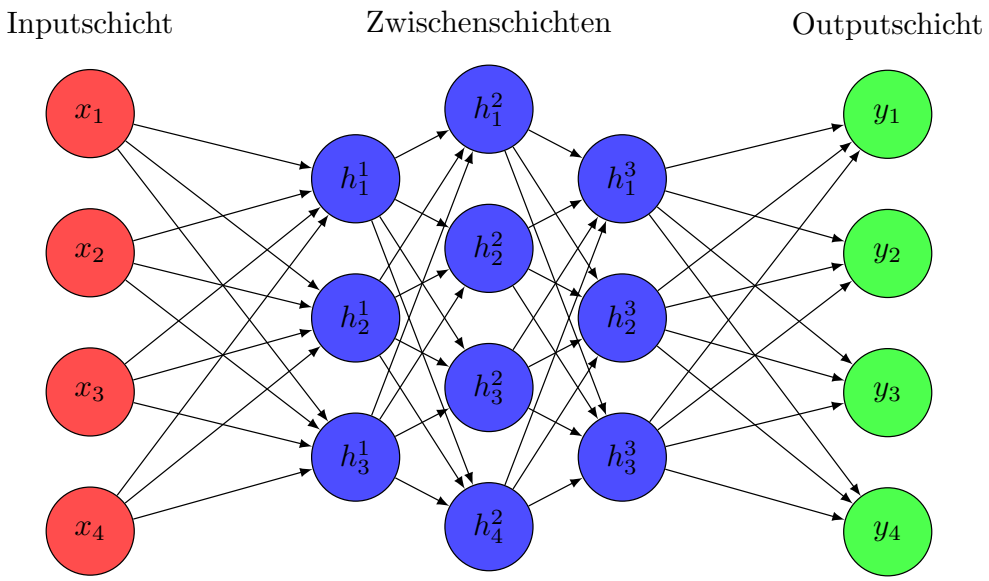

Abbildung 2.7: Schichten eines KNNs

(Mehrere, *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*)
(Nielsen, *Neural Networks and Deep Learning*)

2.4 Lernverhalten

Die Hoffnung beim Trainieren von KNNs besteht darin, dass das Modell für jede weiter Schicht eine höheres Abstraktionsniveau erreicht. Würde man zum Beispiel ein Netzwerk zur Gesichtserkennung trainieren, könnte man sich den Erkennungsprozess folgendermassen vorstellen: Die erste Zwischenschicht erkennt Kanten und Konturen. Die zweite vereint diese Merkmale zu Ecken und primitiven geometrischen Formen. Die dritte Schicht sollte dann schon komplexere geometrische Formen erkennen, welche gewissen Gesichtmerkmalen, wie der Nase, ähneln. Die letzten Schichten soll dann alle diese Merkmale zusammensetzen und so ein Gesicht erkennen. WEITERFÜHREN

2.5 Vorwärtspropagierung

Jetzt, da der Aufbau eines KNNs erklärt wurde, sollte nun die mathematische Funktionsweise des Modells erklärt werden. Hierfür müssen einige Konventionen zur Bezeichnung der Teile eines KNNs getroffen werden. Es sollten vorallem noch Abbildungen (2.8) und (2.9) zum Verstäntnis der Nomenklatur studiert werden.

- l ist der Index einer Schicht. Die Indexierung beginnt bei 0.
- L ist der letzte Schichtindex und somit auch die gesamte Anzahl an Schichten (ohne die Inputschicht).
- $|l|$ ist die Anzahl Neuronen in der l-ten Schicht. [2]
- n_j^l bezeichnet das j-te Neuron in der l-ten Schicht.
- z_j^l ist die gewichtete Summe der Inputs des j-ten Neuron in der l-ten Schicht.
- a_j^l ist die Aktivierung/Output des j-ten Neurons in der l-ten Schicht.
- b_j^l ist die Neigung für das j-te Neuron in der $(l+1)$-ten Schicht. [3]
- $w_{j,k}^l$ ist das Gewicht der Verbindung vom k-ten Neuron in der l-ten Schicht zum j-ten Neuron in der $(l+1)$-ten Schicht. [4]
- φ ist die gewählte Aktivierungsfunktion (diese ist immer eine nicht-lineare Aktivierungsfunktion)

Die Vorwärtspropagierung beginnt bei den Inputneuronen, welche jeweils einen Inputwert in sich tragen. Diese Werte werden, um für eine kohärente Nomenklatur zu sorgen, analog zu den Aktivierungen der anderen Neuronen mit a_j^0 bezeichnet, wobei j der Index des Neurons ist.
Nun müssen die restlichen Aktivierungen der Neuronen bis und mit den Ouputneuronen berechnet werden. Dies geschieht rekursiv, anhand der Aktivierungen der voherigen Schicht und zwar folgendermassen (ersichtlich in Gleichung (FP1)).

Zürst läuft eine Summe über alle Neuronen n_k^l der jetztigen Schicht l. Dabei wird die gewichtete Summe der Aktivierungen a_k^l mit den assozierten Gewichten $w_{j,k}^l$ gebildet. ZU KOMPLIZIERT RELEVANT?: Hierbei ist das Gewicht jenes, welches das k-te Neuron der l-ten Schicht mit dem j-ten Neuron der $(l+1)$-ten Schicht verbindet. Zusätzlich gehört zu der gewichteten Summe auch die jeweilige Neigung b_j^l, welche dazuaddiert wird. Diese gewichtete Summe wird mit z_j^{l+1} bezeichnet.

$$z_j^{l+1} = \sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l \tag{FP1}$$

[2] Diese Schreibweise hat nichts mit dem Betrag zu tun, sondern wird einfach gewählt, da sie sehr platzsparend ist.
[3] Diese Konvention wurde gewählt, damit die folgenden Gleichungen simpler sind.
[4] Man beachte die Reihenfolge!
Diese Konvention scheint zwar auf den ersten Blick unintuitiv, macht jedoch Sinn für die Matrixindezierung. (2.6).

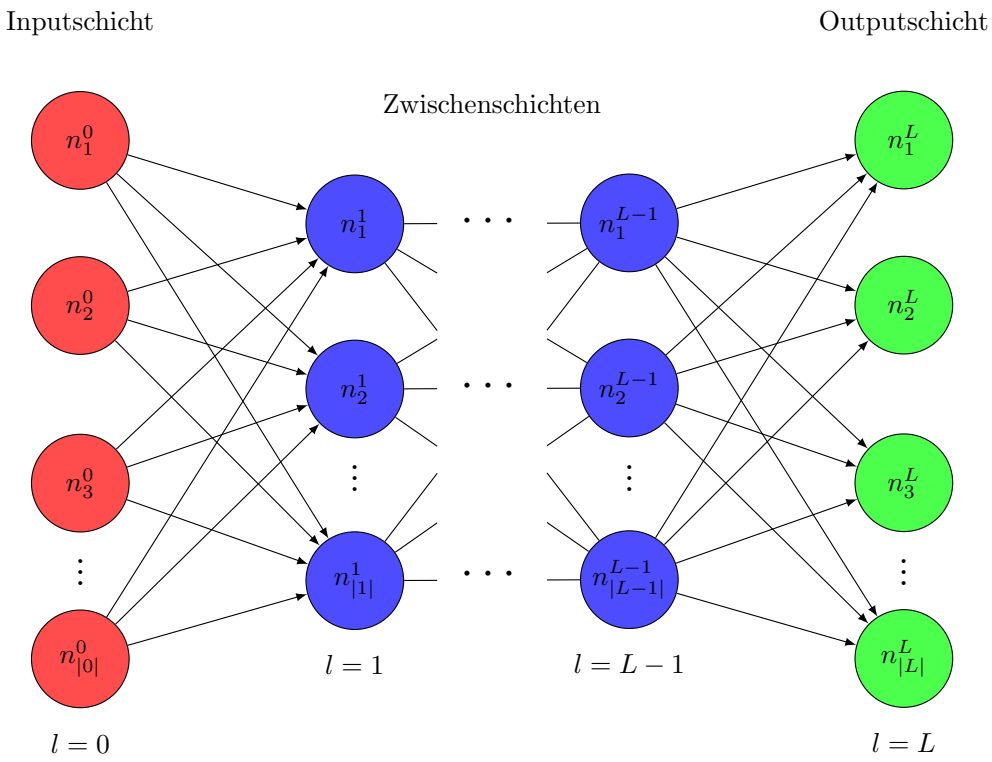

Abbildung 2.8: zum Verständniss der Nomenklatur

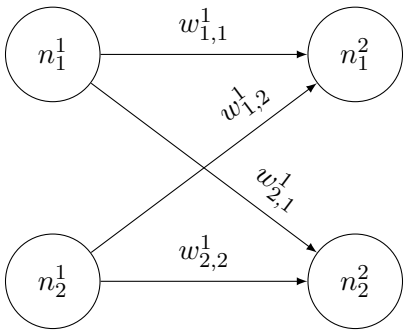

Abbildung 2.9: zum Verständnis der Gewichtebeschriftungen

Auf diese Summe wird dann die Aktivierungsfunktion φ angewandt. Das ist dann die Aktivierung a_j^{l+1} des j-ten Neurons in der $(l+1)$-ten Schicht.

$$a_j^{l+1} = \varphi\left(\sum_{k=1}^{|l|} w_{j,k}^l a_k^l + b_j^l\right) = \varphi\left(z_j^{l+1}\right) \tag{FP2}$$

Für Deep Learning braucht man vorallem sogenannte Deep Neural Networks. Diese zeichnen sich dadurch aus, dass sie sehr viele Zwischenschichten besitzen. Deshalb bezeichnet man sie auch als "deep". Bei solchen Netzwerken ist es nicht unüblich, dass diese sehr viele Neuronen und Verbindungen (über 100'000) besitzen. Um hierbei nicht den Überblick zu verlieren und um nicht in den Indizes zu ertrinken, macht man Gebrauch von **Linearer Algebra**. Man verwendet Matrizen und Vektoren um die vielen Variabeln zusammenzufassen. Ausserdem besteht ein weiterer Vorteil darin, dass Computer mithilfe von Vektor- und Matrixoperationen die Berechnungen paralellisieren können und in kürzerer Zeit und mit weniger Ressourcen viele Berechnungen gleichzeitig ausführen können. Dies beschleunigt das Training der Modelle um ein Vielfaches. Dies wird später in Sektion (5.1) noch weiter thematisiert.

Die Inputs $\boldsymbol{x}$, Vorhersagen $\boldsymbol{y}$ und Labels $\hat{\boldsymbol{y}}$ haben wir schon von Anfang an als Vektoren geschrieben. Nun sollen noch die Modellparameter und die restlichen Komponenten eines KNNs als Vektoren und Matrizen zusammengefasst werden. Sowohl alle gewichteten Summen z_j^l, wie auch alle Aktivierungen a_j^l einer Schicht l, werden in Vektoren $\boldsymbol{z}^l \in \mathbb{R}^{|l|}$ und $\boldsymbol{a}^l \in \mathbb{R}^{|l|}$ zusammengefasst. Auch alle Neigung b_j^l für eine Schicht $(l+1)$ bilden einen Vektor $\boldsymbol{b}^l \in \mathbb{R}^{|l+1|}$.

Zu guter letzt, wird noch eine **Gewichtsmatrix** $\boldsymbol{W}^l \in \mathbb{R}^{|l+1|\times|l|}$ definiert. Sie enthält alle Gewichte welche die l-te Schicht *zu* der $(l+1)$-ten Schicht verbindet. Das heisst der Eintrag in der j-ten Zeile und in der k-ten Spalte ist $w_{j,k}^l$ und verbindet so das Neuron n_k^l zu dem Neuron n_j^{l+1}.

$$\boldsymbol{z}^l = \begin{pmatrix} z_1^l & z_2^l & \cdots & z_{|l|}^l \end{pmatrix}^\mathsf{T}$$
$$\boldsymbol{a}^l = \begin{pmatrix} a_1^l & a_2^l & \cdots & a_{|l|}^l \end{pmatrix}^\mathsf{T}$$
$$\boldsymbol{b}^l = \begin{pmatrix} b_1^l & b_2^l & \cdots & b_{|l+1|}^l \end{pmatrix}^\mathsf{T}$$

$$\boldsymbol{W}^l = \begin{pmatrix} w_{1,1}^l & w_{1,2}^l & \cdots & w_{1,|l|}^l \\ w_{2,1}^l & w_{2,2}^l & \cdots & w_{2,|l|}^l \\ \vdots & \vdots & \ddots & \vdots \\ w_{|l+1|,1}^l & w_{|l+1|,2}^l & \cdots & w_{|l+1|,|l|}^l \end{pmatrix}$$

Mit diesen Definitionen kann nun fast Gleichung (FP1) in Matrixform geschrieben werden, denn die Matrixmultiplikation von $\boldsymbol{W}^l$ mit $\boldsymbol{a}^l$ ergibt einen Vektor $\tilde{\boldsymbol{z}}^{l+1}$, welcher alle gewichteten Summen $\tilde{z}_j^{l+1}$ ohne die jeweilige Neigung enthält.

$$\boldsymbol{W}^l\boldsymbol{a}^l = \begin{pmatrix} \sum_{j=1}^{|l|} w_{1,j}^l a_j^l & \sum_{j=1}^{|l|} w_{2,j}^l a_j^l & \cdots & \sum_{j=1}^{|l|} w_{|l+1|,j}^l a_j^l \end{pmatrix}^\mathsf{T} = \tilde{\boldsymbol{z}}^{l+1}$$

Nun müssen wir noch den Neigungsvektor $\boldsymbol{b}^l$ draufaddieren und wir erhalten Gleichung (FP1a), mithilfe der wir den Vektor der gewichteten Summen $\boldsymbol{z}^{l+1}$ bilden können.

$$\boldsymbol{z}^{l+1} = \mathbf{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l \tag{FP1a}$$

Der letzte Schritt besteht noch darin die Aktivierungsfunktion auf $\boldsymbol{z}^{l+1}$ anzuwenden um den Aktivierungsvektor $\boldsymbol{a}^{l+1}$ zu bilden. Hierfür muss aber noch ein neues mathematisches Konzept eingeführt werden: die Vektorisierung einer Funktion.

Vektorisierung einer Funktion

Die Vektorisierung einer skalaren Funktion f, geschrieben als $\boldsymbol{f}[\boldsymbol{v}]$ hat als Argument einen Vektor $\boldsymbol{v}$, auf dessen Komponenten jeweils *einzeln* die Funktion f angewandt wird. Dieser neue Vektor ist der Rückgabewert der Funktion. Er besitzt die gleichen Dimensionen wie der Argumentvektor.

$$\boldsymbol{f}[\boldsymbol{v}] = \begin{pmatrix} f(v_1) \\ \vdots \\ f(v_n) \end{pmatrix}$$

Nun kann ganz einfach die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf $\boldsymbol{z}^{l+1}$ angewandt werden.

$$\boldsymbol{a}^{l+1} = \boldsymbol{\varphi}\left[\boldsymbol{W}^l\boldsymbol{a}^l + \boldsymbol{b}^l\right] = \boldsymbol{\varphi}\left[\boldsymbol{z}^{l+1}\right] \tag{FP2a}$$

(Nielsen, *Neural Networks and Deep Learning*)

2.5.1 Initialisierung der Modellparameter

Ein Schritt der getan werden muss, bevor das Training beginnt, ist das Initialisieren aller Modellparameter, in diesem Fall die Gewichte und Neigungen. Dies ist ein sehr essentieller Schritt, denn diese Startwerte entscheiden erheblich über die Leistungsfähigkeit des Modells.

Wie in Sektion (1.2.2) gezeigt, muss am Anfang des Gradientenverfahrens ein Startpunkt $\boldsymbol{p}_0$ innerhalb des Gradientenfeldes $\boldsymbol{\nabla}C$ gewählt werden, von welchem aus der Gradientenabstieg beginnt. Da wir das Gradientenverfahren zur Optimierung der Modellparameter verwenden, ist unser Startpunkt der Vektor aller Hyperparameter $\boldsymbol{\lambda} = \begin{pmatrix}\lambda_1 & \cdots & \lambda_k\end{pmatrix}^\mathsf{T}$. Dieser Startpunkt entscheidet darüber, in welches lokale Minimum konvergiert wird und bestimmt somit auch die bestmögliche Exaktheit der Vorhersagen. Falls schlechte Initialwerte gewählt werden, konvergiert der Punkt in ein hohes lokales Minimum, was grosse Kostenfunktionswerte und schlechte Vorhersagen verursacht.

Es ist nicht möglich im Vorhinein zu wissen, welche Initialwerte gute Resultate liefern. Man muss ausprobieren, deshalb initialisert man gängierweise die Hyperparameter mit Zufallswerten. Dafür nimmt man aber nicht irgendwelche Zufallsvariabeln sondern man benutzt die Gauss'sche Normalverteilung $\mathcal{N}(\mu, \sigma^2)$ bzw. ihre Dichtefunktion.

$$\phi(x \mid \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\frac{(x-\mu)^2}{2\sigma^2}\right\}$$

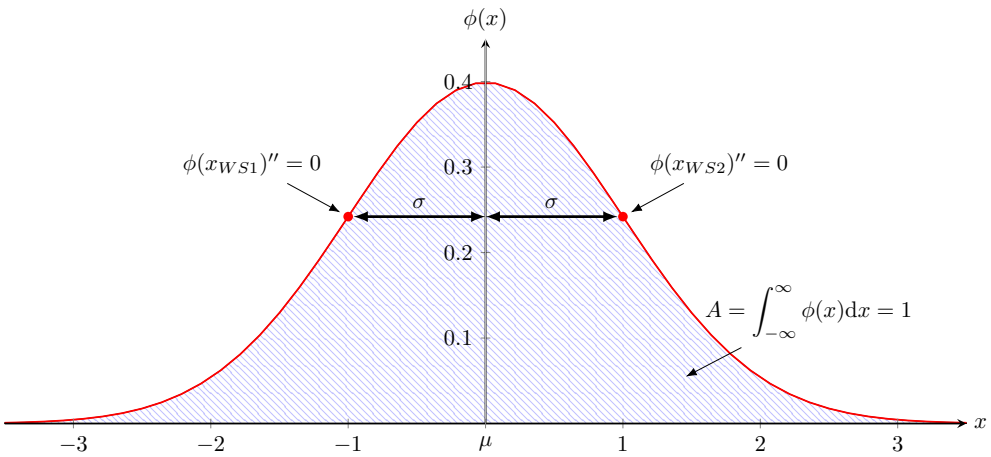

Abbildung 2.10: Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften

In den Anfängen des Maschinellen Lernens verwendet man einfach die normierte Normalverteilung. Jedoch hatte dies zur Konsequenz, dass mit jeder Schicht die Outputs eine stetig grösser werdende Standardabweichung σ aufweisten. Dadurch saturierten gewisse Neuronen eher.

Als Konsequenz wurde eine neue Technik entwickelt: die Glorot-Initalisierung (auch Xavier-Initalisierung gennant). Man verwendet erneut eine Normalverteilung mit Erwartungswert $\mu = 0$. Die Standardabweichung σ skaliert man nun, angepasst an die Grösse einer Schicht. Für eine Schicht l berechnet man den Durchschnitt zwischen der Anzahl Inputs und der Anzahl Neuronen einer Schicht $r = \frac{|l-1|+|l|}{2}$. Der Kehrwert davon ist nun die Varianz. Somit initalisiert man die Gewichte folgendermassen.

$$w_{t=0}^l \sim \mathcal{N}\left(\mu = 0, \sigma^2 = \frac{2}{|l-1|+|l|}\right) \tag{2.3}$$

Durch dieses Verfahren bleibt die Varianz der Outputneuronen gleich der Varianz Für die Neigungen b verwendet man teilweise das selbe Verfahren. Zum Teil aber initalisiert man die Neigungen auch einfach mit 0. Keras macht dies zum Beispiel.

$$b^l_{t=0} = 0 \tag{2.4}$$

(Mehrere, *Normal distribution — Wikipedia, The Free Encyclopedia*)
(Nielsen, *Neural Networks and Deep Learning*)
(Géron, *Hands-On Machine Learning with Scikit-Learn and TensorFlow*)

2.6 Rückwärtspropagierung

Die wahre Herausforderung besteht beim Gradientenverfahren darin, die partiellen Ableitungen der Modellparameter, also die Komponenten des Gradienten, zu bestimmen. Anders gesagt müssen alle Terme $\frac{\partial C}{\partial w^l_{j,k}}$, wie auch alle Terme $\frac{\partial C}{\partial b^l_k}$ berechnet werden. Das Verfahren zum bestimmen dieser Ausdrücke ist so spezifisch und aufwendig, dass das Gradientenverfahren für KNNs einen eigenen Namen hat: die **Rückwärtspropagierung** (engl.: backpropagation) (auch Fehlerrückführung). Im Verlauf der Arbeit ist es nicht notwendig die Rückwärtspropagierung bis ins Detail zu verstehen. Man sollte lediglich ein Gespür dafür entwickeln, wie der Gradient berechnet wird.

Da ein KNN, wie der Name es schon sagt, vernetzt ist, können die partiellen Ableitungen einer Schicht bezüglich seiner Nachbarsschichten berechnet werden. Dies ist auch der namensgebende Grundgedanke der Rückwärtsprogagierung: Man beginnt in der letzten Schicht die partiellen Ableitungen zu bestimmen und berechnet dann im Rückwärtsgang Schicht für Schicht die vorherigen partiellen Ableitungen, bis zur Inputsschicht.
Dies macht man mithilfe der Kettenregel der Ableitungen. Es ist sinnvoll für das Aufstellen dieser Gleichungen das Netzwerk als **Computation Graph** zu betrachten.

Computational Graph

Ein Computation Graph ist eine Darstellung einer Verkettung von Funktionen als Netzwerk von Operationen. Die Knoten im Graph stellen Variabeln dar und die Pfade, welche die Knoten verbinden, sind die Funktionen, welche die Variabeln aufeinander abbilden. Die Funktion wird auf die Variable angewandet, von der der Pfad ausgeht. Der Knoten in welchem der Pfad endet, nimmt dann den Funktionswert an. Falls mehrere Pfade in einem Knoten enden, werden die einzelnen Werte der Pfade zusammenaddiert, um die Variable zu bilden.
KETTENREGEL NOCHMALS ERWÄHNEN ODER IN ABBILDUNG (LEIBNIZ-SCHREIBWEISE!)

Beispiel: Computational Graph

Untenstehend ist ein Beispiel eines Computation Graphs zusammen mit der Herleitung der partiellen Ableitungen dargestellt.

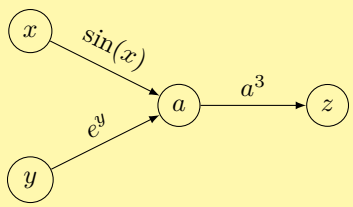

$$a(x,y) = \sin(x) + e^y$$
$$z(a(x,y)) = a^3(x,y) = (\sin(x) + e^y)^3$$

$$\frac{\partial z}{\partial x} = \frac{\partial a}{\partial x} \cdot \frac{\partial z}{\partial a} = \cos(x) \cdot 3a^2$$
$$\frac{\partial z}{\partial y} = \frac{\partial a}{\partial y} \cdot \frac{\partial z}{\partial a} = e^y \cdot 3a^2$$

Der erste Schritt der Rückwärtsprogagierung besteht darin, dass man die partiellen Ableitungen $\frac{\partial C}{\partial z_j^l}$ der Kostenfunktion C bezüglich den gewichteten Summen z_j^l aller Schichten berechnet. Daraus lässt sich dann später sehr einfach die partiellen Ableitungen bezüglich den Gewichten $\frac{\partial C}{\partial w_{j,k}^l}$ und bezüglich den Neigung $\frac{\partial C}{\partial b_j^l}$ berechnen.

Zur Übersichtlichkeit definiert man einen **Fehler** δ_j^L für jedes j-te Neuron in jeder l-ten Schicht, welcher die partielle Ableitung bezüglich der gewichteten Summe dieses Neurons ist (siehe Gl. (BP0). Ebenfalls definiert man analog einen Fehlervektor $\boldsymbol{\delta}^l$, welcher alle Fehler δ_j^l einer Schicht l zusammenfasst (siehe Gl. (BP0a)). Nun heisst es diesen für jedes Neuron jeder Schicht zu berechnen.

$$\delta_j^l := \frac{\partial C}{\partial z_j^l} \tag{BP0}$$

$$\boldsymbol{\delta}^l := \begin{pmatrix} \frac{\partial C}{\partial z_1^l} & \frac{\partial C}{\partial z_2^l} & \cdots & \frac{\partial C}{\partial z_{|l|}^l} \end{pmatrix}^\mathsf{T} \tag{BP0a}$$

Da die Kostenfunktion unmittelbar auf die letzte Schicht L angewandt wird, beginnt man auch dort mit der Berechnung des Fehlers $\boldsymbol{\delta}^L$. Wir stellen nun einen Computation Graph auf, um die partiellen Ableitungen zu bilden.

Wir können dem Computation Graph aus Abbildung (2.11) entnehmen, dass die Kosten C eine Funktion in Abhängigkeit von den letzten Aktivierungen a_j^L ist, welche wiederum in Abhängigkeit von der jeweiligen gewichteten Summe z_j^L berechnet werden. Somit können wir mithilfe der Kettenregel die Beziehung (2.5) aufstellen.

$$\delta_j^L = \frac{\partial C}{\partial z_j^L} = \frac{\partial C}{\partial a_j^L} \cdot \frac{\partial a_j^L}{\partial z_j^L} \tag{2.5}$$

Da a_j^L durch die Anwendung der Aktivierungsfunktion φ auf z_j^L gebildet wird, ist $\frac{\partial a_j^L}{\partial z_j^L}$ einfach die Ableitung der Aktivierungsfunktion $\varphi'(z_j^L)$. Somit erhalten wir die erste (BP1) von vier wichtigen Gleichungen für die Rückwärtsprogagierung.

$$\delta_j^L = \frac{\partial C}{\partial a_j^L} \cdot \varphi'(z_j^L) \tag{BP1}$$

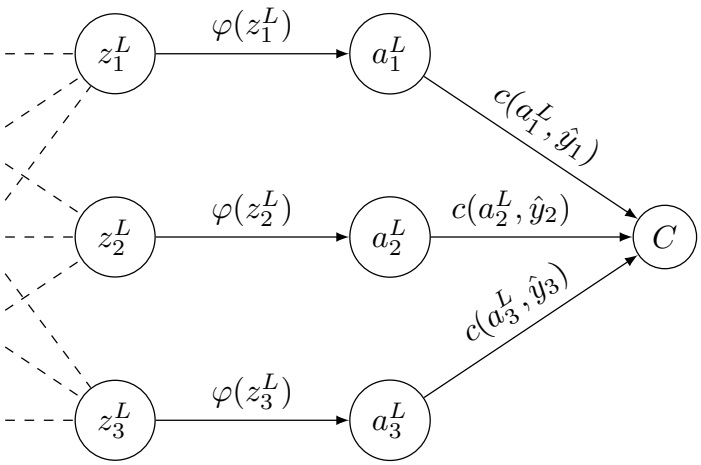

Abbildung 2.11: Computation Graph zur Berechnung von $\boldsymbol{\delta}^L$

Nun möchten wir diese Ausdrücke wieder in Matrixschreibweise realisieren, welche die ganze Schicht L zusammenfasst. Dazu muss eine neue Operation eingeführt werden: das Hadamard-Produkt.

Hadamard-Produkt

Das Hadamard-Produkt (auch elementweises Produkt) ist ein spezielles Produkt zweier gleichgrossen Matrizen $\boldsymbol{A} \in \mathbb{R}^{m\times n}$ und $\boldsymbol{B} \in \mathbb{R}^{m\times n}$. Die resultierende Matrix ergibt sich aus der elementweisen Multiplikation der Ausgangsmatrizen.

$$\boldsymbol{A}\odot\boldsymbol{B} = \begin{pmatrix} A_{1,1}B_{1,1} & \cdots & A_{1,n}B_{1,n} \\ \vdots & \ddots & \vdots \\ A_{m,1}B_{m,1} & \cdots & A_{m,n}B_{m,n} \end{pmatrix} \in \mathbb{R}^{m\times n} \qquad \boldsymbol{v}\odot\boldsymbol{w} = \begin{pmatrix} v_1w_1 \\ \vdots \\ v_nw_n \end{pmatrix}$$

Mit $\boldsymbol{\varphi}'$ als die vektorisierte Ableitung der Aktivierungsfunktion, könne wir den Fehlervektor der letzten Schicht nach Gleichung (2.6) berechnen.

$$\boldsymbol{\delta}^L = \begin{pmatrix} \frac{\partial C}{\partial a_1^L} & \frac{\partial C}{\partial a_2^L} & \cdots & \frac{\partial C}{\partial a_{|L|}^L} \end{pmatrix}^{\mathsf{T}} \odot \boldsymbol{\varphi}'[\boldsymbol{z}^L] \tag{2.6}$$

Dabei ist der erste Operand des Hadamard-Produkts nichts anderes als der Gradient $\boldsymbol{\nabla}_{\boldsymbol{a}^L}C$ der Kostenfunktion C bezüglich dem Aktivierungsvektor $\boldsymbol{a}^L$ der letzten Schicht. Dieser Gradient kann einfach berechnet werden, indem man die vektorisierte Ableitungsfunktion für die gewählte Kostenfunktion bildet. Würde man die Mittlere quadratischen Abweichung $C = \frac{1}{2|L|}(\hat{\boldsymbol{y}} - \boldsymbol{a}^L)^2$ als Kostenfunktion wählen, hätten wir $\boldsymbol{\nabla}_{\boldsymbol{a}^L}C = (\boldsymbol{a}^L - \hat{\boldsymbol{y}}) \cdot \frac{1}{|L|}$.

Daraus folgt die kompakte matrix-version (BP1a) der Gleichung (BP1), welche den Fehlervektor für die letzte Schicht berechnet.

$$\boldsymbol{\delta}^L = \boldsymbol{\nabla}_{\boldsymbol{a}^L}C \odot \boldsymbol{\varphi}'(\boldsymbol{z}^L) \tag{BP1a}$$

Nun müssen wir eine rekursive Berechnungsmethode des Fehlers δ_j^{l-1} der vorherigen Schicht anhand des Fehlers δ_j^l der jetzigen Schicht erarbeiten. Dafür stellen wir zuallererst wieder einen Computation Graph auf (siehe Abb. (2.12)).

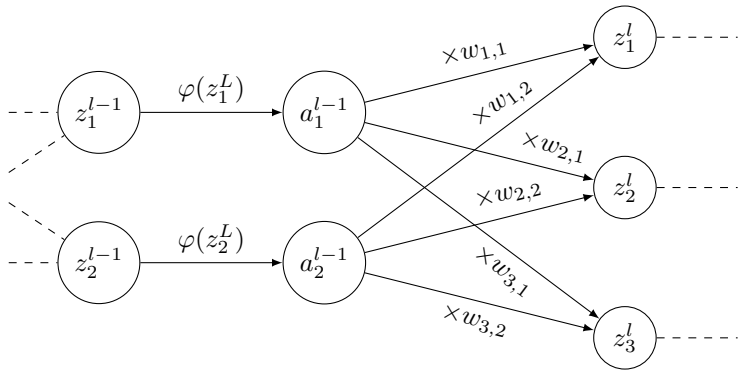

Abbildung 2.12: Computation Graph zur Berechnung von δ_j^{l-1}

Es gilt erneut die Gleichung (2.5) für die Berechnung des Fehlers δ_j^{l-1}.

$$\delta_j^{l-1} = \frac{\partial C}{\partial z_j^{l-1}} = \frac{\partial a_j^{l-1}}{\partial z_j^{l-1}} \cdot \frac{\partial C}{\partial a_j^{l-1}} \tag{2.5}$$

Zürst einmal ist der erste Faktor wieder die Ableitung $\varphi'(z_j^{l-1})$ der Aktiverungsfunktion. Desweiteren beeinflusst beim Übergang der Schicht $(l-1)$ zur Schicht l eine Aktivierungen a_j^{l-1} alle gewichteten Summen z_k^l. Mit der Kettenregel folgt daher, dass die partielle Ableitung $\dfrac{\partial C}{\partial a_j^{l-1}}$ die Summe aller $\dfrac{\partial C}{\partial z_k^l} \cdot \dfrac{\partial z_k^l}{\partial a_j^{l-1}}$ sein muss. Wir erhalten Gleichung (2.7).

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\frac{\partial C}{\partial z_k^l} \cdot \frac{\partial z_k^l}{\partial a_j^{l-1}} \right) \tag{2.7}$$

Um die gewichtete Summe z_k^l zu bilden, multipliziert man einfach die Aktivierung a_j^{l-1} der vorherigen Schicht mit den entsprechenden Gewichten $w_{k,j}^{l-1}$. Dadurch ist diese partielle Ableitung $\dfrac{\partial z_k^l}{\partial a_j^{l-1}}$ gerade das Gewicht selbst. Desweiteren ist $\dfrac{\partial C}{\partial z_k^l}$ per Definition der Fehler δ_k^l. Mit dieser Erkenntnis erhalten wir die zweite essentielle Gleichung (BP2) für die Rückwärtsprogagierung.

$$\delta_j^{l-1} = \varphi'(z_j^{l-1}) \cdot \sum_{k=1}^{|l|} \left(\delta_k^l \cdot w_{k,j}^{l-1} \right) \tag{BP2}$$

Auch diese Gleichung hätten wir gerne in der Matrixschreibweise. Wir beginnen mit der Erweiterung auf alle gewichteten Summen.

$$\boldsymbol{\delta}^{l-1} = \boldsymbol{\varphi}'[\boldsymbol{z}^{l-1}] \odot \begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|}^{l-1} \cdot \delta_k^l \end{pmatrix}^{\mathsf{T}}$$

Der zweite Operant des Hadamard-Produkts ist hierbei gerade das Produkt der Matrixmultiplikation zwischen der transponierten Gewichtsmatrix $(\boldsymbol{W}^{l-1})^{\mathsf{T}}$ der Schicht $(l-1)$ und dem Fehlervektor $\boldsymbol{\delta}^l$ der Schicht l (ersichtlich in folgender Gleichung).

$$\begin{pmatrix} \sum_{k=1}^{|l|} w_{k,1}^{l-1} \cdot \delta_k^l & \cdots & \sum_{k=1}^{|l|} w_{k,|l-1|} \cdot \delta_k^l \end{pmatrix}^\mathsf{T} = \begin{pmatrix} w_{1,1}^{l-1} & w_{2,1}^{l-1} & \cdots & w_{|l|,1}^{l-1} \\ w_{1,2}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{|l|,2}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{1,|l-1|}^{l-1} & w_{2,|l-1|}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix} \begin{pmatrix} \delta_1^l & \cdots & \delta_{|l|}^l \end{pmatrix}^\mathsf{T}$$

$$= \begin{pmatrix} w_{1,1}^{l-1} & w_{1,2}^{l-1} & \cdots & w_{1,|l-1|}^{l-1} \\ w_{2,1}^{l-1} & w_{2,2}^{l-1} & \cdots & w_{2,|l-1|}^{l-1} \\ \vdots & \vdots & \ddots & \vdots \\ w_{|l|,1}^{l-1} & w_{|l|,2}^{l-1} & \cdots & w_{|l|,|l-1|}^{l-1} \end{pmatrix}^\mathsf{T} \boldsymbol{\delta}^l = (\boldsymbol{W}^{l-1})^\mathsf{T} \boldsymbol{\delta}^l$$

Nun haben wir unsere rekursive Fehlerdefinition in Matrixschreibweise und somit die kompakte Version (BP2a) der zweiten wichtigen Formel (BP2).

$$\boldsymbol{\delta}^{l-1} = ((\boldsymbol{W}^{l-1})^\mathsf{T} \boldsymbol{\delta}^l) \odot \boldsymbol{\varphi}'[\boldsymbol{z}^{l-1}] \tag{BP2a}$$

In einem letzten Schritt müssen wir jetzt noch Formeln herleiten, mit welchen man anhand des Fehlers δ_j^l die partiellen Ableitungen der Gewichte und der Neigungen berechnen kann.

Eine Neigung b_j^l ist Funktionsbestandteil der entsprechenden gewichteten Summe z_j^{l+1}. Somit gilt für die Neigung Formel (2.8).

$$\frac{\partial C}{\partial b_j^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial b_k^l} \tag{2.8}$$

Der erste Term ist hierbei per Definition unser Fehler δ_j^{l+1} und der zweite Term lässt sich zu 1 evaluieren, da die Summe z_k^{l+1} nur aus b_k^l besteht und aus Summanden, welche für die partielle Ableitung als konstant gelten. Somit ist die Ableitung der Neigung gerade unser Fehler und wir erhalten die dritte (BP3) von vier essentielen Gleichungen.

$$\frac{\partial C}{\partial b_j^l} = \delta_j^{l+1} \tag{BP3}$$

Somit ist der Kostengradient bezüglich der Neigung gerade der Fehlervektor (siehe Gl. (BP3a)).

$$\boldsymbol{\nabla}_{\boldsymbol{b}^l} C = \boldsymbol{\delta}^{l+1} \tag{BP3a}$$

Ein Gewicht $w_{j,k}^l$ ist ebenfalls ein Funktionsbestandteil der assozierten gewichteten Summe z_j^{l+1}. Dadurch gilt für die partiellen Ableitungen der Kosten nach dem Gewicht Gleichung (2.9).

$$\frac{\partial C}{\partial w_{j,k}^l} = \frac{\partial C}{\partial z_j^{l+1}} \cdot \frac{\partial z_j^{l+1}}{\partial w_{j,k}^l} \tag{2.9}$$

Dabei lässt sich der erste Teil wieder zum Fehler δ_j^{l+1} evaluieren. Die zweite partielle Ableitung ist gerade die Aktivierung a_k^l, da sich die gewichtete Summe aus der Multiplikation des Gewichtes mit der Aktivierung ergibt. Somit erhalten wir die letzte der vier essentiellen Gleichungen (BP4).

$$\frac{\partial C}{\partial w_{j,k}^l} = \delta_j^{l+1} \cdot a_k^l \tag{BP4}$$

Die Matrix-version davon ist Gleichung (BP4a).

$$\boldsymbol{\nabla}_{\boldsymbol{W}^l} C = \boldsymbol{\delta}^{l+1} (\boldsymbol{a}^l)^\mathsf{T} \tag{BP4a}$$

ALLES ZUSAMMENFASSEN
(Nielsen, *Neural Networks and Deep Learning*)

2.7 Universal Approximation Theorem

Es stellt sich nun die Frage, was ein Neuronales Netz alles erlernen kann. Diese Frage kann man mit dem **Universal Approximation Theorem** (UAT) beantworten. Dieser Satz ist ein mathematischer Beweis dafür, dass ein KNN grundsätzlich in der LAge ist jede kontinürliche Funktion beliebig gut zu approximieren. Er wurde von Kurt Hornik in 1991 beweisen.
Etwas genaür besagt der UAT, dass ein Feed-Forward Netzwerk mit einer einzigen Zwischenschicht, welche eine endliche Anzahl Neuron hat, jede Kontinuierliche Funktion approximieren kann. Voraussetzung dafür ist, dass es sich bei den Neuronen und Nicht-lineare-Neuronen handelt. Dies ist nur eine theoretische Ausage über das Lernpotenzial eines KNNs. Jedoch macht es keinerlei Aussage darüber, ob ein KNN wirklich die Funtkionen erlernen wird.
IAN GOODFELLOW: A feedworward network with a single layer is sufficient to represent any function, but the layer may be infeasibly large and may fail to lean and generalize correctly.
Die meisten Klassen von Probleme können einfach als eine Funktion formuliert werden. Somit bedeutet der UAT, dass ein KNN theoretisch jedes Problem lösen kann.
Der eigentliche Beweis ist mathematisch ziemlich anspruchsvoll, deshalb werden wir diesen nicht behandeln.
AUF ANDERE RESOURCE (QR-CODE) VERWEISEN FÜR ILLUSTRIEVEN BEWEIS ODER ANHANG VON MIR GESCHRIEBEN
(Mehrere, *Universal approximation theorem — Wikipedia, The Free Encyclopedia*)

Kapitel 3

Convolutional Neural Networks

Viele Anwendungen von Machine Learning sind verbunden mit Bild- oder Audioverarbeitung, wie z.B Bildklassifizierung, Gesichtserkennung oder Spracherkennung. Vorallem aber für hochauflösende Bilder sind die KNNs, die wir söben kennengelernt haben, nicht geeignet. Sie sind zum Teil gar nicht in der Lage eine Korrelation zwischen den Inputs und Outputs zu erlernen. Um diesen Umstand zu erklären, wird nun ein kleines Beispielmodell erlaütert:

Es soll ein KNN designed werden, welches eine Photographie klassifizieren soll, ob darauf ein Hund sichtbar ist oder nicht. Wir nehmen für dieses Gedankenexperiment bereits ein relativ niedrig aufgelöstes Bild mit 256×256 Pixel, dies entspricht weniger als 0.07 Megapixel (ein iPhone XS hat eine Kamera mit 12 Megapixel). Um die verschiedenen Farben zu codieren besitzt jeder Pixel drei Komponten: R, G und B. Somit hat dieses Bild insgesamt $256 \times 256 \times 3 = 196'608$ Komponenten. Jede Komponente ist ein Feature welches das KNN zu verrechnen hat. Somit bestünde die erste Schicht des Netzwerkes aus fast $200'000$ Neuronen. Um diese Schicht nun mit seiner Nachbarsschicht, welche gleiche Dimensionen besitzt, zu verbinden, braucht es $196'608 \times 196'608 = 38'654'705'664$ Verbindungen und damit gleich so viele Gewichte! Für ein Netwerk ohne eine einzige Zwischenschichten gäbe es also über 38 Milliarden Modellparameter zu erlernen! Dass dies nicht realistisch ist, sollte auf der Hand liegen.

Nicht nur die Anzahl Modellparameter sind ein Problem für KNNs in der Bildverarbeitung, sondern es bestehen noch weiter Probleme. Trotzdem sollte nun klar sein, dass eine andere Modellarchitektur nötig ist, um Machine Learning auf Bilder anzuwenden. Für genau solche Anwendungen wurde eine modifizierte Version eines KNNs entwickelt: das **Convolutional Neural Network** (CNN). Im Allgemeinen sind CNNs immer dann geeignet, wenn es Daten zu verarbeiten gibt, welche eine rasterartige Form haben, wie eben z.B Bilder. Diese Art von Netzwerk macht Gebrauch von Konzepten aus der klassischen Bildverarbeitung, wie sie mit beispielsweise Photoshop gemacht werden kann. Wie beim Perzeptron und bei den klassischen KNNs auch, ist die Architektur biologisch inspiriert. Der folgende Abschnitt wird die Funktionsweise eines solchen CNNs erklären.

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.1 Bilder als Tensoren

CNNs operieren an Bildern. Diese Bilder stellen den Input für die Modelle dar. Um mit diesen Bildern rechnen zu können, ist es sinnvoll, sie als sogenannte **Tensoren** vom Rang 3 zu untersuchen, anstatt sie als Anordnungen von Pixeln zu betrachten.
Um zu verstehen, was ein Tensor dritten Ranges ist, müssen wir zürst verstehen, was ein Tensor im Allgemeinen ist.

Tensor

Ein Tensor $\mathbf{T}$ ist eine Verallgemeinerung von Skalaren, Vektoren und Matrizen auf n Dimensionen. Es handelt sich wie bei Matrizen um eine Zahlenanordnung. Dabei wird die Anzahl Dimensionen, innerhalb welchen die Zahlen liegen als Rang oder Stufe n des Tensors bezeichnet. Vorstellen kann man sich einen Tensor als ein Hyperrechteck mit n Dimensionen, innerhalb dessen die Zahlen in einem Raster angeordnet sind. Diese Zahlen sind die Elemente des Tensors. Ein Tensor nullten Ranges ist ein Skalar, einer erster Stufe ein Vektor und einer mit Rang 2 ist eine normale Matrix.

$$1 \in \mathbb{R} \text{ (Skalar)} \qquad \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix} \in \mathbb{R}^3 \text{ (Vektor)} \qquad \begin{pmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{pmatrix} \in \mathbb{R}^{2\times 3} \text{ (Matrix)}$$

Tensor 3. Ranges

Ein Tensor $\mathbf{T} \in \mathbb{R}^{h\times w\times d}$ mit Rang 3 ist eine 3-dimensionale Zahlenanordnung. Man kann sich diesen Tensor einfach als eine 3D-Matrix vorstellen; ein Volumen innerhalb dessen Zahlen in einem Raster angeordet sind. Analog zum Volumen bezeichnet man die Form des Tensors mit Höhe, Breite und Tiefe.
Ein Tensor von der Form $\mathbb{R}^{3\times 3\times 3}$ könnte folgendermassen aussehen:

$$\mathbf{T} = \begin{pmatrix} \begin{pmatrix} 1 & 0 & 1 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{pmatrix} & \begin{pmatrix} 0 & 1 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 0 \end{pmatrix} & \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \\ \begin{pmatrix} 0 & 1 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 0 \end{pmatrix} & \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} & \begin{pmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \end{pmatrix} \in \mathbb{R}^{3\times 3\times 3}$$

Ein Bild kann somit einfach als Tensor dritten Ranges $\mathbf{B} \in \mathbb{R}^{h\times w\times c}$, der Form (Bildhöhe $\times$ Bildbreite $\times$ Anzahl Farbkomponenten) betrachtet werden. Elemente der Matrix nehmen dann einfach die Werte der Pixelkomponenten an. Ein schwarzweiss Bild hat nur eine Komponente, welche die Helligkeit angibt. Somit wäre es eine normale 2D-Matrix $\boldsymbol{B} \in \mathbb{R}^{h\times w}$ (siehe Abb. (3.1)).

Abbildung 3.1: Beispiel einer Bildmatrix

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Tensor — Wikipedia, Die freie Enyklopädie*)

3.2 Topologie von CNNs

Ein CNN besteht, wie auch ein KNN, aus Schichten. Jede dieser Schichten erhält als Input ein Bild und hat auch wieder eines als Output.
Ein wichtiger Unterschied eines CNNs ist, dass es aus unterschiedlichen Typen von Schichten besteht. Man unterscheiden zwischen vier Arten von Schichten:

- **Fully-connected-Schichten**,
- **Convolutional-Schichten**,
- **Pooling-Schichten**, und
- **Upsampling-Schichten**.

Die Fully-Connected-Schicht ist altbekannt und ist einfach die klassische Schicht eines KNNs, bestehend aus Neuronen. Aus diese werden wir nicht weiter eingehen, da wir sie schon im vorherigen Kapitel kennengelernt haben.
Die Convolutional-Schicht ist eine neuartige Schicht, welche es im KNN nicht gibt. Sie ist die Schicht, welche für das Training relevant ist, da sie die Modellparameter beinhaltet. Sie extrahiert die relevanten Features aus den Inputbildern und lernt so die Bilder zu verstehen.
Die Pooling-Schicht, wie auch die Upsampling-Schicht, beinhaltet keine Modellparameter und sind deshalb für das Training nicht direkt relevant. Diese Schichten werden lediglich gebraucht, um die verarbeiteten Bilder neu zu skalieren. Dies ist sinnvoll, da durch die Extraktion gewisser Features, die restlichen Features wegfallen. Somit muss weniger Information pro Bild gehalten werden und die Bilder sollten schrumpfen, um Overfitting vorzubeugen. Die Pooling- Schichten reduzieren die Bilder und die Upsampling-Schichten erweitern die Bilder um mehr Pixel. Dies wird in Sektion (4) für die Autoencoder hilfreich werden.
Grundsätzlich folgt auf eine Convolutional-Schicht immer entweder eine Pooling- oder eine Upsampling-Schicht. Somit bilden sie gewissermassen eine Einheit.

In Abbildung (3.2) ist ein Schema eines CNNs abbgebildet.

Abbildung 3.2: Schichtung eines CNNs

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.3 Convolutional-Schichten und Filter

Zürst betrachten wir die Convolutional Schicht. Diese Schicht macht ausgiebig Gebrauch von sogenannten Filtern. Diese werden in diesem Abschnitt behandelt.

3.3.1 Filter in der Bildverarbeitung

Filter (auch Kerne) sind in der Bildverarbeitung sehr verbreitet. Jeder kennt sie entweder von Photoshop, von Instagram oder sonstigen Bildbearbeitungsprogrammen. Auch CNNs machen Gebrauch von solchen Filtern, in diesem Fall um die Features eines Bildes zu erlernen.

Abbildung 3.3: der Instagramfilter: Blablabla

Ein Filter ist einfach eine Region, deutlich kleiner als das verarbeitete Bild $\mathbf{B}$, welche über alle Pixel wandert, diese manipuliert und so wieder ein neues Bild $\tilde{\mathbf{B}}$ liefert. Mathematisch gesehen handelt es sich bei einem Filter einfach um einen Tensor, den sogennanten **Filtertensor F** oder Faltungstensor (siehe Abb. (3.4)). Solche Filter sind immer quadratisch, wobei ihre Zeilen- und Spaltenlänge mit f bezeichnet wird. Dabei ist f immer eine ungerade Zahl, damit ein Element, der sogennante **Zentralelement** (engl.: Center element), bezeichnet mit $(\mathbf{F})_C$, immer im Zentrum des Filters liegt.

Abbildung 3.4: eine 2D-Filtermatrix

Das Verhalten des Filters wird durch seine Matrixeinträge bestimmt. Die Elemente können also so gewählt werden, dass wenn der Filter auf ein Bild angewandt wird, er bestimmte Features aus dem Bild hervorhebt. Solche Features könnten zum Beispiel Ränder oder Kanten sein, welche betont werden.

Ein gutes Beispiel ist der Sobel-Filter. Er ist ein typischer 2D-Kantendetektions-Filter mit einer Grösse von $f = 3$. Wir betrachten nun den Sobelfilter $\boldsymbol{G}_x$, welcher horizontale Kanten akzentuiert. Die Einträge dieses Filters lauten wie folgt:

$$\boldsymbol{G}_x = \begin{pmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{pmatrix}$$

Angewandt auf ein schwarz-weisses Bild, erhält man ein neues Bild, bei welchem alle erkannten Kanten weiss eingefärbt sind und die restlichen Bereiche schwarz sind. Der Filter erkennt dabei jede Stelle als Kante, welche zwei Regionen mit genug grossem Kontrast voneinander trennt. In Abbildung (3.5) wurde der horizontale Sobelfilter auf ein Beispielbild angewandt. Links ist das Ursprungsbild und rechts ist das prozessierte Bild.

Abbildung 3.5: Sobel-Filter angewandt auf Beispielsbild

(Mehrere, *Sobel operator — Wikipedia, The Free Encyclopedia*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Kernel (image processing) — Wikipedia, The Free Encyclopedia*)

3.3.2 Filter in CNNs

Aus didaktischen Gründen betrachten wir nun zürst nur 2D-Filter, welche sich für graustufige Bilder $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ eignen. Somit ist der hierfür geeignete Filter einfach eine 2D-Matrix, bezeichnet mit $\boldsymbol{F} \in \mathbb{R}^{f \times f}$. Man bedenke bei jeder Filtermatrix einfach immer, dass es sich eigentlich im allgemeinen Fall um einen 3D-Tensor handelt.

Wie wir vorhin erfahren haben, können Filter genutzt werden um gewisse Features eines Bildes hervorzuheben und andere Features zu ignorieren. Dabei bestimmen die Filtereinträge, welche Features extrahiert werden. Somit besteht die Aufgabe darin, die richtigen Filtereinträge zu bestimmen, damit die gewünschten Features erkannt werden und auf die gewünschten Outputs abgebildet werden. Naheliegend sollte jetzt der Gedanke sein, die Filtereintreage als die Modellparameter eines CNNs zu definieren. Mithilfe des Gradietenverfahrens sollten erneut diese Parameter erlernt werden.
Da die Filter die gleiche Funktion haben, wie die Gewichte in einem KNN, bezeichnet man die Filter in einem CNN mit $\boldsymbol{W}$. Die Grösse des Filters stellt dabei einen Hyperparameter dar.

$$\boldsymbol{W} = \begin{pmatrix} w_{1,1} & \cdots & w_{1,f} \\ \vdots & \ddots & \vdots \\ w_{f,1} & \cdots & w_{f,f} \end{pmatrix}$$

3.3.3 Filteroperation intutitiv

Wie wendet man nun einen solchen Filter auf ein Bild an? Um das Prozedere einer Filteroperation leichter verständlich zu machen, wird es erneut für ein graustufiges Bild $\boldsymbol{B} \in \mathbb{R}^{h \times w}$ erlaütert. Später werden auch noch farbige Bilder erklärt.

Bei einer Filteroperation, wendet man einen Filter $\mathbf{W}$ auf einen Bildtensor $\mathbf{B}$ an und erhält so ein neues Bild $\tilde{\mathbf{B}}$. Man schreibt dafür: $\tilde{\mathbf{B}} = \mathbf{W} * \mathbf{B}$.

Um nun diese Operation zu erklären, verwenden wir als Beispiel eine 2D-Filtermatrix $\boldsymbol{W} \in \mathbb{R}^{3 \times 3}$, bei welcher $f = 3$ gewählt wurde. Wie bereits oben erwähnt, wandert der Filter über das Bild. Dabei befindet sich der Filter immer über einer Region des Bilder, welche gleich gross ist, wie der Filter selber (in diesem Fall (3×3)), sodass den Filtermatrixeinträgen immer eindeutig Bildmatrixeinträge entsprechen. Diese Region des Bildes bezeichnet man als das **rezeptives Feld** des Filters (siehe Abb. (3.6)). Das Rezeptive Feld, bezeichnet mit $\hat{\boldsymbol{B}} \in \mathbb{R}^{3 \times 3}$ ist also einfach eine Untermatrix der Obermatrix $\boldsymbol{B}$.

Jedem Element des Filters entspricht ein Element des rezeptiven Feldes. Dem Zentralelement $(\boldsymbol{W})_c$ entspricht dabei gerade dem sogenannten Qüllenpixel (engl.: source pixel) $(\mathbf{B})_s$ des Bildes. Ihn verwenden wir für eine Namenskonvention für das rezeptive Feld. Wir bezeichnen das rezeptive Feld mit $\hat{\boldsymbol{B}}^{(y,x)}$, wobei die hochgestellten Indizes (y, x) die Position des Qüllenpixel $(\boldsymbol{B})_S$ im Bild $\boldsymbol{B}$ angibt.

Abbildung 3.6: ein Filter und sein rezeptives Feld

Der Filter beginnt nun oben links über das Bild zu wandern. Somit hat der Filter zu beginn das rezeptive Feld $\hat{\boldsymbol{B}}^{(2,2)}$, denn der Filter darf nicht über die Ränder des Bildes hinausragen. Nun werden die Elemente der Filters mit den Elementen des rezeptiven Feldes verrechnet, welche die gleichen Dimensionen besitzen. Dabei wird einfach das Hadamard-Produkt (das elementweise Produkt) des beiden Matrizen miteinander gebildet. Nun erhalten wir eine neue Matrix $\boldsymbol{W} \odot \hat{\boldsymbol{B}}^{(2,2)} = \boldsymbol{P} \in \mathbb{R}^{3\times 3}$. Nun werden noch alle Elemente der neuen Matrix $\boldsymbol{P}$ aufsummiert. Diese Zahl ist dann der Grauwert des ersten Pixels $(\tilde{\boldsymbol{B}})_{1,1}$ des bearbeiteten Bildes (siehe Gl. (3.1)). In diesem Sinne stellt der Filter eine Gewichtung der Nachbarspixel dar, welche bestimmt, wie die neuen Pixel aussehen.

$$(\tilde{\boldsymbol{B}})_{1,1} = \sum_{y=1}^{3}\sum_{x=1}^{3}(\boldsymbol{P})_{y,x} \tag{3.1}$$

Nun wird der Filter um ein Element nach rechts verschoben und die gleiche Prozedur angewandt, um den zweiten Pixel zu berechnen. Dies wird durchgezogen, bis eine ganze Zeile der Bildmatrix durchstreift wurde. Danach wird der Filter wieder nach ganz links verschoben und er bewegt sich ein Element nach unten. Das geschieht, bis das ganze Bild verrechnet wurde. Dabei werden die Elemente des ursprünglichen Bildes durchaus mehrmals verrechnet, da es zu einer Überlappung des vorherigen Filters und des verschobenen Filters kommt.

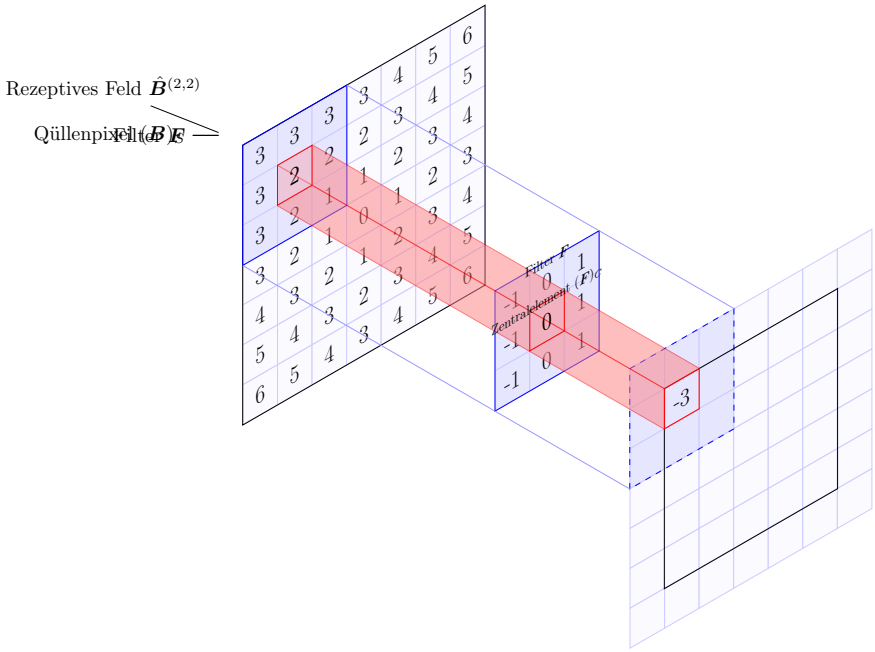

Abbildung 3.7: Schema, wie ein Filter über ein Bild laüft

Es ist zu bemerken, dass das neue Bild $\tilde{\boldsymbol{B}} \in \mathbb{R}^{(h-2)\times(w-2)}$ nicht mehr die gleichen Masse hat, wie das Ursprungsbild $\boldsymbol{B} \in \mathbb{R}^{h\times w}$. Das liegt daran, dass pro Lage des Filters jeweils nur ein Pixel des neuen Bildes berechnet wird. Man kann sich vorstellen, dass an der Position des Qüllenpixel jeweils ein neuer Pixel entsteht. Dabei muss der Filter immer eine vollständige Region als rezeptives Feld haben. Dadurch kommt das Zentralelement nie auf die Ränder des Bildes zu liegen. Somit fallen diese weg.

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolution— Wikipedia, The Free Encyclopedia*)

3.3.4 Filteroperationen als diskrete Faltungen

Eigentlich handelt es sich bei einer Anwendung eines Filters auf ein Bild um eine spezifische mathematische Operation: eine **diskrete Faltung** (engl.: **convolution**). [1] Daher rührt auch der Name des Convolutional Neural Networks. Wir werden die Faltung als mathematische Operation nicht im vollen Umfang betrachten, da sie relativ kompliziert ist. Wir werden uns lediglich auf die Bedeutung der Faltung für Filter beschränken.

Diskrete Faltung

Definintion Faltung

$$(f * g)(x) = \int_{-\infty}^{\infty} f(\tau)g(x-\tau)\mathrm{d}\tau \tag{3.2}$$

Mithilfe der Faltungsoperation können wir die Schritte welche in Sektion (3.3.3) erklärt wurden zusammenfassen. Bei der Filteroperation handelt es sich lediglich um eine diskrete Faltung des Filtertensors $\mathbf{W}$ über den Bildtensor $\mathbf{B}$. Somit können wir folgende Formel verwenden, um einen Pixel $\tilde{\boldsymbol{B}}(x, y)$ des neuen Bildes zu berechnen.

$$(\tilde{\boldsymbol{B}})_{y,x} = (\boldsymbol{W} * \boldsymbol{B})_{y,x} = \sum_{v=1}^{f}\sum_{u=1}^{f}(\boldsymbol{W})_{v,u}(\boldsymbol{B})_{y+v-1,x+u-1} \tag{3.3}$$

[1] Streng genommen wird in CNNs nicht eine diskrete Faltung durchgeführt, sondern eine sogenannte **Kreuzkorrelation**. Der Unterschied dabei ist, dass bei einer Kreuzkorrelation die Faltungsmatrix nicht zürst horizontal, wie auch vertikal gespiegelt wird, im Gegensatz zu der eigentlichen Faltung. Jedoch verwendet man begrifflich das Wort Faltung für beide Operationen. Im Verlauf dieser Arbeit wird mit dem Wort Faltung immer die Kreuzkorrelation gemeint sein.

Faltung Beispielrechnung

$$\boldsymbol{B} = \begin{pmatrix} 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \\ 10 & 10 & 10 & 0 & 0 & 0 \end{pmatrix} \text{ und } \boldsymbol{W} = \begin{pmatrix} 1 & 0 & -1 \\ 1 & 0 & -1 \\ 1 & 0 & -1 \end{pmatrix}$$

Für die Berechnung des ersten Pixels $(\tilde{\boldsymbol{B}})_{1,1}$ führen wir folgende Rechnung aus.

$$\begin{aligned} (\tilde{\boldsymbol{B}})_{1,1} = (\boldsymbol{W} * \boldsymbol{B})_{1,1} &= \sum_{v=1}^{f} \sum_{u=1}^{f} (\boldsymbol{W})_{u,v} (\boldsymbol{B})_{u,v} \\ &= 10 \cdot 1 + 10 \cdot 0 + 10 \cdot -1 + 10 \cdot 1 + 10 \cdot 0 + 10 \cdot -1 + 10 \cdot 1 + 10 \cdot 0 + 10 \cdot -1 \\ &= 0 \end{aligned}$$

Das Gesamtergebniss lautet dann:

$$\tilde{\boldsymbol{B}} = \boldsymbol{W} * \boldsymbol{B} = \begin{pmatrix} 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \\ 0 & 30 & 30 & 0 \end{pmatrix}$$

Für farbige Bilder ist das Vorgehen praktisch das Selbe. Es werden nun lediglich 3D-Tensoren anstatt 2D-Tensoren verwendet. Wir betrachten den allgemeinen Bildtensor $\mathbf{B}_{h \times w \times c}$, wobei c die Anzahl Farbkomponenten (engl.: channels) ist. Nun benutzt man einen Filter $\mathbf{W}_{f \times f \times c}$ mit beliebiger Grösse f aber mit der gleicher Tiefe c wie das Ursprungsbild $\mathbf{B}$. Dadurch muss der Filter nicht entlang der Tiefe des Bildes wandern, da er gerade gleich tief ist wie das Bild. Das hat zur Folge, dass das verarbeitete Bild $\tilde{\boldsymbol{B}}$ immer eine 2D-Matrix ist. Die allgemeine Filtergleichung lautet:

$$(\tilde{\boldsymbol{B}})_{y,x} = (\mathbf{W} * \mathbf{B})_{y,x} = \sum_{v=1}^{f} \sum_{u=1}^{f} \sum_{w=1}^{c} (\mathbf{W})_{v,u,w} (\mathbf{B})_{x+u-1,y+v-1,w} \tag{FO}$$

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)

3.3.5 Mehrere Filter

Eine Filteroperation ist nicht auf einen einzigen Filter beschränkt. Es können mehrere Filter auf das gleiche Ausgangsbild angewandt werden und zusammen ein Endbild erzeugen.

Die Anzahl Filter bezeichnen wir mit c. Nun macht man pro Filter $\mathbf{W}_i$ eine Faltung über das Ursprungsbild $\mathbf{W}$, wobei jede Faltung einen neue Matrix $\tilde{\boldsymbol{B}}_i = \mathbf{W}_i * \mathbf{B}$ liefert, wobei i der Index des Filters ist. All diese gefalteten Bilder $\tilde{\boldsymbol{B}}_i$ sind zweidimensionale Matrizen, unabhängig davon, wieviele Komponenten das Ursprungsbild hatte. Aus diesem Grund können die einzelnen Matrizen $\tilde{\boldsymbol{B}}_i$ aufeinander gelegt werden und somit einen grossen 3D-Endtensor $\tilde{\mathbf{B}}$ bilden. Hierfür müssen alle Filter $\mathbf{W}_i$ gleich gross sein. Die Tiefe des neuen Bildes $\tilde{\mathbf{B}}$ ist jetzt gerade die Anzahl Filter c. Wir haben bereits

Abbildung 3.8: aufeinander gelegte gefaltene Bilder

früher immer die Tiefe des Bildes (bzw. die Anzahl Farbkomponenten) mit c bezeichnet. Somit ist c sowohl die Anzahl Filter einer Schicht, wie auch die Tiefe des verarbeiteten Bildes.

(Goodfellow, Bengio und Courville, *Deep Learning*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.6 Padding

Wie bereits erwähnt schrumpfen die Bilder (an den Rändern), wenn man einen Filter auf sie anwendet. Zur Erinnerung: Dies liegt daran, dass pro Lage des Zentralelements nur ein Pixel des neuen Bildes entsteht und das Zentralelement nunmal nicht auf allen Ursprungspixeln zu liegen kommt. Die Ränder fallen so weg. Diese Grösse des Wegfalls hängt von der Filtergrösse f ab. Hierbei gilt folgende Formel für die neue Grösse n_1 des Bildes, anhand der alten Grösse n_0. n bezeichnet eine der zwei Seitenlängen.

$$n_1 = n_0 - f + 1 \tag{3.4}$$

Das Problem hierbei ist, dass nach einigen Faltungen das Bild extrem geschrumpft ist und im Grenzfall kleiner als der Filter wird. Das darf natürlich nicht passieren. Ausserdem kommt es dabei zu einem relativen Informationverlust an den Ränder, da es im Innern des Bildes zu viel Überlappungen der Filterlagen kommt und es bei den Rändern nur seltener zur Überlappung kommt.

Diese Probleme werden mit sogenanntem **Padding** behoben. Padding ist ein Schritt, welcher vor der eigentlichen Faltung stattfindet. Dabei werden einfach zusätzliche Ränder (Zeilen und Spalten) an das Ursprungsbild angebracht. Der Tensor wird der Länge und der Breite nach (nicht der Tiefe entlang!) an den Enden erweitert. Die neuen Elemente werden dabei auf den Wert 0 gesetzt.

Abbildung 3.9: Padding

Das Padding p ist eine Zahl, welche angibt wieviele Elemente an allen Rändern hinzugefügt werden. Padding $p = 1$ bedeutet, dass an allen Kanten jeweils eine Reihe bzw. Spalte hinzugefügt wird. Begrifflich unterscheidet man zwischen zwei Arten von Padding:

- **Valid-Padding**: Es werden keine züsäzlichen Elemente angebracht. p ist also 0.
- **Same-Padding**: Es werden so viele Reihen und Spalten angebracht, dass die Grösse des Bildes nach der Faltung unverändert bleibt.

Um Same-Padding durchzuführen, muss man p so wählen, dass es den Wegfall durch den Filter gerade kompensiert. Da durch das Padding das Bild der Länge und Breite nach jeweils um zwei p länger wird, erhält man den Ausdruck $n_1 = n_0 - f + 1 + 2p$. Wenn man diese Formel jetzt nach p auflöst, erhält man folgende Formel für das Wählen des Same-Paddings p.

$$p = \frac{f-1}{2} \tag{3.5}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.7 Stride

Bis jetzt haben wir bei den Filterfaltungen, den Filter pro Anwendung immer nur um einen Pixel verschoben. Das muss aber nicht so sein. Man kann den Filter auch mit einer anderen Schrittgrösse verschieben. Diese Eigenschaft bezeichnet man als **Stride** s. Falls $s = 2$ gewählt wird, bedeutet das, dass der Filter sich pro Matrixmultiplikation um zwei Elemente bewegt. Somit wurde eine Position übersprungen. Zur Folge hat dies, dass das neue Bild deutlich kleiner geworden ist, denn das Zentralelement überspringt somit auch diese Felder und bildet so deutlich weniger Pixel.

Folgende Formel beschreibt die Dimensionen des neuen Bildes unter Berücksichtigung der Filtergrösse f, dem Padding p und dem Stride s.

$$n_1 = \frac{n_0 + 2p - f}{s} + 1 \tag{3.6}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.8 Vorzüge von Filtern

Es stellt sich nun die Frage, weshalb sich Filter für Maschinelles Lernen mit Bildern eignen. Wie bereits erwähnt besteht die Aufgabe von Filtern darin, bestimmte Features eines Bildes hervorzuheben und die Restlichen auszublenden. Genau die gleiche Aufgabe erfüllen die Neuronen in einem KNN. Auch sie sollen Features der Inputdaten erlernen, wobei gewisse Neuronen auf gewisse Features reagieren. Weshalb verwendet man also nicht einfach KNNs? (abgesehen von dem Problem mit der Überzahl an Modellparametern, siehe Sektion 3)

Man muss erkennen, dass Bilddaten sich deutlich von sonstigen Daten unterscheiden. Bildfeatures bzw. Pixel sind nur im Kontext von ihren Nachbarn relevant. Denn ein Pixel ist erst dann eine Kante oder eine Ecke, wenn er zwei verschiedene Farbregionen voneinander trennt. Oder ein Gegenstand wird erst durch eine ganzen Haufen von Pixeln und deren relative Position züinander ausgezeichnet. Man bezeichnet diesen Umstand als **lokalisierte Features**.

Desweiteren sind Bildausschnitte nicht immer gleich orientiert. Wenn man ein Gesicht auf einem Bild erkennen möchte, sollte es aber keine Rolle spielen, wo auf dem Bild es sich befindet, welche Grösse es hat und was für eine Lage es hat. Um diese Eigenschaften irrelevant für das Modell zu machen, muss dieses gewisse **Invarianzen** erfüllen.

Die Eigenschaft, welche CNNs geeignet macht für lokalisierte Features und solche Invarianzen, bezeichnet man als **Parameter-Sharing**. Es bezeichnet den Umstand, dass auf mehrere oder alle Features die gleichen Modellparameter wirken. Bei CNNs wird dies durch die Bewegung des Filters bzw. seiner Einträge über (fast) alle Pixel bewerkstelligt. Somit ist es egal, wo und wie sich die lokalisierten Features befinden. Dies führt dann eben zu den gewünschten Invarianzen: Translations-, Rotations- und Helligkeitsinvarianz.
Eine weiterer Vorteil durch dieses Parameter-Sharing ist, dass die Inputbilder beliebige Dimensionen besitzen können, da die Filter ihre Bewegung lediglich an die Grösse des Bildes anpassen müssen.
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)

3.3.9 Convolutional-Schicht

Nun möchten wir alles zusammentragen, was wir über Filter gelernt haben, um nun die Convolutional-Schicht zu definieren.

Beginnen tut eine Convolutional-Schicht l mit seinem Input, also den Aktivierungen $\mathbf{A}^{l-1} \in \mathbb{R}^{h^l \times w^l \times c^l}$, welche die vorherige Schicht $(l-1)$ produziert hat, oder falls es die erste Schicht ist, erhält sie den Input $\mathbf{X}$ des Netzes, welchen man auch mit $\mathbf{A}^0$ bezeichnet.
Die Schicht besitzt c^l Varianten an Filtern $\mathbf{W}_i^l \in \mathbb{R}^{f^l \times f^l \times c^{l-1}}$. Diese Filter haben alle die gleichen Eigenschaften, bezüglich: der Grösse f^l, der Tiefe c^{l-1}, dem Padding p^l und dem Stride s^l. Sie unterscheiden sich nur in den Modellparametern $w^l_{i\,|\,\alpha,\beta,\gamma}$.

$$\mathbf{W}_i^l = \left[\begin{pmatrix} w^l_{i\,|\,1,1,1} & \cdots & w^l_{i\,|\,1,f,1} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,1} & \cdots & w^l_{i\,|\,f,f,1} \end{pmatrix} \overset{\vec{\gamma}}{\cdots} \begin{pmatrix} w^l_{i\,|\,1,1,c^l} & \cdots & w^l_{i\,|\,1,f,c^l} \\ \vdots & \ddots & \vdots \\ w^l_{i\,|\,f,1,c^l} & \cdots & w^l_{i\,|\,f,f,c^l} \end{pmatrix} \right]$$

Nun faltet man jeden Filter $\mathbf{W}_i^l$ einzeln über das Bilder $\mathbf{A}^l$ und erhält so mehrere neue 2D-Bilder $\tilde{\boldsymbol{A}}_i^l$.

$$\tilde{\boldsymbol{A}}_i^l = \mathbf{W}_i^l * \mathbf{A}^l \tag{3.7}$$

Die Faltung berechnet man nach folgender Gleichung:

$$(\tilde{\boldsymbol{A}}_i)_{y,x}^l = (\mathbf{W}_i^l * \mathbf{A}^l)_{y,x} = \sum_{v=1}^{f}\sum_{u=1}^{f}\sum_{w=1}^{c}(\mathbf{W}_i^l)_{v,u,w}(\mathbf{A}^l)_{x+v-1,y+u-1,w} \tag{FO}$$

Jede dieser Matrizen ist ein Qürschnitt $\tilde{\boldsymbol{A}}_{:,:,i}^l$ entlang der Tiefe des neuen 3D-Tensors $\tilde{\mathbf{A}}^l \in \mathbb{R}^{h^{l+1}\times w^{l+1}\times c^l}$. Hierbei ist die Tiefe c^l gerade die Anzahl Filter c^l und die Höhe h^{l+1} und die Breite w^{l+1} werden jeweils nach der folgenden Formel berechnet anhand der Höhe h^l und der Breite w^l des Ausgangsbildes.

$$n^{l+1} = \frac{n^l + 2p^l - f^l}{s^l} + 1 \tag{3.8}$$

Da die Faltungsoperation eine lineare Operation ist, braucht man wieder eine nicht-lineare Aktivierungsfunktion um das Modell zu befähigen nicht-lineare Probleme zu lösen. Deshalb wendet man in einem letzten Schritt die vektorisierte Aktivierungsfunktion $\boldsymbol{\varphi}$ auf den Tensor $\tilde{\boldsymbol{A}}^l$ an und erhält so die neue Aktiverung der nächsten Schicht $\mathbf{A}^{l+1}$. Empirisch hat man festgestellt, dass es für CNNs eine bessere Aktivierungsfunktion als die Sigmoidfunktion gibt. Die ReLU-Aktivierungsfunktion $\boldsymbol{\varphi}^{ReLU}$ aus Sektion (2.2.3) erziehlt bessere Resultate als die Sigmoidfunktion. Deshalb verwendet man eigentlich nur diese in CNNs.

$$\mathbf{A}^{l+1} = \boldsymbol{\varphi}[\tilde{\mathbf{A}}^l] \tag{3.9}$$

(Mehrere, *Convolutional neural network — Wikipedia, The Free Encyclopedia*)
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)
(Nielsen, *Neural Networks and Deep Learning*)

3.4 Dimensionalitätskontrolle

Beim Anwenden einer Convolutional Schicht gehen Informationen verloren, da nur die relevanten Features hervorgehoben werden und der Rest verworfen wird. Jedoch schrumpft das Bild entweder gar nicht (bei Same-Padding) oder es schrumpft nur sehr leicht (bei Valid-Padding). Dies ist ein Problem, da die Information in deutlich weniger Pixeln bzw. Tensorelementen codiert werden könnte. Deshalb haben wir einen unötigen Ressourcenverbrauch und eine erhöhte Gefahr für Overfitting. Um diesem Problem entgegenzuwirken, gibt es einerseits sogenannte **Pooling-Schichten** und als Gegenstück dazu **Upsampling-Schichten**. Ersteres wird verwendet, um die Dimensionalität der Bilder zu vermindern, und letzteres, um die Dimensionalität der Bilder zu erweitern. Somit ermöglichen diese Schichten eine kontrollierte Art (im Gegensatz zum Padding) die Dimensionalität einzustellen.

3.4.1 Pooling-Schicht

Die Pooling-Schicht verringert die Dimensionalität durch das Zusammenfassen eines Feldes von Tensorelementen zu einem einzigen Tensorelement der nächsten Schicht. Dabei geht das Feld nur entlang der Länge und Breite des Bildes und nicht entlang der Tiefe. Dies bedeutet, das Pooling wird auf jeden Channel einzeln angewandt, dadurch ändert sich die Tiefe des Bildes nicht.

Für die Beschreibung einer Pooling-Schicht wird viel Begrifflichkeit der Convolutional-Schicht und der Filter übernommen. Die Grösse des Elementfeldes, welches zusammengefasst wird, bezeichnet man analog zur Filtergrösse mit f^l. Das Stride s^l bezeichnet auch beim Pooling wieder, wie gross die Schrittgrösse beim Verschieben des Feldes ist. Meistens wählt man den Stride s^l gerade gleich der Feldgrösse f^l, damit alle Pixel zusammengefasst werden. Kleiner als f^l kann s^l nicht gewählt werden.

Man unterscheidet zwischen zwei Arten von Pooling:

- **Average-Pooling**: Das Elementenfeld wird zusammengefasst, indem man das arithmetische Mittel der Elemente bildet.
- **Max-Pooling**: Das Elementenfeld wird zusammengefasst, indem das Element mit dem höchsten Wert beibehalten wird und die anderen verworfen werden.

In Praxis verwendet man eigentlich nur Max-Pooling, da es deutlich bessere Resultate erzielt.

MaxPooling Beispiel

Wir wählen eine MaxPooling-Schicht mit $f^l = 2$ und $s^l = 2$. Diese fasst also jedes (2×2)-Feld zu einem Element zusammen. Da aus vier Elementen jeweils eines wird, entspricht dies einer Informationsreduktion von 75%.

$$\begin{pmatrix} 5 & 2 & 4 & 3 \\ 8 & 9 & 5 & 1 \\ 3 & 8 & 6 & 7 \\ 8 & 1 & 4 & 2 \end{pmatrix} \rightarrow_{\text{MaxPool}} \begin{pmatrix} 9 & 5 \\ 8 & 7 \end{pmatrix}$$

Es ist festzuhalten, dass eine Pooling-Schicht keinerlei Modellparameter besitzt. Somit gibt es nichts zu trainieren. Sie besitzt lediglich einige Hyperparameter, wie die Feldgrösse f^l und den Stride s^l.

Um zu berechnen, was die neuen Dimensionen nach dem Pooling sind, gelten die gleichen Formeln wie für die Filteroperationen:

$$n_1 = \frac{n_0 - f}{s} + 1 \tag{3.10}$$

(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)

3.4.2 Upsampling-Schicht

Die Upsampling-Schicht bildet das Gegenstück zur Pooling-Schicht, da sie die Dimensionalität der Bilder erhöht. Auf den ersten Blick erscheint unklar, weshalb man die Dimensionalität erhöhen wollen könnte, da die eigentliche Motivation dieser Schichten in der Verhinderung von Overfitting besteht. Jedoch sollte in Kapitel (4) klar werden, weshalb solche Schichten notwendig sind.

Man verwendet auch hier wieder den Begriff der Feldgrösse f^l. Diesemal beschreibt dieser Wert, wie stark das Bild hochskaliert wird. Beim Upsampling wird ein Element zu einem $(f^l \times f^l)$-Feld hochgerechnet und erweitert so die Dimensionalität.

Es stellt sich natürlich die Frage, was für Werte das neue Feld erhält. Dafür muss man eine Interpolationsart wählen. Zwei Arten sind besonders verbreitet:

- **Bilineare Interpolation**
- **Nächste-Nachbar-Interpolation** (engl.: nearest-neighbor-interpolation)

Wir werden hier nur die Nächste-Nachbar-Interpolation betrachten. Sie ist ziemlich trivial, denn alle neuen Feldelemente nehmen einfach den Wert des alten Elements an. Der Wert wird also einfach vermehrt.
(deeplearning.ai, *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*)
(Goodfellow, Bengio und Courville, *Deep Learning*)

Kapitel 4

Autoencoder

Nun möchten wir uns vorerst von der Architektur des Convolutional Neural Networks abwenden, um den Autoencoder zu betrachten. Wir werden uns erneut mit der Funktionsweise und der Nützlichkeit dieser Architekur auseinandersetzen. Danach werden wir den Autoencoder mit dem Convolutional Neural Network fusionieren und so einen Convolutional-Autoencoder erhalten. Zu guter letzt betrachten wir dann noch eine Anwendung eines solchen Convolutional-Autoencoder, nämlich einen Denoiser.

Ein **Autoencoder** ist eine weitere Architektur eines KNNs. Diese Architektur beschreibt das Netzwerk jedoch nicht bezüglich der Schichtenarten, sondern beschreibt es auf der Ebene der Netzform.
Die Aufgabe eines Autoencoders besteht darin eine neue Repräsentation einer Datenmenge zu erlernen. Diese neuartige Repräsentation soll mit weniger Daten möglichst die gleiche Information codieren. Somit entwickelt das Modell eine **effiziente Daten-Codierung** für einen Datensatz. Dadurch kann er zur **Dimensionalitätsreduktion** verwendet werden.
Neben dieser neuen Repräsentation erlernt das Netzwerk noch, wie es aus dieser Codierung wieder die Ursprungsdaten reproduzieren kann.

Autoencoder gehören nicht dem klassischen überwachtem Lernen an. Strenggenommen gehören sie dem unüberwachtem Lernen an, da in den Trainingsdaten keine Labels enthalten sein müssen. Jedoch ist diese Begrifflichkeit etwas irreführend, weil nur deshalb keine Labels benötigt werden, da die Labels gleich den Features sind! Somit wird das Netzwerk trotzdem darauf trainiert gewisse gewünschte Outputs zu liefern.
(Saalmann, *Einführung in Autoencoder und Convolutional Neural Networks*)

4.1 Topologie

Ein Autoencoder besteht wie das klassische KNN auch aus Neuronen. Wie bereits erwähnt sind die "Labels" eines Autoencoders gleich den Features. Somit versucht ein Autoencoder einfach die Werte der Inputneuronen möglichst exakt in die Outputneuronen zu kopieren. Diese Operation wäre an sich ziemlich bedeutungslos und nutzlos, da mit den Daten nichts passiert. Das Netzwerk würde einfach erlernen eine Identitätsfunktion zu imitieren. Aus diesem Grund muss man gewisse Einschränkungen einführen. Diese bringen das Netzwerk dazu, interessante Methoden zu entwickeln um die Features *approximativ* zu rekonstruieren.

Die angesprochene Einschränkung besteht darin, dass dem Autoencoder nicht beliebig viel Kapatzität für die Codierung der Features gegeben wird. Es stehen dem Netzwerk nur wenige Zahlenwerte zur Verfügung um die Features in der neuen Repräsentation zwischenzuspeichern, bevor sie wieder in die ursprünliche Form gebracht werden. Diese Kapazitätseinschräkung wird durch die Topologie des Autoencoders bezweckt.

Der einfachste Autoencoder, besteht aus drei Schichten, welche sich wie folgt eingliedern lassen:

- eine Inputschicht mit d Neuronen
- eine Zwischenschicht mit p Neuonen, bezeichnet als **Flaschenhals**
- eine Outputschicht mit d Neuronen

In Abbildung (4.1) ist ein beispielhafter Autoencoder abbgebildet, mit $d = 5$ Features und einem Flaschenhals der Grösse $p = 2$.

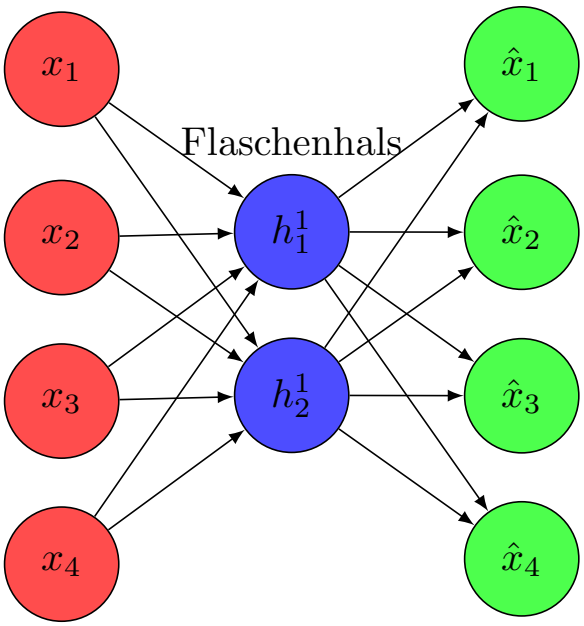

Abbildung 4.1: Schichten eines kurzen Autoencoders

Die Inputschicht enthält die Features $\boldsymbol{x} \in \mathbb{R}^d$. Die Outputschicht dagegen enthält die **Rekonstruktionen** der Features, welche wir mit $\hat{\boldsymbol{x}} \in \mathbb{R}^d$ bezeichnen. Als logische Konseqünz müssen die beiden Schichten die gleiche Anzahl d an Neuronen besitzen. Die Flaschenhalsschicht hingegen besitzt nur p Neuronen, wobei $p \ll d$. Somit ist die sie deutlich kleiner als die anderen beiden Schichten und bildet so die Kapazitätseinschränkung.

Wir haben nun einen Autoencoder nur mit einer Zwischenschicht betrachtet. Gängier ist es jedoch das Netz aus mehreren Zwischenschichten zu bauen. Dabei werden die Schichten zum Flaschenhals hin immer schmaler und die Schichten nach dem Flaschenhals wieder immer dicker. In Abbildung (4.2) ist dies gut ersichtlich. Wir werden nun aber weiterhin mit dem Autoencoder, welcher nur eine Zwischtenschicht besitzt, die Funktionsweise herleiten.

4.2 Funktionsweise

Ein Autoencoder möchte die Features $\boldsymbol{x}$ von der Inputschicht in die Outputschicht kopieren. Jedoch zwingt der Flaschenhals den Autoencoder dazu eine neue Repräsenation der Features zu erlernen. Dies hat den Grund, dass die Features in ihrer jetzigen Form keinen Platz im Flaschenhals finden, da $p \ll d$. Somit muss das Modell die Informationen, welche in den Features stecken nur auf einige wenige Eigenschaften komprimieren. Es muss gewissermassen einen Code entwickeln. Diese neue Repräsentation nennt man das **Encoding**.
In einem zweiten Schritt muss der Autoencoder aus diesem Encoding wieder versuchen die ursprünlichen Features zu rekonstruieren. Diese Rekonstuktion bezeichnet man als das **Decoding**.

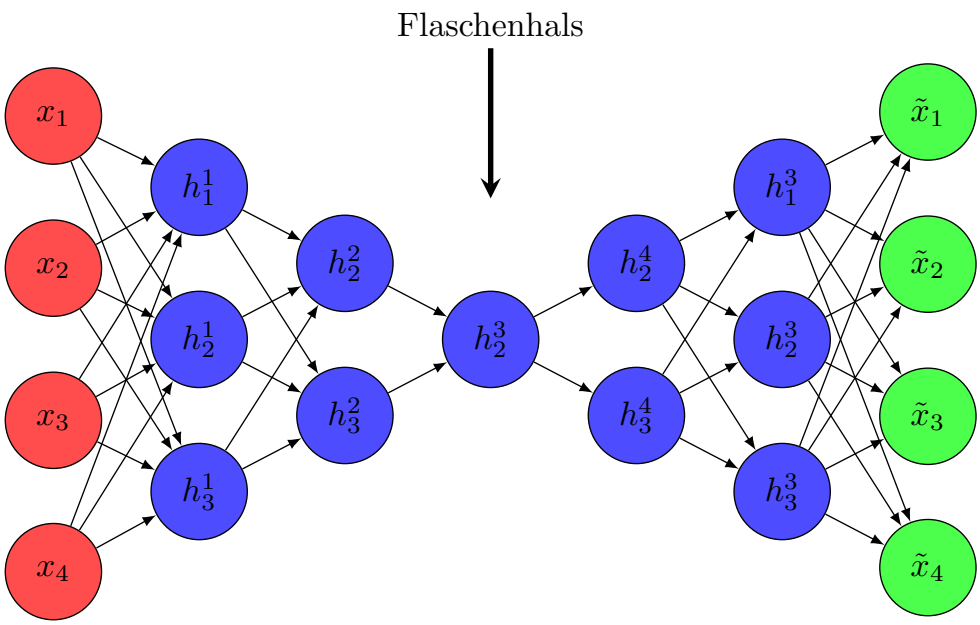

Abbildung 4.2: Schichten eines tieferen Autoencoders

Encoder und Decoder

Man kann einen Autoencoder gewissermassen als zwei Teilmodelle betrachten. Das einte Modell erzeugt das Encoding und das andere das Decoding. Wir spalten dafür die Hypothesenfunktion h in ein Funktionenpaar (ϕ, ψ) auf.

- $\phi : \mathcal{X} \to \mathcal{E}$ Encoder-Funktion
- $\psi : \mathcal{E} \to \mathcal{X}$ Decoder-Funktion

Die erste Teilfunktion ϕ ist dafür zuständig das Encoding zu erzeugen. Sie bildet den Inputraum $\mathcal{X} \subseteq \mathbb{R}^d$, welcher die Features $\boldsymbol{x}$ enthält, auf den Encodingraum $\mathcal{E} \subseteq \mathbb{R}^p$, welcher die neuen Repräsenation $\boldsymbol{x}^*$ enthält, ab.
Das Gegenstück ist die Teilfunktion ψ. Sie bildet den Encodingraum $\mathcal{E}$ zurück auf den Inputraum $\mathcal{X}$ ab.

Der Output des Autoencoders $\hat{\boldsymbol{x}}$ wird somit durch die aufeinander folgende Anwendung der Teilfunktion auf die Features $\boldsymbol{x}$ gebildet:

$$\hat{\boldsymbol{x}} = \psi(\phi(\boldsymbol{x})) = (\psi \circ \phi)(\boldsymbol{x}) \tag{4.1}$$

Wenn wir dieses Modell trainieren, minimieren wir die Kostenfunktion. Als Beispiel können wir den Mittleren-quadratischen-Fehler C_{MSE} nehmen. Verwenden wir ihn als Kostenfunktion, minimieren wir folgenden Ausdruck:

$$\min_{\phi,\psi} \|\boldsymbol{x} - \hat{\boldsymbol{x}}\|^2 = \min_{\phi,\psi} \|\boldsymbol{x} - (\psi \circ \phi)(\boldsymbol{x})\|^2 \tag{4.2}$$

Anderst ausgedrückt versuchen wir Funktion ϕ und ψ zu finden, welche die Differenz der ursprünglichen Features $\boldsymbol{x}$ und den Rekonstruktionen $\hat{\boldsymbol{x}}$ minimieren. Dabei muss der Autoencoder Dimensionalitätsreduktion betreiben. Er entwickelt einen Code um die Features in der Flaschenhalsschicht komprimiert zu repräsentieren. Durch die Kapazitätseinschräkung $p \ll d$ muss $\mathcal{E}$ eine niedrig-dimensionale Codierung der Features darstellen. Dem Modell ist es nicht möglich die Inputs identisch wiederherzustellen, da bei der Abbildung ϕ Informationen verloren gegangen sind. Dadurch sollte der Code im Optimalen Fall nur noch die Merkmale der Features umfassen, welche für die grösste Information codieren. Dieser Code kann extrahiert werden, um eine Repräsentation der Features zu erhalten, welche nicht mehr mehrere Hundert Merkmale umfasst sonder nur noch ein paar wenige. Jedliche natürliche Schwankungen in den Werten der Features gehen verloren, da sie nicht im COde enthalten sind. Sie können nicht verallgemeinert werden.

Der Code

Bei der Suche dieser Funktionen muss der Autoencoder einen gewissen "Code" entwickeln, um die Features neu zu repräsentieren. Dies da der Falschenhals nicht den nötigen Kapazität bietet, um die Features in der ursprünlichen Form zu halten. Somit muss der Autoencoder Dimensionalitätsreduktion betreiben, um die Features komprimiert darzustellen.

Durch diese Komprimierung ist es dem Modell unmöglich die Rekonstruktionen perfekt zu machen. Sie sind immer approximativ, da bei der Komprimierung Informationen verloren gegangen sind. Am effektivsten wird die Kostenfunktion minimiert, wenn das Modell einen Code entwickelt, welcher die Features mit dem höchsten Informationsgehalt abstrahiert. Die Features, welche unwichtig sind oder nur durch züfalliges Rauschen der Daten entsteht können verworfen werden, da sie nicht verallgemeinert werden können.

Es ist wichtig zu erkennen, das der Code welcher der Autoencoder entwickelt **datenspezifisch** ist. Das heisst er kann nicht wie z.B ein Bildkompressionalgorithmus auf beliebige Daten angewendet werden. Stattdessen ist er nur sinnvoll für die Kompression von Daten, mit welchen er trainiert wurde. Der Autoencoder erlernt die Eigenschaften eines Datensatz zu abstrahieren und neu darzustellen. BEISPIEL EINER ABSTRAKTION (a la Menschliches Gesicht beschreiben).

4.3 Anwendungen

Die Eigenschaft, welche einen Autoencoder sich für die verschiedensten Anwendungen geeignet macht, ist die Dimensionalitätsreduktion.
Wir werden nun einige Anwendungen grob betrachten.

4.3.1 Kompression

Es handlet sich um Verlustbehaftete Kompression. Dimensionalitätsreduktion. Falls lineare Neuronen, ähnlich zur Hauptkomponentenanalyse $\frac{p}{d}$ des ursprünglichen Speicherbedarfs. Diese Komprimierung ist dabei Datenspezifisch.
Datenverkehr beschleunigen, weil weniger Daten.

4.3.2 Neue Datenrepräsentation

neues Datenformat

4.3.3 Visualisierung von Daten

Visualisierung von hochdimensionaler Daten in $\mathbb{R}^2$ und $\mathbb{R}^3$
Im übernachsten Kapitel werden wir eine Anwendung noch genaür Betrachten die des Denoisers.

4.4 Convolutional-Autoencoder

Ein Convolutional-Autoencoder ist wie der Name es schon sagt, ein Autoencoder, welcher anstatt die normalen Fully-connected-Schichten eines KNNs die Schichten eines CNN verwendet.
Er ist interessant, weil er zur Kompession von Bildern verwendet werden kann. Wie bereits erwähnt ist auch hier die Kompression datenspezifisch. Beispielsweise könnte man einen Convolutional-Autoencoder mit einem Datensatz von menschlichen Gesichtern trainieren. Dieser würde dann einen datenspezifischen Code für diese Gesichter entwickeln. Mann kann sich vorstellen, dass das Modell nicht mehr die Farbwerte der Features im Encoding speichert, sondern stattdessen diese Features abstrahiert. Somit könnten Eigenschaften, wie die Augenfarbe, Breite der Nase, Mundposition und vieles mehr im Flaschenhals gespeichert werden. Diese Informationen brauchen offenkundig weniger Kapazität als alle Pixelwerte.

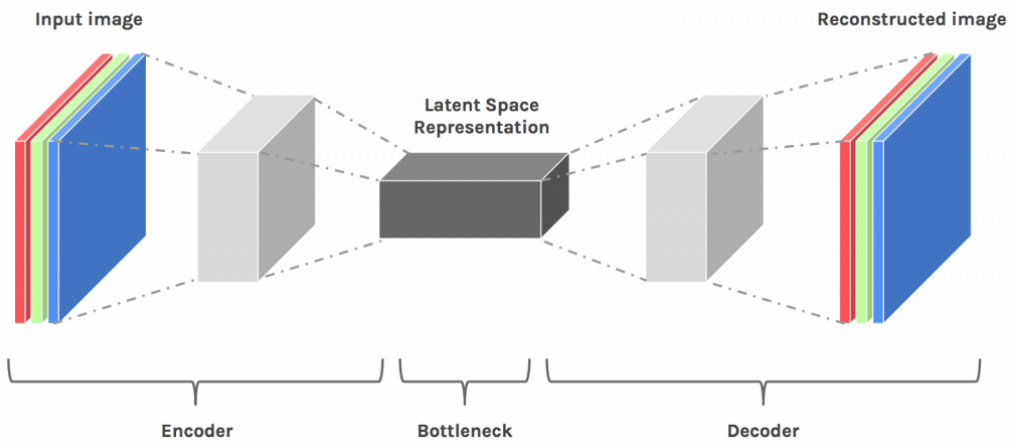

Abbildung 4.3: Darstellung eines Convolutional Autoencoders

Des weiteren sind Convolutional-Autoencoder interessant, da sie uns auf eine weitere Anwendung eines Autoencoders bringen: den Denoising-Autoencoder. Diesen betrachten wir im nächsten Abschnitt. (CodeParade, *Computer Generates Human Faces*)

4.5 Denoising-Autoencoder

Ein Denoising-Autoencoder oder einfach Denoiser ist ein leicht abgeänderter Autoencoder. Er wird verwendet um ein Rauschen aus Bildern zu entfernen.

Er unterscheidet sich insofern von dem klassischen Autoencodern, dass er richtige Labels hat und nicht einfach die Features kopiert. Sein Input stellen die verrauschten Bilder dar und die Labels sind die unverrauschten Bilder. Somit wird er darauf trainiert das Rauschen zu entfernen.
Man mag sich nun die Frage stellen, weshalb man hierfür einene Autoencoder und kein normales CNN verwendet. Empirisch hat sich einfach gezeigt, dass sich Denoiser dafür besser eignen. Das hat nachvollziehbare Gründe. Bei der Entwicklung des Code für Encoding-Repräsentation, kann das Rauschen nicht codiert werden, da es völlig zufällig ist. Es existieren keine Muster oder Gesetzmässigkeiten, welche anderst codiert werden könnten. Somit muss der Autoencoder diese Rausch-Features verwerfen. Somit hat er leichteres Spiel gegenüber sonstigen CNNs.

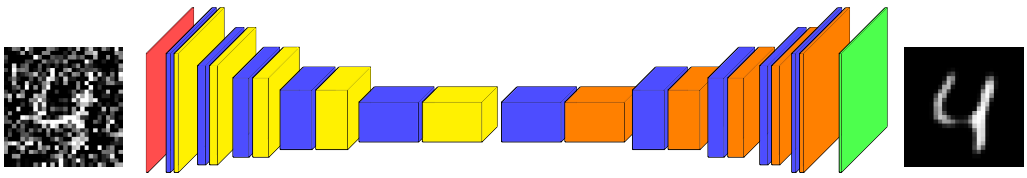

Abbildung 4.4: Visualisierung eines Convolutional-Denoising-Autoencoder

Corrupted Input

4.5.1 Generierung der verrauschten Bilder

Um den Autoencoder zu trainieren, muss man die verrauschten Daten generieren. Dies macht man indem man auf die Features ein additives Gauss'sches Rauschen anwendet. Man verwendet dafür einfach eine Gauss'sche Normalverteilung $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ mit Erwartungswert $\mu = 0$ und Varianz $\sigma^2 = 1$. Man entnimmt dieser dann einfach jeweils einen Zufallswert und addiert ihn zu jedem Feature. Somit

erhält man einen Datensatz, welcher aus verrauschten Daten besteht.

$$r \sim \mathcal{N}(\mu = 0, \sigma^2 = 1)$$
$$\tilde{x} = x + r$$

Kapitel 5

Frameworks für Maschinelles Lernen

In diesem Kapitel werden wir zwei Frameworks betrachten, welche eine Implementation der ML-Algorithemen realisiert haben. Wir werden sie in ihrer groben Funktionsweise untersuchen. Diese Tools werden wir im nächsten Kapitel benutzten um dann ein konkretes Modell zu programmieren.

5.1 TensorFlow

Abbildung 5.1: TF-Logo

TensorFlow, kurz TF, ist ein von Google entwickeltes **Framework** für **datenstromorientierte Programmierung**. Es ist im Grunde genommen eine Mathematik-Programmbibliothek für numerische Berechnungen, dessen Hauptanwendungsbereich im Maschinellen Lernen liegt. Die Vorteile von TF bestehen vorallem darin, dass die praktische Anwendung des Frameworks sehr einfach ist und fast keine mathematische Vorkenntnisse voraussetzt. Somit kann man sehr einfach ein ML-Modell definieren, trainieren und verwenden. Ausserdem besitzt TF sehr performante Implementierungen, welche Algorithmen, wie die Vorwärtspropagierung und die Rückwärtspropagierung, sehr schnell ausführen lässt. Somit geht das Training von ML-Modellen deutlich schneller als bei selbstgeschriebenen Implementationen. TF ist gratis und ein Open-Source-Projekt. Es kann auf Github gefunden werden (siehe QR-Code).

In der Industrie ist TensorFlow sehr weit verbreitet. Es wird von den verschiedensten Unternehmen für ihre ML-Anwendungen gebraucht; darunter waren: Google, Twitter, AirBnB, Intel, CocaCola, Snapchat und noch viele mehr.

Grundsätzlich wurde TF für Maschinelles Lernen entwickelt. Speziell eignet es sich für Deep Learning mit künstlichen neuronalen Netzen. Es ist ein Interface, welches das definieren von Modellen erlaubt, welche dann mit den eingebauten ML-Algorithmen trainiert werden können.
Trotz dieser eigentlichen Grundidee von TF, sollten die Abstraktionen eigentlich für beliebige Anwendugen, welche mit numerischen Berechnungen zu tun haben, sich eignen.

Im folgenden werden die grobe Funktionsweise von Tensorflow untersuchen. Um genau zu sein betrachten wir Tensorflow-Core Version r1.14. [1] Wir werden TF nur sehr grob betrachten, da wir später nicht direkt damit arbeiten werden, sondern mit der High-Level-API Keras. Trotzdem ist er hilfreich ein grobes Verständniss über TF zu besitzen.

Die wichtige Resource um TensorFlow zu lernen ist wohl die offizielle TensorFlow Website. Dort findet man auch die Dokumentation.

[1] Momentan befindet sich TF 2.0 in der Beta. Es ist eine grosse Überarbeitung des Frameworks. Es ist zu empfehlen, sobald TF 2.0 offiziel veröffentlich wurde, es zu verwenden.

(Many, *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*)

5.1.1 Client und Master

Wie die meisten grossen Programmbibliotheken ist Tensorflow in Backend und Fontend aufgeteilt. Das Frontend von Tensorflow bezeichnet man als **Client** und das Backend als **Master**.

Fontend und Backend

Das **Frontend** ist der Teil eines Programmes, mit welchem der Benutzer interagiert. Es stellt eine Schnittstelle zu dem sogennanten Backend eines Programmes dar. Es exponiert so gewisse Funktionalitäten des Programmes dem Benuzter gegenüber, ohne dass er dabei etwas von der zugrundeliegenden Logik mitbekommt.

Das **Backend** ist das Gegenstück zum Frontend. Es implementiert jedigliche Programmlogik, welche das gewünschte Verhalten der Applikation hervorruft. Der Benutzer hat keinen direkten Zugriff auf diesen Teil des Programmes und bekommt somit nichts von dessen Existenz mit.

Der Client - also das Frontend - von TF ist in **Python** geschrieben. [2] Python ist allgemein als eine sehr einsteigerfreundliche Programmiersprache bekannt. Sie ermöglicht es dem Benutzer mit wenigen Zeilen Code und ziemlich intuitiv TensorFlow zu verwenden. Wenn wir also mit TensorFlow programmieren, werden wir mit Python-Code arbeiten.

Der Master - also das Backend - von TF ist dagegen in **C++** (und CUDA) geschrieben. Dies hat den Grund, dass C++ im Gegensatz zu Python sehr performant ist. Also ist die Zeit zum Aufführen eines Programmes sehr kurz. Dafür ist der Programmcode deutlich anspruchsvoller und verboser. Da der Benutzer jedoch keine direkte Interaktion mit dem Master hat, bekommt er davon nichts mit.

5.1.2 Verwendung — der Client

Nun möchten wir betrachten wie man TensorFlow zu verwenden hat, damit wir später ein ML-Modell damit basteln können. Dafür werden gewisse Python-Kenntnisse vorausgesetzt. Wir betrachten nun also den Client von TF. Man verwendet verschiedene Konzepte um programmatisch mit TF zu arbeiten. Im folgenden Abschnitt werden wir diese Konzepte behandeln.

5.1.2.1 Graph

TensorFlow ist datenstromorientiert. Das bedeutet, dass man eine Berechnung (engl.: computation) durch einen gerichteten Graphen beschreibt. Zürst stellt man diesen Graph auf und fügt ihn zusammen und erst nach der Definition führt man ihn aus. Es handelt es sich dabei um einen **Computation Graph**, wie wir ihn schon in Sektion (2.6) kennengelernt haben. In TensorFlow bezeichnet man diesen Graphen als einen `tf.Graph`.

Er besteht aus einer Menge an Knoten, welche miteinander über Pfade verbunden sind. Die Knoten halten Werte in sich, welche über die Pfade, verrechnet werden und in den nächsten Knoten eingespeist werden. Die Pfade sind also die Operationen, welche auf die Werte angewandt werden. So führt der Graph eine Datenstrom-Berechnung aus. Jeder Knoten hat null oder mehr Inputs und null oder mehr Outputs.

[2] Tensorflow besitzte mehrere Frontends, welche in den verschiedensten Programmiersprachen geschrieben sind. Wir werden jedoch nur das Python-Frontend betrachten, da es am besten von TF unterstützt ist.

Man muss einen Graph nicht explizit definieren (kann es aber, falls man mehrere Graphen braucht), da beim defnieren der Operationen sie implizit dem sogennanten **Default Graph** hinzugefügt werden.

5.1.2.2 Tensoren

Die zentrale Dateneinheit in TensorFlow sind Tensoren, wie wir sie bereits in Sektion (3.1) kennengelernt haben. Auch die Knoten des Graphs reprasentieren Tensoren, welche aber keine feste Wert enthalten, da sie erst beim Ausführen des Graphens, mit Werten befüllt werden. Nach der Ausführung der Graphs, kann man die Zahlenwerte auslesen.

Man verwenet in TF deshalb Tensoren, weil so die Daten beliebige Dimensionalitäten und Formen annehmen können. Es können sowohl Listen von Zahlen (Vektoren), wie auch Bilder (Tensoren dritter Ordnung) verrechnet werden.
Nun sollte auch klar sein, weshalb wir bei der Herleitung der Gleichungen, auch immer eine Matrixschreibweise erarbeitet haben.

In Tensorflow bezeichnet man einen Tensor mit `tf.Tensor`. Er ist definiert durch seine Form (Stufe inbegriefen) und den Datentyp seiner Elemente (z.B. tf.float32).

Jeder tf.Tensor ist mit einer einzigen Graph-Ausführung assoziert. Sie besitzen ihren Wert nur für den jeweiligen Durchlauf, danach wird er verworfen. Man sagt die Tensoren sind "immutable", da die Werte nicht erhalten bleiben und so nicht modifiziert werden können.

Die söben beschriebene Tensoren agieren einfach als Durchflussstellen innerhalb des Graphen. Sie müssen nicht explizit definiert werden, da sie automatisch eingefügt werden, wenn der Graph durch seine Operationen definiert wird.

Neben dieser Art von Knoten, gibt es noch verschiedene Inputknoten. stellen den Input in den Graphen dar und müssen explizit definiert werden. Von ihnen gibt es verschiedene Arten, welche wir nun betrachten werden.

tf.constant

Der `tf.Constant` Tensor ist ein Input-Knoten in den Graphen. Er hat immer einen konstanten Wert als Output. Dieser wird beim Erstellen angegeben.

```
<Varname> = tf.constant(<Wert>)
```

Folgender Python-Code ist ein Beispiel, welcher drei konstante Tensoren mit unterschiedenlichen Formen erstellt. Als Argument, gibt man die Elemente des Tensors, worüber auch die Form ersichtlich an.

```
skalar = tf.constant(1.0)
vector2 = tf.constant([1.0, 2.0])
matrix2x2 = tf.constant([[1.0, 2.0], [3.0, 4.0]])
```

$$\text{skalar} = 1 \quad \text{vector2} = \begin{pmatrix} 1 & 2 \end{pmatrix} \quad \text{matrix2x2} = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}$$

tf.placeholder

Um den Graphen für Maschinelles Lernen zu verwenden, braucht man eine Möglichkeit ihn mit Inputs für die Modelle zu befüttern. Um dies möglichst komfortabel zu machen, gibt es den sogennanten `tf.Placeholder` Tensor. Wie der Name es schon sagt, ist er ein Platzhalter für die Inputs, welcher beim Start der Graphausführnug eingespeist werden. Man muss einzig seine Dimensionen und seinen Datentyp (z.B. tf.float32) bei der Erstellung angeben.

```
<Varname> = tf.placeholder(dtype=<Datentyp>, shape=<Form>)
```

Für den Datentyp wählt man eigentlich immer `dtype=tf.float32`. Somit kann man mit Gleitkommazahlen rechnen. Die Form gibt man einfach als n-Tupel von Integern an, welche die Anzahl Komponenten in der jeweiligen Dimension angeben. Somit bedeutet die Form `shape=(4,2,3)` einen Tensor im Tensorraum $\mathbb{R}^{4\times2\times3}$.

tf.variable

Ein weiteres Kriterium um Maschinelles Lernen mit dem tf.Graph durchzuführen, ist dass man Modellparameter einführen kann. Dafür ist der `tf.Variable` Tensor geeignet. Er ist im Gegensatz zu den anderen Tensoren "mutable". Das bedeutet, dass seine Werte unabhängig von einer einzigen Graphenausführung existieren und erhalten bleiben. Seine Elementen können modifiziert werden. Somit sind sie geeignet, für Modellparameter. Die Werte bleiben grundsätzlich jede Ausführung erhalten und können beim Trainingsdurchlauf angepasst werden.

Folgender Python-Code kreirt eine tf.Varaible mit einem Anfangswert und ändert ihren Wert danach.

```
<Varname> = tf.Variable(<Initialwert>, name=<optionaler Name>)
<Varname>.assign(<neuer Wert>)
```

Bei der neuen Wertebesetzung kann auch der alte Wert des Tensors referenziert werden, um den Wert zum Beispiel zu erhöhen: `var.assign(var + 2.0)`.

5.1.2.3 Operationen

Die Knoten des tf.Graph - also die Tensoren - werden über die Pfade aufeinander abbgebildet. Die Operationen, welche sie aufeinander abbildet, bezeichnet man als `tf.Operation`. Eine tf.Operation besitzt jeweils einen Namen und repräsentiert eine abstrakte Berechnung. Sie hat jeweils null oder mehr Tensor-Objekte als Input, wie auch als Output.

Man definiert meistens keine neuen Operationen, sondern verwendet einfach die vordefinierten. Ein Beispiel dafür wäre die `tf.matmul(a,b)`, welche eine Matrixmultiplikation zwischen `a` und `b` ausführt. Im folgenden Code wird das Resulat im neuen Tensor `c` gespeichert. "MatMul" bezeichnet).

```
c = tf.matmul(a, b)
```

Mit diesem Konzept können wir nun endlich den eigentlichen Graph definieren. Dafür muss man lediglich ein paar Inputtensoren erstellen, und diese mithilfe von Operationen verrechnen. Natürlich kann man die Resulate der Operationen dann weiter verrechnen, bis man den gewünschten Grapen hat.

Hier ein Beispiel eines solchen Graphs.

```
# Inputknoten
a = tf.constant([[1.0, 2.0], [3.0, 4.0]])
b = tf.constant([[1.0, 1.0], [0.0, 1.0]])
# Operationen
c = tf.matmul(a, b)
d = tf.placeholder(dtype=tf.float32, shape(2,2))
e = tf.add(c, e)
```

Abbildung 5.2: Visualisierung des beschriebenen `tf.graph`

5.1.2.4 Session

Der Client kommuniziert mit dem Master über eine sogennante `tf.Session`. Sie ist die Schnittstelle zwischen Frontend und Backend und ermöglicht es einen tf.Graph zu erstellen und ihn auszuführen. Um die Session zu erstellen verwendet man die Funktion `tf.Session()`.

```
sess = tf.Session()
```

Es ist Best-Practise eine Session, wie eine Datei über das `with`-Statment zu öffen und zu schliessen.

```
with tf.Session() as sess:
# Code
```

Um den Graphen nun zu berechnen, muss man lediglich die Session ausführen, das geschieht über die Methode `tf.Session.run()`. Diese Funktion erwartet als Argument einerseits den Knotenpunkt, welchen man berchnen möchte. Dessen Wert ist der Rückgabewert der Funktion. Andererseits erwartet die Funktion noch einen Python-Dictionary, den sogennanten `feed_dict`, welcher die `tf.placeholder` mit ihren Werten befüllt.

```
result = sess.run(<Knotenpunkt>, feed_dict=<Placeholder-Dictionary>)
```

Es folgt nun ein Codebeispiel, welches die Forwärtspropagierung eines Sigmoide Neurons mit drei Inputs implementiert. Es wird es mit den Inputs $x = \begin{pmatrix} 1 & 2 & 3 \end{pmatrix}^{\mathsf{T}}$ ausgeführt.

```
import tensorflow as tf

# Inputs
x = tf.placeholder(dtype=tf.float32, shape=(3))

# Modellparameter
w = tf.Variable(tf.random_uniform([3], -1, 1), name='weight')
b = tf.Variable(tf.random_uniform(1, -1, 1), name='bias')

# Forwärtspropagierung
z = tf.add(tf.tensordot(x, w, 1), b)
a = tf.sigmoid(z)
y = a

with tf.Session() as sess:
res = sess.run(y, feed_dict = {x: [1, 2, 3]})
print(res)
```

5.1.2.5 Optimizer

Um ein ML-Modell in TF zu implementieren, muss man das ganze Modell mit allen Operationen als Graphen definieren. Dies hört sich im Moment noch sehr aufwendig an, ist es jedoch nicht. Wir werden nämlich die High-Level-API Keras zur Hilfe ziehen, bei der Graphen erstellt. Keras stellt Implementationen von verschiedenen KNN-Schichten zu verfügen, damit man sie nicht mehr selber

erstellen muss. Diese kann man dann einfach zu einem Graphen zusammenfügen. Aber dazu später mehr.

Die Ausführung des erstellen Graphen stellt dann einfach eine Vorwärtspropagierung dar. Bevor jedoch das Modell brachbare Resualte liert, muss man es trainieren. Dafür verwendet man einen `tf.train.Optimizer`.

Der erste Schritt ist dafür eine Kostenfunktion zu definieren. Es sthene dabei Verschiedne aus `tf.losses` zur Verfügung. Als Argument nimmt die Kostenfunktion die Label-Tensoren `labels` und die Vorhersagen-Tensoren `predictions`. Beispielsweise könnte man den Mittleren Quadratischen Fehler wählen:

```
cost = tf.losses.mean_squared_error(labels=y_hat, predictions=y)
```

Nun erstellt man den Optimizer. Dabei stehen wieder mehrere zur Auswahl. Der `tf.train.GraidentDescentOptimi` ist eine Implementation des Gradientenverfahren. Er nimmt als Arugment die Lernrate η.

```
optimizer = tf.train.GradientDescentOptimizer(learning_rate=<>)
```

Nun kann man den Optimizer damit beauftragen die Kostenfunktion `loss` zu minimieren. Ausserdem muss man dem Optimizer eine List von `tf.Variable`s geben, welche die zu optimierenden Modell-parameter sind. Man erhält so man eine Optimierungs-Operation, welche man dann ausführen kann.

```
opt_op = opt.minimize(cost, var_list=<Hyperparameter-Liste>)
opt_op.run()
```

Nun folgt ein kleines Beispielmodell, welches trainiert wird.

```
import tensorflow as tf

# Inputs
x = tf.placeholder(dtype=tf.float32, shape=(3))

# Modellparameter
w = tf.Variable(tf.random_uniform([3], -1, 1), name='weight')
b = tf.Variable(tf.random_uniform(1, -1, 1), name='bias')

# Forwärtspropagierung
z = tf.add(tf.tensordot(x, w, 1), b)
a = tf.sigmoid(z)
y = a

cost = tf.losses.mean_squared_error(labels=y_trü, predictions=y_pred)


with tf.Session() as sess:
print(sess.run(cost)) # cost is just another node
optimizer = tf.train.GradientDescentOptimizer(0.01)
train = optimizer.minimize()
res = sess.run(y, feed_dict = {x: [1, 2, 3]})
print(res)

# Daten
x = tf.constant([[1], [2], [3], [4]], dtype=tf.float32)
```

```
y_trü = tf.constant([[0], [-1], [-2], [-3]], dtype=tf.float32)

# Modell
linear_model = tf.layers.Dense(units=1)
y_pred = linear_model(x)

# Evalutaion
sess = tf.Session()
init = tf.global_variables_initializer()
sess.run(init)

print(sess.run(y_pred))

# Loss
loss = tf.losses.mean_squared_error(labels=y_trü, predictions=y_pred)

print(sess.run(loss))


# Training
optimizer = tf.train.GradientDescentOptimizer(0.01)
train = optimizer.minimize(loss)


for i in range(100):
_, loss_valü = sess.run((train, loss))
print(loss_valü)
```

5.1.3 Implementation — der Master

TF ist gerade deshalb sehr attraktiv für ML, da es sehr performant (schnell ausführbar) ist und dadurch die Trainingszeit für die Modelle relativ kurz haltet. Dies wurde durch verschieden Designentscheidungen von TF erreicht.

In diesem Abschnitt werden wir grob die zugrundeliegende Implementation von TensorFlow betrachten - also den Master - und dabei herausfinden weshalb TF so performant ist. Ausserdem werden wir herausfinden, wie TF ableiten kann.

5.1.3.1 Devices

Die Kernstücke des Masters sind die verschiedenen **Devices**, auf welchen die Berechnungen ausgeführt werden. Ein Device ist jedliche Art von Computerprozessor, auf welchem die Graphen ausführt werden können. Zu diesen Prozessoren gehören die CPU (Hauptprozessor) und die GPU (Grafikprozessor). [3]

Der Master analysiert die verfügbaren Devices und bewertete sie, bezüglich ihren Fähigkeiten. Anhand dieser Bewertung entscheidet der Master dann, auf welchem Device die Berechnugen ausgefürt werden. [4] Insofern GPUs zur Verfügung stehen, wählt TF grundsätzlich immer diese, da sie Tensoroperationen deutlich schneller als CPUs verarbeiten können.

[3] Die normale TensorFlow Version ist nicht in der Lage die GPU zu verwenden. Um sie verfügbar zu machen, muss man die GPU Version installieren. Wir werden im folgenden von der GPU-Version ausgehen, da sie erhebliche Performance Vorteile gewährt.

[4] Es ist möglich die Graphen auf mehreren Devices gleichzeitig auszuführen und so noch schneller die Modelle zu trainieren. Dies ist jedoch erst für sehr aufwendige Projekte nötig und erfordert ein fortgeschritteneres Versteantniss.

5.1.3.2 Performance und Hardwarebeschleunigung

Nun möchten wir die Gründe für die beachtliche Performance von TF erschliessen. Der erste wichtiger Faktor dabei ist, dass der Master hauptsächlich in C++ geschrieben ist. C++ ist eine Programmiersprache die sehr nahe am Maschinen-Code (engl.: low-level) ist. Somit ist der Code sehr hardwarenah und kann so schneller ausgeführt werden. Der Nachteil besteht dafür darin, dass die Programmiersprache ziemlich verbos ist. Das bedeutet man braucht viel Code um eine relativ einfach Idee auszudrücken. Deshalb wurde der Client von TF in Python geschrieben, was Abhilfe verschafft und so ein relativ einfaches und unverboses Entwickeln ermöglicht.

Der andere wichtige Aspekt für die Performance ist wohl die sogennante **Hardwarebeschleuniging** (engl. Hardware Acceleration), von welcher TF gebrauch macht.
Hardwarebeschleunigung bezeichnet eine Sammlung an Methoden, bei welchen man spezialisierte Hardware verwendet um rechenintensive Aufgaben schneller auszuführen. Die Architektur einer CPU ist zwar so ausgelegt, dass sie beliebige Aufgaben ausführen kann, jedoch meistens nicht besonders effizient. Deshalb wurden einerseits neue externe Hardwarebausteine, wie die GPU, welche sich für Grafikberechnungen besonders eignet, entwickelt. Andererseits wurde auch die interne Architektur der CPU so angepasst, dass sie auch spezielisierte Aufgaben besser meistert.

Der Grossteil der Hardwarebeschleunigung wird durch die **Parallelisierung** von Operationen erreicht. Dabei spaltet man eine rechenintensive Aufgabe in viele Teilaufgaben auf, welche gleichzeitig in gleicher Weise ausgeführt werden. Voraussetzung dafür ist, dass die Teilaufgaben unabhängig voneinander bearbeitet werden können.
Ein typisches Beispiel für die Paralleliserbarkeit von Operationen ist die Matrixmultiplikation. Möchte man eine Matrix $\boldsymbol{A} \in \mathbb{R}^{n \times m}$ mit einer zweiten Matrix $\boldsymbol{B} \in \mathbb{R}^{m \times p}$ multiplizieren, muss man praktisch m-mal die gleichen Schritte ausführen: Man berechnet jeweils das Skalarprodukt zwischen der i-ten Zeile von $\boldsymbol{A}$ und der i-ten Spalte von $\boldsymbol{B}$. Alle diese Skalarprodukte haben keinen Einfluss aufeindander und können so unabhänigig mit der gleichen Prozedur berchnet werden.

Allgemein eignen sich Tensoroperatiön für Parallelisierung und damit zur Hardwarebeschleunigung. Nun ist auch ersichtlich, weshalb TensorFlow als Hauptdatentyp Tensoren verwendet; damit es gebrauch von der Hardwarebeschleunigung machen kann. wir fast alle Gleichungen des Maschinellen

CPU-Beschleunigung

Die Hardwarebeschleunigung der CPU ist für TensorFlow nur von geringfügiger Relevanz, da TF sich vorallem für GPU-Hardwarebeschleunigung eignet und dafür optimiert ist. Ausserdem ist es praktisch unmöglich die gleiche Performance von TF mit einer CPU zu erreichen, welche mit einer GPU möglich ist.

Hauptsächlich parallelisiert TensorFlow mithilfe von der **SIMD**. SIMD ist ein Prinzip zur Parallelisierung einer Insturktion für mehrere Dateneinheiten und steht deshalb für "Single Instruction, Multiple Data". SIMD umfasst einerseits die spezifische CPU-Architektur und den dazugehörigen Befehlssatz, um die Operatiön zu parallelisieren. Es gibt verschiedene
SSE4.1, SSE4.2, AVX, AVX2, FMA

GPU-Beschleunigung durch cuDNN und CUDA

cuDNN ist die NVIDIA CUDA Deep Neural Network library. Sie ist eine GPU-beschleunigte Bibliothek für deep neural networks. Sie stellt implementation für standard routines wie Vorwärts- und Rückwärtspropagierung bereit.

CUDA

cuDNN

5.1.3.3 Automatische Gradientenberechnung

Als wir die Rückwärtsprogagierung hergeleitet haben, haben wir mithilfe von Computation Graphs die Kettenregel angewandt um die partiellen Ableitungen zu bilden. Genau das gleiche macht TF, jedoch automatisiert. Aus diesem Grund ist TF auch datenstromorient.

5.1.4 Tensorboard

TensorBoard ist ein externes Zusatzprogramm zu TensorFlow. Mit dessen Hilfe man Daten zum Modell-Graph und zu dem Trainingsprozess sammeln kann und diese dann Visualisieren kann.
Es ist möglich eine Visualisierung des Modell-Graphs zu betrachten. Desweiteren kann man Funktionsgraphen der Kostenfunktionentwicklung betrachten.

TensorBoard ist als WebServer geschrieben und kann über einen WebBrowser benutzt werden. Man muss TensorBoard als Backend/Callback in TensorFlow aktivieren, damit die nötigen Daten während der Graphausführung gesammelt werden.

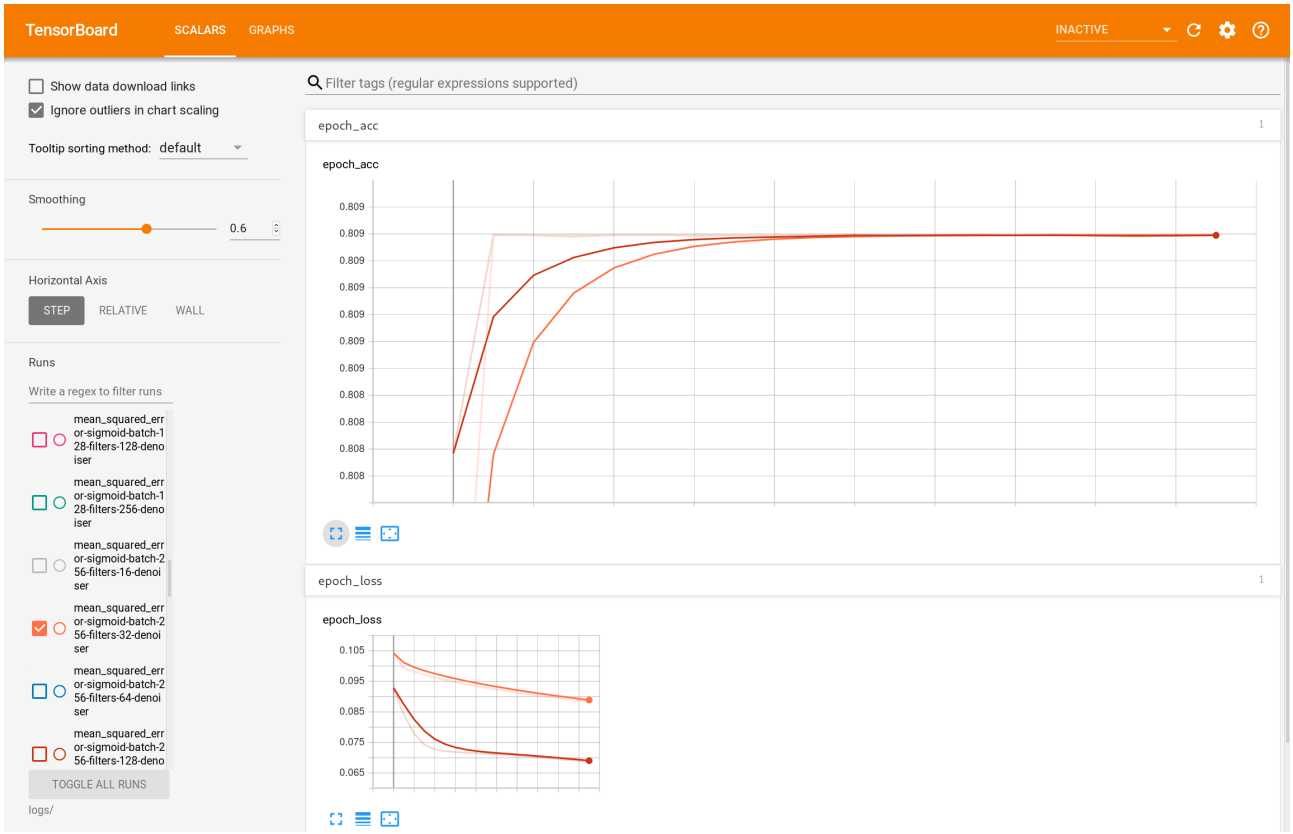

Abbildung 5.3: das TensorBoard-Webinterface

5.1.4.1 Hyperparameter einstellen

Der wichtigste Aspekt für uns von TensorBoard stellt die Tatsache dar, dass man die Trainingsfortschritte visualisieren kann. Man kann verschiedene Funktionsgraphen der Kostenfunktion betrachten. Es ist sogar möglich mehrere solcher Graphen miteinander zu vergleichen. Somit kann man ein Modell, bei welchem man mehrere Trainings mit jeweils verschiedene Hyperparameter gemacht hat, miteinander vergleichen. So ist es ziemlich einfach gute Hyperparameter herauszusuchen. Genau dieses Verfahren werden wir dann bei unserem eigenen Modell anwenden.
Der Graph ist interaktiv, was bedeutet, dass man mit ihm interagieren kann und so detailiertere Angaben erhalten kann. Zum Beispiel kann man so auch die beanspruchte Trainingszeit des Modells erfassen, welche meistens von Interesse ist.

In der untenstehenden Abbildung ist ein Graph von TensorBoard dargestellt, welcher die Entwicklung der Kostenfunktion für den Testdatensatz verschiedener Modell anzeigt. In diesem Beispiel hätte die orange Kurve ganz unten am besten Abgeschnitten. Dieses Modell hat die kleinsten Kosten verursacht.

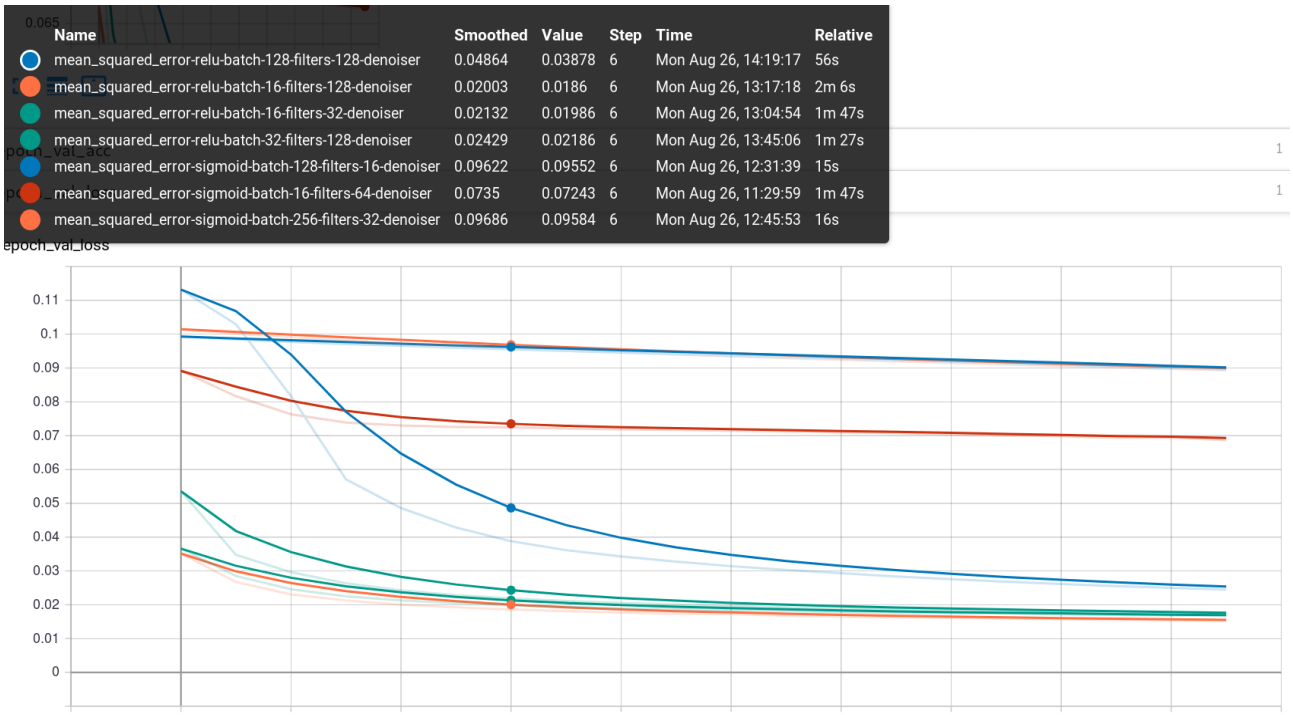

Abbildung 5.4: Trainingsvisualisierungen in TensorBoard

5.2 Keras

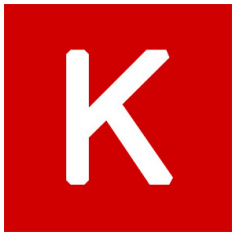

Abbildung 5.5: Keras-Logo

Keras ist ein Open-Source Deep-Learning Framework geschrieben in Python. Keras wurde entwickelt, um eine einheitliche Schnittstelle für verschieden Backends, wie TensorFlow, Microsoft Cognitive Toolkit und Theano zu bieten. Seit TF Version 1.4 ist Keras ein fester Bestandteil der TensorFlow-Core-API.
Keras ermöglicht ein sehr simples und benutzerfreundliches defnieren von Deep-Learning-Modeln welche dann sehr einfach trainiert werden können. Wir werden also anstatt TF direkt zu verwenden, über Keras das Modell definieren. Deshalb ist ein tiefgehendes Verstätniss von TF überflüssig.

5.2.1 Funktionsweise

Keras baut auf TensorFlow auf. Es verwendet die verschiedenene Konzepte von TF, wie Variabeln, Operationen und Graphen und abstrahiert sie. Dadurch bietet Keras eine einfacheres Vorgehen dem Benutzer an.

Die gängigste Vorgehensweise besteht darin, ein sogennantes **Sequential-Modell** zu bauen. Dies ist ein Modell, welches einfach ein linearer Stapel von verschiedenen Schichten ist. Keras stellt verschiedene Arten von KNN-Schichten bereits zur verfügung, welche einfach aneinander gereiht werden können und so einen Graph bilden.

Es gibt verschiedene Arten ein Modell zu definieren. Entweder definiert man eine `tf.keras.Seqüntial` Variabel, welcher dann mit der Methode `add()` neue Schichten hinzugefügt werden. Oder man speichert die verschiedenene Schichten in Variabeln und gibt dann die Anfangsschicht und die Schlussschicht bei der Erstellung des Modellvariabel an.

5.2.2 Schichten

Bei der Initalizsierung der Modellparameter, benutzt Keras standardmässig anderes Vorgehen als in der Theorie in Sektion 2.5.1 erklärt. Es benutzt nämlich eine Glorot-Initalisierung mit einer Uniformen Verteilung. Wir werden spezifizieren bei der Schicht-Erstellung, dass wir die in der Theorie erklärte Variante verwenden wollen.
Wir werden nun kurz die verschiedenen Schichttypen von Keras durchgehen, welche wir in der Theorie schon vorgestellt haben.

(Mehrere, *Keras Documentation - Initalizers*)

Input-Schicht

Die Input-Schicht ist ziemlich selbsterklärend. Sie ist einfach die Platzhalter-Schicht, welche alle Features enthält. Man definiert sie folgendermassen:

```
tf.keras.Input(shape=(<Form>)
```

Dense-Schicht

Wir beginnen mit dem Fully-Connected-Schicht. Diese wird in Keras als `Dense` bezeichnet. Der Name kommt davon, dass sie dicht mit jedem Neuron der vorherigen Schicht verbunden ist.

```
tf.keras.layers.Dense(<Anzahl Neuronen>,
activation=<Aktivierungsfunktion>)(<vorherige Schicht>, kernel_initalizer='glorot_normal')
```

Conv2D-Schicht

```
tf.keras.layers.Conv2D(filters=<#Filters>, kernel_size=<Filtergrösse>,
strides=<>, padding=<>, activation=<>, )
```

Für alle Schichten eines CNNs gilt folgendes Datenformat: Input muss folgende Form haben $(samples, channels, rou$
Output hat analoge Form $(samples, filters, new_rows, new_cols)$

MaxPool2D-Schicht

```
tf.keras.layers.MaxPool2D(pool_size=<Feldgrösse>, strides=<>, padding=<>)
```

UpSampling2D-Schicht

```
tf.keras.layers.UpSampling2D(size=<>, interpolation=<>)
```

```
model = tf.keras.Seqüntial()
# Adds a densely-connected layer with 64 units to the model:
model.add(layers.Dense(64, activation='relu'))
# Add another:
model.add(layers.Dense(64, activation='relu'))
# Add a softmax layer with 10 output units:
model.add(layers.Dense(10, activation='softmax'))
```

5.2.3 Training und Evaluierung

Nach dem das Modell definiert wurde, muss man es Kompilieren. Dies macht man mit der Methode `tf.keras.Model.compile` diese erwartet als Arugmente, den Optimzier und eine Kostenfunktion. Man kann optional noch gewisse Metriken angeben, welche wahrend des Trainings erfasst werden sollen.

```
model.compile(optimizer=tf.train.AdamOptimizer(0.001),
loss='categorical_crossentropy',
metrics=['accuracy'])
```

Die Optimizer sind die gleichen wie die in TensorFlow-Core. Sie befinden sich alle in tf.train. Die Kostenfunktionen sind auch die gleichen wie in TF-Core. Zum beispeil tf.loss.mean_squared_error.

Hier ein Beispiel:

```
model.compile(optimizer='sgd', loss='mean_squared_error')
```

Das Kompilieren bildet dann aus den gegeben Schichten den eigentlichen Computational Graph.

5.2.3.1 Fit

Nach der Kompilierung kann das Modell trainiert werden. Dies wird durch einen einzigen Methodenaufruf gemacht. Mann muss nur die `fit` Methode aufrufen. Diese erwartet als Parameter ein NumPy-Array aller Inputdaten, ein NumPy-Array aller Labels, die Anzahl Epochen und die Minibatch-Grösse. Optional kann man noch einen Testdatensatz angeben, welcher benutzt wird um die Kosten zu bestimmen.

```
model.fit(<inputs>, <labels>, epochs=<>, batch_size=<>)
```

5.2.3.2 Predict

Sobald das Modell trainiert wurde, kann man es dazu verwenden, Vorhersagen für neue Daten zu machen. Dazu benutzt man die `Predict`-Methode. Sie erwartet einfach ein Array mit Inputs. Als Rückgabewert hat sie die Vorhersagen zu den gegeben Inputs.

```
result = model.predict(data, batch size=32)
```

5.2.4 Keras Beispielmodell

```
inputs = tf.keras.Input(shape=(32,))  # Returns a placeholder tensor

# A layer instance is callable on a tensor, and returns a tensor.
x = layers.Dense(64, activation='relu')(inputs)
x = layers.Dense(64, activation='relu')(x)

predictions = layers.Dense(10, activation='softmax')(x)

Instantiate the model given inputs and outputs.

model = tf.keras.Model(inputs=inputs, outputs=predictions)

# The compile step specifies the training configuration.
model.compile(optimizer=tf.train.RMSPropOptimizer(0.001),
loss='categorical_crossentropy',
metrics=['accuracy'])

# Trains for 5 epochs
model.fit(data, labels, batch_size=32, epochs=5)
```

Kapitel 6

Entwicklung eines Denoising-Autoencoders

In diesem Kapitel soll nun das bisherige Wissen zusammengeführt werden, indem unter Anwendung von TensorFlow und Keras ein konkretes Anwendungsbeispiel programmiert wird.
Dabei wird darauf eingegangen, welche Schritte die Entwicklung eines solchen Modells umfasst und wie dabei am besten vorgegangen wird.

6.1 Das konkrete Modell

Wir werden nun einen Convolutional-Denoising-Autoencoder programmieren. Dieser kann verwendet werden um das Bildrauschen von Bildern zu eliminieren und sie so wieder erkenntlich zu machen. Zu Demonstrationszwecken werden handgeschriebene Ziffern vom MNIST-Datenset verwendet, weil die Funktionsfähigkeit auf dieser Basis sehr einfach erkennbar ist.

6.1.1 Daten

Als Trainingsdaten verwenden wir den **MNIST**-Datensatz. Er ist der wohl bekannteste Datensatz für beispielhaftes Maschinelles Lernen. Er besteht aus schwarz-weiss Bildern von handgeschrieben Ziffern. Zusätzlich würde es auch noch Labels zu den Ziffern geben, um das Modell beispielweise für Zifferner-kennung zu trainieren. Jedoch werden wir diese nicht brauchen, da wir einen Autoencoder entwickeln, dessen Labels den Inputs entsprechen.

Der Datensatz besteht aus einem Trainingsdatensatz von 60'000 Sampels und einem Testdatensatz von 10'000 Sampels. Alle Ziffern sind bereits korrekt formatiert, da ihre Grösse auf 28×28 Pixel normalisiert wurde und sie im Bild zentriert sind.

(Yann LeCun, *The MNIST Database of handwritten digits*)

6.2 Setup

Zunächst ist es wichtig, das Entwicklungsumfeld richtig zu konfigurieren. Das bedeutet konkret, dass Python zusammen mit den verschiedenen Programmbibliotheken installieren werden muss.

Die Installationsschritte werden in dieser Arbeit für eine arch-basierte Linuxdistribution erklärt, welche den **Pacman**-Package-Manager verwendet.

Falls der Leser ein anderes Betriebssystem verwendet möchte, ist auf die offizielle TensorFlow Website für die Installationsschritte zu verweisen:

Abbildung 6.1: grobes Schema des Modells

Abbildung 6.2: ein Auszug an MNIST-Bildern (invertierte Farben) (Steppan, *File:MnistExamples.png — Wikipedia, The Free Encyclopedia*)

Python3

Damit TensorFlow und Keras verwenden werden können, bedingt dies, dass Python3 installiert sein muss. Folgender Befehl muss in der Kommandozeile ausgeführt werden, um die Installation vorzunehmen.

```
sudo pacman -S python
```

TensorFlow

Für die Installation von TensorFlow muss unter Arch Linux das entsprechende Package installieren werden. Falls der Leser über eine Nvidia-Grafikkarte verfügt, welche eine "Compute Capability" von mehr als 3.5 besitzt, kann er von der GPU-Hardwarebeschleunigung Gebrauch machen. Somit ist die CUDA-Version von TF mihtilfe des folgenden Kommandos zu installieren:

```
sudo pacman -S python-tensorflow-cuda
```

Pacman installiert nun automatisch zuerst alle Programmabhängigkeiten, wie CUDA, cuDNN und das TensorFlow-Backend, bevor das eigentliche Python-TensorFlow installiert wird.

Falls keine geeignete Grafikkarte vorliegt, ist es ebenso möglich die normale TF-Version ohne Unterstützung für die GPU zu verwenden. Dies kann durch nachstehendes Kommando vorgenommen werden.

```
sudo pacman -S python-tensorflow
```

Dabei muss Keras nicht explizit installiert werden, da es in TensorFlow implementiert ist.

Python-Module

Für das Python-Programm werden zwei Packages benötigt, welche nicht in der Standardbibliothek von Python enthalten sind:

- NumPy: Ein Package, welches verschiedene mathematische Konzepte implementiert; vorallem Vektor- und Matrix-Arithmetik
- Matplotlib: Ein Package zum Erstellen von Plots und Grafiken

Man installiert beide mit folgenden Kommandos.

```
sudo pacman -S python-numpy
sudo pacman -S python-matplotlib
```

6.3 Entwicklung

Nun beginnt die eigentliche Programmierung.

6.3.1 Testprogramm

Zunächst wird ein kleines Testprogramm geschrieben, welches überprüft, ob alle Programmabhängigkeiten korrekt installiert wurden und verwendet werden können.
In den ersten Zeilen des Pythonprogamms werden die Importstatments geschreiben, um NumPy, Matplotlib und TensorFlow verfügbar zu machen. Keras muss wie gesagt nicht explizit geladen werden, da es in TensorFlow enthalten ist. Nun können die Versionnummern der verschiedenen Programmbibliotheken in die Konsole geschrieben werden, um zu überprüfen, ob alles richtig konfiguriert ist.

```
import numpy as np # NumPy wird impotiert
import matplotlib as mpl # Matplotlib wird impotiert

import tensorflow as tf # TensorFlow wird impotiert

print(np.__version__) # Schreibt die NumPy-Version nach stdout.
print(mpl.__version__) # Schreibt die Matplotlib-Version nach stdout.
print(tf.__version__) # Schreibt die TensorFlow-Version nach stdout.
```

Falls der Output folgenden Charakter hat (die Versionsnummern müssen nicht die gleichen sein) und keine Fehlermeldungen erfolgen, sollte alles funktionieren.

```
1.17.
3.1.1
1.14.0
```

6.3.2 Trainingsdaten

Nun haben wir mit dem kleinen Testprogramm verifiziert, dass alle Programmabhängigkeiten funktionieren. Auf dieser Basis können wir mit dem eigentlichen Programm beginnnen.

In den folgenden Auschnitten wird der Code laufend weiter ausgebaut. Auf diese Weise zeigt sich, was er bewirkt. Das eigentliche Programm beginnt mit folgenden Importstatements.

```
import numpy as np
import matplotlib.pyplot as plt
import tensorflow as tf
```

6.3.2.1 Laden des MNIST-Datensatzes

Der erste Schritt besteht darin, die Datensätze zu laden. Wie bereits erwähnt, wird dabei vom MNIST-Datensatz Gebrauch gemacht. Da dieser stark verbreitet ist, existiert eine Funktion in Keras, welche automatisch diese Daten herunterlädt und sie als NumPy-Arrays zur Verfügung stellt. Die Funktion gibt die verschiedenen Komponenten der Daten in folgendem Format zurück `(x_train, y_train), (x_test, y_test)`. Da nur Interesse an den Features `x` besteht, werden die überflüssigen Labels `y` mithilfe der Wegwerf-Variabel `_` verworfen.

```
(x_train, _), (x_test, _) = tf.keras.datasets.mnists.load_data()
```

Nun sind die Features fürs Training in der Variabel `x_train` und die Features des Trainingsdatensatzes in der Variabel `x_test` gespeichert.

6.3.2.2 Formatieren der Daten

In einem nächsten Schritt müssen die Daten transformiert werden, damit sie die richtige Form für das Modell haben. Wie bereits erwähnt, ist der MNIST-Datensatz einfach verwendbar, da alle Bilder die gleichen Masse aufweisen und die Ziffern zentriert sind.

Jedoch sind die Grauwerte zu normalisieren, denn im Moment liegen sie noch im Intervall $[0, 255]$ und sind vom Typ Integer. Das Modell kann am besten mit Kommazahlen, welche im Intervall $[0, 1]$ liegen, umgehen. Um diese Anpassung vorzunehmen, kann folgender Code angefügt werden.

```
x_train = x_train.astype('float32') / 255.0 # Normalisierung
x_test = x_test.astype('float32') / 255.0 # Normalisierung
```

Desweiteren werden im Modell ConvLayers verwendet. Diese in Keras implementierten ConvLayers erwarten Inputs in der Form (m, w, h, c), wobei m die Anzahl der Bilder ist, w die Bildbreite, h die Bildhöhe und c die Anzahl der Farbkomponenten. Die Bildbreite w und -höhe h von 28 Pixeln wird beibehalten, wie auch die Anzahl Farbkomponeten $c = 1$. Die Anzahl Bilder m lässt sich aus der Länge des Arrays entnehmen `len(x_train)`. Mithilfe vom NumPy lässt sich das Array wie folgt umformen.

```
x_train = np.reshape(x_train, (len(x_train), 28, 28, 1)) # neue Form: (60'000, 28, 28, 1)
x_test = np.reshape(x_test, (len(x_test), 28, 28, 1)) # neue Form: (10'000, 28, 28, 1)
```

Die Daten besitzen nun die richtige Form für das Modell.

6.3.2.3 Generieren der verrauschten Bilder

Den Input in das Modell stellen nicht die normalen MNIST-Bilder dar, sondern eine verrauschte Variante von diesen. Sie werden nun generiert, indem ein additives Gauss'sches Rauschen auf sie angewendet wird.

Zuerst wird eine Matrix $\boldsymbol{R} \in \mathbb{R}^{28\times28\times1}$ erstellt, welche die gleiche Form, wie die Bilder besitzt. Diese Matrix wird mit Zufallswerten gefüllt. Für die Zufallswerte wird eine normalisierte Gauss'sche Normalverteilung $\mathcal{N}(\mu = 0, \sigma^2 = 1)$ mit Erwartungswert $\mu = 0$ und Varianz $\sigma^2 = 1$ verwendet. Da jedes Bild eine eigene Rauschmatrix verlangt, wird zu diesem Zweck eine Liste $(\boldsymbol{R}_1, \boldsymbol{R}_2, \ldots, \boldsymbol{R}_m)$ der Länge m an Rauschmatrizen erzeugt. Dafür kann die NumPy Funktion `np.random.normal(loc=<μ>,`

`scale=<`σ^2`>,size=<Form>)` verwendet werden. Die somit erhaltenen Rauschmatrizen werden dann mit einer Rauschkonstante `noise_factor` multiplziert und anschliessend wird das Produkt auf die MNIST-Bilder addiert. Nach dem Hinzufügen der Rauschwerte müssen die Grauwerte noch auf das Intervall $[0, 1]$ zurecht gestutzt werden. Auch hierfür kann eine NumPy-Funktion `np.clip(var, min, max)` angewendet werden. Diese Schritte werden sowohl mit dem Trainingsdatensatz, als auch mit dem Testdatensatz vollzogen.
Somit lautet der Code:

```
noise_factor = 0.5

# für x_train
noise_matrices = np.random.normal(loc=0.0, scale=1.0, size=x_train.shape)
noise_matrices *= noise_factor
x_train_noisy = x_train + noise_matrices
x_train_noisy = np.clip(x_train_noisy, 0.0, 1.0)

# für x_test in Kurzfassung
x_test_noisy = x_test + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_test.shape)
x_test_noisy = np.clip(x_test_noisy, 0.0, 1.0)
```

Mithilfe der Matplotlib ein Blick auf die verrauschten Bilder im Vergleich zu den Originalbildern geworfen werden. Dafür wird ein Plot erstellt, welcher jeweils 10 Bilder beider Arrays zeigt.

Für diesen Zweck wird eine `pyplot.figure` erstellt. Innerhalb dieser werden jeweils 10 `subplots` definiert, sowohl für die verrauschten Bilder, als auch für die Originale. Bevor die Bilder angezeigt werden können, müssen sie in die richtige Form für die Matplotlib gebracht werden. Sie sollen die Form (28×28) aufweisen. Ausserdem ist der Plot als schwarz-weiss Grafik zu spezifizieren.

```
n = 10 # jeweils 10 Bilder
plt.figure()
for i in range(n):
# verrauschte Bilder
ax = plt.subplot(2,n,i+1+n)
img_clean = x_test[i].reshape(28, 28)
plt.gray()
plt.imshow(img_clean)

# Original Bilder
ax = plt.subplot(2, n, i+1)
img_noisy = x_test_noisy[i].reshape(28, 28)
plt.gray()
plt.imshow(img_noisy)

plt.show()
```

Das Ergebniss ist in Abbildung (6.3) sichtbar.

Die Daten liegen nun vollständig und im richtigem Format vor. Somit kann zur Definition des Modells übergegangen werden.

6.3.3 Modell definieren

Mithilfe von Keras kann das Modell eines Convolutional-Denoising-Autoencoder definiert werden. Dies geschieht nach dem Vorbild der Theorie. Wie bereits erklärt umfasst die Topologie eines CNNs die verschiedensten Hyperparameter. Für diese werden der Einfachheit halber zunächst unbegründeten

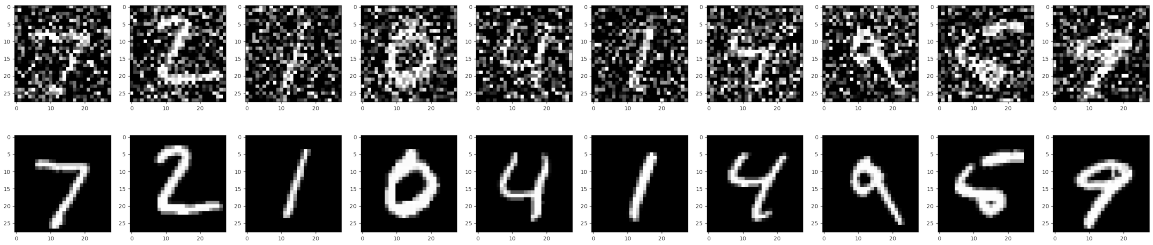

Abbildung 6.3: Verrauschte Bilder neben den Orignalbildern

Werte verwendet. Zu einem späteren Zeitpunkt werden die passenden Hyperparameter durch iteratives Ausprobieren ermittelt.

Das Modell beginnt mit der Inputschicht $l = 0$, welche ein Tensor ist, der die Inputwerte enthält. Die Schicht hat logischerweise die gleiche Form, wie ein MNIST-Bild.

```
input_data = tf.keras.Input(shape=(28,28,1))
```

Nach dieser Inputschicht folgt der Encoder des Autoencoders. Dieser besteht sowohl aus Convolutional-Schichten, wie auch aus Pooling-Schichten, welche sich abwechseln. Für alle Schichten werden vorerst unbegründeten Hyperparameter gewählt. Für die Convolutional-Schichten wird eine Filtergrösse $f^l = 3$, eine Anzahl Filter von $c^l = 32$, ein Stride $s = 1$, Same-Padding und die ReLU-Aktivierungsfunktion $\varphi = \varphi^{\text{ReLU}}$ verwendet.
Der Code für die Defition einer solchen Convolutional-Schicht lautet:

```
conv_layer = tf.keras.layers.Conv2D(filters=32, kernel_size=(3,3),
strides=(1,1),padding='same', activation='relu')(input_data)
```

Für die Pooling-Schichten wird analog eine Feldgrösse $f = 2$, ein Stride $s = 2$ und Same-Padding gewählt. Dies hat zur Wirkung, dass jedes (2×2)-Feld zu einem einzigen Element zusammengefasst wird.
Der Code für eine dieser Pooling-Schichten lautet:

```
pool_layer = tf.keras.layers.MaxPooling2D(pool_size=(2,2),strides=(2,2),padding='same')(econv0)
```

Für den Decoder werden die gleichen Convolutional-Schichten wie für den Encoder verwendet. Anstelle von Pooling-Schichten verwendet er UpSampling-Schichten, welche jeweils nach einer Convolutional-Schicht folgen. Für die UpSampling-Schichten wurde eine Feldgrösse $f = 2$ gewählt. Somit wird ein einziger Pixel auf ein 2×2-Felder hochskaliert. Als Interpolationsmethode wird der Nächste-Nachbar-Algorithmus verwendet. Die beschriebene UpSampling-Schicht wird folgendermassen definiert:

```
dupsample0 = tf.keras.layers.UpSampling2D(size=(2,2), interpolation='nearest')(dconv0)
```

Nun folgt die Deklarierung aller Schichten und deren Verknüpfung.
Das Modell weist einen Flaschenhals auf, welcher zwei Convolutional-Schichten tief ist. Das bedeutet, dass der Encoder aus zwei Convoutional-Layer-Pooling-Player-Paaren besteht. Danach folgt der einschichtige Flaschenhals. Im Anschluss liegt der Decoder, der zwei Convolutional-Layer-Upsampling-Layer-Paaren umfasst.
Der ganze Graph wird durch folgenden Code gebildet:

```
# Encoder
econv0 = tf.keras.layers.Conv2D(
```

```
filters=32, kernel_size=(3,3), strides=(1,1),padding='same',activation='relu')(input_data)
emaxpool0 = tf.keras.layers.MaxPooling2D(
pool_size=(2,2),strides=None,padding='same')(econv0)
econv1 = tf.keras.layers.Conv2D(
filters=32, kernel_size=(3,3), strides=(1,1),padding='same',activation='relu')(emaxpool0)
emaxpool1 = tf.keras.layers.MaxPooling2D(
pool_size=(2,2), strides=None,padding='same')(econv1)

encoded =  emaxpool1 # Flaschenhals der Form (7,7,32)

# Decoder
dconv0 = tf.keras.layers.Conv2D(
filters=32, kernel_size=(3,3), strides=(1,1), padding='same', activation='relu')(encoded)
dupsample0 = tf.keras.layers.UpSampling2D(
size=(2,2), interpolation='nearest')(dconv0)
dconv1 = tf.keras.layers.Conv2D(
filters=32, kernel_size=(3,3), strides=(1,1), padding='same', activation='relu')(dupsample0)
dupsample1 = tf.keras.layers.UpSampling2D(
size=(2,2), interpolation='nearest')(dconv1)
dconv2 = tf.keras.layers.Conv2D(
filters=1,kernel_size=(3,3), strides=(1,1), padding='same', activation='sigmoid')(dupsample1)
decoded = dconv2
```

Auffallend im Code ist, dass der Decoder nicht etwa zwei Convolutional-Layers besitzt, sondern sogar drei. Die letzte Schicht wird benötigt, damit die Daten wieder die richtige Formatierung aufweisen. Das heisst einerseits, dass die Outputs wieder in der Ursprungsform (28×28) vorliegen müssen. Andererseits sollen die Outputs wieder im Intervall $[0, 1]$ befinden. Mithilfe der Sigmoid-Funktion als Aktivierungsfunktion werden sie genau auf dieses Intervall abgebildet.
Für alle anderen Schichten wurde die ReLU-Aktivierungsfunktion gewählt.

Nun muss noch eine Modellvariable deklariert werden, indem man die Input- `input_data` und die Outputschicht `decoded` angibt. Danach ist das Modell zu kompilieren. Bei der Kompilierung kann das Optimierungsverfahren und die Kostenfunktion gewählt werden. Für die Optimierung wird das Stochastische-Gradientenverfahren SGD verwendet. Als Kostenfunktion wird der Mittlere-Quadratische-Fehler C_{MSE} gewählt.

```
autoencoder = tf.keras.Model(input_data, decoded)
autoencoder.compile(optimizer='sgd',loss='mean_squared_error') # SGD und MSE
```

Mithilfe von `tf.keras.Model.summary` kann man eine Zusammenfassung des Modells in Textform erhalten. So können Informationen bezüglich der Form der verschiedenen Schichten abgerufen werden, um zu überprüfen, ob alles stimmig ist. Nachfolgende Summary gilt für unser Modell:

```
_________________________________________________________________
Layer (type)                 Output Shape              Param #
=================================================================
input_1 (InputLayer)         [(None, 28, 28, 1)]       0
_________________________________________________________________
conv2d (Conv2D)              (None, 28, 28, 32)        320
_________________________________________________________________
max_pooling2d (MaxPooling2D) (None, 14, 14, 32)        0
_________________________________________________________________
conv2d_1 (Conv2D)            (None, 14, 14, 32)        9248
_________________________________________________________________
```

```
max_pooling2d_1 (MaxPooling2 (None, 7, 7, 32)         0
_________________________________________________________________
conv2d_2 (Conv2D)            (None, 7, 7, 32)         9248
_________________________________________________________________
up_sampling2d (UpSampling2D) (None, 14, 14, 32)       0
_________________________________________________________________
conv2d_3 (Conv2D)            (None, 14, 14, 32)       9248
_________________________________________________________________
up_sampling2d_1 (UpSampling2 (None, 28, 28, 32)       0
_________________________________________________________________
conv2d_4 (Conv2D)            (None, 28, 28, 1)        289
=================================================================
Total params: 28,353
Trainable params: 28,353
Non-trainable params: 0
_________________________________________________________________
```

Es zeigt sich, dass das Modell gesamthaft circa 28'000 Parameter umfasst, welche zu trainieren sind.

6.3.4 Modell trainieren

Nun gilt es das definierte Modell zu trainieren. Mit Keras kann dies mit einem einzigen Funktionsaufruf durchgeführt werden. Diese Funktion erwartet einige Argumente. Zuerst sind die Features und Labels anzugeben. Die Features wurden in der Variable `x_train_noisy` gespeichert. Die Labels sind die unverrauschten MNIST-Bilder, welche in der Variable `x_train` enthalten sind. Desweiteren wird die Grösse eines Mini-Batches als 128 Sampels spezifiziert. Das Training erfolgt über 100 Epochen. Wichtig ist auch, dass die Trainingssampels vor dem Training druchmischt werden, damit keine Mustern innerhalb der Anordnung der Samples erlernt werden. Als letzen Argument wird noch der Testdatensatz angegeben.

```
autoencoder.fit(
x=x_train_noisy, y=x_train, batch_size=128, epochs=100, shuffle=Trü,validation_data=(x_test_noisy,x_test))
```

Sofern TensorFlow eine geeignete Nvidia-Grafikkarte vorfindet und auch die CUDA-Version von TF installiert ist, erfolgt das Training mithilfe von GPU-Hardwarebeschleunigung. Dadurch sollte das Trainings innherhalb einiger Minuten abgeschlossen sein. Während des Trainings schreibt TensorFlow Informationen zum aktuellen Fortschritt in die Kommandozeile. Diese Infos weisen nachstehenden Charakter auf und geben Auskunft über die aktuelle Epoche und die Werte der Kostenfunktion. Die Kosten für den Trainingsdatensatz werden mit `loss` bezeichnet und die für den Testdatensatz mit `val_loss`.

```
Epoch 99/100
60000/60000 [==============================] - 3s 57us/sample - loss: 0.1102 - val_loss: 0.1089
```

Das Modell hat nach dem Training einen `val_los` von 0.1089, bezüglich dem Testdatensatz.

Jetzt, da das Modell trainiert wurde, ist es sinnvoll es auf dem Computer als Modelldatei abzuspeichern. So muss das es nicht jedesmal wieder neu trainieren werden, sondern kann über die Modelldatei eingelesen werden. Für dieses Einlesen, wird folgender Code benötigt.

```
autoencoder.save('denoiser.model')
```

Um das Modell wieder einzulesen verwendet man folgenden Code:

```
autoencoder = tf.keras.models.load_model('denoiser.model')
```

Mit der Summary-Funktion kann man überprüfen, ob das richtige Modell geladen wurde.

6.3.5 Modell ausführen

Da das Modell nun trainiert ist, kann es nun für seinen eigentlichen Zweck genutzt werden. Dieser besteht darin, Bilder zu entrauschen. Dafür gelangen die Bilder aus dem Testdatensatz zur Anwendung. Damit ist garantiert, dass diese unbenutzten Daten vom Modell nicht auswenig gelernt werden konnten. Mit der Funktion `tf.keras.model.predict` erhält man alle Vorhersagen des Autoencoders zum gesamten Testdatensatz.

```
denoised_imgs = autoencoder.predict(x_test)
```

Mithilfe von der Matplotlib können die entrauschten Bilder mit den ursprünglichen MNIST-Bilder direkt verglichen werden. So kann mit blossem Auge beurteilt werden, wie gut die Ergebnisse tatsächlich sind.

```
n = 10 # jeweils 10 Bilder
plt.figure()
for i in range(n):
# verrauschte Bilder
ax = plt.subplot(3, n, i+1)
plt.imshow(x_test_noisy[i].reshape(28,28))
plt.gray()

# entrauschte Bilder
ax = plt.subplot(3, n, i+1+n)
plt.imshow(decoded_imgs[i].reshape(28,28))
plt.gray()

# Original-Bilder
ax = plt.subplot(3, n, i+1+2*n)
plt.imshow(x_test[i].reshape(28,28))
plt.gray()

plt.show()
```

In der ersten Zeile der Grafik sind die verrauschten Bilder dargestellt. Darunter folgen die Rekonstuktionen als Ergebniss des Modells und ganz unten sind die Original-Bilder zu sehen. Wirkliche

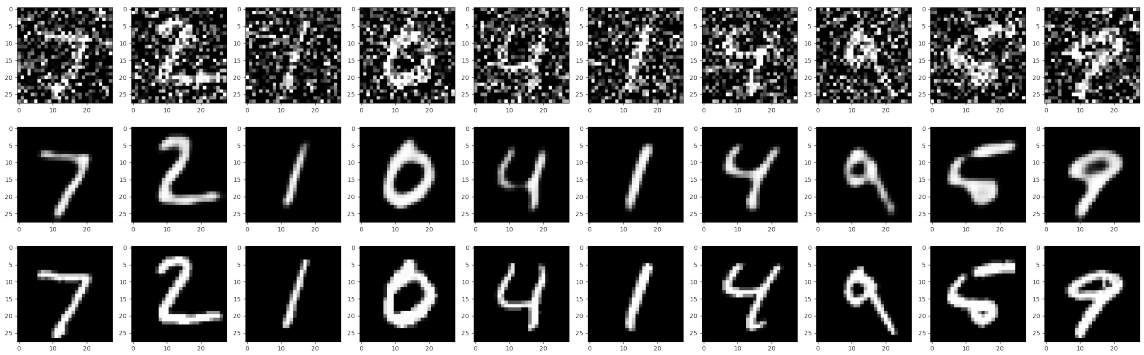

Abbildung 6.4: Verrauschte Bilder, Rekonstruktionen und Orignalbilder

Unterschiede zwischen der zweiten und der dritten Zeile sind kaum zu erkennen.

6.3.6 Hyperparameter einstellen

Um die Hyperparameter einzustellen, müssen lediglich verschiedene Werte ausprobiert werden. Die Applikation wird insofern modifiziert, als dass verschiedene Modelle konstruiert werden, welche unterschiedliche Hyperparametern verwenden. Beim Training werden mithilfe von TensorBoard Daten zum Lernfortschritt und den Kosten der verschiedenen Modelle erfasst. Auf diese Weise kann eine Auswertung erstellt werden, um die besten Hyperparameter zu identifizieren.

Zuerst werden einige Arrays definiert, welche die zu testenden Hyperparameter beinhalten. Ein Hyperparameter ist die Anzahl Epochen. Diesen werden wir aber nicht testen, da es offensichtlich ist, dass mit einer längeren Trainingszeit auch die Resultate verbessern. Alle Modelle werden für 20 Epochen traniert.

Folgende Mini-Batch-Grössen sollen ausprobiert werden: 16, 32, 64, 128, 265. Die Vermutung liegt nahe, dass mit kleineren Mini-Batches die Gradientapproximationen besser mit dem reellen Gradienten übereinstimmt und damit die Resultate besser werden.
Als zu testende Anzahl von Filtern werden definiert: 16, 32, 64, 128, 256. Für die Aktivierungsfunktionen werden Sigmoid und ReLU ausprobiert und gelangen für das ganze Modell zur Anwendung. Jedoch wird die letzte Schicht immer die Sigmoid-Aktivierungsfunktion verwendet, damit die Outputs im Intervall $[0, 1]$ liegen.

```
EPOCHS = 20

POSSIBLE_BATCH_SIZES = [ 16, 32, 64, 128, 256]
POSSIBLE_NUMS_FILTER = [ 16, 32, 64, 128, 256]
POSSIBLE_ACITVATIONFUNCTIONS = [ 'sigmoid', 'relu' ]
```

Nun werden wir den gesamten Code zum Bauen des Graphens, zur Kompilierung und zum Training des Modells in verschachtele For-Loops stecken, welche alle Kombinationen an Hyperparameter ausprobiert.

```
for activation_function in POSSIBLE_ACITVATIONFUNCTIONS:
for batch_size in POSSIBLE_BATCH_SIZES:
for num_filters in POSSIBLE_NUMS_FILTER:
# ganzer Modell-Code
```

6.3.6.1 TensorBoard Konfiguration

Um den Lernprozess und die Leistungen des Modells zu analysieren, wird nun nun TensorBoard konfiguriert. Um TensorBoard einzurichten, ist zuerst eine entsprechende Variable zu definieren. Hierbei ist anzugeben, wo die TensorBoard-Daten gespeichert werden sollen. Um Verwechslungen bei den Hyperparametereinstellungen zu vermeiden, sind die Dateien aussagekräftig zu benennen.
Auch sind gewisse Optionen für die Trainings-Datenerfassung zu spezifizieren. Diese müssen bei der Komilierung des Modells unter `metrics` angegeben werden. Wichtig ist die Präzision des Modells. Die entsprechende Option wird `accuracy` genannt.

```
autoencoder.compile(optimizer='sgd',loss=loss, metrics=['accuracy'])
NAME = '{}-{}-batch-{}-filters-{}-denoiser'.format(loss, activation_function, batch_size, num_filters)
tensorboard =
tf.keras.callbacks.TensorBoard(log_dir='logs/{}'.format(NAME))
autoencoder.fit(x=x_train_noisy, y=x_train, batch_size=batch_size, epochs=EPOCHS, shuffle=Trü,validation_data=(x_t
```

6.3.6.2 Die optimalen Hyperparameter

Die TensorBoard-Analyse hat ergeben, dass folgende Modelle mit den angegeben Hyperparameter am besten eignen:

Rang	Aktivierungsfunktion	Minibatch-Grösse	Anzahl Filter	Kosten
1	ReLU	16	265	0.01502
2	ReLU	16	128	0.0153
3	ReLU	16	64	0.01598
4	ReLU	16	32	0.01694

Tabelle 6.1: Rangliste der besten Modelle mit ihren Hyperparametern

Diese Ergebnisse stimmen ziemlich gut mit den Erwartungen überein. Wie bereits in der Theorie behauptet, liefern die ReLU-Aktivierungsfunktion bessere Ergebnisse in CNNs als die Sigmoid-Aktivierungsfunktion. Auch das die kleinste Minibatch-Grösse die besten Resultate liefert ist naheliegend. Durch die kleine Grösse sind die Fehler bei der Approximation des wahren Gradienten kleiner als bei grossen Batches. Die Anzahl Filter haben den geringsten Einfluss, jedoch gibt es trotzdem minimale Vorteile von einer grösseren Anzahl davon.

6.3.7 Diskussion des Modells

Echt gutes Modell.

6.3.7.1 Maximale Leistung

Wie hoch kann man den Noise-Factor stellen?

6.3.7.2 Mögliche Verbesserungen

Kreuzentropie-Kostenfunktion andere Topologien ausprobieren

Schlusswort

Ausblick

Weitere Architekturen

Variational Autencoder Generative Adversial Networks
Recurrent Neural Networks

Weitere Frameworks

TensorFlow 2.0 PyTorch

Persoenlicher Eindruck

Anhang A

Programmcode

```
import numpy as np
import matplotlib.pyplot as plt

import tensorflow as tf

(x_train, _), (x_test, _) = tf.keras.datasets.mnist.load_data()
x_train = x_train.astype('float32') / 255.
x_test = np.reshape(x_test, (len(x_test),28,28,1))
x_test = x_test.astype('float32') / 255.
x_train = np.reshape(x_train, (len(x_train),28,28,1))

noise_factor = 0.5
x_train_noisy = x_train + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_train.shape)
x_test_noisy = x_test + noise_factor * np.random.normal(loc=0.0, scale=1.0, size=x_test.shape)
x_train_noisy = np.clip(x_train_noisy, 0., 1.)
x_test_noisy = np.clip(x_test_noisy, 0., 1.)


input_data = tf.keras.Input(shape=(28,28,1))

econv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3,3), strides=(1,1),padding='same',activation='relu')(inp
emaxpool0 = tf.keras.layers.MaxPooling2D(pool_size=(2,2),strides=None,padding='same')(econv0)
econv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3,3), strides=(1,1),padding='same',activation='relu')(ema
emaxpool1 = tf.keras.layers.MaxPooling2D(pool_size=(2,2), strides=None,padding='same')(econv1)
encoded =  emaxpool1 # bottleneck (shape=(7,7,32))
dconv0 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3,3), strides=(1,1), padding='same', activation='relu')(e
dupsample0 = tf.keras.layers.UpSampling2D(size=(2,2), interpolation='nearest')(dconv0)
dconv1 = tf.keras.layers.Conv2D(filters=32, kernel_size=(3,3), strides=(1,1), padding='same', activation='relu')(d
dupsample1 = tf.keras.layers.UpSampling2D(size=(2,2), interpolation='nearest')(dconv1)
dconv2 = tf.keras.layers.Conv2D(filters=1,kernel_size=(3,3), strides=(1,1), padding='same', activation='sigmoid')(
decoded = dconv2

autoencoder = tf.keras.Model(input_data, decoded)
autoencoder.compile(optimizer='adadelta',loss='binary_crossentropy')

print(autoencoder.summary())


autoencoder.fit(x=x_train_noisy, y=x_train, batch_size=128, epochs=100, shuffle=True,validation_data=(x_test_noisy

```

```
decoded_imgs = autoencoder.predict(x_test)

autoencoder.save('denoiser.model')

n = 10
plt.figure(figsize=(20,4))
for i in range(n):
    # original
    ax = plt.subplot(2, n, i+1)
    plt.imshow(x_test_noisy[i].reshape(28,28))
    plt.gray()
    ax.get_xaxis().set_visible(False)
    ax.get_yaxis().set_visible(False)

    # reconstruction
    ax = plt.subplot(2,n,i+1+n)
    plt.imshow(decoded_imgs[i].reshape(28,28))
    plt.gray()
    ax.get_xaxis().set_visible(False)
    ax.get_yaxis().set_visible(False)
plt.show()
```

Anhang B

Ausfuehrungen zu TensorFlow

Backend

Anhang C

Intuitiver Beweis fuer UAT?

Literatur

[1] CodeParade. *Computer Generates Human Faces*. [Online; besucht am 21. August 2019]. Youtube. 2017. URL: https://www.youtube.com/watch?v=4VAkrUNLKSo.

[2] Andrew NG - deeplearning.ai. *Convolutional Neural Networks (Course 4 of the Deep Learning Specialization)*. [Online; besucht am 17. Juni 2019]. 2017. URL: https://www.youtube.com/playlist?list=PLkDaE6sCZn6Gl29AoE31iwdVwSG-KnDzF.

[3] Aurélien Géron. *Hands-On Machine Learning with Scikit-Learn and TensorFlow*. O'Reilly Media, 2017.

[4] Ian Goodfellow, Yoshua Bengio und Aaron Courville. *Deep Learning*. http://www.deeplearningbook.org. MIT Press, 2016.

[5] Many. *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. Software available from tensorflow.org. 2015. URL: https://www.tensorflow.org/.

[6] Mehrere. *Convolution— Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolution.

[7] Mehrere. *Convolutional neural network — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Convolutional_neural_network.

[8] Mehrere. *Keras Documentation - Initalizers*. [Online; besucht am 03. September 2019]. URL: https://keras.io/initializers/.

[9] Mehrere. *Kernel (image processing) — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Kernel_(image_processing).

[10] Mehrere. *Künstliches Neuron — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 4. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/K%C3%BCnstliches_Neuron.

[11] Mehrere. *Künstliches Neuronales Netz — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 04. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/K%C3%BCnstliches_neuronales_Netz.

[12] Mehrere. *Linear separability — Wikipedia, The Free Encyclopedia*. [Online; besucht am 9. Juli 2019]. 2019. URL: https://en.wikipedia.org/wiki/Linear_separability.

[13] Mehrere. *Normal distribution — Wikipedia, The Free Encyclopedia*. [Online; besucht am 26. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Normal_distribution.

[14] Mehrere. *Perzeptron — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 28. April 2019]. 2019. URL: https://de.wikipedia.org/wiki/Perzeptron.

[15] Mehrere. *Sigmoidfunktion — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 4. Mai 2019]. 2019. URL: https://de.wikipedia.org/wiki/Sigmoidfunktion.

[16] Mehrere. *Sobel operator — Wikipedia, The Free Encyclopedia*. [Online; besucht am 17. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Sobel_operator.

[17] Mehrere. *Supervised learning — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Supervised_learning.

[18] Mehrere. *Tensor — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 13. Juli 2019]. 2019. URL: https://de.wikipedia.org/wiki/Tensor.

[19] Mehrere. *Überanpassung — Wikipedia, Die freie Enyklopädie*. [Online; besucht am 31. August 2019]. 2019. URL: https://de.wikipedia.org/wiki/%C3%9Cberanpassung.

[20] Mehrere. *Universal approximation theorem — Wikipedia, The Free Encyclopedia*. [Online; besucht am 22. August 2019]. 2019. URL: https://en.wikipedia.org/wiki/Universal_approximation_theorem.

[21] Mehrere. *Unsupervised learning — Wikipedia, The Free Encyclopedia*. [Online; besucht am 25. Juni 2019]. 2019. URL: https://en.wikipedia.org/wiki/Unsupervised_learning.

[22] Michael Nielsen. *Neural Networks and Deep Learning*. http://neuralnetworksanddeeplearning.com. 2018.

[23] Elias Saalmann. *Einführung in Autoencoder und Convolutional Neural Networks*. Universität Leipzig, 2018.

[24] Josef Steppan. *File:MnistExamples.png — Wikipedia, The Free Encyclopedia*. [Online; besucht am 18. August 2019]. 2017. URL: https://en.wikipedia.org/wiki/File:MnistExamples.png.

[25] Christopher J.C. Burges Yann LeCun Corinna Cortes. *The MNIST Database of handwritten digits*. [Online; besucht am 15. August 2019]. URL: http://yann.lecun.com/exdb/mnist/.

Abbildungsverzeichnis

1.1 Schema eines Modells . . . 3
1.2 Visualisierung des Gradientenabstiegs: ein Ball rollt das Gradientenfeld hinab in das lokale Minimum. . . . 6
1.3 Visualisierung verschiedener Lernraten . . . 6
1.4 Visalierung von Under- und Overfitting . . . 9

2.1 Perzeptron mit drei Inputs . . . 11
2.2 erfolgreiche lineare Separierung (links) und das Versagen bei XOR (rechts) . . . 11
2.3 ein künstliches Neuron und seine Bestandteile . . . 12
2.4 Definition und Graph der Heaviside-Funktion Θ . . . 12
2.5 Formel und Graph der ReLU-Funktion . . . 13
2.6 Definition, Ableitung und Graph der Sigmoid-Funktion σ . . . 14
2.7 Schichten eines KNNs . . . 14
2.8 zum Verstäntniss der Nomenklatur . . . 16
2.9 zum Verstäntnis der Gewichtebeschriftungen . . . 16
2.10 Graph der Dichtefunktion $\phi(x \mid \mu = 0, \sigma^2 = 1)$ mit ihren wichtigsten Eigenschaften . . . 18
2.11 Computation Graph zur Berechnung von $\boldsymbol{\delta}^L$ . . . 21
2.12 Computation Graph zur Berechnung von δ_j^{l-1} . . . 22

3.1 Beispiel einer Bildmatrix . . . 26
3.2 Schichtung eines CNNs . . . 27
3.3 der Instagramfilter: Blablabla . . . 27
3.4 eine 2D-Filtermatrix . . . 27
3.5 Sobel-Filter angewandt auf Beispielsbild . . . 28
3.6 ein Filter und sein rezeptives Feld . . . 29
3.7 Schema, wie ein Filter über ein Bild laüft . . . 29
3.8 aufeinander gelegte gefaltene Bilder . . . 31
3.9 Padding . . . 32

4.1 Schichten eines kurzen Autoencoders . . . 37
4.2 Schichten eines tieferen Autoencoders . . . 38
4.3 Darstellung eines Convolutional Autoencoders . . . 40
4.4 Visualisierung eines Convolutional-Denoising-Autoencoder . . . 40

5.1 TF-Logo . . . 42
5.2 Visualisierung des beschriebenen `tf.graph` . . . 46
5.3 das TensorBoard-Webinterface . . . 50
5.4 Trainingsvisualisierungen in TensorBoard . . . 51
5.5 Keras-Logo . . . 52

6.1 grobes Schema des Modells . . . 55
6.2 ein Auszug an MNIST-Bildern (invertierte Farben) (Steppan, *File:MnistExamples.png — Wikipedia, The Free Encyclopedia*) . . . 56
6.3 Verrauschte Bilder neben den Orignalbildern . . . 60

6.4 Verrauschte Bilder, Rekonstruktionen und Orignalbilder 63

Tabellenverzeichnis

6.1 Rangliste der besten Modelle mit ihren Hyperparametern 65

Selbstständigkeitserklärung

Ich erkläre hiermit, dass ich diese Arbeit selbständig durchgeführt und keine anderen als die angegebene Quellen, Hilfsmittel und Hilfspersonen beigezogen habe. Alle Textstellen in der Arbeit, die wörtlich oder sinngemäss aus Quellen entnommen wurden, habe ich als solche gekennzeichnet.

Luis Wirth